

USULAN PENELITIAN

**ANALISIS SENTIMEN TERHADAP APLIKASI
DUOLINGO MENGGUNAKAN INDOBERTWEET
DAN PEMODELAN TOPIK BERTOPIC**



MUHAMMAD FARHAN HADRAWI

F1E122149

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI
2025**

USULAN PENELITIAN

ANALISIS SENTIMEN TERHADAP APLIKASI DUOLINGO MENGGUNAKAN INDOBERTWEET DAN PEMODELAN TOPIK BERTOPIC

Diajukan sebagai salah satu syarat untuk menyelesaikan studi pada
Program Studi Sistem Informasi



MUHAMMAD FARHAN HADRAWI

F1E122149

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI**

2025

HALAMAN PENGESAHAN

USULAN PENELITIAN

“ANALISIS SENTIMEN TERHADAP APLIKASI DUOLINGO MENGGUNAKAN INDOBERTWEET DAN PEMODELAN TOPIK BERTOPIC”

Oleh:

Muhammad Farhan Hadrawi

F1E122149

Disetujui:

Pembimbing Utama

Pembimbing Pendamping

Rizqa Raaiqa Bintana, S.T., M.Kom.
NIP. 199001202019032012

Hasanatul Iftitah, S.Si., M.Kom.
NIP. 199604022024062002

Diketahui :

Dekan Fakultas Sains
dan Teknologi

Ketua Jurusan Teknik Elektro
dan Informatika

Drs. Jefri Marzal, M.Sc., D.I.T.
NIP. 196806021993031004

Edi Saputra, S.T., M.Sc.
NIP. 198501082015041003

DAFTAR ISI

HALAMAN PENGESAHAN	i
DAFTAR ISI.....	ii
DAFTAR TABEL	iii
DAFTAR GAMBAR.....	iv
I. PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	4
1.5 Batasan Penelitian	4
II. TINJAUAN PUSTAKA.....	5
2.1 Mobile-Assisted Language Learning (MALL).....	5
2.2 Duolingo	6
2.3 Natural Language Processing (NLP)	6
2.4 Text Mining.....	7
2.5 <i>Preprocessing</i> Teks	8
2.6 Analisis Sentimen	9
2.7 BERT	10
2.8 IndoBERTweet	12
2.9 BERTopic.....	13
2.10 Visualisasi Data	14
2.11 Penelitian Terdahulu	14
III. METODE PENELITIAN	19
3.1 Tempat dan Waktu Penelitian.....	19
3.2 Bahan dan Alat Penelitian	19
3.3 Tahapan Penelitian	20
DAFTAR PUSTAKA	34

DAFTAR TABEL

Tabel 1. Penelitian Terdahulu	15
Tabel 2. Perangkat lunak yang digunakan	19
Tabel 3. Contoh hasil pelabelan data	23
Tabel 4. Contoh hasil <i>cleaning</i> data	24
Tabel 5. Contoh hasil <i>case folding</i>	25
Tabel 6. Contoh hasil <i>normalization</i>	25
Tabel 7. Contoh hasil <i>tokenizing</i> dan <i>encoding</i> IndoBERTweet	27
Tabel 8. <i>Confusion matrix</i>	28

DAFTAR GAMBAR

Gambar 1. Proses <i>pre-training</i> and <i>fine-tuning</i> BERT	11
Gambar 2. Arsitektur IndoBERTweet	12
Gambar 3. Contoh visualisasi data menggunakan <i>word cloud</i>	14
Gambar 4. Tahapan penelitian	20
Gambar 5. Hasil <i>scrapping</i> ulasan aplikasi Duolingo	22
Gambar 6. Tahapan <i>preprocessing data</i>	24
Gambar 7. Tahapan klasifikasi IndoBERTweet	26
Gambar 8. Tahapan pemodelan topik BERTopic	30
Gambar 9. Visualisasi data menggunakan <i>word cloud</i>	33

I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital yang pesat telah membawa transformasi signifikan dalam berbagai aspek kehidupan, termasuk dalam sektor pendidikan. Fenomena ini melahirkan konsep *Mobile-Assisted Language Learning* (MALL), sebuah pendekatan yang memanfaatkan teknologi seluler untuk mendukung proses pembelajaran bahasa tanpa batasan ruang dan waktu (Rahmawati et al., 2023). Fleksibilitas tersebut memungkinkan pembelajar untuk mengakses materi autentik, berinteraksi dengan penutur asli, serta melakukan praktik belajar secara mandiri dan efisien melalui perangkat seluler (Handayani & Damayanti, 2022).

Di antara berbagai aplikasi MALL yang tersedia secara global, Duolingo telah menjadi salah satu platform yang paling populer dan banyak digunakan, termasuk di Indonesia. Berbagai penelitian menunjukkan bahwa Duolingo efektif dalam meningkatkan penguasaan kosakata bahasa Inggris, kepercayaan diri pengguna, serta motivasi belajar melalui pendekatan gamifikasi yang interaktif (Hakimantieq et al., 2022; Puspita et al., 2025). Meskipun demikian, penggunaan aplikasi ini tidak luput dari kendala, seperti adanya iklan yang mengganggu, sistem "nyawa" yang terbatas, serta kurangnya variasi dalam konteks percakapan yang kompleks (Salsabila et al., 2024).

Opini, keluhan, dan saran pengguna terhadap aplikasi seperti Duolingo terekam dalam jutaan ulasan yang tersedia di platform distribusi aplikasi digital, seperti Google Play Store. Ulasan-ulasan ini merupakan data tekstual yang sangat berharga karena mencerminkan pengalaman pengguna secara jujur dan *real-time* (Nawulansih et al., 2025). Bagi pengembang aplikasi dan pemangku kepentingan, memahami opini publik ini sangat krusial untuk evaluasi layanan dan pengembangan fitur di masa depan. Namun, volume data ulasan yang sangat besar dan tidak terstruktur menjadikan analisis manual tidak efisien dan rentan terhadap bias subjektif. Oleh karena itu, penerapan teknik Pemrosesan Bahasa Alami *NLP* (*Natural Language Processing*) menjadi solusi yang mendesak untuk mengotomatisasi ekstraksi informasi dari data ulasan tersebut (Amien, 2023).

Salah satu tugas utama dalam *NLP* adalah analisis sentimen, yang bertujuan untuk mengklasifikasikan polaritas opini menjadi positif, negatif, atau netral. Seiring dengan kemajuan teknologi *Deep Learning*, metode analisis sentimen telah berkembang dari pendekatan tradisional seperti *Support Vector Machine* (SVM) menuju model berbasis *transformer* yang lebih canggih (Abdillah et al., 2023). Model *transformer*, khususnya BERT (*Bidirectional Encoder Representations from Transformers*), telah merevolusi bidang ini dengan

kemampuannya memahami konteks kata dari dua arah (bidireksional), sehingga mampu menangkap nuansa makna yang lebih kompleks dibandingkan model sekuensial sebelumnya seperti LSTM (Aljabar & Karomah, 2024; Devlin et al., 2019).

Dalam konteks bahasa Indonesia, penerapan model BERT telah diadaptasi melalui pengembangan IndoBERT, sebuah model *pre-trained* yang dilatih menggunakan korpus bahasa Indonesia berskala besar (Kusuma & Mogi, 2023). Namun, ulasan aplikasi di media sosial atau Play Store sering kali menggunakan ragam bahasa tidak baku, bahasa gaul (*slang*), singkatan, dan campuran bahasa yang tidak selalu dapat ditangani dengan optimal oleh model yang dilatih pada teks formal. Untuk mengatasi tantangan ini, dikembangkanlah IndoBERTtweet, model bahasa yang dilatih secara spesifik menggunakan dataset dari Twitter Indonesia (Koto et al., 2021). Penelitian komparatif menunjukkan bahwa IndoBERTtweet memiliki kinerja yang lebih unggul dibandingkan algoritma lain seperti LSTM dalam menganalisis sentimen pada teks informal, seperti ulasan aplikasi TikTok, karena kemampuannya yang lebih baik dalam mengenali pola bahasa kasual (Setiawan et al., 2023). Temuan ini diperkuat oleh penelitian Khairani et al. (2024), yang menunjukkan bahwa IndoBERTtweet mampu mencapai akurasi hingga 92,54% dalam deteksi emosi pada komentar Instagram, melampaui IndoBERT yang hanya memperoleh 88,81%. Hasil tersebut menegaskan bahwa model berbasis media sosial seperti IndoBERTtweet lebih adaptif terhadap variasi bahasa informal dan lebih efektif untuk menganalisis ulasan pengguna aplikasi. Selain itu, efektivitas IndoBERTtweet juga terbukti tetap tinggi meskipun tanpa melalui tahapan *preprocessing* yang agresif seperti *stemming* atau penghapusan *stopwords*, yang justru dapat menghilangkan konteks emosi dalam kalimat (Khairani et al., 2024).

Selain itu, pengetahuan mengenai kategori sentimen saja tidak memberikan konteks yang memadai terhadap opini pengguna. Analisis topik diperlukan untuk mengidentifikasi aspek-aspek spesifik yang menjadi sumber pembahasan dan memengaruhi arah sentimen tersebut. Untuk menjawab kebutuhan ini, teknik pemodelan topik (*topic modeling*) digunakan guna mengekstrak tema-tema tersembunyi dari sekumpulan dokumen. Metode konvensional seperti *Latent Dirichlet Allocation* (LDA) sering digunakan untuk tujuan ini (Ariansyah & Indahyanti, 2024). Namun, metode LDA memiliki keterbatasan karena menggunakan pendekatan *Bag-of-Words* yang mengabaikan urutan kata serta hubungan semantik antarkata, sehingga topik yang dihasilkan terkadang kurang koheren dan sulit diinterpretasikan.

Sebagai respons terhadap keterbatasan model konvensional, muncul pendekatan baru bernama BERTopic. BERTopic adalah teknik pemodelan topik yang memanfaatkan *embedding* dokumen dari model *transformer* dan algoritma klusterisasi berbasis densitas (HDBSCAN) untuk menghasilkan topik yang lebih koheren dan semantik (Grootendorst, 2022). Berbeda dengan LDA, BERTopic menggunakan prosedur *class-based TF-IDF* (c-TF-IDF) untuk mengekstrak kata kunci yang representatif dari setiap kluster dokumen, sehingga mampu menangkap konteks topik dengan lebih akurat. Beberapa studi terbaru di Indonesia telah membuktikan keunggulan BERTopic. Misalnya, dalam analisis ulasan hotel, BERTopic mampu menghasilkan topik yang beragam dengan nilai koherensi yang baik (Mertayasa & Darmawan, 2022). Lebih lanjut, dalam analisis komentar YouTube terkait program pemerintah, BERTopic terbukti mengungguli model LDA dalam hal skor koherensi dan keragaman topik, serta mampu memetakan isu-isu spesifik secara mendetail (Wahyuni et al., 2025).

Mengingat kompleksitas ulasan pengguna Duolingo yang mencakup aspek teknis, materi pembelajaran, hingga pengalaman pengguna, serta karakteristik bahasa ulasan yang cenderung informal, diperlukan kombinasi metode yang mutakhir untuk menghasilkan analisis yang akurat. Penggunaan IndoBERTweet dipilih karena model ini dirancang khusus untuk menangani ragam bahasa informal Indonesia dan terbukti menghasilkan performa yang lebih baik pada teks pendek dan tidak baku, seperti ulasan pengguna aplikasi. Sementara itu, BERTopic menggunakan *embedding* berbasis *transformer* sehingga setiap kata maupun kalimat direpresentasikan dalam bentuk vektor yang mampu menangkap makna semantik secara mendalam. Representasi ini memungkinkan model memahami konteks, hubungan antar kata, serta nuansa bahasa yang tidak dapat ditangkap oleh pendekatan Bag-of-Words pada metode konvensional. Kombinasi fitur ini menjadikan BERTopic lebih unggul dalam menganalisis ulasan aplikasi yang besar dan tidak terstruktur.

Berdasarkan uraian di atas, penelitian ini memandang perlu untuk melakukan analisis mendalam terhadap ulasan aplikasi Duolingo dengan menggabungkan kekuatan IndoBERTweet dalam mendeteksi sentimen dan BERTopic dalam memetakan topik pembicaraan. Pendekatan ini diharapkan mampu memberikan gambaran yang komprehensif mengenai persepsi pengguna terhadap aplikasi Duolingo, tidak hanya dari sisi polaritas emosi tetapi juga substansi masalah yang dibahas. Hal ini menjadi dasar yang kuat untuk merumuskan permasalahan yang akan diselesaikan dalam penelitian ini.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengklasifikasikan sentimen ulasan berbahasa Indonesia terhadap aplikasi Duolingo menggunakan model IndoBERTweet?
2. Bagaimana tingkat akurasi yang diperoleh dari hasil klasifikasi sentimen ulasan aplikasi Duolingo menggunakan model IndoBERTweet?
3. Bagaimana pemodelan topik BERTopic digunakan untuk mengidentifikasi topik-topik utama yang muncul dalam ulasan pengguna aplikasi Duolingo?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Untuk mengklasifikasikan sentimen ulasan berbahasa Indonesia terhadap aplikasi Duolingo menggunakan model IndoBERTweet.
2. Untuk mengukur dan mengevaluasi tingkat kinerja model IndoBERTweet dalam mengklasifikasikan sentimen ulasan pengguna aplikasi Duolingo.
3. Untuk mengidentifikasi topik-topik utama yang muncul dalam ulasan pengguna aplikasi Duolingo menggunakan pemodelan topik BERTopic.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat berupa:

1. Sebagai referensi penggunaan IndoBERTweet dalam analisis sentimen berbahasa Indonesia.
2. Sebagai referensi penggunaan BERTopic dalam pemodelan topik pada ulasan aplikasi.

1.5 Batasan Penelitian

Batasan dalam penelitian ini adalah sebagai berikut:

1. Analisis sentimen dan pemodelan topik hanya pada ulasan pengguna aplikasi Duolingo di Google Play Store sebanyak 1.000 data.
2. Data yang digunakan hanya ulasan teks berbahasa Indonesia, ulasan non-Bahasa Indonesia tidak dianalisis.
3. Klasifikasi sentimen dilakukan menggunakan model IndoBERTweet dengan dua kelas yaitu positif dan negatif.
4. Pemodelan topik dilakukan menggunakan metode BERTopic tanpa perbandingan mendalam dengan metode lain.
5. Evaluasi kinerja model klasifikasi sentimen hanya menggunakan metrik akurasi, presisi, recall, dan F1-score.

II. TINJAUAN PUSTAKA

2.1 Mobile-Assisted Language Learning (MALL)

Mobile-Assisted Language Learning (MALL) merupakan pengembangan dari *Computer-Assisted Language Learning (CALL)* yang secara khusus memanfaatkan perangkat mobile seperti smartphone dan tablet dalam kegiatan pembelajaran bahasa. *MALL* memfasilitasi pembelajaran yang lebih fleksibel karena peserta didik dapat mengakses materi, latihan, maupun sumber belajar kapan saja dan di mana saja melalui aplikasi atau platform berbasis mobile. Rahmawati et al. (2023) menyatakan bahwa *MALL* adalah pendekatan pembelajaran yang memanfaatkan teknologi mobile sebagai alat bantu dalam proses pembelajaran bahasa, khususnya untuk melatih keterampilan tertentu seperti pengucapan (*pronunciation*) melalui aplikasi yang mudah diakses oleh mahasiswa. Pendekatan ini sejalan dengan kebutuhan pembelajaran modern yang menekankan kemandirian belajar, aksesibilitas, dan pemanfaatan teknologi digital dalam pendidikan.

Berbagai penelitian menunjukkan bahwa penerapan *MALL* tidak hanya meningkatkan fleksibilitas, tetapi juga dapat memperkuat keterlibatan dan efektivitas pembelajaran bahasa. Dalam konteks pembelajaran Bahasa Inggris Keperawatan, Suryati et al. (2024) menemukan bahwa penggunaan *MALL* membantu mahasiswa mengakses teks bacaan otentik, memperkaya kosakata istilah keperawatan, dan melatih keterampilan membaca melalui materi digital yang disajikan di perangkat mobile. Mayoritas responden dalam penelitian tersebut menilai *MALL* sangat membantu karena materi dapat dipelajari secara mandiri di luar jam perkuliahan, sekaligus membuat proses belajar menjadi lebih menarik dan kontekstual (Suryati et al., 2024). Temuan ini menunjukkan bahwa *MALL* mampu menjembatani kebutuhan pembelajaran bahasa yang bersifat spesifik bidang dengan kemudahan akses teknologi.

Selain mendukung keterampilan membaca dan pemahaman teks, *MALL* juga berperan dalam pengembangan kosakata dan kemandirian belajar. Handayani & Damayanti (2022) menunjukkan bahwa pemanfaatan aplikasi berbasis *MALL*, seperti *HelloTalk*, dapat membantu calon guru Bahasa Inggris mengembangkan kosakata melalui interaksi langsung dengan penutur lain di lingkungan digital. Penggunaan aplikasi mobile tersebut mendorong mahasiswa untuk lebih sering terpapar pada bahasa target, berlatih secara mandiri, dan memanfaatkan berbagai fitur digital seperti percakapan, koreksi bahasa, dan umpan balik sesama pengguna (Handayani & Damayanti, 2022).

2.2 Duolingo

Duolingo merupakan aplikasi pembelajaran bahasa berbasis mobile yang dikembangkan sejak tahun 2011 dan dirancang sebagai platform belajar bahasa yang bersifat gratis, interaktif, dan mudah diakses oleh berbagai kalangan. Dalam konteks *Mobile-Assisted Language Learning (MALL)*, Duolingo berperan sebagai media pembelajaran bahasa yang menyediakan materi dalam bentuk latihan singkat (*bite-sized lessons*), disertai umpan balik langsung dan sistem penilaian berbasis poin. Hakimantieq et al. (2022) menjelaskan bahwa Duolingo dapat dimanfaatkan sebagai suplemen pembelajaran membaca bahasa Inggris dasar bagi pembelajar *EFL*, karena aplikasi ini menyajikan materi yang terstruktur, repetitif, dan didukung latihan interaktif yang dapat diakses melalui perangkat mobile.

Salah satu karakteristik utama Duolingo adalah penggunaan mekanisme gamification dalam desain pembelajarannya. Pengguna diajak menyelesaikan level, mengumpulkan poin pengalaman (*experience points/XP*), mempertahankan streak harian, serta memperoleh lencana sebagai bentuk penghargaan atas progres belajar. Pendekatan ini membuat aktivitas belajar terasa lebih mirip permainan sehingga dapat meningkatkan keterlibatan dan ketertarikan pengguna. Puspita et al. (2025) menemukan bahwa Duolingo dirancang seperti permainan sehingga terasa lebih menarik bagi pengguna, serta menyediakan berbagai fitur untuk melatih keterampilan bahasa Inggris seperti listening, reading, speaking, dan writing, termasuk latihan kosakata dan tata bahasa yang dikemas secara sederhana dan mudah diikuti.

Berbagai kajian empiris menunjukkan bahwa Duolingo tidak hanya berperan sebagai alat bantu belajar bahasa, tetapi juga dapat memengaruhi aspek motivasi dan hasil belajar. Salsabila et al. (2024) melalui sebuah *literature review*, menyimpulkan bahwa penggunaan aplikasi Duolingo berkontribusi positif terhadap motivasi belajar bahasa Inggris karena pembelajaran terasa lebih menyenangkan, mudah diakses, dan sesuai dengan karakteristik pembelajar generasi digital.

Sementara itu, Puspita et al. (2025) menunjukkan bahwa mayoritas responden menilai Duolingo membantu peningkatan penguasaan kosakata bahasa Inggris mereka. Temuan-temuan tersebut menunjukkan bahwa Duolingo tidak hanya populer sebagai aplikasi pembelajaran bahasa, tetapi juga memiliki relevansi pedagogis yang kuat dalam konteks MALL.

2.3 Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan cabang dari kecerdasan buatan yang berfokus pada bagaimana komputer dapat memproses, memahami,

dan menganalisis bahasa alami manusia dalam bentuk teks maupun suara. *NLP* menggabungkan bidang ilmu komputer, linguistik, dan statistika untuk mengembangkan model yang mampu mengenali struktur bahasa, makna, serta konteks yang terkandung di dalam sebuah teks (Amien, 2023). Dalam konteks bahasa Indonesia, pengembangan *NLP* mencakup berbagai teknologi dasar seperti stemming, part-of-speech tagging, ekstraksi informasi, penerjemahan mesin, hingga analisis sentimen yang diaplikasikan pada beragam domain seperti media sosial, layanan publik, dan pendidikan (Amien, 2023). Seiring dengan meningkatnya jumlah data teks yang dihasilkan pengguna di internet, peran *NLP* menjadi semakin penting untuk mengotomatisasi proses pemahaman dan pengolahan informasi dalam skala besar.

Dalam ranah analisis sentimen, *NLP* digunakan untuk mengubah teks tidak terstruktur menjadi informasi yang terstruktur sehingga dapat diolah lebih lanjut menggunakan teknik data mining maupun pembelajaran mesin. Rivaldi & Wismarini (2024) menjelaskan bahwa *NLP* memungkinkan komputer untuk memahami dan menganalisis teks berbahasa manusia melalui serangkaian tahapan, seperti *tokenizing*, *preprocessing*, penghapusan *stopwords*, *stemming*, representasi vektor teks, hingga klasifikasi sentimen menggunakan algoritma *machine learning*.

2.4 Text Mining

Text mining atau penambangan teks merupakan metode analisis data yang berfokus pada penggalian informasi dan pengetahuan dari kumpulan data teks yang umumnya bersifat tidak terstruktur. Dengan bantuan berbagai teknik komputasional, *text mining* memungkinkan peneliti merancang, menemukan, dan mengekstraksi pola atau pengetahuan dari teks dalam jumlah besar, sehingga data yang semula hanya berupa kata dan kalimat dapat diubah menjadi informasi yang lebih terstruktur dan mudah dianalisis (Ariansyah & Indahyanti, 2024). Dalam praktiknya, *text mining* banyak dimanfaatkan untuk tugas-tugas seperti klasifikasi teks, pengelompokan dokumen, analisis sentimen, maupun pemodelan topik yang mendukung proses *knowledge discovery* pada koleksi dokumen berskala besar (Ariansyah & Indahyanti, 2024).

Data teks biasanya tidak terstruktur, sehingga sebelum dilakukan operasi penambangan data, *text mining* memerlukan beberapa tahapan tambahan agar teks siap diolah. Salah satu tahapan penting adalah text preprocessing, seperti pembersihan teks dari karakter yang tidak relevan, *case folding*, *tokenizing*, penghapusan *stopword*, dan *stemming*, yang bertujuan mengurangi noise dan menyeragamkan bentuk kata (Ariansyah & Indahyanti, 2024). Setelah tahap ini, dilakukan ekstraksi fitur untuk mengubah data teks yang tidak terstruktur

menjadi representasi numerik yang terstruktur (misalnya *BoW* atau *TF-IDF*), sehingga dapat diproses oleh algoritma pembelajaran mesin dan teknik analitik lainnya (Faisal et al., 2022).

Sebelum proses preprocessing dan pemodelan dilakukan, data teks perlu dikumpulkan terlebih dahulu dari sumber daring. Salah satu teknik yang umum digunakan adalah *web scraping*, yaitu proses pengambilan data atau informasi dari sebuah website secara otomatis dan spesifik pada bagian-bagian tertentu sesuai kebutuhan. Berbeda dengan *web crawling* yang cenderung menjelajahi hampir seluruh struktur situs web, *web scraping* lebih terarah pada kumpulan data tertentu sehingga hasil ekstraksinya lebih fokus dan akurat (Rahman et al., 2022). Dalam penelitian ini, pengambilan ulasan pengguna aplikasi Duolingo dari Google Play Store melalui teknik *web scraping* merupakan langkah awal dalam alur *text mining* sebelum dilakukan *preprocessing*, ekstraksi fitur, analisis sentimen, dan pemodelan topik.

2.5 Preprocessing Teks

Preprocessing teks merupakan tahapan awal dalam pengolahan data teks yang bertujuan untuk membersihkan dan mengubah teks mentah menjadi bentuk yang lebih terstruktur sehingga siap dianalisis lebih lanjut, misalnya untuk analisis sentimen atau pemodelan topik. Data teks pada umumnya bersifat tidak terstruktur dan masih mengandung banyak elemen yang tidak relevan, sehingga diperlukan serangkaian langkah seperti pembersihan teks, *tokenizing*, *case folding*, penghapusan karakter khusus, penghapusan stopword, hingga perbaikan kata dan pembentukan kata dasar (Faisal et al., 2022).

Tahapan *preprocessing* yang umum digunakan dalam analisis teks meliputi beberapa proses berikut.

1. Cleaning

Cleaning adalah tahap pembersihan teks dari elemen-elemen yang tidak relevan dan tidak memiliki kontribusi semantik, seperti tanda baca, simbol, *mention* (@username), tagar (#), emotikon, atau URL, yang dilakukan untuk mengurangi kebisingan (*noise*) pada data mentah dan menghasilkan teks yang lebih bersih untuk analisis selanjutnya (Abdillah et al., 2023; Yuwono et al., 2024).

2. Case Folding

Case folding merupakan proses penyeragaman huruf di mana semua karakter teks diubah menjadi huruf kecil (Yuwono et al., 2024). Tujuan utama dari proses ini adalah untuk menghilangkan perbedaan representasi kata yang disebabkan oleh variasi penggunaan huruf kapital, sehingga memastikan bahwa

kata-kata dengan makna yang sama diperlakukan secara konsisten dalam proses pengolahan teks (Rivaldi & Wismarini, 2024)

3. *Tokenizing*

Tokenizing adalah proses memecah teks atau kalimat menjadi satuan-satuan yang lebih kecil yang disebut *token* atau kata individual (Yuwono et al., 2024). Proses ini memungkinkan teks untuk diubah menjadi unit-unit yang dapat diolah secara komputasional, yang sering kali dilakukan dengan memisahkan teks berdasarkan spasi atau pola tertentu (Abdillah et al., 2023).

4. *Normalisasi*

Normalisasi adalah tahapan yang dilakukan untuk mengonversi kata-kata tidak baku, singkatan, atau bahasa gaul (*slang*) menjadi bentuk baku yang standar (Abdillah et al., 2023). Tujuannya adalah untuk memastikan konsistensi dalam representasi kata, sehingga kata-kata yang awalnya tidak sesuai dengan ejaan bahasa Indonesia baku dapat diperbaiki (Yuwono et al., 2024).

5. *Stopword Removal*

Stopword removal adalah proses menghilangkan kata-kata umum yang memiliki kontribusi makna yang relatif rendah, seperti kata sambung ("dan," "yang," "di") dari teks (Setiawan et al., 2023). Tujuan dari penghapusan *stopword* adalah untuk mengurangi dimensi fitur teks dan memfokuskan analisis pada kata-kata yang lebih informatif (Abdillah et al., 2023).

6. *Stemming* atau *Lemmatization*

Stemming atau *lemmatization* adalah teknik untuk mereduksi kata-kata ke bentuk dasar atau akar kata (Setiawan et al., 2023). Tahapan ini dilakukan untuk mengurangi variasi morfologis kata dengan menghilangkan imbuhan (awalan, sisipan, dan akhiran), yang bertujuan untuk menyederhanakan dan menyeragamkan representasi kata dalam proses analisis teks (Yuwono et al., 2024).

Berbagai penelitian analisis sentimen berbasis ulasan pengguna aplikasi maupun media sosial juga menegaskan bahwa kualitas tahap *preprocessing* sangat memengaruhi kinerja model, karena kesalahan atau *noise* pada teks dapat mengurangi akurasi hasil klasifikasi (Abdillah et al., 2023).

2.6 Analisis Sentimen

Analisis sentimen merupakan salah satu penerapan *text mining* dan *Natural Language Processing (NLP)* yang berfokus pada pengklasifikasian opini atau sikap seseorang terhadap suatu objek ke dalam kategori sentimen tertentu, seperti positif, negatif, maupun netral. Rivaldi & Wismarini (2024) menjelaskan bahwa analisis sentimen dilakukan dengan mengubah teks tidak terstruktur menjadi data terstruktur sehingga dapat diolah lebih lanjut menggunakan metode

komputasional untuk mengetahui kecenderungan pendapat pengguna terhadap suatu produk atau layanan. Dalam konteks ulasan aplikasi, analisis sentimen membantu peneliti dan pengembang aplikasi memahami bagaimana pengalaman dan penilaian pengguna tercermin melalui komentar yang mereka tulis.


Secara umum, tahapan analisis sentimen meliputi pengumpulan data, *preprocessing* teks (seperti *cleaning*, *case folding*, normalisasi, dan *tokenizing*), ekstraksi fitur, kemudian klasifikasi menggunakan algoritma pembelajaran mesin atau model berbasis *deep learning*. Abdillah et al. (2023), dalam penelitiannya terhadap ulasan pengguna aplikasi *WeTV*, menunjukkan bahwa penerapan analisis sentimen pada ulasan aplikasi digital dapat memberikan gambaran yang jelas mengenai tingkat kepuasan dan keluhan pengguna terhadap fitur maupun kualitas layanan.

2.7 BERT

BERT (Bidirectional Encoder Representations from Transformers) adalah model bahasa pra-latih berbasis arsitektur transformer yang diperkenalkan oleh Devlin et al. (2019) dari *Google*. Model ini dirancang untuk mempelajari representasi kata secara kontekstual dengan mempertimbangkan konteks di kiri dan kanan suatu kata secara bersamaan (*bidirectional*), sehingga makna kata dipahami berdasarkan keseluruhan kalimat, bukan hanya dari satu arah saja (Devlin et al., 2019). Pada tahap pra-pelatihan (*pre-training*), *BERT* menggunakan dua tugas utama, yaitu *Masked Language Modeling (MLM)* untuk memprediksi kata yang disembunyikan dalam kalimat, serta *Next Sentence Prediction (NSP)* untuk mempelajari hubungan antarkalimat. Kombinasi kedua tugas ini membuat *BERT* mampu menangkap informasi semantik dan sintaksis secara mendalam dan kemudian dengan mudah di-fine-tune untuk berbagai tugas *NLP*, seperti klasifikasi teks, analisis sentimen, dan *question answering* tanpa perlu mengubah arsitektur secara signifikan (Devlin et al., 2019).

Secara arsitektural, *BERT* terdiri dari beberapa lapisan encoder Transformer yang masing-masing memuat mekanisme *multi-head self-attention* dan *feed-forward neural network*. Dalam konfigurasi *BERT-base*, arsitektur ini terdiri atas 12 lapisan *encoder*, dengan ukuran representasi tersembunyi (*hidden size*) sebesar 768 dan 12 *attention heads* pada setiap lapisan (Devlin et al., 2019). Masukan ke dalam model *BERT* direpresentasikan melalui penjumlahan tiga jenis *embedding*, yaitu *token embedding*, *segment embedding*, dan *position embedding*. Token khusus [CLS] digunakan sebagai representasi keseluruhan urutan teks untuk tugas klasifikasi, sedangkan [SEP] berfungsi sebagai pemisah antarsegmen input. Arsitektur *BERT* bersifat konsisten antara tahap *pre-training* dan *fine-*

tuning, sehingga model dapat diadaptasi untuk berbagai tugas NLP tanpa perubahan struktur arsitektur yang berarti.



Gambar 1. Proses *pre-training* and *fine-tuning* BERT

Sumber : Devlin et al. (2019)


Gambar tersebut menunjukkan bahwa selain lapisan keluaran (*output layer*), struktur arsitektur yang digunakan pada tahap *pre-training* dan *fine-tuning* adalah sama. Parameter hasil *pre-training* digunakan sebagai inisialisasi model untuk berbagai tugas *downstream*, dan seluruh parameter disesuaikan kembali selama proses *fine-tuning* sesuai dengan tugas yang dikerjakan.

Dalam konteks analisis sentimen, *BERT* banyak dimanfaatkan karena kemampuannya menghasilkan embedding kata yang bersifat kontekstual. Pradipta & Widodo (2024) menjelaskan bahwa *BERT* memanfaatkan pendekatan *word embedding* kontekstual untuk memahami makna kata dalam dua arah sehingga mampu menangkap nuansa sentimen yang kompleks pada komentar media sosial. Sejumlah penelitian di Indonesia juga telah menerapkan *BERT* untuk menganalisis opini publik dan ulasan pengguna. Aljabar & Karomah (2024) misalnya, menggunakan pendekatan *BERT-based* untuk analisis sentimen komentar film dan melaporkan bahwa model berbasis *BERT* mampu menangkap variasi ekspresi sentimen secara lebih baik dibandingkan metode sebelumnya. Kusuma & Mogi (2023) juga menunjukkan bahwa pemanfaatan varian *BERT* yang telah dipra-latih untuk bahasa Indonesia (*IndoBERT*) dan di *fine-tune* pada ulasan destinasi wisata menghasilkan kinerja yang tinggi dalam mengklasifikasikan ulasan menjadi sentimen positif dan negatif. Berbagai temuan ini menguatkan bahwa *BERT* dan turunannya merupakan fondasi penting dalam pengembangan model analisis sentimen modern, termasuk pada penelitian ini yang selanjutnya memanfaatkan varian khusus untuk bahasa Indonesia yang akan dibahas pada subbab berikutnya.

2.8 IndoBERTweet

IndoBERTweet merupakan model turunan dari IndoBERT yang dikembangkan melalui continual pretraining pada korpus Twitter berbahasa Indonesia, namun tetap menggunakan arsitektur *BERT-base* yang terdiri atas 12 lapisan *encoder*, 768 *hidden size*, dan 12 *attention heads* (Koto et al., 2021). Perbedaan utama *IndoBERTweet* terletak pada data pra-pelatihan dan penyesuaian kosakata yang digunakan dirancang untuk menangani karakteristik bahasa informal media sosial, seperti singkatan, slang, dan penggunaan emotikon (Koto et al., 2021). Pendekatan ini membuat *IndoBERTweet* lebih adaptif terhadap karakteristik bahasa informal di media sosial dibandingkan model *BERT* umum, karena representasi katanya dilatih langsung pada ratusan juta *token Twitter* berbahasa Indonesia.

Untuk memberikan gambaran mengenai struktur internal model, arsitektur IndoBERTweet ditampilkan pada Gambar berikut ini.



Gambar 2. Arsitektur IndoBERTweet

Sumber : Setiawan et al. (2023)

Diagram tersebut menunjukkan alur input berupa *input ids* dan *attention mask*, pemrosesan melalui lapisan-lapisan transformer encoder yang telah diperkaya dengan pengetahuan bahasa dari Twitter, hingga keluaran berupa representasi kontekstual yang digunakan pada tahap klasifikasi.

Keunggulan utama *IndoBERTweet* terletak pada kemampuannya menangani variasi penulisan yang tidak baku, kata gaul, singkatan, serta penggunaan simbol atau emotikon yang lazim dalam percakapan daring. Beberapa kajian menunjukkan bahwa *IndoBERTweet* memiliki performa yang baik untuk tugas-tugas *NLP* di ranah bahasa informal, seperti analisis sentimen dan deteksi emosi. Khairani et al. (2024) misalnya, membandingkan *IndoBERT* dan *IndoBERTweet* untuk mendeteksi emosi pada komentar akun berita di

Instagram dan menemukan bahwa *IndoBERTweet* mampu menghasilkan kinerja yang lebih baik, sekaligus sensitif terhadap variasi bahasa pengguna media sosial. Penelitian lain pada analisis sentimen ulasan *TikTok* juga menunjukkan bahwa *IndoBERTweet* efektif digunakan bersama arsitektur *deep learning* untuk mengklasifikasikan opini pengguna dalam beberapa kategori sentimen (Setiawan et al., 2023).

2.9 BERTopic

BERTopic merupakan salah satu metode *topic modeling* modern yang memanfaatkan representasi semantik dari model *transformer*, seperti *BERT* atau *Sentence-BERT*, kemudian mengelompokkannya menggunakan algoritma *clustering* dan membentuk representasi topik dengan teknik *class-based TF-IDF* (*c-TF-IDF*) (Grootendorst, 2022). Metode ini dikembangkan untuk menghasilkan topik yang lebih koheren dan mudah diinterpretasikan dibandingkan model topik tradisional, seperti *Latent Dirichlet Allocation (LDA)*, terutama pada data teks pendek dan tidak terstruktur yang banyak ditemukan pada media sosial maupun ulasan pengguna.

Secara umum, alur kerja BERTopic dimulai dengan mengubah setiap dokumen teks menjadi *embedding* berdimensi tinggi menggunakan model *sentence transformers*. *Embedding* tersebut kemudian direduksi dimensinya (misalnya dengan *UMAP*), dikelompokkan menggunakan algoritma *clustering* seperti *HDBSCAN*, lalu setiap klaster diberi representasi topik melalui perhitungan *c-TF-IDF* untuk mengekstraksi kata-kata paling representatif dari masing-masing topik (Wahyuni et al., 2025). Pendekatan ini memungkinkan BERTopic menggabungkan keunggulan representasi kontekstual dari model *transformer* dengan kemudahan interpretasi topik berbasis kata kunci, sehingga cocok digunakan untuk menganalisis kumpulan dokumen dalam jumlah besar, termasuk komentar atau ulasan daring.

Berbagai penelitian terbaru telah menerapkan BERTopic pada beragam domain untuk mengidentifikasi tema-tema utama dalam opini publik. Simanjuntak et al. (2024) misalnya, menggunakan BERTopic untuk menganalisis perubahan opini publik terhadap kendaraan listrik di Indonesia berdasarkan komentar *YouTube* dan berhasil mengelompokkan komentar menjadi beberapa topik utama yang merepresentasikan isu-isu penting yang dibicarakan masyarakat. Penelitian lain juga menunjukkan bahwa BERTopic mampu menghasilkan topik yang lebih koheren dibandingkan LDA pada data ulasan hotel dan layanan digital (Mertayasa & Darmawan, 2022).

2.10 Visualisasi Data

Visualisasi data merupakan tahap penting dalam *text mining* dan analisis sentimen karena membantu menyajikan pola dan informasi yang sulit terlihat hanya dari angka atau teks mentah. Dalam konteks data teks, visualisasi sering digunakan untuk menampilkan distribusi kata, tema dominan, maupun perbandingan antar kelompok data seperti kelas sentimen positif dan negatif. Dengan visualisasi yang tepat, peneliti dan pembaca dapat lebih mudah memahami hasil analisis serta menarik *insight* yang relevan dari data ulasan pengguna aplikasi. Salah satu bentuk visualisasi yang banyak digunakan adalah *word cloud*, yang menampilkan kata-kata dengan ukuran *font* sesuai frekuensi kemunculannya sehingga kata yang lebih sering muncul tampak lebih besar dan menonjol (Febriyanti et al., 2021; Pradana, 2020).

Word cloud merupakan teknik visualisasi teks yang menyajikan kumpulan kata dari sebuah *korpus* dalam bentuk gambar, di mana ukuran setiap kata merepresentasikan tingkat kepentingan atau frekuensi kemunculannya. Pendekatan ini populer dalam *text mining* karena mudah dipahami secara intuitif dan mampu memberikan gambaran cepat mengenai topik atau isu yang paling menonjol pada suatu teks (Febriyanti et al., 2021). Dalam analisis sentimen, *word cloud* sering dibuat secara terpisah untuk setiap kategori sentimen (misalnya positif dan negatif) guna melihat perbedaan kata-kata dominan yang muncul di masing-masing kelas. Penelitian mengenai analisis sentimen ulasan aplikasi DANA di *Google Play*, misalnya, memanfaatkan *word cloud* untuk mengidentifikasi kata-kata yang paling sering muncul pada ulasan positif dan negatif setelah proses *preprocessing*, sehingga membantu memahami fokus keluhan maupun apresiasi pengguna secara visual (Nawulansih et al., 2025).



Gambar 3. Contoh visualisasi data menggunakan *word cloud*

Sumber : Wibowo et al. (2024)

2.11 Penelitian Terdahulu

Dalam penelitian ini, diperlukan referensi dari penelitian sebelumnya yang juga menggunakan metode IndoBERTweet dan BERTopic yang merupakan

metode yang akan digunakan dalam penelitian ini. Berikut ini adalah beberapa penelitian terdahulu yang relevan dengan metode serupa yang akan diterapkan dalam penelitian ini :

Tabel 1. Penelitian Terdahulu

No	Judul Penelitian	Peneliti dan Tahun	Metode	Hasil Penelitian
1	Sentiment Analysis and Topic Modelling Using IndoBERTweet and BERTopic for Public Health Issues	Wesly M Sihombing dan Triyanna Widiyaningt yas (2025)	IndoBERTweet dan BERTopic	Penelitian ini menggunakan 6.740 data tweet dari platform X untuk menganalisis isu kesehatan publik di Indonesia secara <i>real-time</i> . Tujuannya adalah memetakan diskusi kesehatan dan mengklasifikasikan sentimen serta topik dominan menggunakan kombinasi metode klasifikasi dan pemodelan topik. Hasilnya menunjukkan dominasi sentimen netral dan teridentifikasinya 44 topik dengan isu utama meliputi kesehatan mental serta vaksinasi, di mana model IndoBERTweet mencapai <i>Weighted F1-Score</i> sebesar 0,7822.
2	Sentiment Analysis of Indonesian TikTok Review Using LSTM and	Jerry C. Setiawan, Kemas M. Lhaksmana, dan	LSTM dan IndoBERTweet	Studi ini menganalisis 22.424 ulasan pengguna TikTok Indonesia yang diambil dari Google Play Store untuk mengklasifikasikan

No	Judul Penelitian	Peneliti dan Tahun	Metode	Hasil Penelitian
	IndoBERTweet Algorithm	Bunyamin (2023)		sentimen negatif, netral, dan positif. Penelitian bertujuan membandingkan performa metode <i>deep learning</i> LSTM standar dengan model <i>pre-trained</i> IndoBERTweet. Hasil pengujian menunjukkan bahwa IndoBERTweet mengungguli LSTM dengan akurasi 80%, sedangkan LSTM hanya mencapai akurasi 78%.
3	Analisis Sentimen Publik pada Tagar #BTSCOMEBA CK di Platform X Menggunakan IndoBERTweet	Nastasya Meryl Damayanti, Imelda Dwi Ariningtyas, Maulana Izuddin Audadi Icham, dan Anggraini Puspita Sari (2025)	IndoBERTweet	Data yang digunakan berupa 6.300 tweet berbahasa Indonesia terkait tagar #BTSComeback yang dikumpulkan pada periode Januari hingga Juni 2025. Penelitian ini bertujuan menganalisis respons emosional publik terhadap fenomena <i>comeback</i> grup BTS menggunakan model IndoBERTweet yang mampu menangani bahasa informal. Model berhasil mengklasifikasikan sentimen dengan akurasi mencapai 95% pada pembagian data 70:30, serta mampu mendeteksi

No	Judul Penelitian	Peneliti dan Tahun	Metode	Hasil Penelitian
				sentimen positif dan negatif dengan sangat baik.
4	Pengaruh Tahapan Preprocessing Terhadap Model IndoBERT dan IndoBERTweet untuk Mendeteksi Emosi pada Komentar Akun Berita Instagram	Ulfia Khairani, Viska Mutiawani, dan Hendri Ahmadian (2024)	IndoBERT dan IndoBERTweet	Penelitian ini menggunakan 5.002 komentar dari akun berita Instagram (@kumparancom dan @detikcom) untuk mendeteksi empat kategori emosi (marah, senang, takut, sedih). Tujuannya adalah membandingkan performa IndoBERT dan IndoBERTweet serta mengevaluasi dampak <i>stemming</i> dan <i>stopwords removal</i> terhadap akurasi model. Temuan utama menunjukkan bahwa model tanpa <i>stemming</i> dan <i>stopwords removal</i> berkinerja lebih baik, di mana IndoBERTweet mencapai akurasi tertinggi sebesar 92,54%, mengungguli IndoBERT yang sebesar 88,81%.
5	Knowledge Discovery Through Topic Modeling on GoPartner User Reviews	Metti Detricia Pratiwi dan Ken Ditha Tania (2025)	BERTopic, LDA dan NMF	Penelitian ini menganalisis 11.417 ulasan pengguna aplikasi GoPartner di Google Play Store untuk menemukan pola

No	Judul Penelitian	Peneliti dan Tahun	Metode	Hasil Penelitian
	Using BERTopic, LDA, and NMF			keluhan dan kepuasan mitra pengemudi. Metode BERTopic, LDA, dan NMF dibandingkan untuk melihat kualitas topik yang dihasilkan melalui nilai koherensi. Hasilnya menunjukkan BERTopic memiliki skor koherensi tertinggi (0,6905) pada data <i>tokenizing</i> dan berhasil mengungkap isu operasional seperti jarak penjemputan serta kesulitan mendapatkan pesanan.

Sumber : Penelitian Terdahulu

Berdasarkan penelitian-penelitian terdahulu, terlihat bahwa metode IndoBERTweet dan BERTopic telah digunakan secara luas dalam berbagai studi analisis teks, terutama pada data informal dari media sosial dan ulasan aplikasi. IndoBERTweet consistently menunjukkan performa yang unggul dalam menangani bahasa tidak baku, singkatan, serta ekspresi khas percakapan daring, sehingga menghasilkan akurasi yang lebih tinggi dibandingkan metode *deep learning* konvensional maupun model berbasis transformer lainnya.

Sementara itu, BERTopic terbukti mampu menghasilkan topik yang lebih koheren dibandingkan pendekatan tradisional seperti LDA dan NMF, khususnya ketika diterapkan pada data teks pendek dalam jumlah besar. Secara keseluruhan, temuan-temuan tersebut memperkuat landasan metodologis penelitian ini, yaitu penerapan IndoBERTweet untuk klasifikasi sentimen dan BERTopic untuk pemodelan topik, karena kedua metode tersebut dinilai paling sesuai dengan karakteristik ulasan pengguna Duolingo yang bersifat informal, variatif, dan tidak terstruktur.

III. METODE PENELITIAN

3.1 Tempat dan Waktu Penelitian

Penelitian ini dilaksanakan di Program Studi Sistem Informasi, Fakultas Sains dan Teknologi, Universitas Jambi sebagai bagian dari penyusunan tugas akhir. Waktu penelitian direncanakan berlangsung mulai dari bulan Oktober 2025 hingga Maret 2026, meliputi tahapan pengumpulan data ulasan pengguna aplikasi Duolingo, *preprocessing* data, pelabelan sentimen, penerapan model klasifikasi sentimen menggunakan IndoBERTweet, pemodelan topik menggunakan BERTopic, serta analisis dan interpretasi hasil penelitian.

3.2 Bahan dan Alat Penelitian

Penelitian ini membutuhkan *dataset* yang diambil dari ulasan berbahasa Indonesia pada aplikasi Duolingo yang tersedia di platform *Google Play Store*. Ulasan tersebut digunakan sebagai bahan utama dalam proses analisis sentimen dan pemodelan topik. Selain itu, informasi pengetahuan pendukung diperoleh dari tinjauan pustaka, jurnal ilmiah, repositori model, artikel *internet*, serta bahan referensi lain yang relevan dengan topik penelitian.

Dalam mendukung pelaksanaan penelitian, digunakan perangkat keras berupa laptop pribadi dengan spesifikasi prosesor *Ryzen 3 5300U*, RAM 8 GB, dan penyimpanan 512 GB SSD, serta didukung dengan koneksi *internet* yang stabil. Perangkat ini digunakan untuk melakukan pengumpulan data, pengolahan data, implementasi model, serta penyusunan hasil penelitian.

Penelitian ini didukung oleh sumber data, perangkat keras, dan perangkat lunak yang menunjang proses pengumpulan data, pengolahan data, implementasi model, hingga penyusunan laporan penelitian secara sistematis.

Tabel 2. Perangkat lunak yang digunakan


No	Perangkat Lunak	Fungsi
1	Windows 11	Sistem operasi utama penelitian
2	Microsoft Edge	Pengambilan data dan penelusuran literatur
3	Google Colab	Lingkungan pemrograman berbasis cloud untuk pengolahan data dan implementasi model
4	Microsoft Word	Penyusunan dan penulisan laporan penelitian
5	Mendeley	Manajemen dan pengelolaan referensi
6	Draw.io	Pembuatan diagram alur penelitian
7	Library Python	Mendukung proses analisis sentimen dan pemodelan topik

3.3 Tahapan Penelitian

Pada tahapan penelitian ini, proses analisis dilakukan untuk mengolah dan memahami ulasan pengguna aplikasi Duolingo yang diperoleh dari *Google Play Store*. Penelitian ini menggunakan dua pendekatan utama, yaitu klasifikasi sentimen menggunakan model *IndoBERTweet* serta pemodelan topik menggunakan *BERTopic* untuk mengidentifikasi tema-tema dominan dalam ulasan pengguna.

Model *IndoBERTweet* digunakan untuk mengklasifikasikan ulasan ke dalam kategori sentimen positif dan negatif, sedangkan *BERTopic* digunakan untuk menemukan topik-topik utama yang sering muncul pada kumpulan ulasan tersebut melalui proses *embedding*, reduksi dimensi, *clustering*, dan ekstraksi kata representatif.

Seluruh proses penelitian dilakukan secara bertahap, dimulai dari identifikasi masalah, studi pustaka, pengumpulan data ulasan, *preprocessing* data, pelabelan, pelatihan model, evaluasi, hingga penarikan kesimpulan. Alur lengkap tahapan penelitian ini dapat dilihat pada Gambar berikut.



Gambar 4. Tahapan penelitian

a. Identifikasi Masalah

Pada tahap ini, peneliti melakukan proses identifikasi masalah sebagai langkah awal untuk menentukan fokus kajian dalam penelitian. Identifikasi

dilakukan melalui pengamatan fenomena terkait penggunaan aplikasi Duolingo sebagai media pembelajaran bahasa di Indonesia, serta analisis terhadap ulasan pengguna pada platform *Google Play Store*. Ulasan tersebut mencerminkan berbagai tanggapan, pengalaman, dan persepsi pengguna yang dapat menjadi dasar dalam memahami kualitas, kelebihan, dan kelemahan aplikasi.

Peneliti juga menelaah berbagai penelitian sebelumnya yang berkaitan dengan analisis sentimen dan pemodelan topik pada ulasan aplikasi. Berdasarkan kajian tersebut, ditemukan bahwa sebagian besar penelitian masih menggunakan pendekatan analisis tradisional dan belum banyak yang menerapkan model bahasa Indonesia berbasis *transformer* seperti *IndoBERTweet*. Selain itu, penggunaan metode pemodelan topik modern seperti *BERTopic* pada data ulasan aplikasi pembelajaran bahasa juga belum banyak dilakukan.

Temuan tersebut menunjukkan adanya kesenjangan penelitian yang perlu diisi, yaitu perlunya analisis yang lebih komprehensif untuk memahami sentimen serta topik-topik utama yang muncul dalam ulasan pengguna. Oleh karena itu, tahap identifikasi masalah ini menjadi dasar penting dalam penentuan arah penelitian, pemilihan metode yang relevan, serta penyusunan strategi analisis agar permasalahan yang dikaji dapat dijawab secara tepat dan mendalam.

b. Studi Pustaka

Pada tahap studi pustaka, peneliti menelaah berbagai sumber ilmiah seperti buku, jurnal, prosiding, dan artikel penelitian untuk memperoleh landasan teori yang relevan dengan topik yang dikaji. Studi ini dilakukan untuk memahami konsep dasar, metode penelitian, serta hasil-hasil temuan terdahulu yang dapat mendukung pelaksanaan penelitian. Melalui kajian tersebut, peneliti dapat melihat perkembangan penelitian sebelumnya, membandingkan berbagai pendekatan yang telah digunakan, serta mengidentifikasi celah penelitian yang masih dapat dikembangkan.

Studi pustaka juga membantu peneliti dalam menentukan kerangka teori, memilih metode yang paling sesuai, serta menyusun langkah penelitian secara sistematis. Dengan demikian, proses ini menjadi acuan penting agar penelitian memiliki dasar ilmiah yang kuat, terarah, dan selaras dengan perkembangan keilmuan yang ada.


c. Pengumpulan Data

Pengumpulan data dalam penelitian ini dilakukan dengan teknik *web scraping* terhadap ulasan pengguna aplikasi Duolingo yang terdapat pada platform *Google Play Store* regional Indonesia. Proses *scraping* dilakukan menggunakan bahasa pemrograman *Python* melalui lingkungan *Google Colab*

dengan memanfaatkan *library google-play-scraper* yang mendukung pengambilan ulasan aplikasi dari *Google Play Store*.

Pada proses ini, peneliti mengambil ulasan pengguna dalam jumlah besar dengan terlebih dahulu menentukan parameter seperti ID aplikasi, bahasa ulasan, *region*, serta rentang waktu ulasan yang ingin dikumpulkan. Data ulasan kemudian diambil secara bertahap hingga seluruh ulasan yang memenuhi kriteria terkumpul. Setiap ulasan yang berhasil diperoleh disimpan ke dalam struktur tabel agar mudah diolah pada tahapan berikutnya.

Hasil *scraping* berupa informasi dasar seperti teks ulasan, rating, waktu ulasan dibuat, serta beberapa atribut pendukung lainnya. Seluruh data tersebut kemudian dikonversi ke dalam format CSV untuk digunakan dalam proses *preprocessing*, pelabelan sentimen, dan analisis lebih lanjut pada model *IndoBERTweet* dan *BERTopic*.



reviewId	userName	userImage	content	score	thumbsUpCount	reviewCreatedAt	replyContent	repliedAt
3c20a46f-7544-4	ALI PURNOMO		https://play-th.go aplikasi ini sangat membantu. makasih min	5	0	06.11.04.01/01/2025.00.00		
7c5656ba-3d9b-4	Puji Malang		https://play-th.go Duolingo ini bagus untuk meningkatkan pengucapan kata maupun kalimat.	5	0	06.11.04.01/01/2025.00.05		
ef0ce4734-627c-4	Siti Mariah		https://play-th.go Mudah dimengerti	5	0	0.306331019.01/01/2025.00.06		
37d8b6d5-e922-4	Hsyam Mahesa		https://play-th.go good	5	0	06.11.04.01/01/2025.00.08		
d750e224-c2c1-4	MIMI CHAN		https://play-th.go i have to do my lessons... or	5	0	06.11.04.01/01/2025.00.10		
4aa4732a-40cd-4	yulya yulya		https://play-th.go sangat membantu. saya sangat berterimakasih	5	0	06.11.04.01/01/2025.00.10		
12681290-b9e6-4	Ahmad Nugraha		https://play-th.go Aplikasi gay, kesel banget gw, padahal aplikasinya bagus banget buat belajar baha	1	152	06.11.04.01/01/2025.00.18		
559198ba-d81c-4	Nur Hidayat Hds		https://play-th.go mantap!!!!	5	0	0.306331019.01/01/2025.00.27		
d3758bac-cf1d-4	Hastuk Fadi		https://play-th.go sangat seru	5	0	06.11.04.01/01/2025.00.27		
0c764e4e-8500-4	Sumarsih Sumi		https://play-th.go aku bisa melakukan sesuatu yang dengan Inggris dan Indonesia	5	0	06.11.04.01/01/2025.00.34		
b8c9624d-8e5f-4	Mustafa Husain		https://play-th.go Ko k k okkk	5	0	0.306331019.01/01/2025.00.36		
5d861a1c-bb8d-4	Marwah Lida		https://play-th.go sangat bagus untuk belajar bahasa	5	0	0.306331019.01/01/2025.00.37		
d3ba579e-b2eb-4	Damar123		https://play-th.go Bismillah mulai dari sekarang 1 DESEMBER 2025 saya akan memulai perubahan	5	0	0.306331019.01/01/2025.00.38		
d233ba19-1b23-4	Emil Salim		https://play-th.go sangat membantu	5	0	06.11.04.01/01/2025.00.40		
59037185-c249-4	Muhammad dar		https://play-th.go semoga saya sukses bisa berbahasa inggris terimakasih aplikasi duolingo	5	0	06.11.04.01/01/2025.00.43		
5ba8e788-009b-4	Zahroh Nur ani		https://play-th.go sangat seru belajar di Duolingo	4	0	06.11.04.01/01/2025.00.45		
0d5f3d22-472a-4	Nur fatihur Abdul		https://play-th.go sangat membantu	5	0	06.11.04.01/01/2025.00.51		
40d58785-d984-4	Marcella Naresw		https://play-th.go soalnya bisa belajar	5	0	06.11.04.01/01/2025.00.53		
3334c9a0-a7e3-4	Priyana Anni		https://play-th.go Luar biasa aku mendapat banyak pelajaran berbahasa inggris	5	0	06.11.04.01/01/2025.01.22		
ae571b41-a163-4	Mathews Kristar		https://play-th.go good	5	0	06.11.04.01/01/2025.01.26		
8e280f4-50a5-4	Nova Adelia		https://play-th.go terima kasih kepada duolingo ini karena saya dapat mengetahui tentang berbahasa	5	1	06.11.04.01/01/2025.01.34		
e46423a7-1616-4	vinokrathana Tan		https://play-th.go aplikasi nya sangat berguna bagi yang mau belajar bahasa asing	5	0	06.11.04.01/01/2025.01.36		
d26e405-8b04-4	Citra Andhyana		https://play-th.go Aplikasi yang paling bagus sih buat belajar bahasa karna tidak membosankan	5	0	06.11.04.01/01/2025.01.39		
3d3de541-eb98-4	Mikhaela Frandi		https://play-th.go sangat menyenangkan dan mudah di pahami	5	0	06.11.04.01/01/2025.01.42		
19d8de01-cdb0-4	fitri angrains		https://play-th.go belajar bahasa dengan mudah	5	0	06.11.04.01/01/2025.01.59		
b2b6c202-ec28-4	Adara Farabi		https://play-th.go sangat membantu	5	0	06.11.04.01/01/2025.02.09		

Gambar 5. Hasil *scraping* ulasan aplikasi Duolingo

Setelah proses *scraping* dilakukan, terkumpul 87.236 ulasan pengguna aplikasi Duolingo dari Google Play Store regional Indonesia. Data tersebut kemudian disaring melalui seleksi bahasa, rentang waktu, penghapusan duplikat, serta pengecekan kelengkapan teks. Pada tahap ini, hanya ulasan berbahasa Indonesia dalam rentang 1 Januari 2025 hingga 30 November 2025 yang digunakan, dengan atribut relevan berupa *content* dan *at*.

Dari data yang telah disaring, sebanyak 1.000 ulasan dipilih sebagai dataset inti menggunakan teknik *random sampling*. Metode ini digunakan untuk menghindari bias pemilihan data dan memastikan bahwa sampel dapat mewakili karakteristik populasi secara umum. Jumlah 1.000 data dipilih berdasarkan pertimbangan kebutuhan data berlabel, keterbatasan proses pelabelan manual, serta efisiensi komputasi selama pelatihan IndoBERTweet.

Berdasarkan eksperimen asli IndoBERTweet, model ini terbukti mampu mencapai performa tinggi meskipun proses *fine-tuning* dilakukan menggunakan dataset berukuran relatif kecil. Koto et al. (2021) menggunakan dataset berjumlah 499 hingga 11.000 data pada tujuh tugas *downstream*. Hal ini menunjukkan bahwa model IndoBERTweet tetap efektif meskipun jumlah data pelatihan tidak terlalu besar.

Dengan demikian, penggunaan 1.000 ulasan berbahasa Indonesia dalam penelitian ini dianggap memadai dan representatif untuk menggambarkan sentimen serta topik utama yang muncul dalam ulasan pengguna aplikasi Duolingo pada periode penelitian.

d. Pelabelan Data

Tahap pelabelan data dilakukan untuk memberikan kategori sentimen pada setiap ulasan yang telah terkumpul. Pelabelan ini dilakukan secara manual oleh peneliti dengan mempertimbangkan konteks kalimat, ekspresi pengguna, serta makna keseluruhan dari teks ulasan. Ulasan diklasifikasikan ke dalam dua kategori sentimen, yaitu positif dan negatif. Proses pelabelan dilakukan secara cermat agar model dapat dilatih menggunakan data yang valid dan akurat, sehingga hasil klasifikasi sentimen oleh model IndoBERTweet dapat mencerminkan kondisi nyata dari opini pengguna.

Pada penelitian ini, sentimen positif diberikan pada ulasan yang mengandung pujian, kepuasan, atau pengalaman menyenangkan terhadap aplikasi Duolingo, seperti kemudahan belajar, fitur yang membantu, atau motivasi belajar. Sebaliknya, sentimen negatif diberikan pada ulasan yang berisi keluhan, kekecewaan, atau pengalaman tidak menyenangkan, seperti masalah teknis, iklan yang mengganggu, atau fitur yang dianggap kurang optimal.


Tabel 3. Contoh hasil pelabelan data

No	Data Mentah	Label
1	Bagus banget  aku tuh suka banget sama cara belajar nya duolingo, ga banyak iklan, serius, tapi bagus banget!!!!  kalian wajib donwload sihhh 	Positif
2	kenapa sih suka nge bug terus?, kalo misal udah masuk soal cerita suka gabisa dibuka... padahal sinyal bagus, hp juga oke, tolong lah di perbaiki loading di soal ceritanya biar bisa dibuka, kalo misal gabisa dibuka nantinya jadi ga maju maju dong progres nya, kalo ga maju maju progresnya, otomatis belajarnya itu itu aja.	Negatif

Setelah proses pelabelan selesai, seluruh data yang telah diberi kategori sentimen kemudian diperiksa kembali untuk memastikan konsistensi dan kesesuaian antar-penilaian. Langkah ini dilakukan agar tidak terdapat ambiguitas makna ataupun kesalahan interpretasi yang dapat memengaruhi kualitas data latih.

e. Preprocessing data

Pada tahap ini dilakukan serangkaian proses *preprocessing* untuk memastikan bahwa data teks berada dalam kondisi yang bersih dan siap digunakan pada tahap analisis lebih lanjut. Preprocessing dilakukan untuk menghilangkan noise, menyeragamkan format teks, serta menyesuaikan struktur data agar optimal ketika diproses oleh model. Adapun alur preprocessing yang digunakan dalam penelitian ini dapat dilihat pada Gambar berikut.



Gambar 6. Tahapan *preprocessing* data

1. Cleaning

Cleaning merupakan tahap awal pra-proses teks yang bertujuan untuk menghilangkan elemen-elemen yang tidak relevan atau berpotensi mengganggu, seperti URL, *mention*, karakter asing tertentu, serta spasi berlebih, tanpa mengubah struktur dan makna asli dari ulasan. Pada tahap ini pembersihan dilakukan secara selektif agar informasi penting seperti emoji, ekspresi pengguna, *slang*, dan tanda baca tetap dipertahankan agar tetap merepresentasikan ekspresi emosional yang relevan dalam analisis sentimen. Dengan demikian, *cleaning* menghasilkan teks yang lebih rapi dan konsisten tanpa menghilangkan konteks yang dibutuhkan oleh model seperti *IndoBERTweet*.

Tabel 4. Contoh hasil *cleaning* data

Contoh Data	
Data Mentah (Input)	Hasil Cleaning (Output)
Bagus banget ♡ aku tuh suka banget sama cara belajar nya duolingo, ga banyak iklan, serius, tapi bagus banget!!!! 😍 kalian wajib donwload sih hh 😊	Bagus banget ♡ aku tuh suka banget sama cara belajar nya duolingo, ga banyak iklan, serius, tapi bagus banget!!!! 😍 kalian wajib donwload sih hh 😊

2. Case Folding

Case folding dilakukan untuk menyeragamkan seluruh karakter dalam teks menjadi huruf kecil. Proses ini memastikan bahwa kata-kata dengan bentuk penulisan berbeda namun memiliki arti yang sama misalnya “Bagus” dan “bagus” diproses secara konsisten. Tahap ini menjadi dasar dalam pembersihan data sebelum masuk ke tahap normalisasi.

Tabel 5. Contoh hasil *case folding*

Contoh Data	
Data Mentah (Input)	Hasil <i>case folding</i> (Output)
Bagus banget ❤️ aku tuh suka banget sama cara belajar nya duolingo, ga banyak iklan, serius, tapi bagus banget!!!! 🥰 kalian wajib donwload sih hh 😊	bagus banget ❤️ aku tuh suka banget sama cara belajar nya duolingo, ga banyak iklan, serius, tapi bagus banget!!!! 🥰 kalian wajib donwload sih hh 😊

3. Normalization


Normalization bertujuan memperbaiki dan menyamakan bentuk kata yang tidak baku, kata gaul, singkatan, maupun kata yang salah ketik menjadi bentuk standar bahasa Indonesia. Normalisasi dilakukan secara ringan (*light normalization*), yaitu hanya pada kata-kata yang memang memiliki banyak variasi penulisan, seperti “gk/ga/nggak” menjadi satu bentuk konsisten, atau “mksh/makasih” menjadi satu bentuk yang seragam. Proses ini tidak menghilangkan *slang*, emotikon, ekspresi, atau struktur kalimat karena elemen-elemen tersebut penting bagi model *IndoBERTweet* dalam menangkap konteks sentimen.

Tabel 6. Contoh hasil *normalization*

Contoh Data	
Data Mentah (Input)	Hasil <i>normalization</i> (Output)
bagus banget ❤️ aku tuh suka banget sama cara belajar nya duolingo, ga banyak iklan, serius, tapi bagus banget!!!! 🥰 kalian wajib donwload sih hh 😊	bagus banget ❤️ aku tuh suka banget sama cara belajar nya duolingo, gak banyak iklan, serius, tapi bagus banget!!!! 🥰 kalian wajib donwload sih hh 😊

f. Klasifikasi IndoBERTweet

Adapun beberapa tahapan dalam klasifikasi sentimen menggunakan model IndoBERTweet pada penelitian ini adalah sebagai berikut.



Gambar 7. Tahapan klasifikasi IndoBERTweet

1. Penyusunan Dataset Siap Klasifikasi

Setelah melalui proses *preprocessing* dan labeling, diperoleh kumpulan ulasan pengguna yang sudah bersih dan siap digunakan sebagai masukan model. Setiap ulasan tersebut telah diberi label sentimen ke dalam dua kategori, yaitu positif dan negatif sesuai dengan kriteria yang ditetapkan peneliti. Selain itu, dilakukan pula pengecekan terhadap adanya duplikasi data serta penyesuaian format agar seluruh ulasan dan label tersimpan dalam bentuk yang konsisten dan dapat dibaca oleh sistem. Label sentimen kemudian dikonversi ke dalam bentuk numerik sehingga dapat diproses pada tahap pelatihan model.

2. Pembagian Data

Dataset yang telah tersusun kemudian dibagi menjadi dua bagian utama, yaitu data *training* dan data *testing* dengan perbandingan 80:20 dari keseluruhan data berlabel. Pembagian ini bertujuan untuk memperoleh keseimbangan antara jumlah data yang cukup besar untuk melatih model dan data yang memadai untuk menguji performa model secara objektif.

Data *training* digunakan untuk melatih model IndoBERTweet agar mampu mempelajari pola hubungan antara teks ulasan dan kategori sentimen. Sementara itu, data *testing* disisihkan dan tidak dilibatkan dalam proses pelatihan, sehingga dapat digunakan untuk menguji kemampuan model dalam memberikan prediksi terhadap data yang belum pernah dilihat sebelumnya. Hasil prediksi pada data *testing* inilah yang selanjutnya dimanfaatkan pada tahap evaluasi kinerja model.

3. Tokenizing dan Encoding dengan IndoBERTweet

Pada tahap ini, setiap ulasan pada data *training* dan *testing* diubah ke dalam bentuk token menggunakan *tokenizer* resmi IndoBERTweet. Teks ulasan dipecah menjadi satuan *subword*, kemudian ditambahkan token khusus seperti [CLS] pada awal dan [SEP] pada akhir kalimat. Selanjutnya dilakukan proses *padding* hingga panjang maksimum tertentu sehingga seluruh masukan memiliki

panjang sekuens yang seragam. Hasil *tokenizing* tersebut dikonversi menjadi vektor numerik berupa *input ids* dan *attention mask* yang menjadi representasi teks dan digunakan sebagai masukan ke dalam model IndoBERTweet.

Tabel 7. Contoh hasil *tokenizing* dan *encoding* IndoBERTweet

Text	Tokenize	Encode Token
sangat bagus tidak membuat bosan karena belajar seperti bermain game tebak tebak dan terdapat kata kata motivasi yang membuat lebih semangat	['[CLS]', 'sangat', 'bagus', 'tidak', 'membuat', 'bosan', 'karena', 'belajar', 'seperti', 'bermain', 'game', 'tebak', 'tebak', 'dan', 'terdapat', 'kata', 'kata', 'motivasi', 'yang', 'membuat', 'lebih', 'semangat', '[SEP]']	[3, 1906, 4839, 1580, 2026, 14943, 1686, 3109, 1730, 2889, 7551, 19363, 25787, 1501, 2478, 1951, 1951, 8964, 1497, 2026, 1716, 4650, 4]
woy kenapa gak bisa di download padahal memo gua banyak , and td udh seratus persen terus gak menginstal" jdi ak batalkan	['[CLS]', 'woy', 'kenapa', 'gak', 'bisa', 'di', 'download', 'padahal', 'memo', 'gua', 'banyak', ',', 'and', 'td', 'udh', 'seratus', 'persen', 'terus', 'gak', 'mengins', '##tal', '', 'jdi', 'ak', 'batalkan', '[SEP]']	[3, 10510, 5396, 7552, 1777, 1485, 12600, 3482, 11918, 7783, 1814, 16, 2316, 11866, 6138, 9799, 3056, 2402, 7552, 19975, 5090, 6, 7555, 1632, 13068, 4]

4. Pelatihan (*Fine-tuning*) Model IndoBERTweet

Model pra-latih IndoBERTweet kemudian di-*fine-tune* untuk tugas klasifikasi sentimen. Pada bagian atas arsitektur IndoBERTweet ditambahkan sebuah lapisan klasifikasi berupa *fully connected layer* dengan fungsi aktivasi *softmax* yang menghasilkan keluaran dua kelas sentimen. Proses pelatihan dilakukan dengan memasukkan pasangan data ulasan dan label sentimen dari data *training* ke dalam model, kemudian menghitung nilai *loss* menggunakan fungsi *cross-entropy*. Nilai *loss* tersebut digunakan untuk memperbarui bobot model melalui proses *backpropagation* sehingga model secara bertahap mampu memetakan representasi teks ke kelas sentimen yang tepat, dengan konfigurasi *hyperparameter* yang telah ditentukan seperti ukuran *batch*, *learning rate*, dan jumlah *epoch*.

5. Prediksi Sentimen pada Data Uji

Setelah proses pelatihan selesai dan diperoleh model IndoBERTweet terbaik, model tersebut digunakan untuk melakukan prediksi sentimen pada data *testing*. Setiap ulasan pada data *testing* terlebih dahulu melalui tahap *tokenizing* dan *encoding* yang sama, kemudian dimasukkan ke dalam model untuk menghasilkan probabilitas dan label kelas sentimen. Label prediksi yang dihasilkan pada tahap ini menjadi dasar dalam menghitung nilai metrik evaluasi, seperti akurasi maupun ukuran kinerja lainnya, yang akan dijelaskan lebih lanjut pada subbab evaluasi model.

g. Evaluasi Model

Setelah proses klasifikasi sentimen dengan model IndoBERTweet dilakukan, diperlukan tahap evaluasi untuk menilai kualitas hasil prediksi yang dihasilkan. Evaluasi ini bertujuan memberikan gambaran seberapa baik model mampu mengelompokkan ulasan ke dalam kelas sentimen yang tepat. Pada tahap ini, label prediksi yang dihasilkan model pada data *testing* dibandingkan dengan label sebenarnya, sehingga kinerja model dapat diukur secara kuantitatif.

Penilaian performa model didasarkan pada *confusion matrix*. *Confusion matrix* merupakan sebuah tabel yang menyajikan ringkasan jumlah data yang diprediksi benar ataupun salah oleh model untuk setiap kelas. Pada matriks ini, baris menunjukkan kelas sebenarnya (*actual class*), sedangkan kolom menyatakan kelas hasil prediksi (*predicted class*). Dengan cara tersebut, dapat diketahui bagaimana model membedakan suatu kelas terhadap kelas lainnya. Struktur *confusion matrix* yang digunakan dalam penelitian ini ditunjukkan pada Tabel berikut.

Tabel 8. *Confusion matrix*

		Predicted Class	
		Positive	Negative
Actual Class	Positive	True Positive (TP)	False Negative (FN)
	Negative	False Positive (FP)	True Negative (TN)

Keterangan elemen-elemen pada *confusion matrix* dinyatakan sebagai berikut:

1. *True Positive (TP)*: jumlah dokumen yang sebenarnya termasuk kelas positif dan diprediksi sebagai kelas positif oleh model.

2. *True Negative (TN)*: jumlah dokumen yang sebenarnya termasuk kelas negatif dan diprediksi sebagai kelas negatif oleh model.
3. *False Positive (FP)*: jumlah dokumen yang sebenarnya termasuk kelas negatif tetapi diprediksi sebagai kelas positif.
4. *False Negative (FN)*: jumlah dokumen yang sebenarnya termasuk kelas positif tetapi diprediksi sebagai kelas negatif.

Berdasarkan nilai TP, TN, FP, dan FN pada *confusion matrix* tersebut, kemudian dihitung beberapa metrik evaluasi, yaitu *accuracy*, *precision*, *recall*, dan *F1-score*.

Rumus perhitungan metrik-metrik tersebut adalah sebagai berikut:

1. *Accuracy* mengukur proporsi keseluruhan prediksi yang benar:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

2. *Precision* menunjukkan tingkat ketepatan model dalam memprediksi suatu kelas positif:

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

3. *Recall* menggambarkan kemampuan model dalam menemukan seluruh data yang benar-benar termasuk kelas positif:

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

4. *F1-score* merupakan rata-rata harmonik antara *precision* dan *recall* yang memberikan ukuran keseimbangan keduanya:

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (4)$$

Hasil perhitungan metrik evaluasi tersebut selanjutnya digunakan untuk menilai seberapa baik model IndoBERTweet dalam melakukan klasifikasi sentimen terhadap ulasan pengguna aplikasi Duolingo. Berdasarkan studi sebelumnya, model IndoBERTweet dapat dikatakan memiliki kinerja yang baik apabila nilai akurasi dan F1-score berada pada rentang lebih dari 0,75 (Khairani et al., 2024; Setiawan et al., 2023).


Apabila hasil evaluasi model belum mencapai batas kinerja yang ditetapkan, maka dilakukan serangkaian langkah perbaikan untuk meningkatkan performa model. Upaya perbaikan tersebut meliputi *hyperparameter tuning*, seperti penyesuaian *learning rate*, *batch size*, *dropout*, serta konfigurasi *optimizer* agar proses pembelajaran berlangsung lebih optimal. Selain itu, jumlah *epoch* disesuaikan untuk meminimalkan risiko *underfitting*.

maupun *overfitting*. Pada tahap selanjutnya, kualitas dataset berlabel ditingkatkan melalui pemeriksaan ulang label, penambahan data berlabel, serta penanganan ketidakseimbangan kelas apabila diperlukan. Proses *preprocessing* juga ditinjau kembali untuk memastikan bahwa pembersihan teks tidak menghilangkan informasi penting, terutama mengingat karakteristik ulasan pengguna yang cenderung bersifat informal. Seluruh langkah perbaikan tersebut dilakukan secara iteratif hingga model mencapai performa yang stabil dan memenuhi batas kinerja yang telah ditentukan.

h. Pemodelan Topik BERTopic

Pada penelitian ini, pemodelan topik dilakukan menggunakan metode BERTopic untuk mengidentifikasi tema-tema utama yang muncul pada ulasan pengguna. BERTopic dipilih karena mampu memanfaatkan representasi teks berbasis transformer dan mengombinasikannya dengan teknik reduksi dimensi, *clustering*, serta pembobotan kata c-TF-IDF sehingga topik yang dihasilkan cenderung lebih koheren dan mudah diinterpretasikan.

Tahapan pemodelan topik menggunakan BERTopic dalam penelitian ini adalah sebagai berikut.



Gambar 8. Tahapan pemodelan topik BERTopic

1. Penyusunan Korpus Pemodelan Topik

Data ulasan yang sudah dibersihkan pada tahap praproses digabungkan ke dalam satu korpus teks yang siap diolah oleh BERTopic. Setiap baris korpus merepresentasikan satu dokumen ulasan. Pada tahap ini, peneliti dapat menyusun korpus secara keseluruhan maupun memisahnya berdasarkan kelas sentimen, misalnya korpus khusus untuk ulasan positif dan negatif. Pemisahan ini memungkinkan analisis topik yang lebih terarah untuk masing-masing kategori sentimen.

2. Pembentukan Embedding Dokumen

Seluruh ulasan dalam korpus kemudian diubah menjadi vektor numerik berdimensi tinggi (*embedding*) menggunakan model *sentence-transformers* yang kompatibel dengan BERTopic. *Embedding* ini menangkap informasi semantik dari teks sehingga ulasan dengan makna yang mirip akan memiliki representasi vektor

yang saling berdekatan. Tahap ini menjadi dasar penting bagi proses pengelompokan ulasan ke dalam topik-topik tertentu.

3. Reduksi Dimensi (UMAP)

Embedding yang dihasilkan umumnya memiliki dimensi yang cukup besar sehingga kurang efisien untuk proses *clustering*. Oleh karena itu, BERTopic menerapkan algoritma reduksi dimensi non-linear, seperti UMAP, untuk memproyeksikan embedding berdimensi tinggi ke ruang berdimensi lebih rendah. Reduksi dimensi bertujuan mempertahankan pola kedekatan antar dokumen sembari menyederhanakan struktur datanya, sehingga proses *clustering* menjadi lebih stabil dan komputasinya lebih ringan.

4. Clustering Dokumen dengan HDBSCAN

Vektor hasil reduksi dimensi kemudian dikelompokkan menggunakan algoritma *clustering* berbasis densitas, seperti HDBSCAN. Algoritma ini mengelompokkan dokumen yang saling berdekatan di ruang vektor ke dalam satu kluster yang diinterpretasikan sebagai satu topik. Keunggulan HDBSCAN adalah kemampuannya mengidentifikasi kluster dengan ukuran yang bervariasi serta mendeteksi *noise* atau dokumen yang tidak jelas keterkaitannya dengan kluster manapun. Setiap kluster yang terbentuk pada tahap ini akan menjadi kandidat topik dalam pemodelan BERTopic.

5. Pembobotan Kata dengan c-TF-IDF

Setelah dokumen terbagi ke dalam kluster, BERTopic membangun representasi setiap topik menggunakan pendekatan *class-based Term Frequency-Inverse Document Frequency* (c-TF-IDF). Berbeda dengan TF-IDF konvensional yang bekerja pada level dokumen, c-TF-IDF memperlakukan seluruh dokumen dalam satu kluster sebagai satu “dokumen gabungan”, kemudian menghitung bobot kata pada tingkat topik. Secara umum, konsep TF-IDF dapat dituliskan sebagai berikut:

a. *Term Frequency (TF)*:

$$TF_{t,d} = \frac{f_{t,d}}{\sum_k f_{k,d}} \quad (5)$$

Di mana $f_{t,d}$ adalah jumlah kemunculan term t dalam dokumen d , dan $\sum_k f_{k,d}$ adalah total seluruh term dalam dokumen tersebut.

b. *Inverse Document Frequency (IDF)*:

$$IDF_t = \log\left(\frac{N}{df_t}\right) \quad (6)$$

Di mana N adalah jumlah seluruh dokumen dalam korpus, dan df_t adalah jumlah dokumen yang mengandung term t .

c. *TF-IDF*:

$$TF - IDF_{t,d} = TF_{t,d} \times IDF_t \quad (7)$$

Namun, pada BERTopic rumus tersebut dimodifikasi menjadi c-TF-IDF dengan mengganti dokumen individu menjadi kumpulan dokumen dalam satu topik atau klaster. Bobot c-TF-IDF untuk suatu term t pada topik/klaster c dapat dituliskan sebagai berikut:

$$cTF - IDF_{t,c} = \frac{f_{t,c}}{\sum_k f_{k,c}} \times \log\left(\frac{N}{df_t}\right) \quad (8)$$

Keterangan:

$cTF - IDF_{t,c}$ = bobot term t pada topik atau klaster c ;

$f_{t,c}$ = jumlah kemunculan term t pada seluruh dokumen yang termasuk ke dalam topik c ;

$\sum_k f_{k,c}$ = total frekuensi seluruh term k pada topik c ;

N = jumlah seluruh dokumen dalam korpus;

df_t = jumlah dokumen dalam korpus yang mengandung term t .

Nilai c-TF-IDF yang tinggi menunjukkan bahwa suatu term sering muncul dalam sebuah topik tetapi relatif jarang ditemukan pada dokumen di luar topik tersebut.

Meskipun BERTopic tidak menetapkan ambang batas khusus untuk pemilihan kata kunci, praktik umum dalam penelitian *topic modeling* adalah memilih sejumlah kata dengan bobot c-TF-IDF tertinggi sebagai representasi topik. Pendekatan ini sejalan dengan penelitian sebelumnya, seperti studi Mertayasa & Darmawan (2022) yang menggunakan 10 kata dengan bobot tertinggi pada analisis ulasan hotel, serta penelitian Wahyuni et al. (2025) yang juga menerapkan pemilihan *top-n words* berbasis c-TF-IDF dalam pemetaan isu pada komentar YouTube. Dengan demikian, penggunaan kata kunci berdasarkan bobot c-TF-IDF tertinggi merupakan praktik yang lazim dan diterima dalam penelitian yang menggunakan BERTopic.

6. Penamaan dan Interpretasi Topik

Berdasarkan daftar kata kunci hasil perhitungan c-TF-IDF dan beberapa contoh ulasan yang termasuk dalam masing-masing klaster, peneliti kemudian memberikan nama atau deskripsi singkat untuk setiap topik. Penamaan ini dilakukan dengan cara mengamati kata-kata yang paling dominan pada topik tersebut, misalnya topik yang didominasi kata terkait “iklan”, “premium”, dan “berbayar” dapat diberi label “iklan dan langganan berbayar”, sedangkan topik

yang berisi kata seperti “error”, “bug”, dan “crash” dapat diberi label “permasalahan teknis aplikasi”.

Melalui rangkaian tahapan di atas, BERTopic tidak hanya menghasilkan kumpulan topik beserta kata kunci yang merepresentasikannya, tetapi juga memberikan gambaran yang lebih terstruktur mengenai tema-tema utama yang muncul dalam ulasan pengguna. Dengan demikian, pemodelan topik ini membantu memperkaya hasil analisis terhadap ulasan dan memberikan informasi yang lebih mendalam mengenai fokus perhatian dan pengalaman pengguna terhadap aplikasi yang diteliti.

i. Visualisasi Data

Pada penelitian ini, visualisasi data dilakukan sebagai tahap akhir untuk menyajikan hasil pengolahan teks dalam bentuk yang lebih mudah dipahami secara visual. Tahap ini bertujuan untuk menampilkan pola-pola utama yang muncul pada data ulasan, seperti kata-kata yang paling sering digunakan oleh pengguna, sehingga dapat mendukung proses interpretasi dan pembahasan hasil analisis pada bab berikutnya. Visualisasi yang digunakan difokuskan pada pemanfaatan *word cloud* sebagai representasi visual dari frekuensi kemunculan kata dalam korpus ulasan.

Data yang digunakan pada tahap visualisasi merupakan data teks yang telah melalui proses praproses. Dengan demikian, kata-kata yang ditampilkan pada *word cloud* telah dibersihkan dari elemen yang tidak relevan, seperti URL, tanda baca, serta kata-kata yang dianggap tidak informatif dihilangkan agar kata kunci yang muncul benar-benar merefleksikan topik atau isu yang sering dibahas oleh pengguna.



Gambar 9. Visualisasi data menggunakan *word cloud*

Sumber : Nawulansih et al. (2025)

Melalui tahapan visualisasi data ini, hasil olahan teks tidak hanya disajikan dalam bentuk angka atau tabel, tetapi juga dalam bentuk gambar yang lebih intuitif. Hal ini diharapkan dapat membantu pembaca memahami pola dan tema utama yang terdapat dalam ulasan pengguna secara lebih cepat dan komprehensif.

DAFTAR PUSTAKA

- Abdillah, R., Haerani, E., & Candra, R. M. (2023). Analisis Sentimen Ulasan Aplikasi Wetv Untuk Peningkatan Layanan Menggunakan Metode Support Vector Machine. *Journal of Information System Research (JOSH)*, 4(3), 865–873. <https://doi.org/10.47065/josh.v4i3.3353>
- Aljabar, A., & Karomah, B. M. (2024). Mengungkap Opini Publik: Pendekatan BERT-based-caused untuk Analisis Sentimen pada Komentar Film. *Journal of System and Computer Engineering (JSCE) ISSN*, 5(1), 2723–1240. <https://doi.org/10.61628/jsce.v5i1.1060>
- Amien, M. (2023). *Sejarah dan Perkembangan Teknik Natural Language Processing (NLP) Bahasa Indonesia: Tinjauan tentang sejarah, perkembangan teknologi, dan aplikasi NLP dalam bahasa Indonesia*. <http://arxiv.org/abs/2304.02746>
- Ariansyah, A., & Indahyanti, U. (2024). Fitur Ekstraksi pada Pemodelan Topik Menggunakan Metode Latent Dirichlet Allocation pada Peristiwa Kebocoran Data. *Indonesian Journal of Applied Technology*, 1(2), 24. <https://doi.org/10.47134/ijat.v1i2.3041>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. <https://doi.org/10.48550/arXiv.1810.04805>
- Faisal, M. R., Kartini, D., Rusadi, A., Triando, A., & Saragih, H. (2022). *Belajar Data Science Text Mining Untuk Pemula I*. https://www.researchgate.net/publication/359619425_Belajar_Data_Science_Text_Mining_Untuk_Pemula_I
- Febriyanti, S., Nursidah, D. R., Gustiara, D., & Yulianti, R. (2021). Analisis Sentimen Masyarakat Indonesia Terhadap Pelaksanaan Vaksin Covid'19. *Khazanah: Jurnal Mahasiswa*, 13(2). <https://doi.org/10.20885/khazanah.vol13.iss2.art4>
- Grootendorst, M. (2022). *BERTopic: Neural topic modeling with a class-based TF-IDF procedure*. <http://arxiv.org/abs/2203.05794>
- Hakimantieq, H., Suherdi, D., & Gunawan, W. (2022). Duolingo as A Mobile-Assisted Language Learning: A New Supplementary of Learning Basic English Reading for EFL Students. *EDUKATIF: JURNAL ILMU PENDIDIKAN*, 4(6), 7548–7558. <https://doi.org/10.31004/edukatif.v4i6.4104>
- Handayani, V., & Damayanti, I. (2022). Mobile-Assisted Language Learning for Vocabulary Development: Insights from Indonesian Pre-Service English Teachers Using HelloTalk. *Jurnal Tahuri*, 19(2), 99–114. <https://doi.org/10.30598/tahurivol19issue2page99-114>

- Mertayasa, I. K. T., & Darmawan, I. D. M. B. A. (2022). Pemodelan Topik Pada Ulasan Hotel Menggunakan Metode BERTopic Dengan Prosedur c-TF-IDF. *Jurnal Nasional Teknologi Informasi Dan Aplikasinya*, 1(1), 307–316. <https://doi.org/10.24843/JNATIA.2022.v01.i01.p37>
- Khairani, U., Mutiawani, V., & Ahmadian, H. (2024). Pengaruh Tahapan Preprocessing Terhadap Model Indobert Dan Indobertweet Untuk Mendeteksi Emosi Pada Komentar Akun Berita Instagram. *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 11(4), 887–894. <https://doi.org/10.25126/jtiik.1148315>
- Koto, F., Han Lau, J., & Timothy, B. (2021). *INDOBERTWEET: A Pretrained Language Model for Indonesian Twitter with Effective Domain-Specific Vocabulary Initialization*. <https://doi.org/10.18653/v1/2021.emnlp-main.833>
- Kusuma, T. B., & Mogi, I. K. A. (2023). Implementasi BERT pada Analisis Sentimen Ulasan Destinasi Wisata Bali. *JELIKU (Jurnal Elektronik Ilmu Komputer Udayana)*, 12(2), 409–420. <https://doi.org/10.24843/JLK.2023.v12.i02.p19>
- Nawulansih, D. F., Santi, N. C., & Sa'ida, I. A. (2025). Analisis Sentimen Ulasan Aplikasi DANA di Google Play Store: Penerapan Support Vector Machine dan Synthetic Minority Over-sampling Technique. *Jurnal Pendidikan Dan Teknologi Indonesia*, 5(9), 2660–2671. <https://doi.org/10.52436/1.jpti.1053>
- Pradana, M. G. (2020). Penggunaan Fitur Wordcloud Dan Document Term Matrix Dalam Text Mining. *Jurnal Ilmiah Informatika (JIF)*, 8(01), 38–43. <https://doi.org/10.33884/jif.v8i01.1838>
- Pradipta, D., & Widodo, E. (2024). Sentiment Analysis on Social Media using Bidirectional Encoder from Transformers (Case Study : Covid-19 Omicron). *INFORMASI (Jurnal Informatika Dan Sistem Informasi)*, 16(2). <https://ojs.stmik-im.ac.id/index.php/INFORMASI/article/download/319/107>
- Rahman, A., Rahman, A., Sholehatin, D., Sugianti, I. R., Musfiroh, Permatasari, U. O. R., & Hasanah, U. (2022). Data Visualisasi Pada Website Layanan Pengadaan Secara Elektronik (LPSE) Menggunakan Metode Web Scraping. *Seminar Nasional Hi-Tech (Health, Humanity, Technology)*, 1(1). <https://ejournal.unuja.ac.id/index.php/hitech/article/view/4418>
- Rahmawati, W. T., Harahap, Y. M., Ginting, R., Anggraini, P. R., Maulana, A. A., & Artikel, S. (2023). Pengenalan Mobile Assisted Language Learning (MALL) untuk Berlatih Pronunciation Informasi Artikel Abstrak. *JOURNAL OF*

- TRAINING AND COMMUNITY SERVICE ADPERTISI (JTCSA)*, 3(2), 50–56.
<https://doi.org/10.62728/jtcsa.v3i2.454>
- Rivaldi, R. C., & Wismarini, T. D. (2024). Analisis Sentimen Pada Ulasan Produk Dengan Metode Natural Language Processing (NLP) (Studi Kasus Zalika Store 88 Shopee). *Elkom: Jurnal Elektronika Dan Komputer*, 17(1), 120–128.
<https://doi.org/10.51903/elkom.v17i1.1680>
- Puspita, S. D., Amanda, S. L., Swara, V. N., & Shaffa, Z. A. (2025). Pemanfaatan Aplikasi Duolingo dalam Meningkatkan Penguasaan Kosakata Bahasa Inggris. *Lencana: Jurnal Inovasi Ilmu Pendidikan*, 3(2), 168–178.
<https://doi.org/10.55606/lencana.v3i2.5030>
- Salsabila, T., Nafilah, N., Patangga, F., Zulfa, S., & Listyaningsih, N. (2024). Literature Review: Efektivitas Penggunaan Aplikasi Duolingo Terhadap Motivasi Belajar Bahasa Inggris. *Jurnal Empati*, 13(4), 302–312.
<https://doi.org/10.14710/empati.2024.46691>
- Setiawan, J. C., M. Lhaksmana, K., & Bunyamin, B. (2023). Sentiment Analysis of Indonesian TikTok Review Using LSTM and IndoBERTweet Algorithm. *JUPI (Jurnal Ilmiah Penelitian Dan Pembelajaran Informatika)*, 8(3), 774–780.
<https://doi.org/10.29100/jupi.v8i3.3911>
- Simanjuntak, K. A., Koyimatu, M., & Ervanisari, Y. P. (2024). Analisis Perubahan Opini Publik Terhadap Kendaraan Listrik di Indonesia Melalui Komentar YouTube: Pendekatan Topic Modeling BERTopic. *Jurnal Inovasi Kewirausahaan*, 1(3), 1–9.
<https://doi.org/10.37817/jurnalinovasikewirausahaan.v1i3>
- Suryati, N. W. N., Dewi, K. M. C., Rusanti, P., & Wismadewi, I. G. A. G. (2024). Penggunaan Mobile Assisted Language Learning (MALL) pada Pembelajaran Bahasa Inggris Keperawatan. *EDUKATIF: JURNAL ILMU PENDIDIKAN*, 6(4), 4008–4017. <https://doi.org/10.31004/edukatif.v6i4.7255>
- Wahyuni, W., Lestari, T. P., Apriliana, M., & Gumelta, R. (2025). Implementation of BERTopic for Topic Modeling Analysis of the Free Nutritious Meal Program Based on YouTube Comments. *Journal of Applied Informatics and Computing (JAIC)*, 9(4), 2548–6861. <https://doi.org/10.30871/jaic.v9i4.9754>
- Wibowo, J. A., Mawardi, V. C., & Sutrisno, T. (2024). Visualisasi Word Cloud Hasil Analisis Sentimen Berbasis Fitur Layanan Aplikasi Gojek Dengan Support Vector Machine. *Jurnal Serina Sains, Teknik Dan Kedokteran*, 2(1), 61–70.
<https://doi.org/10.24912/jsstk.v2i1.32058>
- Yuwono, D. P., Santoso, I. B., & Kusumawati, R. (2024). Pemetaan Sentimen Masyarakat Terhadap Pilpres 2024 Dengan Algoritma Self-Organizing Map.

Jurnal Review Pendidikan Dan Pengajaran, 7(3), 7518–7523.
<https://doi.org/10.31004/jrpp.v7i3.28830>