

USULAN PENELITIAN

**PENERAPAN MODEL LSTM DAN ANALISIS SENTIMEN
UNTUK PREDIKSI HARGA PENUTUPAN SAHAM PT
BANK MANDIRI (PERSERO) Tbk**



Imelda Agustin

F1E122002

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI**

2025

USULAN PENELITIAN

PENERAPAN MODEL LSTM DAN ANALISIS SENTIMEN UNTUK PREDIKSI HARGA PENUTUPAN SAHAM PT BANK MANDIRI (PERSERO) Tbk

Diajukan sebagai salah satu syarat dalam melakukan penelitian dalam rangka
penulisan Skripsi pada Program Studi Sistem Informasi



Imelda Agustin

F1E122002

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI
2025**

HALAMAN PENGESAHAN
USULAN PENELITIAN

**PENERAPAN MODEL LSTM DAN ANALISIS SENTIMEN UNTUK PREDIKSI
HARGA PENUTUPAN SAHAM PT BANK MANDIRI (PERSERO) Tbk**

Oleh:
IMELDA AGUSTIN
FIE122002

Disetujui:

Pembimbing Utama

Pembimbing Pendamping

Ulfa Khaira, S. Komp., M.Kom.
NIP. 198912292019032018

Mutia Fadhila Putri, M.Kom.
NIP. 199612162022032016

Diketahui:

Dekan

Ketua Jurusan

Drs. Jefri Marzal, M.Sc., D.I.T.
NIP. 196806021993031004

Edi Saputra, ST, M.Sc.
NIP. 198501082015041003

DAFTAR ISI

HALAMAN PENGESAHAN	i
DAFTAR ISI.....	ii
DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
I. PENDAHULUAN.....	1
1.1 Latar Belakang Masalah.....	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian.....	4
1.4 Manfaat Penelitian	4
1.5 Ruang Lingkup Penelitian	4
1.6 Batasan Masalah	5
II. TINJAUAN PUSTAKA.....	6
2.1. Pasar Modal dan Saham	6
2.2. PT. Bank Mandiri Tbk.....	6
2.3. Deep Learning.....	8
2.4. Long Short-Term Memory (LSTM).....	10
2.5. <i>Text Mining</i>	15
2.6. Analisis Sentimen	16
2.7. <i>Lexicon-Based</i>	18
2.8. <i>InSet Lexicon</i>	20
2.9. Metrik Performa	22
2.10. Penelitian Terdahulu.....	23
III. METODE PENELITIAN	28
3.1. Tempat dan Waktu Penelitian	28
3.2. Perangkat Penelitian	28
3.3. Tahapan Penelitian	29
DAFTAR PUSTAKA.....	50

DAFTAR GAMBAR

Gambar 1. Pertumbuhan dan profitabilitas Bank Mandiri	7
Gambar 2. Riwayat dividen BMRI.....	7
Gambar 3. Fluktuasi harga saham BMRI	8
Gambar 4. Ilustrasi struktur <i>Deep Learning</i>	9
Gambar 5. <i>Neuron</i> pada LSTM	10
Gambar 6. Struktur dalam satu sel LSTM	11
Gambar 7. <i>Memory Cell</i>	11
Gambar 8. Lapisan <i>Sigmoid</i>	12
Gambar 9. Alur <i>Forget Gate</i> pada LSTM	12
Gambar 10. Alur <i>Input Gate</i> pada LSTM	13
Gambar 11. Alur memperbaharui <i>Cell State</i> pada LSTM	14
Gambar 12. Alur <i>Output</i> pada LSTM	14
Gambar 13. Tahapan penelitian.....	29
Gambar 14. Pengumpulan data historis dari Yahoo Finance	30
Gambar 15. Pengumpulan data sentimen dari Bisnis.Com	31
Gambar 16. Tahapan <i>Preprocessing</i> Data	31
Gambar 17. <i>Graphical User Interface</i> awalan prediksi saham	48
Gambar 18. <i>Graphical User Interface</i> hasil penggabungan data.....	48
Gambar 19. <i>Graphical User Interface</i> hasil prediksi	49

DAFTAR TABEL

Tabel 1. Penelitian terdahulu	24
Tabel 2. Data historis mentah periode Oktober 2025	32
Tabel 3. Hasil cleaning data sentimen headline berita	33
Tabel 4. Hasil proses tokenisasi data	33
Tabel 5. Hasil proses filtering data	34
Tabel 6. Hasil proses stemming data	35
Tabel 7. Contoh Dictionary InSet Lexicon	36
Tabel 8. Hasil kalkulasi polaritas	36
Tabel 9. Hasil klasifikasi sentimen	37
Tabel 10. Menyatukan data historis saham dengan data headline berita	38
Tabel 12. Nilai perhitungan Gate LSTM pada 1 Oktober 2025	44
Tabel 13. Nilai hasil prediksi	45

I. PENDAHULUAN

1.1 Latar Belakang Masalah

Pasar modal merupakan salah satu pilar penting dalam sistem keuangan modern karena menyediakan sarana distribusi dana dari pihak yang memiliki *surplus* kepada pihak yang membutuhkan modal untuk ekspansi bisnis. Pasar Modal (*capital market*) pada prinsipnya merupakan pasar sekuritas jangka panjang baik berbentuk hutang maupun ekuitas serta berbagai produk turunannya (Mahendra, 2022). Bentuk efek dari pasar modal, salah satunya adalah perdagangan saham. Saham dapat didefinisikan sebagai tanda atau pemilikan seseorang atau badan dalam suatu perusahaan atau perseroan terbatas (Mokosolang et al., 2022). Menurut data PT Bursa Efek Indonesia (BEI), jumlah investor saham pada September 2024 mencapai 6 juta single investor identification (SID) atau lebih tepatnya 6.001.573 SID.

Di antara berbagai saham yang diperdagangkan, PT Bank Mandiri Tbk (BMRI) menjadi salah satu emiten yang paling menarik perhatian karena stabilitas kinerja dan posisinya sebagai bank terbesar di Indonesia. Fauzi (2025), menjelaskan bahwa Bank Mandiri mencatatkan total aset konsolidasi mencapai Rp 2.427 triliun dengan pertumbuhan 11,6% YoY (*year on year*) dan didorong oleh ekspansi kredit yang merata serta transformasi digital. Berdasarkan laporan keuangan September 2025, BMRI mencatatkan laba bersih naik 1,84 persen secara bulanan atau *month on month* (MoM) menjadi Rp 4,14 triliun (Bank Mandiri, 2025). Kinerja positif dan fundamental yang kuat ini menunjukkan daya tarik tinggi saham BMRI di pasar modal, sekaligus menjadikannya objek yang relevan untuk penelitian terkait prediksi harga saham.

Pergerakan harga saham dipengaruhi oleh berbagai faktor, baik internal maupun eksternal, sehingga menciptakan dinamika pasar yang kompleks. Oleh karena itu, memahami pola pergerakan harga saham menjadi isu penting dalam pengambilan keputusan investasi. Terdapat tiga jenis analisis yang dapat digunakan untuk pengambilan keputusan investasi saham yaitu analisis fundamental, analisis teknikal, dan bandarmology (Rasyid et al., 2025). Di antara ketiganya, analisis teknikal menjadi pendekatan yang paling banyak digunakan karena menekankan pada pola pergerakan harga dan volume secara historis, berbeda dengan analisis fundamental yang membutuhkan data keuangan yang lebih mendalam (Iqbal & Ningsih, 2021). Melalui grafik harga dan indikator pasar, analisis teknikal membantu investor mengidentifikasi pola dan tren serta memberikan sinyal ketika terjadi suatu perubahan situasional (Herlambang et

al., 2024). Pola dan tren yang terbentuk dari data historis tersebut memberikan dasar pemahaman yang lebih objektif terhadap dinamika pergerakan pasar.

Pola dan tren yang terbentuk dari data historis tidak hanya membantu memahami dinamika pasar, tetapi juga menjadi dasar dalam melakukan prediksi pergerakan harga saham. Prediksi atau *forecasting* merupakan proses memperkirakan kondisi atau peristiwa yang akan terjadi di masa mendatang dengan memanfaatkan informasi relevan dari periode sebelumnya melalui penerapan metode yang bersifat ilmiah dan terstruktur (Rahayu et al., 2023). Salah satu metode yang dapat digunakan dalam analisis prediksi adalah metode *Long Short-Term Memory* (LSTM). LSTM merupakan pengembangan dari RNN (*Reccurent Neural Network*) yang mampu mengekstraksi informasi pada data jangka panjang, khususnya data yang bersifat *time series* atau sekuensial (Julian & Pribadi, 2021). LSTM memiliki kemampuan untuk mengingat informasi jangka panjang dari data historis dan dapat digunakan untuk membuat prediksi berdasarkan urutan waktu (Silalahi & Muljono, 2024).

Penelitian Julian & Pribadi (2021), menunjukkan bahwa metode *Long Short-Term Memory* (LSTM), mampu memberikan hasil prediksi yang lebih akurat. Hal ini terlihat dari penurunan nilai Root Mean Square Error (RMSE) pada saham ANTM dari 54,84 pada epoch 50 menjadi 40,14 pada epoch 200, pada saham TINS dari 40,73 menjadi 31,76, serta pada saham INCO dari 139,67 menjadi 111,47, yang menandakan peningkatan akurasi seiring bertambahnya proses pelatihan model. Temuan tersebut memperkuat alasan mengapa metode LSTM semakin luas diadopsi dalam riset pasar modal modern. Selain itu, studi oleh Pratama & Zahara (2024), menunjukkan bahwa LSTM dapat menghasilkan nilai akurasi yang sangat tinggi pada saham BBNI dan BBRI, ditunjukkan melalui nilai MAE yang rendah, masing-masing sebesar 0,014984 dan 0,014066. Dengan kemampuan tersebut, LSTM menjadi salah satu model yang paling banyak diadopsi dalam prediksi harga saham karena mampu mengatasi keterbatasan metode tradisional dan memberikan hasil yang lebih stabil.

Selain data historis, faktor psikologis seperti sentimen investor ataupun masyarakat turut berpengaruh terhadap pergerakan harga saham dalam jangka pendek. Informasi dari berita, media sosial, dan ulasan publik dapat membentuk persepsi pasar dan memengaruhi keputusan investasi. Salah satu pendekatan yang dapat digunakan dalam menganalisis sentimen ialah pendekatan *lexicon-based*, yang menggunakan *dictionary* atau kamus yang telah memuat nilai polaritas (positif, negatif) untuk penilaian pada kata-kata (Undap et al., 2021). Pendekatan *lexicon-based* dapat memanfaatkan *InSet Lexicon*, yaitu kamus yang

berisi kumpulan kata-kata dalam bahasa Indonesia beserta nilai sentimennya untuk keperluan analisis sentimen. Penelitian terbaru oleh Yuliasuti et al., (2024) menunjukkan bahwa pendekatan *InSet-Lexicon* mampu mencapai tingkat akurasi sebesar 93,16% dalam klasifikasi sentimen masyarakat terhadap isu kenaikan harga BBM dan Difyah et al., (2025) menegaskan bahwa metode *lexicon-based* efektif menganalisis sentimen publik di media sosial karena mampu memetakan persepsi secara kuantitatif tanpa pelatihan model. Temuan ini memperkuat dasar penggunaan *InSet Lexicon* sebagai metode analisis sentimen yang efisien, terutama ketika diintegrasikan dengan LSTM untuk meningkatkan akurasi prediksi.

Integrasi model LSTM dengan fitur sentimen telah menjadi tren riset yang menunjukkan performa prediksi lebih unggul. Studi oleh Nkongolo et al (2025), menunjukkan bahwa model LSTM berbasis sentimen mencapai akurasi 89,6% pada pasar saham India dan lebih unggul dibanding model tanpa sentimen. Penelitian lain yang menggabungkan analisis sentimen dengan LSTM menghasilkan prediksi lebih baik dibanding model tradisional, yang artinya sentimen investor terbukti berpengaruh besar terhadap perubahan harga saham Tesla (Rupadevi & Nadheem, 2025). Temuan serupa ditunjukkan pada aset Bitcoin, di mana performa LSTM meningkat setelah mengintegrasikan sentimen media sosial (Arisandi et al., 2020; A. F. Pratama et al., 2023). Sentimen publik telah banyak digunakan sebagai variabel tambahan dalam model prediksi pasar, meskipun tingkat pengaruhnya dapat berbeda-beda.

Harga saham yang fluktuatif sering kali dikaitkan dengan sentimen publik, sehingga diperlukan penelitian untuk membuktikan apakah benar sentimen publik mempengaruhi harga saham. Meskipun berbagai penelitian sebelumnya telah membuktikan efektivitas LSTM dalam memprediksi harga saham yang fluktuatif dan beberapa studi lain mengintegrasikan fitur sentimen untuk meningkatkan akurasi model, namun penelitian yang secara khusus menggabungkan analisis sentimen berbasis *lexicon* dengan model LSTM pada saham sektor perbankan, khususnya BMRI, masih sangat terbatas. Selain itu, sebagian besar penelitian sentimen lebih banyak menggunakan data media sosial seperti Twitter, sehingga pemanfaatan *headline* berita nasional sebagai sumber sentimen belum banyak dieksplorasi dalam konteks prediksi harga saham. Hal ini membuka ruang bagi penelitian yang menilai efektivitas penggabungan sentimen berbasis *headline* berita nasional dengan model LSTM pada prediksi harga penutupan saham BMRI.

Berdasarkan uraian diatas, penelitian ini akan berfokus bagaimana pengaruh sentimen publik terhadap tingkat akurasi prediksi harga penutupan saham BMRI. Perbedaan penelitian yang akan dilakukan dengan penelitian sebelumnya adalah terletak pada metode dan objek penelitian. Penelitian ini menggunakan metode *lexicon-based* dengan *InSet Lexicon* untuk melakukan analisis sentimen pada *headline* berita nasional, sementara data historis saham BMRI digunakan sebagai dataset utama dalam pemodelan. Pendekatan ini diharapkan tidak hanya menghasilkan model yang lebih andal, tetapi juga memungkinkan analisis yang lebih komprehensif terkait keterkaitan antara sentimen publik dan dinamika harga saham. Dengan demikian, penelitian ini memiliki relevansi akademis dalam pengembangan model prediksi berbasis sentimen serta nilai praktis bagi pengambilan keputusan investasi yang lebih informatif dan berbasis data.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang dijelaskan, rumusan masalah yang akan dibahas dalam penelitian ini adalah sebagai berikut:

1. Bagaimana model LSTM dapat memberikan hasil prediksi terhadap harga penutupan saham BMRI?
2. Bagaimana pengaruh integrasi analisis sentimen publik terhadap peningkatan akurasi model LSTM dalam memprediksi harga penutupan saham BMRI?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Mengimplementasikan model LSTM dalam memprediksi harga penutupan saham BMRI.
2. Membandingkan hasil prediksi harga saham yang dihasilkan model LSTM dengan integrasi analisis sentimen publik terhadap hasil prediksi harga penutupan saham BMRI.

1.4 Manfaat Penelitian

Penelitian ini berkontribusi pada pengembangan ilmu pengetahuan khususnya dalam bidang analisis sentimen dan prediksi harga saham menggunakan model *deep learning*, menambah wawasan dan literatur terkait penerapan metode *Long Short-Term Memory* (LSTM) dan analisis sentimen pasar dalam analisis prediksi harga saham, serta kontribusinya dalam bidang sistem informasi dan pengambilan keputusan investasi.

1.5 Ruang Lingkup Penelitian

Ruang lingkup penelitian ini mencakup:

1. Penelitian difokuskan pada prediksi harga penutupan saham PT Bank Mandiri (BMRI) menggunakan metode *Long Short-Term Memory* (LSTM) yang dikombinasikan dengan analisis sentimen publik berbasis *Lexicon* dengan memanfaatkan *InSet Lexicon*.
2. Data yang digunakan mencakup data historis penutupan harga saham PT Bank Mandiri (BMRI) serta data sentimen pasar yang diperoleh dari *headline* berita daring selama periode penelitian sebagai dasar dalam melakukan analisis dan prediksi harga saham
3. Penelitian ini hanya menggunakan data harga saham BMRI yang tercatat di *Yahoo Finance* serta data sentimen berupa *headline* berita nasional, tanpa membahas faktor fundamental lain seperti kebijakan moneter, inflasi, atau kondisi ekonomi global.

1.6 Batasan Masalah

Batasan masalah dalam penelitian ini meliputi:

1. Penelitian ini hanya memprediksi harga penutupan (*closing price*) saham BMRI sebagai *output* model, sementara harga pembukaan, tertinggi, terendah, dan volume transaksi tetap digunakan sebagai fitur *input* untuk mendukung proses pemodelan.
2. Data historis harga saham BMRI dan data sentimen diperoleh dari *headline* berita nasional dalam rentang waktu November 2024 hingga November 2025.
3. Analisis sentimen dilakukan menggunakan pendekatan *lexicon-based* dengan memanfaatkan *InSet Lexicon* sebagai kamus sentimen utama.
4. Model prediksi yang digunakan dibatasi pada metode *Long Short-Term Memory* (LSTM) tanpa membandingkannya dengan model *deep learning* atau metode prediksi lainnya.
5. Evaluasi performa model hanya menggunakan tiga metrik, yaitu *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan *Mean Absolute Percentage Error* (MAPE).

II. TINJAUAN PUSTAKA

2.1. Pasar Modal dan Saham

Pasar modal (*Capital market*) adalah pasar keuangan yang mempertemukan pemilik dana dengan pengguna dana untuk tujuan investasi jangka menengah (*middle-term investment*) dan jangka panjang (*long-term investment*) (Sholikah et al., 2022). Pasar modal di Indonesia memiliki fungsi ekonomi sebagai pengalokasi dana dari pihak yang kelebihan modal kepada emiten dan fungsi keuangan yang memberikan peluang imbal hasil kepada investor sesuai karakter investasinya, sehingga kedua fungsi tersebut berjalan simultan dalam mendukung aktivitas investasi dan pendanaan (Mardiyati & Rosalina, 2013). Dengan adanya kedua fungsi tersebut, pasar modal berperan penting dalam mendukung aktivitas pendanaan perusahaan, pertumbuhan ekonomi, serta pembentukan harga (*price discovery*) berdasarkan informasi pasar.

Instrumen keuangan yang diperdagangkan di pasar modal merupakan instrumen jangka panjang (jangka waktu lebih dari satu tahun) seperti saham, obligasi, *waran*, *right*, reksadana, dan berbagai instrumen *derivatif* seperti *option*, *futures*, dan lain-lain (Tarigan, 2013). Di antara berbagai instrumen tersebut, saham menjadi instrumen yang cukup diminati karena memberikan hak kepemilikan suatu perusahaan sekaligus peluang memperoleh keuntungan melalui dividen maupun *capital gain*. Saham didefinisikan sebagai dokumen atau surat berharga yang membuktikan kepemilikan suatu perusahaan (Sirait et al., 2024). Harga saham sangat dipengaruhi oleh kondisi fundamental perusahaan, faktor ekonomi makro, dan pergerakan teknikal. Selain itu, berbagai penelitian terbaru menunjukkan bahwa dinamika harga saham di pasar modal juga dipengaruhi oleh sentimen pasar, berita, dan interaksi pengguna media sosial, dan menunjukkan akurasi yang lebih baik terhadap prediksi harga saham (Adisurya & Rizkinia, 2024; Sina & Setiawan, 2023).

2.2. PT. Bank Mandiri Tbk

PT Bank Mandiri (Persero) Tbk didirikan pada 2 Oktober 1998 sebagai bagian dari program restrukturisasi perbankan nasional pasca krisis moneter 1998. Pada Juli 1999, pemerintah menggabungkan empat bank milik negara, Bank Bumi Daya, Bank Dagang Negara, Bank Ekspor Impor Indonesia, dan Bank Pembangunan Indonesia ke dalam satu entitas bernama Bank Mandiri. Konsolidasi besar ini bertujuan membentuk institusi perbankan yang lebih kuat, efisien, dan mampu bersaing dalam menghadapi tantangan ekonomi domestik maupun global. Sejak saat itu, Bank Mandiri berkembang menjadi bank terbesar

di Indonesia dari sisi aset, memiliki peran strategis dalam perekonomian nasional, serta menjadi salah satu saham unggulan di sektor perbankan (Bank Mandiri, 2024).

Pertumbuhan dan Profitabilitas >

Kinerja dan marjin perusahaan terkini




Gambar 1. Pertumbuhan dan profitabilitas Bank Mandiri

Sumber: TradingView

Dari sisi kinerja keuangan, Bank Mandiri menunjukkan pertumbuhan yang konsisten. Pada kuartal I tahun 2025, Bank Mandiri mencatat laba bersih sebesar Rp13,2 triliun, meningkat 3,9% dibandingkan periode yang sama pada tahun sebelumnya (Kontan, 2025). Selain itu, total pendapatan Bank Mandiri pada kuartal III tahun 2025 mencapai Rp50,21 triliun, dan total aset tumbuh menjadi Rp2.563,74 triliun secara *year-on-year*, meningkat 10,30% dari periode sebelumnya (TradingView, 2025). Dari perspektif investasi, saham BMRI dikenal sebagai salah satu saham *blue chip* yang secara konsisten membagikan *dividen* setiap tahunnya. Tidak hanya rutin, nilai *dividen* per saham BMRI juga menunjukkan tren peningkatan dari tahun ke tahun.

Riwayat dividen ?



Gambar 2. Riwayat dividen BMRI

Sumber: TradingView



Gambar 3. Fluktuasi harga saham BMRI

Sumber: TradingView

Reputasi Bank Mandiri juga diperkuat oleh berbagai penghargaan internasional. Pada tahun 2025, Bank Mandiri kembali meraih predikat Best Bank in Indonesia melalui Euromoney Awards for Excellence, sebuah penghargaan yang berhasil dipertahankan selama tiga tahun berturut-turut, Global Finance juga menganugerahi Bank Mandiri sebagai Best Bank in Indonesia dalam ajang World's Best Bank Awards 2025, menegaskan posisi Bank Mandiri sebagai bank dengan kinerja dan inovasi terdepan di Indonesia (Bank Mandiri, 2025). Prestasi ini menunjukkan pengakuan global terhadap stabilitas, kualitas layanan, dan penguatan transformasi digital Bank Mandiri.


Kinerja fundamental yang kuat menjadikan BMRI sebagai salah satu saham yang paling diperhatikan oleh investor di Indonesia. Selain itu, pergerakan harga saham BMRI juga menunjukkan fluktuasi yang signifikan dari waktu ke waktu, dipengaruhi oleh kondisi makroekonomi, kebijakan moneter, serta dinamika sentimen pasar. Kombinasi antara indikator fundamental yang kokoh dan volatilitas harga yang mencerminkan respons pasar tersebut menjadikan BMRI objek yang sangat relevan untuk dianalisis menggunakan pendekatan prediksi harga berbasis data historis, serta analisis sentimen yang menangkap persepsi pasar secara real time. Dengan karakteristik data yang memadai dan eksposur informasi yang luas, BMRI menjadi objek yang tepat untuk menguji kinerja model prediksi harga saham berbasis LSTM dan analisis sentimen. Selain itu, ketersediaan data BMRI yang konsisten dan mudah diakses turut mendukung proses penelitian agar dapat dilakukan secara lebih mendalam dan terstruktur.

2.3. Deep Learning

Deep Learning merupakan cabang dari kecerdasan buatan yang memungkinkan sistem komputer belajar dari data dalam jumlah besar dan membuat prediksi yang akurat (Mawarsari & Wardani, 2022). *Deep learning* memiliki beberapa keunggulan, yaitu mampu mengekstraksi fitur secara

otomatis, bekerja efektif pada data tidak terstruktur seperti teks dan gambar, mendukung proses pembelajaran end-to-end, serta tetap stabil dan akurat meski digunakan pada dataset berukuran besar (Ahmed et al., 2023). Pendekatan ini sangat populer dan terbukti efektif untuk berbagai kebutuhan prediksi di beragam bidang, seperti keuangan, kesehatan, pemasaran, hingga cuaca. Deep learning juga menawarkan fleksibilitas dan skalabilitas dalam memproses berbagai jenis data, termasuk data struktural, semi-struktural, dan tidak terstruktur (Wahyuzi, 2024).

Deep Learning merupakan salah satu bidang dari *Machine Learning* untuk menyelesaikan permasalahan dengan dataset yang besar yang memanfaatkan jaringan syaraf tiruan (Syafa'ah & Lestandy, 2021). *Deep learning* dibangun berdasarkan *neural networks*, yang terdiri dari serangkaian node atau "*neuron*" yang dihubungkan dalam beberapa lapisan: lapisan *input*, lapisan tersembunyi (*hidden layers*), dan lapisan *output* (Tarumingkeng, 2024). Gambar 4 merepresentasikan visual struktur *deep learning* yang terdiri dari 3 lapisan.



Gambar 4. Ilustrasi struktur *Deep Learning*


Sumber: (Syafa'ah & Lestandy, 2021)

Gambar 4 menunjukkan arsitektur jaringan *deep learning* yang terdiri dari tiga bagian utama. *Input layer* sebagai penerima data, *hidden layer* yang memproses dan mengekstraksi pola melalui koneksi antar-*neuron*, serta *output layer* yang menghasilkan prediksi akhir. Kemampuan *deep learning* untuk mengekstraksi informasi dari data yang sangat besar dan tidak terstruktur menjadikannya teknologi yang unggul dalam mengatasi tantangan-tantangan kompleks, yang sebelumnya sulit dipecahkan (Tarumingkeng, 2024). Kemampuan ini membuat *deep learning* semakin relevan digunakan dalam berbagai kebutuhan analisis modern salah satunya prediksi. *Deep learning* menyediakan pendekatan prediksi yang kuat dan adaptif, karena mampu mengolah data yang kompleks dan berstruktur tinggi, sehingga bisa menjadi pilihan utama dalam beragam aplikasi prediksi yang memerlukan tingkat akurasi

tinggi dan pemodelan yang lebih mendalam. Ini membuka peluang baru untuk inovasi dan pengembangan di berbagai sektor, memungkinkan pengambilan keputusan yang lebih baik dan lebih tepat waktu berdasarkan wawasan yang diperoleh dari data (Lim & Zohren, 2021).

2.4. Long Short-Term Memory (LSTM)

Algoritma LSTM ditemukan oleh Hochreiter dan Schmidhuber pada tahun 1997 (Kiramy et al., 2024). LSTM merupakan pengembangan dari model RNN, perkembangan ini bertujuan untuk memecahkan masalah utama yang dihadapi oleh jaringan saraf rekurensi RNN konvensional, khususnya menangani informasi jangka panjang dalam data urutan (Sujjada et al., 2024). Hal yang membedakan LSTM dengan RNN biasa adalah LSTM mampu mempelajari informasi mana yang harus dibuang dan informasi mana yang harus tetap disimpan dalam *memory cell* (Andiyantama et al., 2021). Kemampuan ini didapat dari struktur *neuron* LSTM yang berbeda dengan *neuron* RNN biasa, yang mana setiap *neuron* LSTM memiliki *memory cell* dan *gate units*.



Gambar 5. Neuron pada LSTM

Sumber: (Andiyantama et al., 2021)

Keunggulan dalam model LSTM adalah kemampuannya untuk "mengingat" informasi dalam jangka waktu yang lama, yang memungkinkan model menangkap pola kompleks dalam data historis, mampu mengatasi *gradient* yang hilang dengan menggunakan mekanisme gates dan LSTM mampu mengontrol aliran informasi dalam jaringan, yang memungkinkan pengolahan informasi jangka panjang tanpa kehilangan informasi pada urutan waktu yang lama (Sujjada et al., 2024). Struktur LSTM terdiri dari tiga gerbang: gerbang masukan (*input gate*), gerbang lupakan (*forget gate*), dan gerbang keluaran (*output gate*). Gerbang masukan mengontrol jumlah informasi yang disimpan dalam memori jangka panjang, gerbang lupakan menentukan seberapa banyak informasi yang dihapus, dan gerbang keluaran mengatur berapa banyak informasi yang dikeluarkan dari memori jangka panjang (Kiramy et al., 2024).

Pada setiap sel memori, tiga lapisan *sigmoid* dan satu lapisan *tanh* hadir (Qiu et al., 2020). Fungsi *sigmoid* dapat dilihat pada persamaan berikut (Ma et al., 2015).

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1)$$


Fungsi *tanh* dapat dilihat sebagai berikut:

$$\tanh(x) = 2\sigma(2x) - 1 \quad (2)$$

Keterangan:

σ = Fungsi aktivasi *sigmoid*


x = Data input



Gambar 6. Struktur dalam satu sel LSTM

Sumber: (Qiu et al., 2020)


Gambar 6 menunjukkan struktur di dalam satu sel LSTM, di mana inti arsitekturnya terletak pada jalur yang menghubungkan sel memori sebelumnya (C_{t-1}) dengan sel memori saat ini (C_t). Garis horizontal yang menghubungkan seluruh lapisan *output* merepresentasikan sel memori tersebut. Dengan upaya yang minimal, nilai sel memori lama dapat ditransfer ke sel memori baru menggunakan jalur ini (Firdaus, 2022).



Gambar 7. Memory Cell

Sumber: (Colah, 2015)


LSTM dapat menghapus maupun menambahkan informasi pada sel melalui mekanisme yang dikendalikan oleh struktur bernama gerbang. Lapisan *sigmoid* menghasilkan nilai antara nol hingga satu yang menentukan seberapa besar informasi diizinkan masuk, di mana nilai nol berarti “tidak lolos,” sedangkan nilai satu berarti “lolos”.



Gambar 8. Lapisan Sigmoid

Sumber: (Colah, 2015)

Proses dalam metode LSTM terdiri dari beberapa langkah, dengan langkah pertama adalah menyaring informasi yang harus dibuang melalui *forget gate*. Melalui lapisan *sigmoid*, *output* yang dihasilkan dapat berupa angka antara 0 dan 1. Nilai 0 menandakan bahwa suatu elemen atau informasi perlu dihapus, sedangkan nilai 1 menunjukkan bahwa elemen tersebut harus dipertahankan. Perhitungan pada *forget gate* dilakukan dengan menggunakan *output* pada waktu sebelumnya (h_{t-1}) serta *input* pada waktu sekarang (x_t), seperti pada gambar 9.



Gambar 9. Alur *Forget Gate* pada LSTM

Sumber: (Colah, 2015)

Persamaan *forget gate* dapat diuraikan sebagai berikut:

$$f_t = \sigma(w_f \cdot [h_{t-1}, x_t] + b_f) \quad (3)$$

Keterangan:

f_t = *Forget gate*

σ = Fungsi *Sigmoid*

w_f = Nilai *weight* untuk *forget gate*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_f = Nilai bias pada *forget gate*


Nilai *weight* dirumuskan dengan persamaan berikut:

$$W = \left(-\frac{1}{\sqrt{d}}, \frac{1}{\sqrt{d}} \right) \quad (4)$$

Keterangan:

W = *Weight*

d = Jumlah variabel



Gambar 10. Alur *Input Gate* pada LSTM

Sumber: (Colah, 2015)

Tahapan kedua adalah proses mengolah informasi atau *input gate* untuk menentukan informasi yang akan diperbarui dan kemudian dicadangkan di *cell state*.

Persamaan *input gate* seperti persamaan berikut:

$$i_t = \sigma(w_i \cdot [h_{t-1}, x_t] + b_i) \quad (5)$$

Keterangan:

i_t = *input gate*

σ = Fungsi *Sigmoid*

w_f = Nilai *weight* untuk *input gate*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_i = Nilai bias pada *input gate*

Persamaan kandidat baru dituliskan sebagai berikut:

$$c_t^- = \tanh(w_c \cdot [h_{t-1}, x_t] + b_c) \quad (6)$$

Keterangan:

c_t^- = Nilai baru yang dapat ditambahkan ke *cell state*


$\tanh$ = Fungsi *Tangen Hiperbolik*

w_c = Nilai *weight* untuk *cell state*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_c = Nilai bias pada *cell gate*



Gambar 11. Alur memperbaharui *Cell State* pada LSTM

Sumber: (Colah, 2015)

Langkah selanjutnya adalah memperbarui *cell state* seperti pada gambar 11. Gambar mengilustrasikan pembaruan *cell state* yang terjadi dengan mengalikan *output* (f_t) dengan *cell state* (c_t), kemudian hasilnya ditambahkan dengan hasil langkah kedua, yaitu $i_t * \tilde{C}_t$. Persamaan pembaruan *cell state* sebagai berikut:

$$C_t = f_t \cdot C_{t-1} + i_t * \tilde{C}_t \quad (7)$$

Keterangan:


C_t = *Cell state*

f_t = *Forget gate*

C_{t-1} = *Cell state* sebelum orde ke t

i_t = *Input gate*

$\tilde{C}_t$ = Nilai baru yang dapat ditambahkan ke *Cell state*



Gambar 12. Alur *Output* pada LSTM

Sumber: (Colah, 2015)

Langkah terakhir metode LSTM adalah menentukan hasil *output*, seperti pada gambar 12. Bagian *cell state* yang akan dijadikan *output* ditentukan oleh lapisan *sigmoid*. Persamaan *output gate* sebagai berikut.

$$o_t = \sigma(w_o \cdot [h_{t-1}, x_t] + b_o) \quad (8)$$

Keterangan:

o_t = *Output gate*

σ = Fungsi *Sigmoid*

w_f = Nilai *weight* untuk *input gate*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_o = Nilai bias pada *output gate*

Setelah *output gate* menghasilkan nilainya, *cell state* diproses dengan fungsi *tanh* untuk mendapatkan nilai dalam rentang -1 hingga 1 . Nilai ini kemudian dikalikan dengan *output gate* dari lapisan *sigmoid*. Persamaan nilai *output* pada orde t sebagai berikut.

$$h_t = o_t * \tanh(C_t) \quad (9)$$

h_t = Nilai *output* orde t

o_t = *Output gate*

$\tanh$ = Fungsi *tangen hiperbolik*

C_t = *Cell state*

2.5. Text Mining

Text mining adalah proses mengeksplorasi dan menganalisis sejumlah besar data teks tidak terstruktur dengan bantuan perangkat lunak yang dapat mengidentifikasi konsep, pola, topik, kata kunci, dan atribut lain dalam data (Runimeirati et al., 2023). Berbeda dengan data numerik yang telah terstruktur, teks memiliki keragaman bentuk, gaya bahasa, serta elemen linguistik yang kompleks, sehingga memerlukan tahapan pemrosesan khusus agar dapat dianalisis secara sistematis. Prosedur utama dalam metode ini terkait dengan menemukan kata-kata yang dapat mewakili isi dari dokumen untuk selanjutnya dilakukan analisis keterhubungan antar dokumen dengan menggunakan metode statistik tertentu seperti analisis kelompok, klasifikasi dan asosiasi (Putra & Wardani, 2020). *Text mining* biasa digunakan untuk analisis sentimen, karena berperan untuk mengekstraksi opini, emosi, atau kecenderungan sikap dari teks seperti tweet, ulasan, atau komentar publik. Tahapan proses *text mining* secara umum dapat dijelaskan sebagai berikut (Putra & Wardani, 2020):

1. Pengumpulan dan persiapan data

Proses diawali dengan mengumpulkan data mentah dari sumber yang relevan, seperti media sosial, dokumen teks, atau basis data tertentu.

Data awal ini kemudian diseleksi untuk memastikan hanya data yang sesuai kebutuhan yang dilanjutkan ke tahap berikutnya.

2. *Preprocessing* dan *cleansing*

Pada tahap ini dilakukan serangkaian proses untuk membersihkan dan menormalkan teks. *Preprocessing* mencakup *tokenizing*, *filtering*, *stemming*, dan *tagging*. Setelah itu dilakukan *cleansing* untuk menghilangkan berbagai jenis *noise*, seperti karakter tidak relevan atau nilai yang hilang (*missing value*). Hasil dari tahap ini adalah teks yang sudah bersih dan siap diolah lebih lanjut.

3. *Feature selection* dan *feature extraction*

Tahap ini bertujuan mengubah teks menjadi representasi fitur yang dapat diproses oleh algoritma komputasional. Proses dimulai dengan *feature selection*, yaitu pemilihan fitur yang paling relevan dan berkontribusi terhadap hasil analisis. Setelah fitur yang signifikan dipilih, dilakukan *feature extraction* untuk mengubah data teks menjadi bentuk terstruktur seperti vektor, matriks, atau nilai statistik tertentu. Tahap ini memungkinkan data teks dapat dianalisis oleh berbagai metode *data mining* atau *machine learning*.

4. Penyusunan kamus atau basis pengetahuan (*dictionary*)

Pada beberapa pendekatan, terutama yang bersifat *lexicon-based*, diperlukan penyusunan atau pemilihan kamus kata (*dictionary*) yang berisi daftar kata beserta bobot atau kategorinya. Kamus ini digunakan sebagai acuan untuk menentukan nilai sentimen, topik, atau klasifikasi lainnya berdasarkan teks.

5. Evaluasi hasil

Tahap terakhir adalah mengevaluasi performa sistem *text mining* dengan membandingkan hasil analisis dengan data pembanding atau *ground truth*. Evaluasi biasanya dilakukan menggunakan metrik seperti akurasi, *precision*, *recall*, dan *F-measure* untuk menilai sejauh mana model bekerja dengan baik.

2.6. Analisis Sentimen

Analisis sentimen sering juga disebut dengan *opinion mining* atau *content analysis* adalah proses pengelompokkan teks/serangkaian kata yang mengandung nada emosi yang diterapkan untuk memperoleh pemahaman tentang sikap, opini, pendapat, dan emosi yang diungkapkan dalam percakapan *online* (Mahani & Margono, 2021). Tugas dasar dalam analisis sentimen adalah untuk mengklasifikasikan polaritas teks yang ada dalam dokumen, kalimat, atau pendapat (Wahyudi & Kusumawardhana, 2021). Secara umum sentimen yang

terkumpul dikategorikan menjadi 3, yaitu sentimen positif, sentimen negatif, dan sentimen netral. Sentimen dapat berasal dari berita, media sosial, *e-commerce*, dan aplikasi publik.

Secara umum, terdapat 2 pendekatan dalam melakukan analisis sentimen, yaitu *learning-based* (pendekatan *machine learning*) dan *lexicon-based* (pendekatan berbasis leksikal) (Musfiroh et al., 2021). Pendekatan *learning-based* menggunakan dataset yang telah diklasifikasikan secara manual sebelumnya sebagai data latih untuk menghasilkan klasifikasi teks opini secara otomatis (Musfiroh et al., 2021). Contoh implementasi sentimen analisis dengan pendekatan *learning-based* yakni menggunakan model *Naïve Bayes*, *Linear classifier*, *Support Vector Machine*, dan lain sebagainya. Sedangkan metode *lexicon-based* menggunakan *dictionary* atau kamus yang telah memuat nilai polaritas (positif, negatif) untuk penilaian pada kata-kata (Undap et al., 2021). Contoh implementasi pendekatan *lexicon based* yakni metode VADER, *Text-Blob*, *InSet Lexicon* dan sebagainya. Kedua pendekatan ini pada dasarnya melalui alur kerja yang serupa, sehingga analisis sentimen umumnya dilakukan melalui beberapa tahapan sebagai berikut (Hadna et al., 2016).

1. Pengumpulan Data

Tahap ini dilakukan dengan mengumpulkan teks dari berbagai sumber seperti media sosial, portal berita, forum diskusi, atau ulasan pengguna. Data yang diperoleh biasanya masih mentah dan beragam, sehingga langkah ini bertujuan memastikan ketersediaan dataset yang cukup untuk dianalisis.

2. *Preprocessing* Data

Proses ini bertujuan membersihkan serta menstandarkan teks agar lebih mudah diproses oleh metode analisis sentimen.

a) *Tokenization*

Tokenisasi adalah sebuah proses yang dilakukan untuk memotong atau memecah kalimat menjadi beberapa bagian atau kata (Manning et al., 2009 dalam Hadna et al., 2016). Dengan tokenisasi, teks menjadi lebih mudah diolah dan dianalisis karena setiap kata dapat diproses sebagai unit informasi yang terpisah.

b) *Cleansing*

Cleansing merupakan tahap yang bertujuan menghapus karakter atau tanda baca yang tidak diperlukan dari teks, seperti tanda seru, tanda tanya, koma, maupun titik.

c) *Filtering*

Filtering merupakan proses menghapus kata-kata yang sering

muncul tetapi tidak memiliki makna penting (*stopwords*). Secara umum, daftar *stopwords* berisi kumpulan kata yang umum digunakan dalam suatu bahasa. Alasan penghapusan *stopwords* dalam banyak program aplikasi yang berkaitan dengan *text mining* adalah karena penggunaannya yang terlalu umum, sehingga pengguna dapat berfokus pada kata-kata lain yang jauh lebih penting (Ganesan, 2015 dalam (Hadna et al., 2016))

3. Pembobotan Kata

Pembobotan kata merupakan proses pemberian skor berdasarkan seberapa sering sebuah kata muncul dalam suatu dokumen teks. Contohnya, dengan *InSet Lexicon*, setiap kata dalam teks akan dicocokkan dengan daftar lebih dari 10.000 kata yang sudah memiliki bobot sentimennya masing-masing. Nilai bobot ini kemudian digunakan untuk menghitung kecenderungan sentimen keseluruhan dari teks secara kuantitatif.

4. Analisis Sentimen

Setelah setiap kata memperoleh bobot polaritas melalui proses pembobotan, tahap analisis sentimen dilakukan dengan mengagregasikan skor seluruh kata dalam kalimat atau dokumen. Skor tersebut kemudian dijumlahkan atau dirata-ratakan untuk menghasilkan nilai sentimen akhir yang menunjukkan kecenderungan opini, baik positif, negatif, maupun netral. Dengan cara ini, teks dapat dipahami secara lebih menyeluruh berdasarkan makna emosional yang dikandungnya.

5. Pengukuran Kualitas Hasil Uji

Tahapan pengujian hasil klasifikasi bertujuan untuk mengevaluasi kemampuan model dalam memprediksi kelas secara akurat. Proses ini diawali dengan pembagian data menggunakan teknik *cross-validation*, yang memastikan model tidak mengalami *overfitting* dan mampu melakukan generalisasi dengan baik. Data kemudian diuji melalui *confusion matrix*, yang menggambarkan distribusi prediksi benar maupun salah untuk setiap kelas (Musfiroh et al., 2021).

2.7. *Lexicon-Based*

Lexicon Based merupakan salah pendekatan yang dapat digunakan dalam proses analisis sentiment. *Lexicon Based* adalah kamus yang berisi kata-kata Bahasa Indonesia dan pada tiap kata memiliki bobot untuk menentukan polaritas dalam menentukan jenis sentimen positif atau negatif pada opini (Hamka et al., 2022). Metode ini bekerja dengan cara membuat kamus berupa kata terlebih

dahulu, lalu kata-kata tersebut digunakan untuk mengidentifikasikan apakah kata-kata tersebut mengandung opini atau tidak (Kardian & Gustiana, 2021). Secara umum tahapan penelitian dengan menggunakan metode *lexicon based* sebagai berikut (Undap et al., 2021):

a. Pengumpulan Data

Tahap awal dimulai dengan proses pengambilan data dari berbagai sumber teks, seperti media sosial, portal berita, forum, atau platform digital lainnya. Data yang terkumpul berupa kumpulan opini atau pernyataan yang nantinya akan diproses pada tahap pra-pengolahan.

b. Memuat Kamus Sentimen (*Lexicon*)

Pada metode *lexicon-based*, kamus sentimen menjadi komponen utama karena berisi daftar kata yang telah diberikan nilai polaritas positif atau negatif. Kamus ini berfungsi sebagai acuan dalam proses identifikasi sentimen ketika setiap kata dalam teks dibandingkan dengan entri yang ada pada kamus tersebut.

c. *Pre-processing* Data

Pre-processing dilakukan untuk membersihkan dan menstandarkan data sebelum dianalisis lebih lanjut. Tahap ini dapat meliputi:

- *Punctuation Removal*, yaitu menghapus tanda baca atau simbol yang tidak diperlukan.
- Penghapusan URL, *hashtag*, dan *mention*, agar teks lebih bersih dan fokus pada konten opini.
- *Translation*, menerjemahkan teks jika terdapat perbedaan bahasa.
- *Case folding*, mengubah seluruh huruf menjadi huruf kecil.
- Normalisasi kata, mengubah kata tidak baku atau singkatan menjadi bentuk standar.
- *Stopword removal*, menghilangkan kata-kata umum yang tidak memengaruhi sentimen.
- Tokenisasi, memecah teks menjadi unit kata (token) untuk dianalisis lebih lanjut.

d. Ekstraksi Kata Kunci

Setelah data dibersihkan, setiap token diperiksa dan dicocokkan dengan kamus sentimen. Tujuan tahap ini adalah mengidentifikasi apakah sebuah kata memiliki nilai polaritas positif, negatif, atau tidak memiliki nilai sentimen.

e. Penentuan Sentimen

Tahap akhir adalah menentukan kategori sentimen dari sebuah teks. Nilai polaritas seluruh kata yang dikenali dijumlahkan sehingga menghasilkan

skor akhir. Jika totalnya bernilai positif, maka teks dikategorikan sebagai sentimen positif; jika totalnya negatif, maka teks masuk kategori negatif; dan jika total nilainya nol, maka sentimen dianggap netral. Proses ini menghasilkan penilaian akhir terhadap opini yang dianalisis.

Penggunaan *Lexicon-Based* pada analisis sentimen dapat digunakan diberbagai objek, salah satunya saham dengan memanfaatkan kamus kata yang telah diberi bobot untuk menilai opini publik terhadap pergerakan harga saham atau kinerja perusahaan. Data yang dianalisis berasal dari *headline* berita yang mengabarkan terkait perkembangan sebuah saham ataupun perusahaannya. Setiap kata dalam teks yang sesuai dengan lexicon akan diberi skor sentimen positif atau negatif, sehingga polaritas keseluruhan teks dapat dihitung. Hasil penghitungan ini kemudian digunakan untuk memahami persepsi investor terhadap saham tertentu dan memprediksi tren pergerakan harga saham secara lebih sistematis dan kuantitatif, tanpa perlu membaca setiap opini secara manual.

2.8. InSet Lexicon

InSet (Indonesia Sentiment Lexicon) adalah sebuah kamus berbahasa Indonesia yang digunakan pada pendekatan *Lexicon-Based*, bersifat terbuka dan telah dikembangkan secara publik. *InSet* disusun oleh Fajri Koto dan Gemala Y. Rahmaningtyas pada tahun 2017, kemudian dipublikasikan melalui 21st *International Conference on Asian Language Processing (IALP)* dengan memuat lebih dari 3.600 kata positif dan sekitar 6.600 kata negatif, masing-masing memiliki bobot skor polaritas dalam rentang -5 hingga +5 (Difyah et al., 2025). *Lexicon* ini dibangun untuk mengidentifikasi opini tertulis dan mengkategorikannya menjadi positif atau negative yang bisa digunakan untuk menganalisis sentimen publik terhadap topik, acara atau produk tertentu (Musfiroh et al., 2021). Berikut ini adalah tahapan penelitian dengan *Inset Lexicon*:

a. Pengumpulan Data

Tahap awal dimulai dengan proses pengambilan data dari berbagai sumber teks, seperti media sosial, portal berita, forum, atau platform digital lainnya. Data yang terkumpul berupa kumpulan opini atau pernyataan yang nantinya akan diproses pada tahap pra-pengolahan.

b. Preprocessing Data

Data yang telah diperoleh perlu melalui tahap praproses untuk memastikan data berada dalam kondisi bersih, konsisten, dan siap dianalisis. Praproses ini penting agar hasil klasifikasi sentimen menjadi lebih akurat dan bebas dari gangguan data mentah. Tahapan praproses

mencakup proses *cleaning*, *tokenizing*, *filtering*, dan *stemming*.

- *Cleaning*, tahap ini merupakan proses awal dalam penyiapan data teks, yaitu menghilangkan berbagai elemen yang dianggap sebagai *noise*. Beberapa langkah yang dilakukan meliputi:
 - *Remove punctuation*, yaitu menghapus seluruh tanda baca sehingga hanya karakter alfabet yang dipertahankan.
 - *Case folding*, yaitu mengubah seluruh huruf menjadi bentuk lowercase agar tidak terjadi perbedaan makna akibat variasi kapitalisasi.
 - *Drop duplicates*, yaitu menghapus *headline* yang muncul lebih dari satu kali untuk mencegah duplikasi data atau spam yang dapat memengaruhi analisis.
 - *Spelling correction*, yaitu memperbaiki kesalahan penulisan agar kata dapat dikenali dengan tepat pada tahap berikutnya.
- *Tokenizing*, pada tahap ini, teks yang sudah dibersihkan dipecah menjadi unit-unit kata. Tokenisasi memisahkan rangkaian karakter dalam sebuah kalimat menjadi token-token sehingga dapat dianalisis secara individual.
- *Filtering*, dilakukan untuk memilih kata-kata yang relevan dari hasil tokenisasi. Proses ini mencakup penghapusan *stopword*, yaitu kata-kata umum yang tidak memberikan kontribusi pada makna sentimen, seperti “dan”, “yang”, “atau”, dan sebagainya.
- *Stemming*, tahap ini bertujuan mengembalikan setiap kata ke bentuk dasarnya dengan menghilangkan imbuhan. Proses stemming membantu penyamaan bentuk kata sehingga analisis menjadi lebih konsisten.

c. Perhitungan Polaritas dan Klasifikasi Sentimen

Pada tahap ini, setiap data dianalisis secara individual untuk menentukan kategorinya berdasarkan nilai sentiment. Setiap kata dibandingkan dengan entri pada *InSet Lexicon* untuk memperoleh bobot polaritasnya. Seluruh bobot kata kemudian dijumlahkan sehingga menghasilkan *polarity score* untuk setiap kalimat. Berdasarkan nilai total tersebut, kalimat diklasifikasikan ke dalam kategori sentimen tertentu menggunakan aturan berikut:

- Jika *sentiment score* > 0 $\rightarrow$ Sentimen Positif
- Jika *sentiment score* < 0 $\rightarrow$ Sentimen Negatif
- Jika *sentiment score* $= 0$ $\rightarrow$ Sentimen Netral

Kalimat diklasifikasikan menjadi sentimen positif, negatif, atau netral berdasarkan nilai polarity score yang dihitung. Jika skor tersebut lebih dari 0, dianggap positif; jika kurang dari 0, maka dikategorikan sebagai negatif.

InSet Lexicon memiliki relevansi dalam analisis sentimen karena menyediakan referensi kata-kata berbahasa Indonesia yang sudah diberi bobot polaritas, sehingga memungkinkan identifikasi opini publik secara kuantitatif. Dalam konteks pasar saham, opini publik yang terekam di media sosial, forum investasi, atau berita keuangan dapat dianalisis menggunakan *InSet* untuk mengetahui sentimen positif atau negatif terhadap saham tertentu. Penggunaan *InSet Lexicon* tidak hanya mempermudah proses analisis sentimen publik, tetapi juga memberikan dasar yang sistematis dan kuantitatif untuk memprediksi dinamika harga saham di pasar modal Indonesia.

2.9. Metrik Performa

Mengevaluasi performa dari model *deep learning* merupakan salah satu langkah penting dalam pembuatan model yang efektif. Beberapa metrik yang berbeda dapat digunakan untuk menilai kinerja dan kualitas dari model *deep learning*. Metrik ini biasa dikenal metrik performa atau *performance metrics*. Berikut ini beberapa metrik performa yang umum digunakan.

a. Root Mean Square Error (RMSE)

Root Mean Square Error (RMSE) adalah sebuah metode yang digunakan untuk mengevaluasi keakuratan sebuah algoritma berdasarkan nilai error, metode ini biasa digunakan untuk hasil dari sebuah peramalan (Supriyanto et al., 2022). Semakin rendah nilai RMSE, menunjukkan semakin akurat metode estimasi kesalahan pengukuran yang digunakan (Prasetyo et al., 2021).

Persamaan untuk RMSE dijelaskan melalui persamaan berikut:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n}} \quad (10)$$

Keterangan:

Y_i = Data aktual pada periode i

$\hat{Y}_i$ = Data prediksi pada periode i

n = Jumlah periode prediksi yang terlibat

b. Mean Absolute Error (MAE)

MAE (*Mean Absolute Error*) adalah rata-rata selisih mutlak nilai sebenarnya (aktual) dengan nilai perkiraan (prediksi) (Nurani et al., 2023).

Semakin kecil nilai MAE (*Mean Absolute Error*), maka semakin baik model tersebut dalam melakukan perkiraan (prediksi) (Suryanto, 2019 dalam Nurani et al., 2023).

Persamaan untuk MAE dilihat melalui persamaan berikut:

$$MAE = \frac{1}{n} \sum_{t=1}^n |f_t - y_t| \quad (11)$$

Keterangan:

f_t : nilai hasil perkiraan (prediksi) ke- t ($t=1, \dots, n$),

y_t : nilai sebenarnya (aktual) ke- t ($t=1, \dots, n$),

n : banyaknya data yang diuji

$|f_t - y_t|$: nilai kesalahan atau perbedaan nilai aktual dengan nilai prediksi

c. Mean Absolute Percentage Error (MAPE)

MAPE adalah salah satu metode akurasi perkiraan (prediksi) pada peramalan. MAPE digunakan untuk menghitung persentase kesalahan rata-rata secara mutlak (absolut) (Seno & Kamila, 2022). Semakin kecil nilai persentase kesalahan (percentage error) pada MAPE maka, semakin akurat hasil peramalan tersebut (Nurani et al., 2023). Nilai MAPE antara 10% sampai 20% memiliki tingkat akurasi prediksi baik, nilai MAPE antara 20% sampai 50% memiliki tingkat akurasi prediksi cukup sedangkan nilai MAPE lebih dari 50% memiliki tingkat akurasi prediksi buruk (Nurfadilah et al., 2022). Persamaan metode MAPE dapat dilihat sebagai berikut.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - Y'_t|}{Y_t} \quad (12)$$

Keterangan:

Y_t : nilai sebenarnya (aktual) ke- t ($t=1, \dots, n$),

Y'_t : nilai hasil perkiraan (prediksi) ke- t ($t=1, \dots, n$),

n : banyaknya data yang diuji

2.10. Penelitian Terdahulu

Penelitian terdahulu berfungsi sebagai landasan untuk memahami perkembangan metode dan temuan yang relevan dalam topik prediksi harga saham dan analisis sentimen. Melalui peninjauan penelitian sebelumnya, peneliti dapat mengidentifikasi pendekatan yang telah digunakan dan menemukan celah penelitian (*research gap*) yang dapat dijadikan dasar pengembangan penelitian ini. Rangkuman penelitian-penelitian terdahulu dapat dilihat pada tabel 1.

Tabel 1. Penelitian terdahulu

No	Penulis, tahun	Judul Penelitian	Metode	Hasil
1	(Ouf et al., 2024)	A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis	LSTM, XGBoost, Vader, TextBlob	Hasil menunjukkan. Model mencapai akurasi 99% (Apple), 95% (Google), dan 88% (Tesla), sedangkan LSTM mencapai 98% (Apple) dan 95% (Google), tetapi lebih rendah di Tesla karena data latih terbatas. Penggabungan data kuantitatif dan kualitatif dapat meningkatkan akurasi prediksi saham.
2	(Gupta et al., 2022)	HiSA-SMFM: Historical and Sentiment Analysis based Stock Market Forecasting Model	LSTM, TextBlob	Hasil pengujian menunjukkan bahwa HiSA-SMFM konsisten unggul pada semua epoch. Pada epoch 5, 10, dan 15, akurasinya mencapai 95,41%, 97,18%, dan 92,38%, melampaui DLPM yang hanya memperoleh 91,58%, 94,56%, dan 83,46%. Keunggulan ini dipengaruhi oleh penggunaan fitur harga pembukaan serta sentimen positif dan negatif, sedangkan DLPM hanya menggunakan data historis.
3	(Aslim et al., 2023)	Utilization of LSTM (Long Short-Term Memory) Based Sentiment Analysis for Stock Price Prediction	LSTM, InSet, Lexicon	Hasil menunjukkan bahwa sentimen bersifat faktor pendukung; Model yang menggabungkan data historis dan sentimen cenderung memberikan prediksi lebih akurat dibanding model yang hanya menggunakan data historis.

4	(Thorman et al., 2021)	Stock Price Predictions with LSTM Neural Networks and Twitter Sentiment	LSTM, TextBlob	Penelitian ini mengeksplorasi prediksi harga saham APPL menggunakan LSTM dengan sentimen Twitter. Hasil menunjukkan bahwa model terbaik adalah model yang tidak menggunakan sentimen.
5	(Urlam et al., 2021)	Stock Market Prediction Using LSTM and Sentiment Analysis	LSTM	Meskipun LSTM yang menggunakan data histori dan sentimen, model LSTM yang hanya menggunakan harga saham Amazon (tanpa sentimen) justru memberikan performa prediksi yang lebih baik, menunjukkan bahwa penambahan variabel sentimen tidak selalu meningkatkan akurasi prediksi harga saham.
6	(Chou et al., 2021)	Predicting Stock Closing Price After COVID-19 Based on Sentiment Analysis and LSTM	LSTM	Penelitian ini membandingkan LSTM dasar untuk memprediksi harga penutupan saham AAPL: LSTM dasar, LSTM dengan indeks sentimen (LSTMSA), dan LSTM dengan sentimen serta attention (LSTMSAA) untuk memprediksi harga penutupan AAPL.). Hasilnya menunjukkan bahwa LSTMSAA menghasilkan kinerja terbaik dengan MAE 2,595, RMSE 3,364, MAPE 2,184, dan R^2 0,737, menunjukkan bahwa, lebih unggul dibandingkan LSTM dasar dan LSTMS, sehingga membuktikan bahwa penambahan sentimen dan mekanisme <i>attention</i> meningkatkan akurasi prediksi.

7	(Jothimani K & M Afnan, 2024)	Stocksight: a novel approach to stock price prediction with sentiment analysis and lstm networks	LSTM	Penelitian ini membuktikan bahwa LSTM yang dipadukan dengan analisis sentimen mampu memprediksi harga saham dengan baik. Hal ini terlihat dari nilai MAE yang rendah pada beberapa saham, seperti Tata Motors (2,1), Infosys (1,9), Asian Paints (2,3), Tech Mahindra (1,8), dan TCS (2,2), serta nilai RMSE yang stabil pada kisaran 2,5–2,9, sehingga menghasilkan prediksi yang lebih akurat.
8	(Pradiptyo et al., 2024)	Incorporating Stock Prices And Social Media Sentiment For Stock Market Prediction : A Case Of Indonesian Banking Company	LSTM & VADER	Penelitian ini menunjukkan bahwa penambahan fitur sentimen tidak memberikan peningkatan kinerja prediksi yang signifikan, dan uji-t berpasangan mengonfirmasi bahwa pengaruh sentimen tidak signifikan secara statistik.
9	(Heiden & Parpinelli, 2021)	Applying LSTM for Stock Price Prediction with Sentiment Analysis	LSTM & VADER	Penelitian ini memperlihatkan bahwa penambahan news sentiment berbasis VADER ke dalam model LSTM secara signifikan meningkatkan akurasi prediksi harga saham. Hal ini terlihat dari penurunan RMSE pada sepuluh saham S&P 500, seperti AAPL dari 31.21 menjadi 4.42, AMZN dari 735.39 menjadi 149.96, MSFT dari

10	(Yan et al., 2023)	LSTM-based Stock Price Prediction Model using News Sentiments	LSTM & Naïve Bayes	32.49 menjadi 8.06, dan GOOG dari 243.71 menjadi 60.14. Penelitian ini menunjukkan bahwa penambahan sentimen berita ke dalam model LSTM dapat meningkatkan kinerja prediksi secara signifikan. Pada percobaan awal, LSTM tanpa sentimen hanya menghasilkan R^2 sebesar 0.272510, namun setelah sentiment diintegrasikan, nilai tersebut meningkat menjadi 0.642415, disertai penurunan RMSE dari 1.266469 menjadi 0.887913.
----	-----------------------	--	--------------------------	--

III. METODE PENELITIAN

3.1. Tempat dan Waktu Penelitian

Penelitian ini dilaksanakan di Program Studi Sistem Informasi, Jurusan Teknik Elektro dan Informatika, Fakultas Sains dan Teknologi, Universitas Jambi, Jl. Jambi-Muara Bulian No. KM. 15, Mendalo Darat, Kec. Jambi Luar Kota, Kabupaten Muaro Jambi. Penelitian ini akan dilaksanakan selama 3 bulan, mulai dari Desember 2024 hingga Februari 2025.

3.2. Perangkat Penelitian


Perangkat keras (*hardware*) dan perangkat lunak (*software*) yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Perangkat keras (*hardware*)
Laptop Asus dengan *processor* AMD Ryzen 5 7520U with Radeon Graphics 2.80 GHz, RAM 16 GB, dan *system type* 64-bit operating system, x64-based processor.
2. Perangkat lunak (*software*)
 - a. Sistem Operasi Windows 11.
 - b. Google Colaboratory (Google Colab) sebagai platform komputasi berbasis cloud yang digunakan untuk seluruh proses pemodelan LSTM. Google Colab dipilih karena menyediakan lingkungan Python yang siap pakai tanpa perlu instalasi lokal, mendukung penggunaan GPU untuk mempercepat pelatihan model, serta memungkinkan eksekusi kode secara interaktif. Platform ini juga memudahkan integrasi dengan Google Drive untuk penyimpanan dataset dan *notebook*, serta mendukung kolaborasi secara *real-time*. Dalam proses pemodelan LSTM, penelitian ini menggunakan beberapa library utama, yaitu *NumPy* dan *Pandas* untuk pengolahan data, *Scikit-Learn* untuk normalisasi dan evaluasi model, *TensorFlow* untuk membangun arsitektur LSTM, serta *Matplotlib* untuk visualisasi. Selain itu, proses preprocessing data sentimen menggunakan library NLTK dan Sastrawi untuk tokenisasi serta *stemming*.
 - c. Web Scraper.io digunakan untuk melakukan *crawling headline* berita saham BMRI dari Bisnis.com. Tool ini mengekstraksi tanggal dan judul berita secara otomatis berdasarkan struktur HTML, lalu hasilnya diekspor ke format CSV untuk proses selanjutnya.
 - d. Microsoft Excel 2021 sebagai *tool* untuk penyimpanan dan pengorganisasian data.
 - e. Streamlit digunakan untuk membangun antarmuka *Graphical User*

Interface (GUI) sederhana yang menampilkan hasil pemodelan dan visualisasi secara interaktif.

3.3. Tahapan Penelitian


Penelitian ini memerlukan sebuah kerangka kerja yang terstruktur agar proses pelaksanaannya dapat berjalan dengan lebih terarah. Kerangka penelitian tersebut berfungsi untuk menggambarkan tahapan-tahapan yang dilakukan dalam menyelesaikan permasalahan penelitian. Alur langkah tersebut kemudian divisualisasikan pada gambar berikut.



Gambar 13. Tahapan penelitian

3.3.1. Pengumpulan Data


Langkah awal yang dilakukan dalam penelitian ini adalah melakukan pengumpulan data. Data yang dibutuhkan diperoleh dari Website Yahoo Finance (<https://finance.yahoo.com/>), dengan data yang dikumpulkan yaitu data historis harga saham BMRI dari November 2024 – November 2025 sesuai dengan hari perdagangan saham. Data ini mencakup informasi Tanggal, *Close Price*, *High Price*, *Low Price*, *Open Price*, dan *Volume*. Pemilihan periode satu tahun ini dilakukan untuk menangkap pola pergerakan harga yang representatif, termasuk fluktuasi musiman maupun dinamika pasar yang terjadi selama rentang waktu tersebut.



Summary							Currency in IDR
	Date	Open	High	Low	Close	Adj Close	Volume
News	Nov 24, 2025	4,910.00	4,970.00	4,870.00	4,950.00	4,950.00	79,925,400
Chart	Nov 21, 2025	4,940.00	4,970.00	4,900.00	4,950.00	4,950.00	142,452,600
Conversations	Nov 20, 2025	4,940.00	4,990.00	4,900.00	4,940.00	4,940.00	234,717,700
Statistics	Nov 19, 2025	4,820.00	4,850.00	4,800.00	4,850.00	4,850.00	107,585,700
Historical Data	Nov 18, 2025	4,810.00	4,850.00	4,780.00	4,790.00	4,790.00	127,022,100
Profile	Nov 17, 2025	4,780.00	4,850.00	4,770.00	4,820.00	4,820.00	136,477,100
Financials	Nov 14, 2025	4,690.00	4,750.00	4,680.00	4,750.00	4,750.00	73,479,600
Analysis	Nov 13, 2025	4,760.00	4,760.00	4,690.00	4,700.00	4,700.00	108,100,300
Options	Nov 12, 2025	4,680.00	4,790.00	4,680.00	4,760.00	4,760.00	138,539,800
Holders	Nov 11, 2025	4,740.00	4,750.00	4,610.00	4,680.00	4,680.00	168,794,500
	Nov 10, 2025	4,790.00	4,790.00	4,730.00	4,730.00	4,730.00	88,738,200
	Nov 7, 2025	4,750.00	4,780.00	4,740.00	4,750.00	4,750.00	58,845,500
	Nov 6, 2025	4,790.00	4,790.00	4,750.00	4,750.00	4,750.00	57,932,600
	Nov 5, 2025	4,690.00	4,770.00	4,680.00	4,770.00	4,770.00	102,878,900
	Nov 4, 2025	4,760.00	4,790.00	4,720.00	4,730.00	4,730.00	136,412,400

Gambar 14. Pengumpulan data historis dari Yahoo Finance


Selain itu, penelitian ini juga mengumpulkan *headline* berita terkait saham BMRI dan Bank Mandiri dari Bisnis.com (<https://www.bisnis.com/>) sebagai sumber data sentimen. *Headline* berita tersebut akan digunakan untuk menganalisis pengaruh sentimen pasar terhadap tingkat akurasi prediksi harga saham BMRI. Data *headline* berita yang dikumpulkan dari rentang November 2024 – November 2025 menyesuaikan tanggal dengan data harga saham BMRI. Data ini mencakup, tanggal dan *headline* berita. Data ini selanjutnya akan melalui tahap *preprocessing* untuk memastikan konsistensi format sebelum dilakukan analisis sentimen menggunakan pendekatan *lexicon-based* dengan menggunakan kamus dari *InSet Lexicon*.



Gambar 15. Pengumpulan data sentimen dari Bisnis.Com

3.3.2. *Preprocessing Data*

Tahap selanjutnya adalah proses *preprocessing* data. *Preprocessing* data dilakukan pada kedua dataset, yaitu data historis harga saham dan data *headline* berita. *Preprocessing* data merupakan tahapan mengolah data mentah menjadi format yang siap digunakan untuk pemodelan. Tahapan *preprocessing* data meliputi sebagai berikut:



Gambar 16. Tahapan *Preprocessing Data*

a. *Preprocessing Data Historis Harga Saham*

1. *Data Cleaning*

Data cleaning pada data historis harga saham terdiri dari mengidentifikasi *missing value*, menghapus atau mengisi *missing value* dan mengidentifikasi duplikat data. Tabel 2 menunjukkan data mentah harga saham BMRI pada periode Oktober 2025. Berdasarkan hasil pengecekan,

seluruh atribut pada dataset, meliputi *Date*, *Open*, *High*, *Low*, *Close*, dan *Volume* tidak mengandung nilai kosong maupun data yang terduplikasi. Dengan demikian, data dapat langsung digunakan pada tahap selanjutnya tanpa memerlukan proses imputasi atau penghapusan data. Data historis harga saham dapat dilihat pada tabel 2.

Tabel 2. Data historis mentah periode Oktober 2025

Date	Close_ Price	High_ Price	Low_ Price	Open_ Price	Volume
01/10/2025	4380	4400	4350	4360	92,265,100
02/10/2025	4360	4440	4360	4410	93,387,400
03/10/2025	4310	4380	4300	4370	102,459,100
06/10/2025	4260	4330	4260	4320	96,040,500
07/10/2025	4290	4320	4250	4260	100,237,500
08/10/2025	4250	4290	4210	4280	97,466,800
09/10/2025	4390	4450	4200	4240	183,242,600
10/10/2025	4250	4420	4250	4410	139,911,200
13/10/2025	4230	4240	4200	4210	79,178,600
14/10/2025	4090	4270	4090	4220	188,507,000
15/10/2025	4050	4140	4010	4110	270,562,400
16/10/2025	4090	4150	4050	4050	125,979,600
17/10/2025	4050	4110	4030	4110	247,510,000
20/10/2025	4300	4320	4070	4120	331,939,200
21/10/2025	4350	4390	4300	4350	230,858,900
22/10/2025	4330	4460	4290	4350	216,261,300
23/10/2025	4430	4440	4310	4310	202,102,500
24/10/2025	4550	4590	4380	4380	350,420,300
27/10/2025	4470	4600	4410	4590	245,576,100
28/10/2025	4510	4510	4440	4490	174,666,600
29/10/2025	4650	4650	4490	4500	176,978,800
30/10/2025	4800	4830	4650	4670	390,256,000
31/10/2025	4720	4800	4720	4790	227,378,000

b. *Preprocessing* Data Sentimen

1. *Cleaning*

Pada tahap *cleaning*, data *headline* yang telah dikumpulkan diproses untuk menghilangkan elemen-elemen yang tidak relevan agar teks menjadi lebih bersih dan siap dianalisis. Proses *cleaning* meliputi *Remove punctuation*, *Case folding*, *Drop duplicates*, dan *Spelling correction*. Tabel 3 menunjukkan hasil *cleaning* data *headline* berita yang dikumpulkan.

Tabel 3. Hasil *cleaning* data sentimen *headline* berita

Tanggal	Sebelum	Sesudah
01/10/2025	Saham Pilihan Akhir Tahun, dari Bank BBRI BMRI hingga Konsumer ICBP INDF	saham pilihan akhir tahun dari bank bbri bmri hingga konsumer icbp indf
02/10/2025	Bank Mandiri (BMRI) Tawarkan Promo Bunga KPR mulai 1,27%	bank mandiri (bmri) tawarkan promo bunga kpr mulai 1,27%
03/10/2025	Rupiah Melemah, Cek Kurs Dolar AS Hari Ini di Bank Mandiri, BNI, BRI, dan BCA	rupiah melemah cek kurs dolar as hari ini di bank mandiri bni bri dan bca
06/10/2025	Mandiri (BMRI) Salurkan 63% Guyuran Likuiditas Pemerintah, Setara Rp34,5 Triliun	mandiri (bmri) salurkan 63% guyuran likuiditas pemerintah setara rp34,5 triliun
07/10/2025	PREMIUM WRAP-UP: Ledakan Harga Perak hingga JPMorgan Hindari BBNI dan BMRI	premium wrapup ledakan harga perak hingga jpmorgan hindari bbni dan bmri

2. Tokenization

Tokenisasi dilakukan untuk memecah *string* dalam kalimat *headline* berita menjadi satuan kata yang menyusunnya. Proses ini bertujuan untuk mengubah teks yang semula berbentuk rangkaian kalimat menjadi deretan kata (*tokens*) sehingga lebih mudah diproses pada tahap analisis selanjutnya. Setiap kata dapat dievaluasi untuk polaritas sentimennya. Contoh hasil tokenisasi dari data yang telah dibersihkan disajikan pada tabel 4 dibawah ini.

Tabel 4. Hasil proses tokenisasi data

Tanggal	Sebelum	Sesudah
01/10/2025	saham pilihan akhir tahun dari bank bbri bmri hingga konsumer icbp indf	"saham", "pilihan", "akhir", "tahun", "dari", "bank", "bbri", "bmri", "hingga", "konsumer", "icbp", "indf"
02/10/2025	bank mandiri (bmri) tawarkan promo bunga kpr mulai 1,27%	"bank", "mandiri", "bmri", "tawarkan", "promo", "bunga", "kpr", "mulai", "1,27%"

03/10/2025	rupiah melemah cek kurs dolar as hari ini di bank mandiri bni bri dan bca	"kpr", "mulai", "1,27%", "rupiah", "melemah", "cek", "kurs", "dolar", "as", "hari", "ini", "di", "bank", "mandiri", "bni", "bri", "dan", "bca"
06/10/2025	mandiri (bmri) salurkan 63% guyuran likuiditas pemerintah setara rp34,5 triliun	"mandiri", "bmri", "salurkan", "63", "guyuran", "likuiditas", "pemerintah", "setara", "rp34,5", "triliun"
07/10/2025	premium wrapup ledakan harga perak hingga jpmorgan hindari bbni dan bmri	"premium", "wrapup", "ledakan", "harga", "perak", "hingga", "jpmorgan", "hindari", "bbni", "dan", "bmri"

3. *Filtering*

Dalam proses *filtering*, kata-kata penting diambil dari hasil tokenisasi sebelumnya. Kata henti (*stopwords*) atau kata yang tidak memiliki makna penting dalam konteks analisis akan dihilangkan karena tidak memberikan kontribusi terhadap penentuan sentimen. Proses ini bertujuan untuk memastikan bahwa hanya kata-kata relevan yang digunakan dalam tahap perhitungan skor sentimen, sehingga hasil analisis menjadi lebih akurat dan fokus pada inti informasi dari setiap *headline*. Hasil lengkap dari proses *filtering* pada data sentimen *headline* berita disajikan pada Tabel 5.

Tabel 5. Hasil proses *filtering* data

Tanggal	Sebelum	Sesudah
01/10/2025	"saham", "pilihan", "akhir", "tahun", "dari", "bank", "bbri", "bmri", "hingga", "konsumer", "icbp", "indf"	"saham", "pilihan", "akhir", "tahun", "konsumer"
02/10/2025	"bank", "mandiri", "bmri", "tawarkan", "promo", "bunga",	"tawarkan", "promo", "bunga", "kpr", "mulai"

03/10/2025	"kpr", "mulai", "1,27%", "rupiah", "melemah", "cek", "kurs", "dolar", "as", "hari", "ini", "di", "bank", "mandiri", "bni", "bri", "dan", "bca"	"rupiah", "melemah", "cek", "kurs", "dolar", "as"
06/10/2025	"mandiri", "bmri", "salurkan", "63", "guyuran", "likuiditas", "pemerintah", "setara", "rp34,5", "triliun"	"salurkan", "guyuran", "likuiditas", "pemerintah", "setara", "triliun"
07/10/2025	"premium", "wrapup", "ledakan", "harga", "perak", "hingga", "jpmorgan", "hindari", "bbni", "dan", "bmri"	"premium", "ledakan", "harga", "perak", "jpmorgan", "hindari"

4. Stemming

Pada tahap *stemming*, setiap token diproses untuk dikembalikan ke bentuk kata dasarnya menggunakan algoritma *stemming* Bahasa Indonesia. Proses ini bertujuan untuk menyamakan variasi kata yang memiliki makna dasar serupa, misalnya kata berimbuhan. Tabel 6 memperlihatkan hasil poses *stemming* yang telah dilakukan.

Tabel 6. Hasil proses *stemming* data

Tanggal	Sebelum	Sesudah
01/10/2025	"saham", "pilihan", "akhir", "tahun", "konsumer"	"saham", "pilihan", "akhir", "tahun", "konsumer"
02/10/2025	"tawarkan", "promo", "bunga", "kpr", "mulai"	"tawar", "promo", "bunga", "kpr", "mulai"
03/10/2025	"rupiah", "melemah", "cek", "kurs", "dolar", "as"	"rupiah", "lemah", "cek", "kurs", "dolar", "as"
06/10/2025	"salurkan", "guyuran", "likuiditas", "pemerintah", "setara", "triliun"	"salur", "guyur", "likuiditas", "perintah", "setara", "triliun"
07/10/2025	"premium", "ledakan", "harga",	"premium", "wrapup", "ledak", "harga", "perak",

"perak", "jpmorgan", "jpmorgan",
"hindari" "hindar"

3.3.3. Kalkulasi Polaritas

Pendekatan yang diambil untuk memeriksa polaritas sentimen adalah dengan menggunakan *InSet Lexicon*. *InSet Lexicon* merupakan kamus (dictionary) sentiment berbahasa Indonesia yang berisi ribuan kata yang memiliki bobot skor positif negatif. Tabel 7 menunjukkan isi dari kamus *InSet Lexicon*. Proses pendekatan dalam metode leksikon untuk menghitung polaritas adalah memberikan skor untuk masing-masing kata yang telah dibersihkan sebelumnya dan ini menjadikan penilaian sentimen lebih objektif. Berikut ini tabel 8 yang berisi hasil pemberian skor menggunakan *InSet Lexicon*.

Tabel 7. Contoh *Dictionary InSet Lexicon*

Kata	Bobot
ludes	-5
pedas	-4
pedar	-4
waswas	-3
menonjok	-3
nyanyian	2
dendang	2
gita	2
gending	1
lagu	2

Tabel 8. Hasil kalkulasi polaritas

Kata	Bobot
saham	0
pilihan	5
akhir	0
tahun	0
konsumer	0
Total	5

3.3.4. Klasifikasi Polaritas

Setelah menilai setiap kata, proses selanjutnya adalah memberi label sentimen. Dalam penelitian ini, label sentimen yang digunakan

hanya positif dan negatif karena label netral biasanya tidak memuat opini atau kecenderungan tertentu pada sebuah topik yang sedang dibahas. Sebelum pelabelan, data dirata-rata per tanggal sehingga diperoleh hasil pengelompokan sentimen berdasarkan tanggal, yaitu positif lebih besar dari 0 dan negatif kurang dari 0. Contoh proses klasifikasi polaritas dijelaskan dalam tabel 9 berikut.

Tabel 9. Hasil klasifikasi sentimen

Tanggal	Headline	Skor	Sentimen
01/10/2025	Saham Pilihan Akhir Tahun, dari Bank BBRI BMRI hingga Konsumer ICBP INDF	5	Positif
02/10/2025	Bank Mandiri (BMRI) Tawarkan Promo Bunga KPR mulai 1,27%	3	Positif
03/10/2025	Rupiah Melemah, Cek Kurs Dolar AS Hari Ini di Bank Mandiri, BNI, BRI, dan BCA	-7	Negatif
06/10/2025	Mandiri (BMRI) Salurkan 63% Guyuran Likuiditas Pemerintah, Setara Rp34,5 Triliun	2	Positif
07/10/2025	PREMIUM WRAP-UP: Ledakan Harga Perak hingga JPMorgan Hindari BBNI dan BMRI	-3	Negatif

3.3.5. Combine Data

Pada tahap ini, data historis harga saham BMRI digabungkan dengan data sentimen yang telah diperoleh dari headline berita. Penggabungan dilakukan berdasarkan kecocokan tanggal (*date matching*), sehingga setiap baris data harga saham pada tanggal tertentu dipasangkan dengan skor sentimen berita yang terbit pada tanggal yang sama.

Proses ini menghasilkan satu dataset terpadu yang berisi *Close Price*, *High Price*, *Low Price*, *Open Price*, *Volume*, dan nilai *Sentimen*. Dataset gabungan ini menjadi dasar untuk proses pelatihan model selanjutnya, baik untuk model tanpa sentiment maupun model yang menggunakan fitur sentimen dalam proses prediksi. Berikut ini adalah tabel 10 yang berisi hasil penggabungan data historis dan data sentimen.

Tabel 10. Menyatukan data historis saham dengan data *headline* berita

Date	Close _Price	High_ Price	Low_ Price	Open _Price	Volume	Senti men
01/10 /2025	4380	4400	4350	4360	92,265,100	5
02/10 /2025	4360	4440	4360	4410	93,387,400	3
03/10 /2025	4310	4380	4300	4370	102,459,10 0	-7
06/10 /2025	4260	4330	4260	4320	96,040,500	2
07/10 /2025	4290	4320	4250	4260	100,237,50 0	-3

3.3.6. Normalisasi Data

Setelah proses menyatukan data selesai, selanjutnya melakukan normalisasi data menggunakan metode *Min-Max Scalling* untuk mengubah rentang nilai menjadi sama antara 0 dan 1. Hal ini bertujuan untuk menghasilkan skala nilai yang konsisten antar data, baik sebelum maupun sesudah proses. Hasil normalisasi dapat dilihat pada tabel 11. Persamaan metode ini adalah sebagai berikut:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (13)$$

Keterangan:

X' = Hasil Normalisasi Data

X_{min} = Data minimum dari data X

X_{max} = Data maksimum dari data X

Berikut ini pengaplikasian Min Max Scalling dataset yang telah dibersihkan.

$$X' = \frac{4380 - 4260}{4380 - 4260} = 1$$

Tabel 11. Hasil normalisasi data

Date	Close_ Price	High_ Price	Low_ Price	Open_ Price	Volume	Sentim en
01/10/ 2025	1	0.6667	0.9091	0.6667	0	1

02/10/ 2025	0.83333	1	1	1	0.11009	0.83333
03/10/ 2025	0.41667	0.5	0.45454	0.73333	1	0
06/10/ 2025	0	0.08333	0.09091	0.4	0.37036	0.75
07/10/ 2025	0.25	0	0	0	0.78207	0.33333

3.3.7. Data Training dan Data Testing

Proses pembagian data atau data *split* merupakan langkah untuk memisahkan dataset menjadi beberapa subset yang saling terpisah, yang digunakan untuk keperluan pelatihan (*training*) dan pengujian (*testing*) model. Tujuan utama dari proses ini adalah memperoleh gambaran yang lebih jelas mengenai seberapa baik model mampu bekerja ketika dihadapkan pada data baru. Pada penelitian ini, pembagian data dilakukan dengan rasio 80:20, di mana 80% data digunakan sebagai *training set*, sedangkan 20% sisanya menjadi *testing set*.

Pembagian data menjadi data latih dan data uji juga bertujuan untuk mencegah terjadinya *overfitting*, yaitu kondisi ketika model terlalu menyesuaikan diri dengan data latih sehingga tidak mampu melakukan generalisasi dengan baik pada data yang belum pernah dilihat sebelumnya. Dengan adanya pemisahan ini, peneliti dapat menilai performa model secara lebih objektif dan memastikan apakah model mampu melakukan generalisasi terhadap data baru.

3.3.8. Membuat Model LSTM

Setelah processing dataset dilakukan, data diproses dengan model yang diinginkan. Pada tahap ini, model *Long Short-Term Memory* (LSTM) dibangun untuk melakukan pemodelan dan prediksi harga saham berdasarkan dataset yang telah melalui seluruh proses pra-pemrosesan. Pembangunan model dilakukan dalam dua skenario, yaitu model *baseline* tanpa variabel sentimen dan model LSTM yang mengintegrasikan informasi sentimen dari *headline* berita. Pemisahan kedua model ini bertujuan untuk membandingkan pengaruh penambahan variabel sentimen terhadap peningkatan akurasi prediksi.

Proses pemodelan mencakup pengaturan awal bobot untuk *forget gate*, *input gate*, *cell gate*, dan *output gate*, serta pengaturan awal nilai bias untuk masing-masing gerbang (W_f , W_i , W_c , W_o dan bias b_f , b_i , b_c , b_o).

Nilai bobot W ditentukan dengan menggunakan persamaan (). Bobot yang diperoleh melalui persamaan () kemudian digunakan sebagai bobot awal untuk W_f , W_i , W_{ct} , dan W_o .

$$W = \left(-\frac{1}{\sqrt{d}}, \frac{1}{\sqrt{d}} \right) \quad (14)$$

Keterangan:

W = *Weight*

d = Jumlah variabel

Contoh perhitungan:

$$W = \left(-\frac{1}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right) = (-0.408, 0.408)$$

Nilai $d=6$ diperoleh dari jumlah variabel yang digunakan dalam penelitian.

Terdapat sejumlah gates yang dimiliki LSTM, terdiri dari lapisan *sigmoid* dan operasi *pointwise*. Gates ini berfungsi untuk menambahkan atau menghapus informasi yang akan diteruskan atau dihentikan. Rentang $[0,1]$ merupakan batas dari output lapisan *sigmoid*, dimana nilai 0 merupakan informasi tidak akan diteruskan, sedangkan nilai 1 berarti informasi akan dilanjutkan. Persamaan *sigmoid* dapat dilihat pada persamaan berikut:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (15)$$

a. Perhitungan *Forget Gate*

Forget Gate merupakan gerbang pertama tempat informasi masuk dan diproses pada LSTM. Gerbang ini memiliki fungsi untuk menentukan informasi mana yang akan dihapus dari cell state. Lapisan *sigmoid* memberikan keputusan dengan menghasilkan *output* berupa nilai antara 0 dan 1. Persamaan *forget gate* adalah sebagai berikut:

$$f_t = \sigma(w_f \cdot [h_{t-1}, x_t] + b_f) \quad (16)$$

Keterangan:

f_t = *Forget gate*

σ = Fungsi *Sigmoid*

w_f = Nilai *weight* untuk *forget gate*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_f = Nilai bias pada *forget gate*

Contoh perhitungan:

$$f_t = \sigma(0.408 \cdot [0, 1, 0.6667, 0.9091, 0.6667, 0, 1] + 1)$$

$$f_t = \sigma((0.408 * 0) + (0.408 * 1) + (0.408 * 0.6667) + (0.408 * 0.9091) + (0.408 * 0.6667) + (0.408 * 0) + (0.408 * 1) + 1)$$

$$f_t = \sigma(2.73094)$$

$$f_t = \frac{1}{1 + e^{-2.73094}} = 0.93883$$

Nilai 0,17960 diperoleh dari nilai W (bobot) yang sebelumnya sudah dihitung. X_t adalah nilai variabel yang didapatkan dari dataset dan b_f adalah nilai bias *forget gate*.

Forget Gate	2.73094
	0.93883

Nilai 2.73094 adalah nilai hasil perhitungan *forget gate* sebelum memasuki fungsi *sigmoid*, sedangkan 0.93883 adalah *forget gate* setelah diproses dengan fungsi *sigmoid*.

b. Perhitungan Input Gate

Input gate berperan mengambil *output* sebelumnya, *input* baru, dan melewatkan mereka melalui lapisan *sigmoid*. Nilai 0 atau 1 dikembalikan melalui *gate* ini.

$$i_t = \sigma(w_i \cdot [h_{t-1}, x_t] + b_i) \quad (17)$$

Keterangan:

i_t = *input gate*

σ = Fungsi *Sigmoid*

w_f = Nilai *weight* untuk *input gate*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_i = Nilai bias pada *input gate*

Contoh perhitungan:

$$i_t = \sigma(0.408 \cdot [0, 1, 0.6667, 0.9091, 0.6667, 0, 1] + 0.5)$$

$$i_t = \sigma((0.408 * 0) + (0.408 * 1) + (0.408 * 0.6667) + (0.408 * 0.9091) + (0.408 * 0.6667) + (0.408 * 0) + (0.408 * 1) + 0.5)$$

$$i_t = \sigma(2.23094)$$

$$i_t = \frac{1}{1 + e^{-2.23094}} = 0.90299$$

Input Gate	2.23094
	0.90299

Nilai 2.23094 adalah nilai hasil perhitungan *input gate* sebelum memasuki fungsi *sigmoid*, sedangkan 0.90299 adalah *input gate* setelah diproses dengan fungsi *sigmoid*.

c. Perhitungan Cell State

Cell state berperan mengangkut informasi melalui seluruh rantai sel dan memungkinkan jaringan untuk menyimpan informasi untuk periode waktu yang panjang. Persamaan *cell state* sebagai berikut:

$$c_t^- = \tanh(w_c \cdot [h_{t-1}, x_t] + b_c) \quad (18)$$

Keterangan:

c_t^- = Nilai baru yang dapat ditambahkan ke cell state

$\tanh$ = Fungsi Tangen Hiperbolik

w_c = Nilai *weight* untuk *cell state*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_c = Nilai bias pada *cell gate*

Contoh perhitungan:

$$c_t^- = \tanh(0.408 \cdot [0, 1, 0.6667, 0.9091, 0.6667, 0, 1] + 1)$$

$$c_t^- = \tanh(0.408 \cdot 0) + (0.408 \cdot 1) + (0.408 \cdot 0.6667) + (0.408 \cdot 0.9091) + (0.408 \cdot 0.6667) + (0.408 \cdot 0) + (0.408 \cdot 1) + 1)$$

$$c_t^- = \tanh(2.73094) = 0.99155$$

Selanjutnya pembaharuan *cell state* dengan persamaan berikut:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (19)$$

Keterangan:

C_t = *Cell state*

f_t = *Forget gate*

C_{t-1} = *Cell state* sebelum orde ke t

i_t = *Input gate*

$\tilde{C}_t$ = Nilai baru yang dapat ditambahkan ke *Cell state*

Contoh perhitungan:

$$C_t = 0.93883 \cdot 0 + 0.90299 \cdot 0.99155$$

$$C_t = 0.89536$$

d. Perhitungan Output Gate

Output gate berperan untuk mengontrol berapa banyak *state*

yang lewat ke *output* dan bekerja dengan cara yang sama dengan *gate* lainnya. Dan terakhir menghasilkan *cell state* yang baru (h_t).

$$o_t = \sigma(w_o \cdot [h_{t-1}, x_t] + b_o) \quad (20)$$

Keterangan:

o_t = *Output gate*

σ = Fungsi *Sigmoid*

w_f = Nilai *weight* untuk *input gate*

h_{t-1} = Nilai *output* sebelum orde ke t

x_t = Nilai *input* pada orde ke t

b_o = Nilai bias pada *output gate*

Contoh perhitungan:

$$o_t = \sigma(0.408 \cdot [0, 1, 0.6667, 0.9091, 0.6667, 0, 1] + 0.1)$$

$$o_t = \sigma(0.408 * 0) + (0.408 * 1) + (0.408 * 0.6667) + (0.408 * 0.9091) + (0.408 * 0.6667) + (0.408 * 0) + (0.408 * 1) + 0.1$$

$$o_t = \sigma(1.83094) = \frac{1}{1 + e^{-1.83094}} = 0.86187$$

Nilai 0,408 diperoleh dari nilai W (bobot) yang sebelumnya sudah dihitung. X_t adalah nilai variabel yang didapatkan dari dataset dan b_o adalah nilai bias *forget gate*.

	1.83094
Output Gate	0.86187

Nilai 1.83094 adalah nilai hasil perhitungan *input gate* sebelum memasuki fungsi *sigmoid*, sedangkan 0.86187 adalah *input gate* setelah diproses dengan fungsi *sigmoid*.

e. Perhitungan *Hidden State*

Hidden state merupakan hasil akhir ataupun prediksi yang telah diproses di setiap gerbang LSTM. Hasil *hidden state* merupakan nilai prediksi. Berikut adalah persamaan untuk *hidden state*:

$$h_t = o_t * \tanh(C_t) \quad (21)$$

Keterangan:

h_t = Nilai *output* orde t

o_t = *Output gate*

$\tanh$ = Fungsi *tangen hiperbolik*

C_t = *Cell state*

Contoh perhitungan:

$$h_t = 0.86187 * \tanh(0.89536)$$

$$h_t = 0,61540$$

Tabel 11. Nilai perhitungan *Gate* LSTM pada 1 Oktober 2025

<i>Forget Gate</i>	2.73094
	0.93883
<i>Input Gate</i>	2.23094
	0.90299
c_t^-	2.73094
	0,99155
<i>Output Gate</i>	1.83094
	0.86187
<i>Cell State</i>	0.89536
<i>Hidden State</i>	0.61540

Dengan menggunakan sampel data yang diambil pada tanggal 1 Oktober 2025, proses perhitungan LSTM telah diuraikan satu per satu disini. Pada tabel 12 terlihat hasil dari setiap *gate*. Semua *output* lapisan LSTM terhubung melalui garis horizontal yang ditemukan dibagian atas diagram.

3.3.9. Denormalisasi

Denormalisasi merupakan proses mengembalikan data hasil prediksi ke dalam skala aslinya. Tahap ini penting dilakukan karena data yang digunakan untuk training model telah melalui proses normalisasi sebelumnya. Proses denormalisasi menggunakan formula yang berkebalikan dengan metode normalisasi yang diterapkan pada tahap *preprocessing*. Berikut adalah persamaan untuk denormalisasi.

$$d = d'(max - min) + min \quad (22)$$

Keterangan:

d = Nilai hasil denormalisasi

d' = Nilai data normalisasi

max = Nilai maksimum dari data actual

min = Nilai minimum dari data actual

Contoh perhitungan:

$$d = 0.61540(4380 - 4260) + 4260$$

$$d = 4,333.85$$

Nilai 4,333.85 adalah hasil denormalisasi hasil prediksi data pada tanggal 1 Oktober 2025. Denormalisasi diperlukan agar hasil prediksi dapat

diinterpretasikan dalam satuan harga saham yang sebenarnya (rupiah) dan dapat dibandingkan secara langsung dengan data aktual untuk keperluan evaluasi model.

3.3.10. Evaluasi

Pada tahap ini dilakukan proses evaluasi terhadap kinerja model untuk menilai seberapa baik model mampu memprediksi harga saham. Evaluasi dilakukan dengan menggunakan tiga metrik utama, yaitu *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan *Mean Absolute Percentage Error* (MAPE). Ketiga metrik ini digunakan untuk mengukur tingkat kesalahan prediksi dari berbagai sudut pandang, sehingga dapat memberikan gambaran yang komprehensif mengenai akurasi dan performa model. Untuk mengukur akurasi model menggunakan ketiga metrik ini, diperlukan nilai prediksi pada periode yang telah ditentukan, seperti yang tertera pada tabel 13.

Tabel 12. Nilai hasil prediksi

Tanggal	Nilai Aktual	Nilai Prediksi
01/10/2025	4380	4333.848
02/10/2025	4360	4363.198
03/10/2025	4310	4360.517
06/10/2025	4260	4350.368
07/10/2025	4290	4346.687

1. *Root Mean Square Error* (RMSE)

Root Mean Square Error (RMSE) merupakan metrik yang digunakan untuk menilai tingkat akurasi suatu algoritma berdasarkan besarnya kesalahan prediksi. Metrik ini umum diterapkan dalam analisis hasil peramalan. Nilai RMSE yang semakin kecil menandakan bahwa model memiliki tingkat kesalahan yang rendah sehingga performa prediksinya lebih akurat. Persamaan RMSE dapat dilihat sebagai berikut:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n}} \quad (23)$$

Keterangan:

Y_i = Data aktual pada periode i

$\hat{Y}_i$ = Data prediksi pada periode i

n = Jumlah periode prediksi yang terlibat

Contoh perhitungan:

$RMSE$

$$= \sqrt{\frac{(4380 - 4333.848)^2 + (4360 - 4363.198)^2 + (4310 - 4360.517)^2 + (4260 - 4350.368)^2 + (4290 - 4346.687)^2}{5}}$$

$$RMSE = \sqrt{\frac{16071.993}{5}}$$

$$RMSE = 56.696$$

Nilai RMSE 56,696 berarti, rata-rata selisih (error) antara harga penutupan aktual dan harga penutupan prediksi model untuk 5 periode tersebut adalah 56,696 poin harga.

2. Mean Absolute Error (MAE)

Mean Absolute Error (MAE) merupakan ukuran yang menghitung rata-rata selisih absolut antara nilai aktual dan nilai hasil prediksi. Nilai MAE yang semakin rendah menunjukkan bahwa model memiliki tingkat kesalahan yang lebih kecil, sehingga kualitas prediksinya dianggap semakin baik. Persamaan untuk MAE dilihat melalui persamaan berikut:

$$MAE = \frac{1}{n} \sum_{t=1}^n |f_t - y_t| \quad (24)$$

Keterangan:

f_t : nilai hasil perkiraan (prediksi) ke- t ($t=1, \dots, n$),

y_t : nilai sebenarnya (aktual) ke- t ($t=1, \dots, n$),

n : banyaknya data yang diuji

$|f_t - y_t|$: nilai kesalahan atau perbedaan nilai aktual dengan nilai prediksi

Contoh perhitungan:

$$\begin{aligned} MAE &= \frac{1}{5} |4380 - 4333.848| + |4360 - 4363.198| + |4310 \\ &\quad - 4360.517| + |4260 - 4350.368| + |4290 \\ &\quad - 4346.687| \end{aligned}$$

$$MAE = 49.384$$

Nilai MAE sebesar 49,384 berarti rata-rata selisih antara harga aktual dan prediksi model adalah 49,384 poin harga.

3. Mean Absolute Percentage Error (MAPE)

Mean Absolute Percentage Error (MAPE) merupakan metode evaluasi yang digunakan dalam peramalan untuk mengukur persentase rata-rata kesalahan absolut antara nilai aktual dan

nilai prediksi. Semakin rendah persentase error yang dihasilkan oleh MAPE, semakin tinggi tingkat akurasi model dalam menghasilkan prediksi. Persamaan MAPE dapat dilihat sebagai berikut:

$$MAE = \frac{1}{n} \sum_{t=1}^n |f_t - y_t| \quad (25)$$

Keterangan:

Y_t : nilai sebenarnya (aktual) ke- t ($t=1, \dots, n$),

Y'_t : nilai hasil perkiraan (prediksi) ke- t ($t=1, \dots, n$),

n : banyaknya data yang diuji

Contoh perhitungan:

$$MAPE = \frac{1}{5} \left(\frac{|4380 - 4333.848|}{4380} + \frac{|4360 - 4363.198|}{4360} + \frac{|4310 - 4360.517|}{4310} + \frac{|4260 - 4350.368|}{4260} + \frac{|4290 - 4346.687|}{4290} \right)$$

$$MAPE = \frac{1}{5} (0.05742)$$

$$MAPE = 0.0115 = 1.15\%$$

Hasil nilai MAPE 1.15% berarti rata-rata kesalahan prediksi model adalah sekitar 1.15% dari harga aktual. Hasil ini mengonfirmasi bahwa model memiliki tingkat akurasi yang sangat tinggi (eror sangat rendah) untuk 5 periode tersebut.

3.3.11. GUI (*Graphical User Interface*)

Setelah menyelesaikan tahap pengolahan dan evaluasi data secara manual, peneliti mengembangkan sebuah sistem peramalan berbasis web dengan *Graphical User Interface* (GUI). *Graphical User Interface* (GUI) adalah salah satu jenis user interface (UI) yang merupakan komponen penting dalam teknologi modern yang memudahkan penggunaan perangkat lunak, sistem, dan perangkat (Prihastomo & Winanti, 2024). GUI berfungsi sebagai penghubung komunikasi antara pengguna dan perangkat lunak. Peneliti mengembangkan GUI yang dirancang secara khusus agar mudah digunakan tanpa memerlukan pengetahuan pemrograman. Dengan demikian, berdasarkan hasil pengujian sebelumnya, sistem peramalan berbasis web ini dirancang dengan *mockup* yang menekankan pada kemudahan penggunaan,

memungkinkan pengguna untuk memasukkan dan memproses data deret waktu didalamnya.

PREDIKSI PENUTUPAN HARGA SAHAM DENGAN LSTM DAN ANALISIS SENTIMEN

Upload Data Sentimen

Upload Data Saham

Proses Data

Data Sentimen

Index	Date	Headline News	Polaritas	Label
0	2025-10-01 00:00:00	Saham Pilihan Akhir Tahun, dari Bank BBRI BMRI hingga Konsumer ICBP INDF	5	positif
1	2025-10-02 00:00:00	Bank Mandiri (BMRI) Tawarkan Promo Bunga KPR mulai 1,27%	3	positif
2	2025-10-03 00:00:00	Rupiah Melemah, Cek Kurs Dolar AS Hari Ini di Bank Mandiri, BNI, BRI, dan BCA	-7	negatif
3	2025-10-06 00:00:00	Mandiri (BMRI) Salurkan 63% Guyuran Likuiditas Pemerintah, Setara Rp34,5 Triliun	2	positif
4	2025-10-07 00:00:00	PREMIUM WRAP-UP: Ledakan Harga Perak hingga JPMorgan Hindari BBNI dan BMRI	-3	negatif

Data Saham

	Date	Close_Price	High_Price	Low_Price	Open_Price	Volume
0	2025-10-01	4380	4400	4350	4360	92265100
1	2025-10-02	4360	4440	4360	4410	93387400
2	2025-10-03	4310	4380	4300	4370	102459100
3	2025-10-06	4260	4330	4260	4320	96040500
4	2025-10-07	4290	4320	4250	4260	100237500

Gabungkan Data

Gambar 17. *Graphical User Interface* awalan prediksi saham

	Date	Close_Price	High_Price	Low_Price	Open_Price	Volume	Polaritas
0	2025-10-01	4380	4400	4350	4360	92265100	5
1	2025-10-02	4360	4440	4360	4410	93387400	3
2	2025-10-03	4310	4380	4300	4370	102459100	-7
3	2025-10-06	4260	4330	4260	4320	96040500	2
4	2025-10-07	4290	4320	4250	4260	100237500	-3

Lakukan Prediksi

Gambar 18. *Graphical User Interface* hasil penggabungan data

Prediksi Tanpa Sentimen



Prediksi Dengan Sentimen

**Gambar 19.** Graphical User Interface hasil prediksi

DAFTAR PUSTAKA

- Adisurya, & Rizkinia, M. (2024). Implementation of Diffusion Variational Autoencoder for Stock Price Prediction with the Integration of Historical and Market Sentiment Data. *International Journal of Electrical, Computer and Biomedical Engineering*, 2(2), 229 – 242. <https://doi.org/https://doi.org/10.62146/ijecbe.v2i2.55> <https://ijecbe.ui.ac.id>
- Ahmed, S. F., Alam, S. Bin, Hassan, M., Rozbu, M. R., Ishtiak, T., Rafa, N., Mofijur, M., Ali, A. B. M. S., & Gandomi, A. H. (2023). Deep learning modelling techniques : current progress , applications , advantages , and challenges. In *Artificial Intelligence Review* (Issue 0123456789). Springer Netherlands. <https://doi.org/10.1007/s10462-023-10466-8>
- Andiyantama, M. Q., Zahira, I., & Irawan, A. (2021). Prediksi Energi Listrik Kincir Angin Berdasarkan Data Kecepatan Angin Menggunakan LSTM. *JITCE (Journal of Information Technology and Computer Engineering)*, 05(1), 1–7. <https://doi.org/https://doi.org/10.25077/jitce.5.01.1-7.2021>
- Arisandi, A. D., Ferdiansyah, Atika, L., & Negara, E. S. (2020). Prediksi Mata Uang Bitcoin Menggunakan LSTM dan Analisis Sentimen pada Sosial Media Pendahuluan Metode Penelitian. *Jurnal Ilmiah Komputer & Sistem Informas*, 19(4), 559 – 566. <https://doi.org/https://doi.org/10.32409/jikstik.19.4.370>
- Aslim, M. F., Firmansyah, G., Akbar, H., Tjahyono, B., & Widodo, A. M. (2023). Utilization of LSTM (Long Short Term Memory) Based Sentiment Analysis for Stock Price Prediction. *Asian Journal of Social and Humanities*, 1(12), 1241–1255.
- Bank Mandiri. (2025). Bank Mandiri Pertegas Optimisme Bisnis, Buyback Saham Jadi Sinyal Kekuatan Fundamental. In Bank Mandiri. Bank Mandiri. <https://www.bankmandiri.co.id/en/press-detail?primaryKey=499487920&backUrl=/press>
- Bank Mandiri. (2024). Raja Aset Terbesar di Indonesia, Bank Mandiri Sabet Posisi Puncak Fortune Indonesia 100. Bank Mandiri. <https://www.bankmandiri.co.id/en/news-detail?primaryKey=335438232&backUrl=/news#:~:text=Raja%20Aset%20Terbesar%20di%20Indonesia,Posisi%20Puncak%20Fortune%20Indonesia%20100>
- Chou, C., Park, J., & Chou, E. (2021). Predicting Stock Closing Price After COVID-19 Based on Sentiment Analysis and LSTM. *IEEE 5th Advanced Information Technology, Electronic and Automation Control Conference (IAEAC)*, 2021, 2752 – 2756. <https://doi.org/10.1109/IAEAC50856.2021.9390845>
- Colah. (2015). Understanding LSTM Networks. Colah's Blog. <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- Difyah, S. M. Z. A., Winanto, E. A., & Jusia, P. A. (2025). Analisis Sentimen Persepsi Publik terhadap Tagar # KaburAjaDulu di di Twitter Menggunakan Metode Lexicon-Based dengan Kamus InSet. *Jurnal Processor*, 20(2), 223–233. <https://doi.org/10.33998/processor.2025.20.2.2542>

- Fauzi, M. P. (2025). Aset Bank Mandiri Naik 11,6%, Total Mencapai Rp 2.427 Triliun. In detikFinance. detikfinance. <https://finance.detik.com/moneter/d-7767914/aset-bank-mandiri-naik-11-6-total-mencapai-rp-2-427-triliun>
- Firdaus, R. F. (2022). Prediksi Curah Hujan Menggunakan Metode Long Short Term Memory (Studi Kasus : Kota Bandung).
- Gupta, I., Singh, S., Madan, T. K., & Singh, A. K. (2022). HiSA-SMFM: Historical and Sentiment Analysis based Stock Market Forecasting Model. Cornell University. <https://doi.org/https://doi.org/10.48550/arXiv.2203.08143>
- Hadna, N. M. S., Santosa, P. I., & Winarno, W. W. (2016). Studi Literatur Tentang Perbandingan Metode untuk Proses Analisis Sentimen di Twitter. Seminar Nasional Teknologi Informasi Dan Komunikasi 2016 (SENTIKA 2016).
- Hamka, M., Alfatari, N., & Sari, D. R. (2022). Analisis Sentimen Produk Kecantikan Jenis Serum Menggunakan Algoritma Naïve Bayes Classifier. Jurnal Sistem Komputer Dan Informatika (JSON), 4(September), 64–71. <https://doi.org/10.30865/json.v4i1.4740>
- Heiden, A., & Parpinelli, R. S. (2021). Applying LSTM for Stock Price Prediction with Sentiment Analysis. Congresso Brasileiro de Inteligência Computacional. <https://doi.org/10.21528/CBIC2021-45>
- Herlambang, M. Y., Kusuma, P. J., Usman, U., & Waluyo, D. E. (2024). Analisis Teknikal Saham Energi Menggunakan Indikator Macd Dan Indikator Rsi Pada Indeks Lq45. Jurnal Ilmiah Manajemen, Ekonomi, & Akuntansi (MEA), 8(2), 187–206. <https://doi.org/10.31955/mea.v8i2.4021>
- Iqbal, M., & Ningsih, N. W. (2021). Prediksi Harga Saham Harian PT BTPN Syariah Tbk Menggunakan Model Arima dan Model Garch. Jurnal Ilmiah Ekonomi Islam, 7(03), 1573 – 1580. <http://jurnal.stie-aas.ac.id/index.php/jiedoi:http://dx.doi.org/10.29040/jiei.v7i3.2795>
- Jothimani K, D., & M Afnan, M. (2024). Stocksight: A Novel Approach To Stock Price Prediction With Sentiment Analysis And LSTM Networks. *International Journal of Engineering Applied Sciences and Technology*, 9(01), 141–146.
- Julian, R., & Pribadi, M. R. (2021). Peramalan Harga Saham Pertambangan Pada Bursa Efek Indonesia (BEI) Menggunakan Long Short Term Memory (LSTM). Jurnal Teknik Informatika Dan Sistem Informasi, 8(3), 1570–1580.
- Kardian, A. R., & Gustiana, D. (2021). Analisis Sentimen Berdasarkan Opini Pengguna pada Media Twitter Terhadap BPJS Menggunakan Metode Lexicon Based dan Naïve Bayes Classifier Twitter Text Mining. Jurnal Ilmiah KOMPUTASI, 20(1), 39 – 52. <https://doi.org/http://dx.doi.org/10.32409/jikstik.20.1.401>
- Kiramy, R. Al, Permana, I., Marsal, A., Munzir, M. R., & Megawati. (2024). Comparison of RNN and LSTM Algorithm Performance in Predicting the Number of Umrah Pilgrims at PT . Hajar Aswad Perbandingan Performa Algoritma RNN dan LSTM dalam Prediksi Jumlah Jamaah Umrah pada PT . Hajar Aswad. MALCOM: Indonesian Journal of Machine Learning and Computer Science, 4(October), 1224 – 1234. <https://doi.org/https://doi.org/>

org/10.57152/malcom.v4i4.1373

- Kontan (2025). Laba Bank Mandiri capai Rp 13,2 triliun. Kontan. <https://share.google/8q82TcBIbSo3BKbqY>
- Lim, B., & Zohren, S. (2021). Time-series forecasting with deep learning : a survey
Subject Areas : Author for correspondence : The Royal Society Publishing.
- Ma, X., Tao, Z., Wang, Y., Yu, H., & Wang, Y. (2015). Long short-term memory neural network for traffic speed prediction using remote microwave sensor data. *Transportation Research Part C*, 54, 187–197. <https://doi.org/10.1016/j.trc.2015.03.014>
- Mahani, A., & Margono, H. (2021). Prediksi Sentimen Investor Pasar Modal Di Jejaring Sosial Menggunakan Text Mining. *BALANCE: Economic, Business, Management, and Accounting Journal*, XVIII(2), 32–45.
- Mahendra, J. I. (2022). Faktor-Faktor Yang Mempengaruhi Underpricing Saham Pada Saat Initial Public Offering Di Bursa Efek Indonesia. Tesis Akuntansi Universitas Sumatera Utara.
- Mardiyati, U., & Rosalina, A. (2013). Analisis Pengaruh Nilai Tukar, Tingkat Suku Bunga Dan Inflasi Terhadap Indeks Harga Saham Studi Kasus Pada Perusahaan Properti Yang Terdaftar Di Bursa Efek Indonesia. *Jurnal Riset Manajemen Sains Indonesia (JRMSI)*, 4(1), 1–15.
- Mawarsari, N., & Wardani, K. W. (2022). Pengaruh Penerapan Model Problem Based Learning terhadap Kemampuan Numerasi pada Kurikulum Merdeka Peserta Didik Kelas 1 Sekolah Dasar. *JiIP (Jurnal Ilmiah Ilmu Pendidikan)*, 5(12), 5461–5465. <https://doi.org/https://doi.org/10.54371/jiip.v5i12.1177>
- Mokosolang, G., Langi, Y. A. R., & Mananohas, M. L. (2022). Prediksi Harga Saham Kimia Farma dan Saham Netflix di Era New Normal Menggunakan Model Autoregressive Integrated Moving Average. *Jurnal Matematika Dan Aplikasi*, 11(1), 23–31. <https://ejournal.unsrat.ac.id/index.php/decartesian>
- Musfiroh, D., Khaira, U., Utomo, P. E. P., & Suratno, T. (2021). Analisis Sentimen terhadap Perkuliahan Daring di Indonesia dari Twitter Dataset Menggunakan InSet Lexicon. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 1(1), 24 – 33. <https://doi.org/https://doi.org/10.57152/malcom.v1i1.20>
- Nkongolo, A. N., Gaba, Y. O., Pierre, K. K., Mbuyi, B., & Mabela, E. M. (2025). Natural Language Processing-Based Financial Time Series Forecasting : Utilizing Sentiment Analysis for Improved Stock Price Prediction. *Journal of Innovation Information Technology and Application*, 7(1), 19–25. <https://doi.org/doi.org/10.35970/jinita.v7i1.2290>
- Nurani, A. T., Setiawan, A., & Susanto, B. (2023). Perbandingan Kinerja Regresi Decision Tree dan Regresi Linear Berganda untuk Prediksi BMI pada Dataset Asthma. *Jurnal Sains Dan Edukasi Sains*, 6(1), 34–43. <https://doi.org/https://doi.org/10.24246/juses.v6i1p34-43>
- Nurfadilah, A., Budi, W., Kurniati, E., & Suhaedi, D. (2022). Penerapan Metode Moving Average untuk Prediksi Indeks Harga Konsumen. *Jurnal*

- Matematika, 21(1), 19–25.
<https://doi.org/https://doi.org/10.29313/matematika.v21i1.337>
- Ouf, S., Hawary, M. El, Aboutabl, A., & Adel, S. (2024). A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis. (IJACSA) International Journal of Advanced Computer Science and Applications, 15(12), 207–218.
<https://doi.org/10.14569/IJACSA.2024.0151223>
- Pradiptyo, D. R., Sahid, I. H., Budi, I., Santoso, A. B., & Putra, P. K. (2024). Incorporating Stock Prices And Social Media Sentiment For Stock Market Prediction : A Case Of Indonesian Banking Company. *Jurnal Nasional Pendidikan Teknik Informatika : JANAPATI*, 13(1), 156–165.
<https://doi.org/https://doi.org/10.23887/janapati.v13i1.74486>
- Prasetyo, V. R., Lazuardi, H., Mulyono, A. A., & Lauw, C. (2021). Penerapan Aplikasi RapidMiner Untuk Prediksi Nilai Tukar Rupiah Terhadap US Dollar Dengan Metode Regresi Linier. *JITCE (Journal of Information Technology and Computer Engineering)*, 07(01), 8 – 17. <https://doi.org/https://doi.org/10.25077/TEKNOSI.v7i1.2021.8-17>
- Pratama, A. F., Kurniawan, T. B., Misinem, & Dewi, D. A. (2023). Implementasi Analisis Sentimen dan Model Deep Learning Untuk Prediksi Harga Bitcoin. *Jurnal Penelitian Ilmu Dan Teknologi Komputer*, 15(1b), 403–412.
<https://doi.org/https://doi.org/10.5281./5522/15.jupiter.2023.04>
- Pratama, Y. P. L., & Zahara, S. (2024). Prediksi Saham Bbni Dan Bbri Menggunakan Lstm (Long Short Term Memory). *Jurnal Ilmiah Teknologi Informasi Dan Sains*, 2(4), 1–4.
- Prihastomo, Y., & Winanti. (2024). Tren Perkembangan Graphical User Interface Melalui Permohonan Desain Industri di Indonesia. *Jurnal Of Community Education and Professionalism (JOCE IP)*, 18(2).
- Putra, M. P. R., & Wardani, K. R. N. (2020). Penerapan Text Mining Dalam Menganalisis Kepribadian Pengguna Media Sosial. *JUTIM (Jurnal Teknik Informatika Musirawas)*, 05(01), 63–71.
- Qiu, J., Id, B. W., & Zhou, C. (2020). Forecasting stock prices with long-short term memory neural network based on attention mechanism. *PLoS ONE*, 1–15.
<https://doi.org/https://doi.org/10.1371/journal.pone.0227222>
- Rahayu, C. A., Hartono, R., & Sudiarjo, A. (2023). Prediksi Penderita Diabetes Menggunakan Metode Naive Bayes. *Jurnal Informatika Dan Teknik Elektro Terapan*, 11(3), 261 – 266. <https://doi.org/https://doi.org/10.23960/jite.t.v11i3.3055>
- Rasyid, A., Muharam, A. B., & Solichin, A. (2025). Prediksi Harga Saham Syariah Indonesia Berdasarkan Analisis Fundamental, Teknikal Dan Bandarmology Menggunakan Metode Random Forest. *JUPI (Jurnal Ilmiah Penelitian Dan Pembelajaran Informatika)*, 10(Vol. 10, No. 2, Juni 2025, Pp. 1663–1677), 1633–1677.
<https://doi.org/https://doi.org/10.29100/jupi.v10i2.7855>
- Runimeirati, Muis, A., & Muhammad, Fi. (2023). Pelatihan Text Mining Menggunakan Bahasa Pemrograman Python. *JURNAL PENGABDIAN*

- KEPADA MASYARAKAT, 3(1). <https://doi.org/https://doi.org/10.53769/jpm.v3i1.83>
- Rupadevi, B., & Nadheem, S. (2025). Predicting Stock Prices with Investor Sentiment and Deep Learning Techniques. *International Scientific Journal of Engineering and Management (ISJEM)*, 04(04), 1–7. <https://doi.org/10.55041/ISJEM02926>
- Seno, N. M. L. I., & Kamila, I. (2022). METODE DOUBLE EXPONENTIAL SMOOTHING DALAM INTERVAL. *Jurnal Ilmiah Matematika*, 2(1), 23–31. <https://doi.org/10.33751/interval.v2i1.5163>
- Sholikah, F. P., Putri, W., & Djangi, R. M. (2022). Peranan Pasar Modal Dalam Perekonomian Negara Indonesia. *ARBITRASE: Journal of Economics and Accounting*, 3(2), 341–345. <https://doi.org/10.47065/arbitrase.v3i2.496>
- Silalahi, R. N., & Muljono. (2024). Perbandingan Kinerja Metode Linear Regression , LSTM dan GRU untuk Prediksi Harga Penutupan Saham Coca-Cola Performance Comparison Of Linear Regression , LSTM & GRU Methods For Coca-Cola Stock Closing Price Prediction. *Komputika: Jurnal Sistem Komputer*, 13(2), 201 – 211. <https://doi.org/10.34010/komputika.v13i2.12265>
- Sina, M. N. I., & Setiawan, E. B. (2023). Stock Price Correlation Analysis with Twitter Sentiment Analysis Using The CNN-LSTM Method. *Sinkron : Jurnal Dan Penelitian Teknik Informatika*, 7(4), 2190–2202. <https://doi.org/https://doi.org/10.33395/sinkron.v8i4.12855>
- Sirait, R. A., Miyandini, R., Ditama, A. Y., & Azmi, Z. (2024). Analisis Faktor-Faktor Yang Mempengaruhi Harga Saham (Systematic Literature Review). *BISMA: Business and Management Journal*, 2(1), 11–20.
- Sujjada, A., Sembiring, F., & Febriansyah. (2024). Prediksi Harga Bitcoin Menggunakan Algoritma Long ShortTerm Memory. *Jurnal INOVTEK Polbeng*, 9(1), 450–459. <https://doi.org/https://doi.org/10.35314/isi.v9i1.4247>
- Supriyanto, Y., Ilhamsyah, M., & Enri, U. (2022). Prediksi Harga Minyak Kelapa Sawit Menggunakan Linear Regression Dan Random Forest. *Jurnal Ilmiah Wahana Pendidikan*, 8(7), 178 – 185. <https://doi.org/https://doi.org/10.5281/zenodo.6559603>
- Syafa'ah, L., & Lestandy, M. (2021). Penerapan Deep Learning untuk Prediksi Kasus Aktif Covid-19. *Jurnal Sains Komputer & Informatika (J-SAKTI)*, 5(1), 453–457.
- Tarigan, R. E. (2013). Peranan Sistem Informasi Dengan Online Trading Terhadap Pertumbuhan Pasar Modal Di Indonesia. *ComTech: Computer, Mathematics and Engineering Applications*, 4(2), 803 – 811. <https://doi.org/https://doi.org/10.21512/comtech.v4i2.2517>
- Tarumingkeng, R. C. (2024). Deep learning.
- Thormann, M.-L., Farchmin, J., Weisser, C., Kruse, R.-M., Safken, B., & Silbersdorff, A. (2021). Stock Price Predictions with LSTM Neural Networks and Twitter Sentiment. *STATISTICS, OPTIMIZATION AND INFORMATION COMPUTING*, 9, 268–287. <https://doi.org/10.19139/soic-2310-5070->

1202

- TradingView. (2025). IDX: BMRI — Bank Mandiri chart & data. from <https://id.tradingview.com/symbols/IDX-BMRI/>
- Undap, M. G., Rantung, V. P., & Rompas, P. T. D. (2021). Analisis Sentimen Situs Pembajak Artikel Penelitian Menggunakan Metode Lexicon-Based. *JOINTER-JOURNAL OF INFORMATICS ENGINEERING*, 02(02), 39–46. <https://doi.org/https://doi.org/10.53682/jointer.v2i02.44>
- Urlam, S., Ghosh, B., & Suresh, A. (2021). Stock Market Prediction Using LSTM and Sentiment Analysis. *Turkish Journal of Computer and Mathematics Education*, 12(11), 4653–4659.
- Wahyudi, R., & Kusumawardhana, G. (2021). Analisis Sentimen pada review Aplikasi Grab di Google Play Store Menggunakan Support Vector Machine. *JURNAL INFORMATIKA*, 8(2), 200–207.
- Wahyuzi, Z. (2024). Analisis dan Prediksi Konsumsi Listrik Smart Office Berbasis IoT Terhadap Faktor Internal dan Eksternal Menggunakan Deep Learning. <https://dspace.uui.ac.id/bitstream/handle/123456789/50562/22917021.pdf?sequence=1&isAllowed=y>
- Yan, Y., Nie, X., Wang, M., & Chen, Y. (2023). LSTM-based Stock Price Prediction Model using News Sentiments 2 . Construction of News Sentiment Indicators Based on Financial News Data. *Advances in Economics and Management Research*, 6, 57–65.
- Yulastuti, G. E., Wardhana, S. R., & Maulana, A. (2024). Penerapan Insert-Lexicon untuk Analisis Sentimen Kenaikan Harga BBM pada Media Sosial Twitter. *Jurnal Teknologi Informasi Dan Komunikasi*, 19(100), 93–100. <https://doi.org/https://doi.org/10.33005/scan.v19i2.4730>