

**ANALISIS SENTIMEN PENGGUNA PLATFORM X
TERHADAP GAME ROBLOX PADA KOMUNITAS
ROBLOX INDONESIA MENGGUNAKAN
INDOBERTWEET DAN PEMODELAN
TOPIK BERTOPIC**

PROPOSAL PENELITIAN



**NADIATUL MAWADDAH
F1E122072**

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI
2026**

**ANALISIS SENTIMEN PENGGUNA PLATFORM X
TERHADAP GAME ROBLOX PADA KOMUNITAS
ROBLOX INDONESIA MENGGUNAKAN
INDOBERTWEET DAN PEMODELAN
TOPIK BERTOPIC**

PROPOSAL PENELITIAN

Diajukan sebagai salah satu syarat untuk memperoleh Gelar Sarjana pada
Program Studi Sistem Informasi



**NADIATUL MAWADDAH
F1E122072**

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI
2026**

HALAMAN PENGESAHAN

PROPOSAL SKRIPSI

ANALISIS SENTIMEN PENGGUNA PLATFORM X TERHADAP GAME ROBLOX PADA KOMUNITAS ROBLOX INDONESIA MENGGUNAKAN INDOBERTWEET DAN PEMODELAN TOPIK BERTOPIC

Oleh:

**Nadiatul Mawaddah
F1E122072**

Disetujui:

Pembimbing Utama

Pembimbing Pendamping

Rizqa Raaiqa Bintana, S.T., M.Kom.
NIP. 199001202019032012

Mutia Fadhila Putri, M.Kom.
NIP. 199612162022032016

Diketahui:

Dekan Fakultas Sains
dan Teknologi

Ketua Jurusan Teknik Elektro
dan Informatika

Drs. Jefri Marzal, M.Sc., D.I.T.
NIP. 196806021993031004

Edi Saputra, S.T., M.Sc.
NIP. 198501082015041003

DAFTAR ISI

HALAMAN PENGESAHAN	iii
DAFTAR GAMBAR	v
DAFTAR TABEL	vi
I. PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Tujuan Penelitian	3
1.4. Manfaat Penelitian	3
1.5. Batasan Penelitian	3
II. TINJAUAN PUSTAKA	5
2.1. Platform X	5
2.2. Roblox	5
2.3. <i>Natural Language Processing</i> (NLP)	6
2.4. <i>Text Mining</i>	7
2.5. Analisis Sentimen	8
2.6. <i>Pre-Processing Text</i>	8
2.7. Teknik Pengumpulan Data	9
2.8. BERT	11
2.9. IndoBERTweet	12
2.10. Pemodelan Topik	13
2.11. BERTopic	15
2.12. Visualisasi Data	16
2.13. Penelitian Terdahulu	18
III. METODOLOGI PENELITIAN	26
3.1. Tempat dan Waktu Penelitian	26
3.2. Bahan dan Alat Penelitian	26
3.3. Tahapan Penelitian	26
DAFTAR PUSTAKA	46

DAFTAR GAMBAR

Gambar 1. Prosedur <i>Pre-Training & Fine-Tuning</i> pada BERT	11
Gambar 2. Contoh Visualisasi Data <i>Word Cloud</i>	17
Gambar 3. Alur Penelitian	27
Gambar 4. Komunitas Roblox Indonesia	28
Gambar 5. Hasil <i>Scraping</i>	28
Gambar 6. <i>Pre-Processing</i> Data.....	30
Gambar 7. Tahap Klasifikasi IndoBERTWEET.....	32
Gambar 8. Tahap Alur Pemodelan Topik BERTopic	37
Gambar 9. Contoh Visualisasi data word cloud.....	40

DAFTAR TABEL

Tabel 1. Penelitian Terdahulu	18
Tabel 2. Contoh Pelabelan Data.....	29
Tabel 3. Contoh Hasil <i>Cleaning Data</i>	30
Tabel 4. Contoh Hasil <i>Case Folding</i>	31
Tabel 5. Contoh Hasil Normalisasi	31
Tabel 6. Contoh Hasil <i>Tokenizing</i> dan <i>Encoding</i>	33
Tabel 7. <i>Confusion Matrix</i> Klasifikasi Sentimen (3 Kelas)	34

I. PENDAHULUAN

1.1. Latar Belakang

Platform X yang sebelumnya Twitter telah berkembang menjadi salah satu ruang komunikasi digital terbesar yang memengaruhi dinamika sosial, budaya, dan interaksi publik di berbagai negara, termasuk Indonesia. Studi sosiologis mencatat bahwa X (Twitter) merupakan platform yang mampu membentuk wacana sosial melalui arus informasi yang cepat, sifat komunikasi *real time*, dan struktur percakapan yang memungkinkan penyebaran opini publik secara luas (Murthy, 2025a). Sejak diperkenalkannya fitur Komunitas, pengguna semakin mudah terhubung berdasarkan minat tertentu sehingga diskusi yang tercipta menjadi lebih terarah dan berfokus pada satu topik spesifik. Salah satu komunitas yang aktif adalah Komunitas Roblox Indonesia, tempat para pemain, kreator, dan penggemar Roblox membagikan pengalaman bermain, pendapat, serta berbagai reaksi terhadap perkembangan game tersebut. Percakapan yang muncul dalam komunitas ini bersifat organik dan mencerminkan persepsi riil pengguna Indonesia, sehingga menjadi sumber data yang relevan untuk dianalisis menggunakan pendekatan komputasi modern.

Roblox sendiri merupakan platform permainan dan kreasi digital berbasis metaverse yang menyediakan lingkungan virtual bagi pengguna untuk bermain, belajar, berinteraksi sosial, hingga menciptakan konten digital mereka sendiri. Dalam penelitian sebelumnya, Roblox disebut sebagai salah satu platform game-metaverse terbesar di dunia, dengan jutaan pengguna aktif dan kemampuan untuk mendukung aktivitas kolaboratif serta pengembangan kreativitas digital penggunanya (Alhasan et al., 2023). Selain sebagai game, Roblox telah digunakan dalam lingkungan pendidikan, media sosial, hingga ruang virtual dimana pengguna, terutama remaja, berkomunikasi dan membangun identitas digital mereka (Julio Salas, 2023). Studi lainnya menunjukkan bahwa Roblox memiliki delapan elemen kunci metaverse seperti identitas, imersivitas, interaksi sosial, hingga ekonomi virtual yang menjadikannya ekosistem digital dinamis yang sangat menarik untuk diteliti dalam konteks perilaku pengguna online (Han et al., 2023a). Besarnya peran Roblox dalam interaksi digital menjadikan platform ini sering dibahas dalam Komunitas Roblox Indonesia di X (Twitter), baik dalam bentuk apresiasi, kritik, keluhan, maupun saran terhadap fitur tertentu.

Aktivitas diskusi dalam komunitas tersebut memperlihatkan bahwa pengguna Indonesia memiliki pengalaman yang beragam terhadap Roblox. Ada pemain yang merasa puas terhadap kreativitas tanpa batas dan akses komunitas yang luas, tetapi ada pula yang mengungkapkan kekhawatiran terkait keamanan, masalah teknis, interaksi sosial negatif, hingga isu ekonomi digital seperti mikrotransaksi Robux. Hal ini sejalan dengan penelitian terdahulu yang menunjukkan bahwa percakapan media sosial mengandung emosi dan opini publik yang kompleks, sehingga analisis sentimen diperlukan untuk memetakan persepsi masyarakat secara objektif (Nugraha & Febriani, 2025a). Studi analisis sentimen terhadap ulasan Roblox berbahasa Indonesia memperkuat hal tersebut dengan menunjukkan adanya distribusi sentimen positif, negatif, dan netral berdasarkan pengalaman pemain terhadap fitur maupun kualitas permainan tertentu (Randy Suryono, 2025). Dengan demikian, opini pengguna yang muncul dalam Komunitas Roblox Indonesia memiliki nilai informatif yang tinggi untuk dianalisis secara ilmiah.

Untuk menganalisis sentimen pengguna dari teks di platform X (Twitter), diperlukan pendekatan pemrosesan bahasa alami (NLP) yang sesuai dengan karakteristik bahasa Indonesia di media sosial yang cenderung informal, singkat, menggunakan singkatan, emotikon, campuran bahasa, dan struktur kalimat tidak baku. Model IndoBERTweet merupakan salah satu model terbaik yang dirancang secara khusus untuk data X (Twitter) berbahasa Indonesia, dan penelitian membuktikan bahwa model ini memiliki tingkat akurasi lebih tinggi dibandingkan IndoBERT dalam tugas klasifikasi berbasis teks media sosial (Khairani, 2024). Selain itu, dalam konteks tekstual Indonesia bertema Roblox, model berbasis transformer seperti IndoBERT terbukti berperforma baik, dan bahkan mampu ditingkatkan dengan teknik seperti SMOTE dalam menangani ketidakseimbangan data sentimen, menghasilkan peningkatan akurasi yang signifikan dalam klasifikasi sentimen ulasan Roblox (Randy Suryono, 2025). Oleh karena itu, penggunaan IndoBERTweet sangat relevan untuk menganalisis sentimen pengguna dalam komunitas Roblox Indonesia di X (Twitter).

Selain sentimen, pemahaman mengenai isu utama yang dibicarakan pengguna dalam komunitas juga diperlukan. Metode BERTopic adalah salah satu pendekatan pemodelan topik berbasis embedding yang efektif dalam menemukan tema percakapan secara otomatis dari data dalam jumlah besar. Studi terkait pemodelan topik pada platform X (Twitter) menunjukkan bahwa BERTopic dapat memetakan topik secara akurat dan memberikan wawasan mendalam mengenai pola diskusi pengguna, terutama dalam konteks isu publik dan tren digital (Muhammad Rayhan Nur et al., 2025a). Dengan menggabungkan analisis sentimen menggunakan IndoBERTweet dan pemodelan topik menggunakan BERTopic, penelitian ini dapat memberikan gambaran menyeluruh mengenai persepsi dan dinamika percakapan pemain Roblox Indonesia dalam platform X (Twitter).

Meskipun terdapat banyak penelitian terkait Roblox, seperti dampak pendidikan, interaksi sosial pemain, potensi metaverse, maupun perilaku komunikasi remaja, belum ditemukan penelitian yang secara spesifik menganalisis sentimen dan topik dalam Komunitas Roblox Indonesia pada platform X (Twitter). Sebagian besar studi sebelumnya berfokus pada lingkungan pendidikan, ulasan aplikasi, atau studi perilaku digital secara umum, bukan pada percakapan *real time* yang muncul dalam ruang komunitas terfokus seperti di X (Twitter) (Alhasan et al., 2023) & (Khaerunisa, 2025a). Sebaliknya, penelitian analisis sentimen di Indonesia lebih banyak berfokus pada isu lain seperti hiburan, kebijakan pemerintah, dan peristiwa viral sehingga konteks game online khususnya Roblox masih kurang dieksplorasi (Damayanti, 2025a). Oleh karena itu, penelitian ini mengisi kekosongan ilmiah dengan mengkaji bagaimana sentimen dan topik terkait Roblox terbentuk dalam komunitas pemain Indonesia di X (Twitter).

Berdasarkan latar belakang di atas, penelitian ini dilakukan untuk menganalisis sentimen pengguna terhadap game Roblox melalui percakapan yang berlangsung dalam Komunitas Roblox Indonesia di platform X (Twitter). Peneliti berfokus pada bagaimana sentimen tersebut dapat diklasifikasikan secara akurat menggunakan model IndoBERTweet yang telah terbukti unggul dalam memproses bahasa media sosial, serta bagaimana isu-isu utama dalam komunitas tersebut dapat diidentifikasi melalui pemodelan topik menggunakan BERTopic. Melalui pendekatan ini, peneliti berupaya memperoleh gambaran

menyeluruh mengenai persepsi dan dinamika diskusi para pemain Roblox di Indonesia, baik dari segi kecenderungan opini maupun tema-tema yang paling sering dibahas dalam komunitas. Maka, dari uraian tersebut peneliti tertarik untuk mengkaji lebih lanjut mengenai “ANALISIS SENTIMEN PENGGUNA PLATFORM X TERHADAP GAME ROBLOX PADA KOMUNITAS ROBLOX INDONESIA MENGGUNAKAN INDOBERTWEET DAN PEMODELAN TOPIK BERTOPIC.”

1.2. Rumusan Masalah

Berdasarkan uraian latar belakang, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana hasil klasifikasi sentimen pengguna platform X (Twitter) terhadap game Roblox pada komunitas Roblox Indonesia menggunakan model IndoBERTweet ?
2. Apa saja topik dominan yang muncul dalam percakapan komunitas Roblox Indonesia di platform X (Twitter) menggunakan pemodelan BERTopic ?

1.3. Tujuan Penelitian

Adapun tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut :

1. Untuk mengidentifikasi sentimen pengguna terhadap game Roblox di Indonesia melalui analisis komunitas di media sosial menggunakan model IndoBERTweet.
2. Untuk mengetahui topik yang dominan muncul dalam percakapan komunitas Roblox Indonesia di platform X (Twitter) menggunakan pemodelan BERTopic.

1.4. Manfaat Penelitian

Hasil penelitian ini di harapkan bermanfaat untuk :

1. Memberikan hasil analisis yang dapat digunakan sebagai rujukan dalam pengembangan penelitian selanjutnya, khususnya terkait penggunaan metode IndoBERTweet dan BERTopic dalam kajian analisis sentimen pada media sosial.
2. Menyediakan gambaran yang jelas mengenai kecenderungan sentimen pengguna platform X (Twitter) terhadap game Roblox pada komunitas Roblox Indonesia, baik yang bersifat positif, negatif, maupun netral.

1.5. Batasan Penelitian

Batasan masalah dalam penelitian ini adalah :

1. Penelitian ini menggunakan data berupa cuitan publik di platform X (Twitter) yang berkaitan dengan game Roblox dan komunitas Roblox Indonesia sebagai sampel dalam proses analisis sentimen.
2. Penelitian ini tidak membahas faktor-faktor yang memengaruhi opini pengguna, melainkan berfokus pada proses dan hasil klasifikasi sentimen yang dihasilkan oleh metode IndoBERTweet serta topik yang diidentifikasi menggunakan BERTopic.
3. Hasil penelitian ini diarahkan untuk menghasilkan informasi mengenai pola sentimen dan topik pembahasan utama dalam komunitas Roblox Indonesia di platform X (Twitter), tanpa melakukan evaluasi terhadap konteks psikologis maupun karakteristik demografis pengguna.

II. TINJAUAN PUSTAKA

2.1. Platform X

Platform X, yang sebelumnya dikenal sebagai Twitter, merupakan platform mikroblogging yang memungkinkan pengguna membagikan pesan singkat secara publik dan mengikuti percakapan secara *real time*. Dalam kajian sosiologi digital, platform ini dipandang sebagai ruang komunikasi yang penting karena banyak digunakan untuk membangun komunitas, berbagi informasi, serta merespons berbagai isu sosial yang berkembang di masyarakat (Murthy, 2025). Penelitian-penelitian di bidang sosiologi juga menunjukkan bahwa data dari Twitter sering dimanfaatkan untuk memahami perilaku pengguna, dinamika komunitas, hingga pola komunikasi digital dalam berbagai konteks seperti sosial, politik, dan budaya.

Dari sisi pengalaman pengguna, penelitian mengenai interaksi di X (Twitter) memperlihatkan bahwa pengguna sering menyesuaikan cara mereka berkomunikasi berdasarkan siapa yang mereka bayangkan sebagai audiens. Pengguna memanfaatkan platform ini sebagai sarana untuk menjaga hubungan sosial, mengekspresikan diri, atau sekadar menyampaikan pendapat kepada pengikut mereka, sehingga percakapan yang muncul dapat mencerminkan proses sosial yang berlangsung di ruang digital (Marwick & Boyd, 2011). Sementara itu, laporan resmi X (Twitter) menjelaskan bahwa platform ini memiliki infrastruktur berskala besar dan menyediakan berbagai fitur seperti hashtag, retweet, pencarian topik, serta akses API yang memungkinkan peneliti mengumpulkan data publik dari platform secara sistematis (Twitter, 2019). Dengan karakteristik tersebut, Platform X (Twitter) menjadi sumber data yang relevan dalam penelitian ini untuk menganalisis percakapan yang terjadi dalam Komunitas Roblox Indonesia.

2.2. Roblox

Roblox merupakan platform permainan dan ruang virtual imersif yang memungkinkan pengguna bermain, berinteraksi, serta menciptakan pengalaman digital melalui ekosistem berbasis konten buatan pengguna. Laporan resmi perusahaan mencatat bahwa Roblox memiliki 82,9 juta pengguna aktif harian, 73,5 miliar jam keterlibatan pada tahun 2024, serta lebih dari 14 juta pengalaman aktif yang dapat dijelajahi oleh pemain di seluruh dunia (Roblox, 2025a). Kinerja ini menunjukkan pertumbuhan yang stabil, dan pada awal 2025 platform kembali mengalami peningkatan pada metrik keterlibatan serta indikator finansial (Roblox, 2025). Pertumbuhan tersebut menegaskan bahwa Roblox merupakan salah satu platform interaktif terbesar di pasar global.

Sebagai ekosistem *metaverse*, Roblox menyediakan lingkungan virtual yang bersifat kolaboratif, kreatif, dan terbuka. Platform ini mencatat peningkatan jumlah pengguna dari 12 juta pada tahun 2018 menjadi 42,1 juta pada tahun 2021, serta memiliki lebih dari 150 juta pengguna aktif bulanan. Selain itu, lebih dari 54,86% penggunanya merupakan anak di bawah usia 13 tahun, sehingga Roblox menjadi ruang interaksi digital yang dominan bagi generasi muda (Han et al., 2023). Pengguna dapat bertemu, berkomunikasi, membangun jejaring sosial,

serta membuat dunia virtual mereka sendiri menggunakan Roblox Studio, menjadikan platform ini tidak hanya sebagai media hiburan tetapi juga sarana untuk berekspresi dan berkolaborasi.

Roblox juga memberi dampak signifikan dalam bidang sosial, pendidikan, dan ekonomi digital. Platform ini mendukung kreativitas, literasi digital, serta kemampuan kolaboratif melalui pembuatan konten, interaksi sosial berbasis avatar, dan aktivitas pembelajaran berbasis simulasi. Pengguna dapat memonetisasi karya mereka melalui ekosistem ekonomi Roblox, sehingga membuka peluang komersial bagi kreator di dalam platform (Khaerunisa, 2025b). Dengan komunitas pengguna yang besar dan aktivitas interaksi yang beragam, Roblox menjadi topik yang banyak diperbincangkan di media sosial, termasuk pada Komunitas Roblox Indonesia di Platform X (Twitter). Percakapan tersebut mencerminkan pengalaman dan persepsi pemain, sehingga relevan dijadikan sumber data dalam analisis sentimen dan pemodelan topik.

2.3. Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan cabang kecerdasan buatan yang berfokus pada bagaimana komputer dapat memahami, memproses, dan menghasilkan bahasa manusia secara efektif. Salah satu tahapan awal dalam NLP adalah pra-pemrosesan teks, yang bertujuan menyiapkan data mentah agar dapat diolah secara optimal oleh model. Tahapan ini mencakup proses seperti pembersihan teks, normalisasi, pengubahan huruf (*case folding*), dan tokenisasi yang membantu mengurangi gangguan linguistik serta variasi penulisan. Penelitian menegaskan bahwa kualitas analisis NLP sangat bergantung pada kualitas pra-pemrosesan, terutama ketika data berasal dari sumber tidak terstruktur seperti media sosial yang banyak mengandung bahasa informal (Cunningham et al., 2025). Setelah melalui tahap ini, teks dapat dipetakan ke dalam representasi linguistik yang lebih terstruktur melalui teknik seperti *lemmatization* dan *part-of-speech tagging*.

Pada tahap pemahaman yang lebih dalam, NLP mengandalkan kemampuan *Natural Language Understanding (NLU)* untuk mengenali struktur sintaksis, konteks, dan hubungan semantik dalam teks. Teknik seperti *syntactic parsing*, analisis konteks, dan pemetaan token membantu komputer memahami makna yang tersirat meskipun kalimat memiliki struktur kompleks atau ambigu (Jane, 2025). Sebaliknya, *Natural Language Generation (NLG)* memfasilitasi komputer dalam menghasilkan teks baru yang koheren dan kontekstual berdasarkan informasi yang tersedia. Model NLG modern berbasis transformer telah digunakan dalam berbagai aplikasi seperti pembuatan ringkasan otomatis, sistem tanya jawab, dan penyusunan teks medis secara otomatis (Blake et al., 2025). Dengan keberadaan NLU dan NLG, sistem NLP mampu bekerja dua arah, memahami masukan dari pengguna dan menghasilkan keluaran yang menyerupai bahasa manusia.

Selain tugas memahami dan menghasilkan bahasa, NLP juga diterapkan dalam berbagai proses lanjutan seperti klasifikasi teks, analisis sentimen, dan *Named Entity Recognition (NER)*. Klasifikasi teks membantu mengelompokkan dokumen berdasarkan pola linguistik dan fitur semantik, sehingga memudahkan proses analisis yang membutuhkan pengelompokan otomatis. Analisis sentimen digunakan untuk mengidentifikasi opini atau emosi dalam teks, yang sangat penting dalam membaca persepsi publik pada platform digital. Sementara itu, NER membantu mengenali entitas seperti nama orang, lokasi, atau istilah khusus

dalam teks panjang sehingga informasi dapat diekstraksi secara efisien (Hart et al., 2025). Ketiga tugas tersebut memperlihatkan bagaimana NLP tidak hanya memahami struktur bahasa, tetapi juga mampu mengidentifikasi makna, pola, dan informasi yang terkandung di dalamnya.

Pada tingkat penerapan yang lebih luas, NLP digunakan untuk mengekstraksi informasi dari dokumen medis, merangkum temuan ilmiah, maupun membaca pola ancaman pada laporan keamanan siber. Penelitian menunjukkan bahwa NLP berperan penting dalam membantu tenaga medis memahami catatan pasien secara lebih cepat dan akurat melalui teknik ekstraksi konsep medis (Wadkar et al., 2025). Di bidang keamanan digital, NLP digunakan untuk menganalisis teks yang berkaitan dengan aktivitas ancaman, sehingga membantu deteksi dini serangan siber dan penguatan sistem keamanan (Lent et al., 2025). Selain itu, NLP juga diterapkan untuk merangkum dokumen penelitian besar, mengorganisasi data ilmiah, dan mendukung proses penemuan pengetahuan dari teks tidak terstruktur (Blake et al., 2025). Meskipun memiliki manfaat luas, tantangan seperti bias data, ketidakseragaman bahasa informal, serta keterbatasan interpretabilitas model masih menjadi perhatian penting dalam pengembangannya.

2.4. Text Mining

Text mining merupakan pendekatan analitis yang berfokus pada pemrosesan teks tidak terstruktur untuk menemukan pola, informasi, dan pengetahuan baru dari kumpulan dokumen dalam jumlah besar. Perkembangan digitalisasi telah membuat data berbentuk teks meningkat secara signifikan, sehingga *text mining* menjadi metode penting untuk mengubah data mentah menjadi informasi terstruktur yang dapat dianalisis secara komputasional. Dalam konteks ini, *text mining* menggabungkan teknik linguistik, statistika, dan pembelajaran mesin untuk memungkinkan peneliti mengolah teks dalam skala besar dengan lebih efisien dibandingkan analisis manual (Hassani et al., 2020).

Proses *text mining* diawali dengan tahap *pre-processing*, yaitu pembersihan dan penyiapan teks agar berada dalam bentuk yang konsisten. Tahap ini meliputi tokenisasi, normalisasi huruf, penghapusan *stopwords*, *stemming*, dan pembentukan representasi numerik seperti *term-frequency* atau TF-IDF. Representasi ini memungkinkan teks diubah menjadi matriks fitur sehingga pola linguistik dapat dianalisis lebih sistematis. Dalam penelitian inovasi dan manajemen, tahapan ini merupakan langkah fundamental karena kualitas pra-pemrosesan sangat memengaruhi hasil analisis lanjutan seperti klasifikasi, klasterisasi, atau pemodelan topik (Antons et al., 2020).

Selain itu, *text mining* juga dapat digunakan untuk memahami karakteristik wacana dalam dokumen melalui teknik pembobotan kata dan analisis struktur teks. Metode seperti pengukuran elaborasi, analisis *part-of-speech*, serta identifikasi kata-kata bermakna memungkinkan peneliti mengevaluasi seberapa detail atau seberapa luas suatu ide dijelaskan dalam teks. Pendekatan tersebut tidak hanya memberikan wawasan tentang isi dokumen, tetapi juga membantu mengukur kualitas penjelasan atau ekspresi gagasan dalam penelitian berbasis teks (Dumas et al., 2020). Dengan cakupan metode yang luas, *text mining* menjadi landasan penting dalam berbagai aplikasi analitis, termasuk analisis sentimen, klasifikasi opini, dan pemodelan topik.

2.5. Analisis Sentimen

Analisis sentimen merupakan metode yang digunakan untuk mengetahui sikap atau emosi yang terkandung dalam sebuah teks, seperti apakah isi tulisan cenderung positif, negatif, ataupun netral. Metode ini banyak digunakan karena media sosial menghasilkan data opini dalam jumlah besar yang sulit dianalisis secara manual. Dengan analisis sentimen, peneliti dapat memahami bagaimana pandangan pengguna terhadap suatu topik dengan lebih cepat dan terstruktur. Menurut literatur, analisis sentimen bertujuan mengidentifikasi opini, emosi, serta subjektivitas dalam teks dengan memakai teknik NLP dan pembelajaran mesin (Wankhade et al., 2022).

Dalam perkembangannya, analisis sentimen dapat dilakukan menggunakan berbagai pendekatan seperti metode leksikon, model machine learning, hingga model deep learning modern. Metode *machine learning* seperti *Support Vector Machine* dan *naïve Bayes* terbukti efektif, namun masih memiliki keterbatasan dalam memahami konteks kalimat. Karena itu, model berbasis transformer seperti BERT mulai banyak digunakan karena mampu membaca hubungan antar kata dalam konteks yang lebih luas, sehingga hasil klasifikasinya menjadi lebih akurat, terutama pada teks media sosial yang sering bersifat informal (Tan et al., 2023). Selain itu, penelitian terbaru juga mengembangkan analisis sentimen multimodal, yaitu analisis yang tidak hanya mengandalkan teks tetapi juga gambar atau suara untuk memahami emosi secara lebih utuh (Das & Singh, 2023).

Proses analisis sentimen biasanya meliputi tahap pengumpulan data, pra-pemrosesan teks, representasi fitur, dan klasifikasi polaritas. Tahapan pra-pemrosesan dilakukan untuk memastikan teks berada dalam kondisi bersih dan mudah dibaca oleh model. Setelah itu, teks dikonversi menjadi fitur seperti TF-IDF atau embedding agar dapat diproses oleh model klasifikasi. Literatur menjelaskan bahwa tahapan-tahapan ini merupakan struktur dasar analisis sentimen yang banyak digunakan di berbagai penelitian (Umar, 2021). Pada penelitian ini, analisis sentimen digunakan untuk melihat bagaimana pengguna platform X (Twitter) memberikan tanggapan terhadap game Roblox pada komunitas Roblox Indonesia, sehingga dapat diketahui kecenderungan opini yang muncul di ruang diskusi daring.

2.6. Pre-Processing Text

Pre-processing text merupakan tahap awal yang sangat penting dalam pengolahan data teks karena berfungsi menyiapkan teks mentah menjadi bentuk yang lebih bersih, terstruktur, dan siap untuk dianalisis. Teks yang berasal dari media sosial cenderung memiliki banyak variasi penulisan, termasuk penggunaan emoji, singkatan, bahasa gaul, hingga kesalahan penulisan yang dapat mengganggu proses analisis. Oleh karena itu, *pre-processing* diperlukan untuk mengurangi *noise* dan meningkatkan kualitas representasi teks sebelum masuk ke tahap pembobotan maupun pemodelan. Penelitian sebelumnya menunjukkan bahwa *pre-processing* yang tepat dapat meningkatkan kinerja model analisis sentimen secara signifikan, terutama pada data yang bersifat informal (Palomino & Aider, 2022).

Secara umum, tahapan *pre-processing* teks yang digunakan adalah sebagai berikut:

1. *Cleaning*, yaitu menghapus elemen-elemen tidak relevan seperti emoji, mention (@username), URL, angka, dan simbol lain yang tidak diperlukan.

Langkah ini penting untuk menghindari adanya gangguan pada proses analisis dan menjaga konsistensi teks (Vel, 2021)

2. *Case Folding*, yaitu mengubah seluruh huruf menjadi huruf kecil agar konsistensi penulisan terjaga dan model tidak memperlakukan kata yang sama sebagai entitas berbeda hanya karena perbedaan kapitalisasi.
3. Normalisasi, yaitu mengganti kata tidak baku, singkatan, atau bahasa gaul menjadi bentuk standar sehingga variasi penulisan tidak menambah noise dalam representasi teks. Langkah ini sangat relevan untuk data media sosial yang banyak mengandung bahasa informal (Tabassum & Patil, 2020).
4. *Tokenizing*, yaitu memecah teks menjadi token berupa kata atau sub-kata sehingga dapat diproses lebih lanjut pada tahap ekstraksi fitur atau pemodelan berbasis transformer seperti IndoBERTweet (Palomino & Aider, 2022).
5. *Stopword Removal*, yaitu proses menghapus kata-kata umum yang sering muncul namun tidak memiliki kontribusi signifikan terhadap analisis sentimen, seperti kata hubung dan kata keterangan tertentu. Tujuan tahap ini adalah untuk memfokuskan analisis pada kata-kata yang lebih informatif.
6. *Stemming* atau *Lemmatization*, yaitu proses mengubah kata berimbuhan menjadi bentuk kata dasar. Tahap ini bertujuan untuk menyatukan berbagai bentuk kata yang memiliki makna serupa sehingga representasi teks menjadi lebih sederhana dan konsisten (Mao et al., 2022).

Namun, tidak seluruh tahapan *pre-processing* tersebut diterapkan dalam penelitian ini. Berdasarkan karakteristik data yang digunakan serta kebutuhan model analisis sentimen berbasis *transformer*, penelitian ini hanya menerapkan tahapan *cleaning*, *case folding*, normalisasi, dan *tokenizing*. Tahapan *stopword removal* serta *stemming* atau *lemmatization* tidak digunakan untuk menjaga konteks dan makna asli teks, terutama karena model yang digunakan mampu menangkap informasi kontekstual secara lebih efektif. Tahap-tahap tersebut dipilih untuk meningkatkan kualitas teks serta hasil klasifikasi pada berbagai penelitian *text mining* dan analisis sentimen. Dengan melakukan *pre-processing*, struktur teks menjadi lebih seragam, informasi penting tetap terjaga, dan model dapat membaca konteks secara lebih efektif. Pendekatan ini menjadi dasar penting sebelum memasuki tahapan lanjutan seperti pembobotan kata, representasi vektor, ataupun klasifikasi sentimen, sehingga hasil analisis dapat diperoleh secara lebih akurat dan dapat dipertanggungjawabkan secara metodologis (Mao et al., 2022).

2.7. Teknik Pengumpulan Data

Teknik pengumpulan data merupakan langkah awal dalam penelitian untuk memperoleh data yang relevan dan dapat dianalisis lebih lanjut. Pada penelitian berbasis teks dari platform digital, metode pengumpulan data perlu dipilih dengan mempertimbangkan karakteristik sumber data dan kebutuhan penelitian. Dua teknik yang sering digunakan dalam pengumpulan data dari web adalah *web scraping* dan *web crawling*. Meskipun keduanya sama-sama bertujuan untuk memperoleh data dari internet, keduanya memiliki perbedaan mendasar dalam fungsi dan cara kerjanya.

Web Scrapping

Web scraping adalah teknik pengambilan data dari halaman web secara otomatis dengan mengekstraksi konten tertentu dan mengubahnya menjadi data terstruktur. Dalam penelitian sebelumnya, *scraping* dijelaskan sebagai proses mengambil informasi penting dari web menggunakan pendekatan pengambilan data yang diotomatisasi dan menyimpannya dalam bentuk yang dapat diproses lebih lanjut, misalnya *spreadsheet* atau CSV (Alhafiz & Adiguna, 2024). Proses ini bekerja dengan membaca struktur HTML halaman web dan memilih elemen yang dibutuhkan, seperti teks, angka, atau metadata, melalui metode seperti HTML parsing atau CSS *selector*.

Selain itu, penelitian lain menjelaskan bahwa *scraping* memungkinkan sistem mengakses halaman web dan mengumpulkan informasi tanpa harus melakukannya secara manual, sehingga teknik ini sangat efisien untuk penelitian yang membutuhkan data publik dalam jumlah besar (Rizquina & Ratnasari, 2023). *Web scraping* juga banyak digunakan dalam penelitian berbasis analisis teks karena hasil ekstraksi yang diperoleh dapat langsung dimasukkan ke dalam tahap pra-pemrosesan. Dengan kemampuan mengekstraksi data secara cepat dan konsisten, *scraping* menjadi metode pengumpulan data yang banyak digunakan dalam penelitian berbasis media sosial, *e-commerce*, dan platform digital lainnya.

Web Crawling

Web crawling adalah proses menelusuri berbagai halaman web secara otomatis untuk menemukan lokasi atau sumber data yang relevan. Dalam penelitian terkait sistem *crawling*, dijelaskan bahwa *crawler* bekerja dengan mengikuti tautan pada halaman web secara berurutan, membuka halaman baru, serta mengumpulkan URL yang berkaitan dengan topik tertentu menggunakan alat seperti *Selenium* yang dapat meniru interaksi pengguna (Danang et al., 2024). Teknik ini biasanya digunakan ketika peneliti membutuhkan pemetaan struktur web atau pencarian data dari banyak halaman yang saling terhubung. *Crawling* sangat berguna pada penelitian yang memerlukan pencarian dokumen atau artikel dalam jumlah besar berdasarkan kata kunci tertentu.

web crawling dirancang untuk mengumpulkan informasi dari halaman web secara otomatis dengan mengikuti pola tertentu sehingga sistem dapat menemukan halaman yang relevan untuk dianalisis lebih lanjut. Teknik ini efektif untuk menelusuri halaman-halaman dalam jumlah besar dan mengumpulkan metadata sebelum tahap ekstraksi isi dilakukan (Lathifah et al., 2021). Dengan demikian, *crawling* berfungsi sebagai metode penelusuran halaman, sedangkan *scraping* berfungsi sebagai metode pengambilan isi dari halaman. *Scraping* mengambil data secara langsung, sedangkan *crawling* hanya menemukan lokasi data tersebut.


Berdasarkan karakteristik keduanya, *scraping* dan *crawling* memiliki perbedaan mendasar yang menentukan penggunaannya dalam penelitian. *Crawling* lebih cocok digunakan ketika penelitian membutuhkan penelusuran halaman yang luas, misalnya mengidentifikasi artikel dari berbagai situs atau memetakan struktur web secara keseluruhan. Sebaliknya, *scraping* lebih tepat digunakan ketika fokus penelitian adalah mengambil isi teks tertentu dari halaman web yang sudah diketahui lokasinya. Dalam konteks penelitian ini, pengumpulan data dilakukan berdasarkan kata kunci tertentu pada platform X (twitter), sehingga teknik yang paling relevan secara konseptual adalah *web*

scraping, karena mampu mengekstraksi isi teks unggahan dan komentar secara langsung tanpa memerlukan penjelajahan halaman berskala besar seperti pada *crawling*.

2.8. BERT

Bidirectional Encoder Representations from Transformers (BERT) merupakan model representasi bahasa berbasis transformer yang diperkenalkan oleh Devlin et al. untuk meningkatkan pemahaman konteks bahasa alami secara mendalam (Devlin et al., 2019). Berbeda dengan model bahasa generasi sebelumnya yang bersifat satu arah, BERT dirancang untuk mempelajari representasi kontekstual secara dua arah (*bidirectional*), sehingga setiap token dalam teks dapat dipahami dengan mempertimbangkan konteks dari sisi kiri dan kanan secara bersamaan. Pendekatan ini memungkinkan model menangkap hubungan semantik yang lebih kaya, terutama pada kalimat dengan makna implisit, ambiguitas, atau struktur bahasa yang kompleks. Kemampuan *bidirectional* ini menjadikan BERT sangat unggul dalam berbagai tugas pemrosesan bahasa alami, seperti analisis sentimen, *named entity recognition*, dan *question answering* (Gardazi et al., 2025).

Arsitektur BERT dibangun berdasarkan *Transformer Encoder* yang diperkenalkan dengan mekanisme *self-attention* sebagai komponen utama dalam mempelajari hubungan antar-token dalam satu urutan teks (Koroteev MV, 2021). Model ini terdiri dari beberapa lapisan *encoder transformer* yang ditumpuk, di mana setiap lapisan mencakup *multi-head self-attention* dan *feed-forward neural network*. Untuk merepresentasikan teks masukan, BERT menggunakan tiga jenis *embedding*, yaitu token embedding untuk merepresentasikan kata atau subkata, segment embedding untuk membedakan pasangan kalimat, serta positional embedding untuk mempertahankan informasi urutan token dalam kalimat (Z. Zhu, 2025). Kombinasi ketiga *embedding* ini memungkinkan BERT memahami makna kata, struktur kalimat, serta hubungan antar-kalimat secara lebih komprehensif.



Gambar 1. Prosedur Pre-Training & Fine-Tuning pada BERT

Sumber : (Devlin et al., 2019)

Gambar 1 merupakan tahap utama penggunaan BERT, yaitu *pre-training* dan *fine-tuning* (Devlin et al., 2019). Pada tahap *pre-training*, BERT dilatih menggunakan data teks tidak berlabel melalui dua tugas utama, yaitu *Masked Language Model (MLM)* dan *Next Sentence Prediction (NSP)*. MLM bekerja dengan cara menyamarkan sebagian token dalam kalimat dan meminta model untuk memprediksi token yang hilang berdasarkan konteks sekitarnya, sedangkan NSP

bertujuan untuk melatih model memahami hubungan logis antar-kalimat dalam suatu dokumen. Tahap *pre-training* ini memungkinkan BERT membangun representasi bahasa yang kaya sebelum digunakan pada tugas spesifik.

Setelah proses *pre-training*, BERT dapat disesuaikan (*fine-tuning*) untuk berbagai tugas NLP dengan menambahkan lapisan keluaran yang sesuai dengan kebutuhan tugas tertentu, seperti klasifikasi sentimen atau ekstraksi entitas (Rizkia et al., 2025). Pada tahap ini, seluruh parameter model disesuaikan menggunakan data berlabel, sehingga model dapat beradaptasi secara optimal terhadap konteks domain tertentu. Berbagai penelitian menunjukkan bahwa pendekatan *fine-tuning* pada BERT mampu menghasilkan performa yang lebih tinggi dibandingkan metode konvensional, khususnya pada data media sosial yang bersifat informal dan kontekstual (El-Demerdash & Abdel-Hamid, 2025). Selain itu, performa BERT juga dapat ditingkatkan melalui optimasi hiperparameter yang tepat, terutama pada tugas analisis sentimen berskala besar.

Seiring perkembangannya, BERT melahirkan berbagai model turunan yang dirancang untuk mengatasi keterbatasan tertentu atau menyesuaikan dengan domain dan bahasa spesifik. Beberapa varian populer antara lain RoBERTa, yang mengoptimalkan proses *pre-training* dengan data lebih besar dan tanpa NSP, DistilBERT, yang berfokus pada efisiensi komputasi, serta ALBERT, yang mengurangi jumlah parameter melalui parameter sharing (Gardazi et al., 2025). Selain itu, untuk konteks bahasa Indonesia, dikembangkan model IndoBERT dan IndoBERTweet yang dilatih khusus menggunakan korpus berbahasa Indonesia dan data media sosial, sehingga lebih efektif dalam menangani bahasa informal dan singkat pada platform X (Twitter) (Rizkia et al., 2025). Keberadaan model turunan ini menunjukkan fleksibilitas BERT sebagai fondasi utama dalam pengembangan model NLP modern.

2.9. IndoBERTweet

IndoBERTweet merupakan model bahasa Indonesia berbasis arsitektur Transformer yang dikembangkan secara khusus untuk memproses teks media sosial, terutama X (Twitter). Model ini dibangun melalui perluasan IndoBERT dengan menambahkan kosakata baru yang berasal dari ratusan juta tweet bahasa Indonesia, sehingga mampu mengenali bentuk bahasa informal seperti singkatan, emotikon, hashtag, kata berulang, serta campuran bahasa yang merupakan ciri khas pengguna X (Twitter) di Indonesia (Koto et al., 2021). Penyesuaian kosakata ini diperlukan karena model BERT Indonesia standar sering mengalami vocabulary mismatch terhadap teks X (Twitter), yang menyebabkan representasi kata kurang akurat. Dengan adaptasi tersebut, IndoBERTweet mampu memahami pola penulisan tidak baku dan variasi linguistik informal yang umum muncul pada percakapan digital.

Secara teknis, IndoBERTweet menggunakan proses tokenisasi berbasis *TweetTokenizer* dan *AutoTokenizer* yang dirancang agar mampu mengenali token khusus seperti emotikon, *hashtags*, *username*, dan bentuk kata yang dimodifikasi oleh pengguna (Koto et al., 2021). Tokenisasi ini bertujuan agar setiap elemen teks media sosial dapat dianalisis secara konsisten. Setelah teks diubah menjadi token, setiap token direpresentasikan dalam bentuk embedding dan diproses melalui mekanisme self-attention pada arsitektur Transformer, sehingga model dapat memahami hubungan makna antar kata secara dua arah. Mekanisme ini memungkinkan IndoBERTweet menangkap nuansa emosional dan gaya bahasa

informal yang sering muncul pada tweet (Damayanti, 2025b). Selain itu, penelitian mengenai deteksi depresi berbasis Twitter menunjukkan bahwa IndoBERTweet sensitif terhadap variasi ekspresi emosional, termasuk frasa implisit yang sulit dideteksi oleh model lain (Fadhel, 2024).

Keunggulan IndoBERTweet terlihat dari performanya pada berbagai tugas NLP bahasa Indonesia. Model ini mencapai akurasi 86,2% pada benchmark IndoLEM dan 90,4% pada dataset SmSA untuk tugas analisis sentimen, mengungguli IndoBERT dan BERT Multilingual yang tidak dioptimalkan untuk gaya bahasa media sosial (Koto et al., 2021). Selain itu, penelitian lain menunjukkan bahwa embedding IndoBERTweet meningkatkan performa model deep learning seperti CNN-BiLSTM, mencapai akurasi 86,75% dalam tugas deteksi ujaran kebencian, lebih tinggi dibandingkan kombinasi model lainnya (Mufva et al., 2025). Pada studi analisis sentimen bertema BTS Comeback, model ini juga mampu mencapai akurasi hingga 95% setelah dilakukan fine-tuning pada dataset khusus X (Twitter), menegaskan konsistensi kinerjanya pada domain media sosial (Damayanti, 2025).

Tahapan penggunaan IndoBERTweet dalam penelitian ini mengikuti alur pemrosesan yang umum digunakan dalam literatur. Langkah pertama adalah pra-pemrosesan teks, yang meliputi pembersihan karakter tidak relevan, case folding, normalisasi singkatan, penghapusan URL, serta penanganan emotikon agar teks menjadi lebih terstruktur sebelum dianalisis (Khairani et al., 2024). Setelah itu, proses tokenisasi dilakukan menggunakan *tokenizer* IndoBERTweet untuk memastikan setiap kata, simbol, dan emotikon dipetakan secara konsisten sesuai korpus Twitter (Koto et al., 2021). Tahap berikutnya adalah encoding, yaitu mengubah token menjadi embedding numerik yang kemudian diproses oleh IndoBERTweet. Selanjutnya, model menjalani *fine-tuning* untuk menyesuaikan parameter dengan dataset tugas tertentu, seperti sentimen atau deteksi emosional (Fadhel, 2024). Tahap terakhir adalah evaluasi performa menggunakan metrik seperti akurasi dan F1-score untuk menilai efektivitas model dalam memproses data X (Twitter) (Damayanti, 2025b).

Dengan kombinasi adaptasi kosakata, arsitektur Transformer, sensitivitas terhadap bahasa informal, serta fleksibilitas proses fine-tuning, IndoBERTweet menjadi model yang sangat relevan untuk analisis data media sosial berbahasa Indonesia. Kemampuannya memahami konteks percakapan digital yang cepat, spontan, dan penuh variasi membuat model ini unggul dalam tugas-tugas seperti analisis sentimen, deteksi emosi, deteksi ujaran kebencian, maupun eksplorasi perilaku pengguna di platform X (Twitter).

2.10. Pemodelan Topik

Pemodelan topik merupakan pendekatan unsupervised yang dirancang untuk mengidentifikasi pola tematik tersembunyi dalam kumpulan dokumen. Teknik ini bekerja dengan mengasumsikan bahwa sebuah dokumen tersusun atas beberapa topik, sedangkan setiap topik direpresentasikan sebagai distribusi probabilitas atas kata-kata dalam korpus. Dengan prinsip ini, peneliti dapat merangkum ribuan dokumen menjadi daftar tema yang lebih ringkas dan mudah diinterpretasikan, sehingga sangat bermanfaat dalam menganalisis data teks berukuran besar. Kemunculan awal pemodelan topik dipengaruhi oleh metode seperti *Latent Semantic Indexing* (LSI), yang menggunakan *singular value decomposition* untuk mereduksi dimensi representasi teks dan mengungkap struktur semantik tersembunyi (Vayansky & Kumar, 2020). Meskipun sederhana,

LSI membuka jalan bagi pendekatan-pendekatan selanjutnya dengan menunjukkan bahwa relasi latin dalam teks dapat dimodelkan secara matematis.

Perkembangan berikutnya ditandai oleh *probabilistic Latent Semantic Indexing* (pLSI), yang memperkenalkan model generatif berbasis probabilitas untuk memetakan kata dan dokumen ke dalam faktor latin (Vayansky & Kumar, 2020). Namun, pLSI memiliki keterbatasan karena jumlah parameternya meningkat seiring bertambahnya dokumen, sehingga menimbulkan risiko *overfitting*. Kelemahan tersebut diperbaiki melalui model *Latent Dirichlet Allocation* (LDA), yang memperkenalkan struktur probabilistik lebih stabil dengan mengasumsikan bahwa dokumen mengikuti distribusi *Dirichlet* atas topik (Vayansky & Kumar, 2020). LDA kemudian menjadi model paling terkenal dalam pemodelan topik, tetapi performanya menurun drastis ketika diterapkan pada teks pendek seperti tweet. Hal ini disebabkan oleh tingginya sparsitas, *noise*, dan rendahnya ko-kemunculan kata dalam teks pendek yang membuat model generatif klasik sulit menghasilkan topik yang koheren (Churchill & Singh, 2022). Oleh karena itu, berbagai model baru dikembangkan untuk menanggapi keterbatasan tersebut.

Jenis-jenis pemodelan topik berkembang pesat seiring meningkatnya kebutuhan untuk menganalisis data digital yang semakin kompleks. Pada kelompok model generatif, *Hierarchical Dirichlet Process* (HDP) dikembangkan untuk memungkinkan jumlah topik yang fleksibel tanpa harus ditentukan sejak awal, sehingga lebih adaptif terhadap korpus besar atau terus berkembang. *Correlated Topic Model* (CTM) memperbaiki kelemahan LDA dengan memodelkan korelasi antar-topik, sedangkan *Dynamic Topic Models* (DTM) memungkinkan analisis topik yang berubah seiring waktu sehingga relevan untuk dataset temporal seperti berita atau percakapan daring (Churchill & Singh, 2022). Di luar kelompok generatif, pendekatan *matrix factorization* seperti *Non-negative Matrix Factorization* (NMF) menjadi alternatif penting, khususnya untuk teks pendek, karena menghasilkan topik melalui dekomposisi matriks yang lebih stabil dan cenderung menghasilkan topik yang koheren pada data media sosial (Egger & Yu, 2022). Keragaman pendekatan ini menunjukkan bahwa pemodelan topik tidak lagi terbatas pada satu paradigma, melainkan berkembang menyesuaikan kebutuhan analisis modern.

Perkembangan paling mutakhir dalam pemodelan topik memanfaatkan kemajuan representasi semantik melalui embeddings dan deep learning. Top2Vec merupakan salah satu model yang memetakan dokumen dan kata ke dalam ruang vektor semantik, kemudian secara otomatis membentuk topik berdasarkan kedekatan makna tanpa menentukan jumlah topik sejak awal (Egger & Yu, 2022). Model ini mampu menangkap relasi semantik yang tidak dapat ditangkap oleh pendekatan berbasis frekuensi kata tradisional. Pendekatan yang lebih unggul lagi adalah BERTopic, yang mengintegrasikan *transformer embeddings*, algoritma clustering HDBSCAN, dan class-based TF-IDF (c-TFIDF) sehingga menghasilkan topik yang lebih kontekstual dan sangat efektif untuk teks pendek seperti X (Twitter) (Egger & Yu, 2022). Studi komparatif terbaru menunjukkan bahwa BERTopic dan NMF secara konsisten menghasilkan topik yang lebih stabil, informatif, dan representatif dibandingkan LDA, terutama pada analisis media sosial (Egger & Yu, 2022). Dengan demikian, perkembangan pemodelan topik menunjukkan pergeseran dari model probabilistik tradisional menuju

pendekatan berbasis representasi vektor yang lebih adaptif terhadap karakteristik data modern.

2.11. BERTopic

BERTopic merupakan algoritma pemodelan topik berbasis neural topic modeling yang memanfaatkan kekuatan *transformer embeddings* untuk menghasilkan topik yang lebih koheren dan kontekstual dibandingkan model *generatif* tradisional seperti LDA maupun pendekatan faktorisasi seperti NMF. Model ini dikembangkan dengan tujuan mengatasi keterbatasan representasi *bag-of-words* yang tidak mampu menangkap hubungan semantik antarkata dalam dokumen (Grootendorst, 2022). BERTopic bekerja dengan mengonversi dokumen ke ruang vektor semantik menggunakan Sentence-BERT sehingga dokumen yang memiliki makna serupa akan berada dekat dalam ruang vektor tersebut. Representasi inilah yang memungkinkan model mengidentifikasi kelompok dokumen secara lebih akurat dibandingkan teknik klasik yang hanya mengandalkan frekuensi kata. Karena berbasis unsupervised, BERTopic dapat digunakan untuk berbagai sumber data teks, mulai dari artikel ilmiah hingga media sosial (Liao & Li, 2025).

Secara umum, alur kerja BERTopic mencakup tiga tahap utama. Pertama, setiap dokumen diubah menjadi *dense embedding* menggunakan *Sentence-BERT*, yang memberikan representasi semantik yang kaya (Grootendorst, 2022). Kedua, embedding berukuran besar direduksi dimensinya menggunakan *Uniform Manifold Approximation and Projection* (UMAP), sebuah teknik reduksi dimensi yang terbukti mempertahankan struktur lokal dan global data lebih baik daripada PCA dan t-SNE (Grootendorst, 2022). Setelah reduksi dimensi, BERTopic melakukan klasterisasi menggunakan *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN), sebuah algoritma berbasis densitas yang mampu membentuk klaster dengan kepadatan berbeda sekaligus mengidentifikasi noise atau outliers. Ketiga, setelah klaster terbentuk, BERTopic mengekstraksi representasi topik menggunakan *class-based TF-IDF* (c-TF-IDF), yaitu modifikasi dari TF-IDF yang memperlakukan seluruh dokumen dalam satu klaster sebagai satu dokumen besar untuk mendapatkan kata-kata paling representatif dari topik tersebut (Grootendorst, 2022). Pendekatan ini menghindari kelemahan metode yang hanya mengandalkan jarak ke centroid klaster, seperti yang terjadi pada model Top2Vec.

Salah satu keunggulan utama BERTopic adalah kemampuannya menghasilkan topik yang lebih koheren pada teks pendek dan berisik, seperti tweet, ulasan pengguna, atau komentar singkat. Hal ini karena embedding transformer mampu menangkap konteks kata meskipun dokumen memiliki jumlah kata terbatas, sehingga topik tetap terbaca dan stabil (Y. Zhu & Liu, 2025). Selain itu, BERTopic juga unggul dalam skalabilitas karena dapat memproses dataset besar dengan cepat berkat kombinasi SBERT dan UMAP yang efisien (Grootendorst, 2022). Dalam berbagai penelitian, BERTopic digunakan untuk menganalisis artikel ilmiah, cuitan politik, hingga literatur teknis, dan hasilnya menunjukkan kemampuan yang konsisten dalam menemukan struktur tematik tersembunyi serta menghitung evolusi topik secara dinamis dari waktu ke waktu (Rejeb et al., 2025). Model ini juga efektif untuk aplikasi penemuan konsep (*concept discovery*) dalam pengembangan ontologi, karena dapat mengungkap istilah-istilah penting yang sering terlewat jika analisis dilakukan secara manual (Jesudas et al., 2025).

Meskipun kuat, BERTopic tetap memiliki sejumlah keterbatasan. Model ini hanya menetapkan satu topik utama pada setiap dokumen, sehingga tidak dapat memodelkan distribusi multi-topik seperti pada LDA (Grootendorst, 2022). Selain itu, BERTopic dapat menghasilkan outlier dalam jumlah lebih besar, terutama pada dataset kecil yang menyebabkan kepadatan kluster tidak stabil (Y. Zhu & Liu, 2025). Pemodelan juga sensitif terhadap kualitas embedding sehingga performa BERTopic meningkat atau menurun bergantung pada model transformer yang digunakan, sesuatu yang menjadi keunggulan sekaligus tantangannya. Penelitian terbaru menunjukkan bahwa pemilihan lapisan embedding SBERT berpengaruh signifikan terhadap koherensi topik, dan konfigurasi standar bukan selalu yang terbaik untuk semua jenis dataset (Koterwa & Świtała, 2025). Temuan ini memperkuat pandangan bahwa BERTopic adalah teknik fleksibel yang dapat dioptimalkan lebih jauh dengan menyesuaikan representasi embedding dan parameter klusterisasi.

Perkembangan terbaru menunjukkan bahwa BERTopic semakin matang sebagai pendekatan pemodelan topik modern dan sangat relevan digunakan dalam penelitian yang melibatkan teks pendek dan bising seperti tweet. Model turunan seperti *Gibbs-BERTopic* terbukti mampu meningkatkan stabilitas kluster dan koherensi topik pada korpus berukuran kecil atau sangat beragam, menjadikannya lebih adaptif terhadap karakteristik data media sosial yang dinamis (Y. Zhu & Liu, 2025). Selain itu, penelitian dalam pengembangan ontologi menunjukkan bahwa BERTopic secara konsisten menghasilkan konsep-konsep baru yang tidak terdeteksi melalui analisis manual, yang berarti model ini efektif menangkap hubungan semantik halus yang sering muncul dalam percakapan informal di platform digital (Jesudas et al., 2025). Penggunaan BERTopic dalam studi berskala besar seperti pemetaan literatur Industri 5.0 juga membuktikan kemampuannya dalam mengurai pola tematik kompleks, sehingga model ini dapat diandalkan untuk memahami dinamika topik yang berubah dari waktu ke waktu (Rejeb et al., 2025). Berdasarkan pertimbangan tersebut, BERTopic menjadi pilihan tepat untuk penelitian ini karena mampu menangani teks pendek dari pengguna X (Twitter) Indonesia, mengelompokkan opini secara lebih kontekstual, serta memberikan struktur topik yang lebih koheren dan representatif dibandingkan metode klasik seperti LDA atau NMF. Dengan demikian, BERTopic memungkinkan peneliti memperoleh gambaran topik yang lebih akurat dalam menganalisis respons dan persepsi komunitas Roblox Indonesia.

2.12. Visualisasi Data


Visualisasi data merupakan teknik penyajian data dalam bentuk grafis yang bertujuan untuk membantu manusia memahami informasi secara lebih cepat dan intuitif. Visualisasi memungkinkan penyajian data yang kompleks menjadi lebih sederhana sehingga pola, tren, dan hubungan antarvariabel dapat dikenali dengan mudah (Prihatin Prakoso et al., 2025). Dalam penelitian berbasis data teks dan media sosial, visualisasi menjadi sangat penting karena data yang dihasilkan umumnya berskala besar, tidak terstruktur, dan memiliki variasi bahasa yang tinggi. Oleh karena itu, visualisasi data berfungsi tidak hanya sebagai alat presentasi hasil, tetapi juga sebagai sarana eksplorasi dan analisis awal terhadap data.

Dalam konteks analisis sentimen, visualisasi data digunakan untuk menggambarkan distribusi sentimen pengguna secara jelas dan informatif.

Representasi visual seperti diagram batang dan diagram lingkaran dapat menunjukkan perbandingan jumlah sentimen positif, negatif, dan netral sehingga memudahkan peneliti dalam menarik kesimpulan awal mengenai kecenderungan opini pengguna (Prameswari & Wahyono, 2025). Selain itu, visualisasi word cloud sering dimanfaatkan untuk menampilkan kata-kata yang paling sering muncul pada masing-masing kategori sentimen, di mana ukuran kata mencerminkan tingkat frekuensi kemunculannya dalam data (Fadilah, 2025). Visualisasi ini membantu mengungkap karakteristik bahasa dan emosi dominan yang digunakan oleh pengguna media sosial.

Visualisasi data juga berperan penting dalam tahap *Exploratory Data Analysis* (EDA), yaitu untuk memahami struktur dan karakteristik data sebelum dilakukan pemodelan lebih lanjut. Melalui EDA berbasis visual, peneliti dapat mengidentifikasi distribusi data, ketidakseimbangan kelas sentimen, serta keberadaan data menyimpang (*outliers*) yang berpotensi memengaruhi kinerja model analisis sentimen (Fadilah, 2025). Beberapa penelitian menunjukkan bahwa penggunaan visualisasi pada tahap EDA dapat membantu peneliti dalam menentukan strategi pemodelan yang lebih tepat dan meningkatkan kualitas interpretasi hasil analisis (Prameswari & Wahyono, 2025).

Pada pemodelan topik, visualisasi data digunakan untuk menampilkan struktur topik dan hubungan antar-topik yang terbentuk dari hasil pemodelan. Visualisasi berbasis reduksi dimensi, seperti pemetaan dua dimensi menggunakan UMAP, memungkinkan peneliti untuk melihat pemisahan kluster topik secara visual sehingga mempermudah proses interpretasi topik yang dihasilkan. Selain itu, visualisasi kata kunci topik yang diperoleh dari metode c-TF-IDF membantu dalam memahami makna dan konteks setiap topik yang terbentuk (Mawaddah et al., 2025). Penelitian mengenai pemetaan lanskap emosional di Twitter menunjukkan bahwa visualisasi topik dan emosi mampu memberikan gambaran komprehensif mengenai dinamika diskusi dan perubahan fokus percakapan pengguna dalam suatu komunitas daring (Mawaddah et al., 2025).



Gambar 2. Contoh Visualisasi Data Word Cloud
Sumber : (Prameswari & Wahyono, 2025)

2.13. Penelitian Terdahulu

Penelitian terdahulu diperlukan agar peneliti dapat memahami bagaimana topik yang sama atau serupa telah dikaji oleh peneliti sebelumnya. Melalui peninjauan tersebut, peneliti dapat melihat perkembangan metode, menemukan pendekatan yang relevan, serta menghindari terjadinya pengulangan penelitian. Kajian ini juga membantu memberikan gambaran mengenai bagaimana analisis sentimen dan pemodelan topik diterapkan pada data media sosial, khususnya pada platform X (Twitter) yang memiliki karakteristik bahasa yang beragam. Dengan melihat hasil penelitian sebelumnya, peneliti memperoleh dasar yang lebih kuat dalam menentukan arah penelitian. Berikut ini merupakan beberapa penelitian terdahulu yang berkaitan dengan analisis sentimen, model bahasa berbasis transformer, serta pemodelan topik menggunakan BERTopic.

Tabel 1. Penelitian Terdahulu

No	Judul Penelitian	Penulis dan Tahun	Tujuan Penelitian	Hasil Penelitian
1	Analisis Sentimen Topik #Kaburajadulu di Platform X Berbasis Model IndoBERTweet	(Nugraha & Febriani, 2025b)	Menentukan sentimen dominan (pro, kontra, netral) pada tagar #KaburAjaDulu menggunakan model IndoBERTweet.	Model IndoBERTweet menghasilkan performa sangat baik dengan seluruh metrik (akurasi, presisi, recall, F1-score) di atas 94%, menunjukkan keandalan tinggi dalam mengklasifikasikan sentimen tweet berbahasa Indonesia
2	Analisis Sentimen Publik Pada Tagar #Btscomeback Di Platform X Menggunakan IndoBERTweet	(Damayanti, 2025c)	Menganalisis sentimen publik Indonesia terhadap tagar #BTSComeback menggunakan model IndoBERTweet untuk mengetahui kecenderungan emosi publik selama periode comeback BTS, serta memahami pola ekspresi pengguna melalui visualisasi seperti word cloud yang menggambarkan	IndoBERTweet mampu mengklasifikasikan sentimen dengan akurasi mencapai 95%, dan menunjukkan performa evaluasi yang konsisten tinggi pada ketiga kategori sentimen, terutama dalam mendeteksi sentimen positif. Visualisasi word cloud memperlihatkan keberagaman ekspresi publik, mulai dari dukungan antusias hingga bentuk kritik yang muncul dalam percakapan terkait comeback BTSNeighbor. Dari penelitian ini diperoleh hasil akurasi

			keberagaman respons publik terhadap fenomena tersebut	sebesar 82% dari 100 plat tes dengan akurasi pengenalan angka 93,75% dan akurasi pengenalan huruf sebesar 91,92%
3	<i>Sentiment Analysis on Tweets of Kanjuruhan Tragedy Using Deep Learning IndoBERTweet</i>	(Maulana & Lhaksana, 2023)	Menilai sentimen publik terhadap tragedi Kanjuruhan dan membandingkan IndoBERTweet dengan Naive Bayes.	IndoBERTweet mencapai akurasi 88%, jauh lebih tinggi dibandingkan Naive Bayes (62%), membuktikan bahwa model transformer lebih efektif untuk analisis sentimen berbahasa Indonesia.
4	<i>Analisis Sentimen dan Pemodelan Topik pada Post tentang Merek Teknologi di X Menggunakan Fine-tuning IndoBERT dan BERTopic</i>	(Muhammad Rayhan Nur et al., 2025b)	Menganalisis sentimen dan mengidentifikasi topik diskusi pada unggahan mengenai merek teknologi Xiaomi di Platform X menggunakan pendekatan berbasis Transformer, sehingga dapat menggambarkan persepsi publik terhadap merek tersebut secara lebih komprehensif.	Model IndoBERT mencapai akurasi 79.8%, precision 73.0%, recall 67.7%, dan F1-score 0.699. Sentimen didominasi netral, dan BERTopic menghasilkan 16 topik koheren, dengan nilai coherence 0.5437. Topik terbesar membahas Xiaomi Series & Poco, sentimen negatif dominan pada service center, dan sentimen positif tertinggi terkait tablet Xiaomi.
5	<i>BERTopic Implementation for 'X' Data Analysis: Blood Donation in the Japanese Context</i>	(Chamorro et al., 2025)	Mengoptimalkan kinerja BERTopic dengan menyesuaikan parameter dan melakukan kustomisasi lapisan untuk menganalisis data X berbahasa Jepang terkait	BERTopic berhasil mengidentifikasi topik umum dan spesifik Jepang seperti donation requests, festivity campaigns, health considerations, technology benefits, dan prefecture campaigns. Kategorisasi data menghasilkan temuan seperti food and beverage incentives dan

			donor darah, agar model lebih mampu menangkap pola dan nuansa percakapan publik.	hospital interaction, menunjukkan efektivitas BERTopic dalam mengungkap faktor-faktor yang memengaruhi perilaku donor darah.
6	<i>Mpox Discourse on Twitter by Sexual Minority Men and Gender-Diverse Individuals: Infodemiological Study Using BERTopic</i>	(Wang et al., 2024)	Mensintesis tema diskusi mpox di kalangan pengguna SMMGD dan mengidentifikasi masalah dalam komunikasi kesehatan publik untuk meningkatkan inklusivitas dan keadilan.	BERTopic mengidentifikasi 11 topik, termasuk health activism (29.81%), mpox vaccination (25.81%), sarcasm & emotional expressions, dan mpox symptoms. Analisis geografis menemukan korelasi negatif ($\rho = -0.322$) antara topik health activism dan tingkat penerimaan LGB, serta menyoroti isu stigma, advokasi, dan hambatan kesehatan dalam komunitas SMMGD.

Sumber : Penelitian Terdahulu

Berdasarkan penelitian terdahulu yang telah disajikan pada Tabel 1, dapat dilihat bahwa penggunaan model berbasis transformer seperti IndoBERTweet dan metode pemodelan topik seperti BERTopic menunjukkan hasil yang beragam sesuai dengan karakteristik data dan konteks penelitian. Setiap penelitian memiliki fokus yang berbeda-beda, baik dari segi objek kajian, tujuan analisis, maupun jenis data yang digunakan, sehingga menghasilkan variasi performa model dan temuan topik yang unik. Perbedaan tersebut menunjukkan bahwa analisis sentimen dan pemodelan topik pada data media sosial sangat dipengaruhi oleh sifat bahasa, domain pembahasan, serta kualitas data yang dianalisis. Berdasarkan hal tersebut, penelitian ini diarahkan untuk menerapkan IndoBERTweet dalam mengklasifikasikan sentimen dan BERTopic dalam mengidentifikasi topik dominan pada percakapan Komunitas Roblox Indonesia di Platform X (Twitter), sehingga dapat memberikan gambaran yang lebih komprehensif mengenai opini dan isu yang berkembang dalam komunitas tersebut.

III. METODOLOGI PENELITIAN

3.1. Tempat dan Waktu Penelitian

Penelitian ini dilakukan pada Program Studi Sistem Informasi, Jurusan Teknik Elektro dan Informatika, Fakultas Sains dan Teknologi, Universitas Jambi yang beralamat di Jl. Jambi–Muaro Bulian No. KM.15, Mendalo Darat, Kecamatan Jambi Luar Kota, Kabupaten Muaro Jambi, Provinsi Jambi. Waktu pelaksanaan penelitian dimulai setelah seminar usulan penelitian dinyatakan disetujui dan berlangsung hingga seluruh rangkaian tahapan penelitian terselesaikan, meliputi pengumpulan data, pra-pemrosesan teks, penerapan metode IndoBERTweet dan BERTopic, analisis hasil, serta penyusunan laporan penelitian.

3.2. Bahan dan Alat Penelitian

Penelitian ini membutuhkan dataset berupa unggahan berbahasa Indonesia yang diperoleh dari Komunitas Roblox Indonesia pada Platform X (Twitter), yang berisi opini, percakapan, dan diskusi pengguna mengenai game Roblox. Informasi pendukung lainnya diperoleh melalui tinjauan pustaka, jurnal ilmiah, internet, serta referensi bacaan yang relevan dengan topik analisis sentimen dan pemodelan topik.

Alat yang dibutuhkan dalam penelitian ini adalah:


1. Perangkat Keras (*Hardware*)
Laptop Lenovo V14 G2 ITL dengan spesifikasi :
 - a. Processor 11th Gen Intel(R) Core(TM) i5-1135G7 @ 2.40GHz
 - b. Intel(R) Iris(R) Xe Graphics
 - c. SSD 512 GB
 - d. RAM 16 GB, dan
2. Perangkat Lunak (*Software*)
 - a. Sistem Operasi Windows 11
 - b. Visual Studio Code
 - c. Google Colab
 - d. Library Selenium pandas, NumPy dll
 - e. Microsoft Office 365 untuk penulisan laporan
 - f. Google Chrome untuk akses data dan literatur

3.3. Tahapan Penelitian

Penelitian ini disusun secara sistematis untuk menggambarkan alur kerja mulai dari tahap perencanaan hingga tahap akhir penelitian. Proses penelitian diawali dengan identifikasi masalah dan studi pustaka sebagai landasan teoritis terkait analisis sentimen, pemodelan topik, serta karakteristik data pada Platform X (Twitter). Selanjutnya dilakukan pengumpulan data dari Komunitas Roblox Indonesia yang memuat opini dan diskusi pengguna mengenai game Roblox.

Data yang telah diperoleh kemudian diberi label sentimen secara manual dengan kategori positif, negatif, dan netral untuk mempertahankan konteks asli unggahan pengguna. Setelah proses pelabelan, data diproses melalui tahapan pre-processing yang meliputi cleaning data, case folding, dan normalisasi guna meningkatkan kualitas teks tanpa mengubah makna sentimen. Data bersih selanjutnya digunakan dalam analisis sentimen menggunakan IndoBERTweet melalui proses pembagian data, tokenizing, encoding, dan fine-tuning model, yang diakhiri dengan evaluasi kinerja model.

Tahap selanjutnya adalah pemodelan topik menggunakan BERTopic untuk mengidentifikasi topik pembahasan utama berdasarkan hasil analisis sentimen. Proses ini meliputi pembentukan embedding teks, reduksi dimensi menggunakan UMAP, klasterisasi menggunakan HDBSCAN, serta ekstraksi kata kunci dengan c-TF-IDF. Hasil pemodelan topik kemudian divisualisasikan untuk memudahkan interpretasi dan analisis lebih lanjut. Adapun alur penelitian secara keseluruhan ditunjukkan pada Gambar 3.



Gambar 3. Alur Penelitian

Identifikasi Masalah


Tahap identifikasi masalah dilakukan untuk menentukan fokus penelitian berdasarkan fenomena yang terjadi dalam Komunitas Roblox Indonesia pada Platform X (Twitter). Meskipun komunitas tersebut aktif membagikan opini, curhatan dan pengalaman terkait game Roblox, belum terdapat analisis yang secara khusus memetakan sentimen pengguna maupun topik pembahasan yang dominan. Kondisi ini menunjukkan perlunya pendekatan berbasis NLP yang mampu mengolah dan menganalisis percakapan pengguna secara otomatis. Oleh karena itu, penelitian ini dilakukan untuk mengidentifikasi sentimen dan topik yang muncul menggunakan IndoBERTweet dan BERTopic.

Studi Pustaka

Tahap studi pustaka dilakukan untuk mengumpulkan referensi yang relevan dengan penelitian, meliputi teori mengenai Platform X (Twitter), game Roblox, analisis sentimen, NLP, model IndoBERTweet, dan metode pemodelan topik BERTopic. Studi pustaka ini digunakan sebagai dasar dalam memahami konsep, metode, serta hasil penelitian terdahulu yang berkaitan sehingga dapat mendukung perumusan langkah penelitian secara sistematis.


Pengumpulan Data

Pengumpulan data dalam penelitian ini dilakukan dengan menggunakan teknik *scraping*. Data yang diambil merupakan data tweet yang berasal dari Komunitas Roblox Indonesia di X (Twitter) sebagaimana yang ditunjukkan pada Gambar 4.



Gambar 4. Komunitas Roblox Indonesia

Pada penelitian ini, proses *scraping* menggunakan *Visual Studio Code*, dengan bahasa pemrograman yang digunakan berupa Python. Proses otomatisasi pengambilan data dilakukan menggunakan bahasa pemrograman Python dengan memanfaatkan *library Selenium*. *Library* ini memungkinkan interaksi langsung dengan antarmuka web, seperti melakukan klik, menggulir halaman, serta mengekstraksi informasi dari konten web secara otomatis. Pada penelitian ini, data yang dikumpulkan dari komunitas meliputi tanggal dan waktu unggahan, serta isi tweet dalam bentuk teks, seperti pada Gambar 5.



Gambar 5. Hasil Scraping

Setelah proses *scraping* dilakukan, diperoleh sebanyak 2.465 tweet dari Platform X (Twitter) yang berasal dari Komunitas Roblox Indonesia. Pengambilan data dilakukan dalam rentang waktu 7 hari, yaitu mulai dari 6 Desember 2025

hingga 13 Desember 2025, sehingga data yang dikumpulkan merepresentasikan opini dan diskusi pengguna yang bersifat aktual. Informasi yang diambil pada tahap ini meliputi tanggal dan waktu unggahan serta isi *tweet* (teks) yang menjadi fokus analisis sentimen dan pemodelan topik.

Pelabelan Data

Pelabelan data dilakukan untuk mengklasifikasikan setiap tweet ke dalam kategori sentimen yang telah ditentukan sebagai dasar analisis sentimen. Pada penelitian ini, sentimen dibagi ke dalam tiga kelas, yaitu positif, negatif, dan netral. Penentuan label sentimen didasarkan pada makna teks, konteks kalimat, serta ekspresi emosi yang terkandung dalam unggahan. Tweet yang mengandung pujian, pengalaman menyenangkan, atau tanggapan bernada mendukung dikategorikan sebagai sentimen positif, sedangkan tweet yang berisi keluhan, kritik, atau ekspresi ketidakpuasan diklasifikasikan sebagai sentimen negatif. Adapun tweet yang bersifat informatif, berupa pertanyaan, atau tidak menunjukkan kecenderungan emosi yang jelas dikategorikan sebagai sentimen netral.

Proses pelabelan dilakukan dengan mengacu pada kriteria yang konsisten untuk setiap kelas sentimen agar hasil anotasi dapat merepresentasikan persepsi pengguna secara tepat. Apabila suatu tweet tidak menunjukkan kecenderungan sentimen yang jelas atau menimbulkan keraguan dalam penentuan label, maka tweet tersebut diklasifikasikan sebagai sentimen netral. Hasil pelabelan data ini selanjutnya digunakan sebagai data berlabel pada tahap pelatihan dan evaluasi model IndoBERTweet, serta menjadi dasar dalam analisis sentimen dan pemodelan topik pada tahap penelitian selanjutnya.


Tabel 2. Contoh Pelabelan Data

No	Data Mentah	Label
1.	alhamdulillah setelah 2 minggu lebih ga dapet secret, akhirnya ada yang naik juga . padahal kemarin udah cape bgt ga sanggup mau naik kapal dan ke pulau lain, makanya ditinggal tidur sambil mancing di fisherman . btw ini jadinya lulus s3 ya? tapi aku blm lulus s2	Positif
2.	Kakak kakak ada yang punya dc fisch buat mabar dan sharing info gitu gaaak? Aku mau join dong kalau ada, suka iseng kalau main sendirian :c	Netral
3.	Buat yang main the forge, kalian kalau nambang pake cara nunggu reset batunya tuh gausah nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur, gedeg banget berapa kali gw dikatain orang cuman gara2 gw getok ampe ancur, SUKA SUKA GW NJING GW JUGA PAHAM	Negatif

Setelah tahap pelabelan data selesai, seluruh data yang telah diklasifikasikan ke dalam kategori sentiment dilakukan peninjauan Kembali untuk memastikan kesesuaian dari penilaian. Proses ini bertujuan untuk meminimalkan makna yang ambigu serta menghindari kesalahan yang berpotensi memengaruhi kualitas data latih.

Pre-Processing Data

Tahap *pre-processing* data dilakukan untuk membersihkan dan menyiapkan teks sebelum digunakan dalam proses analisis sentimen dan pemodelan topik. Tahapan ini bertujuan untuk mengurangi noise serta menyeragamkan format teks agar data yang digunakan lebih terstruktur dan mudah diproses oleh model. Setiap tahapan *pre-processing* dilakukan secara berurutan, di mana hasil dari satu tahap digunakan sebagai masukan pada tahap berikutnya. Alur *pre-processing* data yang diterapkan dalam penelitian ini ditunjukkan pada Gambar 6.



Gambar 6. Pre-Processing Data

1. *Cleaning Data*

Tahap *cleaning data* dilakukan untuk membersihkan teks dari elemen-elemen yang tidak relevan dan berpotensi menimbulkan noise dalam proses analisis. Proses ini mencakup penghapusan URL, *mention*, *hashtag*, simbol khusus, serta karakter yang tidak diperlukan, sehingga teks menjadi lebih bersih dan mudah diproses pada tahap selanjutnya. Contoh hasil *cleaning data* yang diperoleh pada penelitian ini disajikan pada Tabel 3.

Tabel 3. Contoh Hasil *Cleaning Data*

Contoh data	
Data Mentah (Input)	Hasil <i>Cleaning</i> (Output)
Buat yang main the forge, kalian kalau nambang pake cara nunggu reset batunya tuh gausah nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur, gedeg banget berapa kali gw dikatain orang cuman gara2 gw getok ampe ancur, SUKA SUKA GW NJING GW JUGA PAHAM	Buat yang main the forge kalian kalau nambang pake cara nunggu reset batunya tuh gausah nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur gedeg banget berapa kali gw dikatain orang cuman gara2 gw getok ampe ancur SUKA SUKA GW NJING GW JUGA PAHAM

2. *Case Folding*

Tahap *case folding* dilakukan untuk menyeragamkan bentuk huruf pada teks dengan mengubah seluruh karakter menjadi huruf kecil (lowercase), seperti kata “PAHAM” menjadi “paham”. Proses ini bertujuan untuk mengurangi variasi penulisan kata akibat perbedaan penggunaan huruf kapital, sehingga kata dengan makna yang sama dapat diperlakukan secara konsisten oleh model. Contoh hasil *Case Folding* pada penelitian ini disajikan pada Tabel 4.

Tabel 4. Contoh Hasil Case Folding

Contoh data	
Hasil <i>Cleaning</i> (<i>Input</i>)	Hasil <i>Case folding</i> (<i>Output</i>)
Buat yang main the forge kalian kalau nambang pake cara nunggu reset batunya tuh gausah nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur gedeg banget berapa kali gw dikatain orang cuman gara2 gw getok ampe ancur SUKA SUKA GW NJING GW JUGA PAHAM	buat yang main the forge kalian kalau nambang pake cara nunggu reset batunya tuh gausah nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur gedeg banget berapa kali gw dikatain orang cuman gara2 gw getok ampe ancur suka suka gw njing gw juga paham

3. Normalisasi


Normalisasi bertujuan untuk menyeragamkan penulisan kata tidak baku, singkatan, serta bahasa informal yang umum digunakan pada unggahan Platform X (Twitter) ke dalam bentuk yang lebih konsisten. Normalisasi dilakukan secara ringan, yaitu hanya pada kata-kata yang memiliki banyak variasi penulisan, seperti “ga/gak/nggak” yang diseragamkan menjadi satu bentuk, atau singkatan tertentu yang diubah ke bentuk yang lebih baku. Proses normalisasi tidak dilakukan secara menyeluruh agar konteks, gaya bahasa, serta ekspresi yang terdapat dalam teks tetap terjaga, mengingat elemen-elemen tersebut berperan penting dalam membantu model IndoBERTweet memahami sentimen secara kontekstual. Untuk memperjelas proses yang dilakukan, contoh hasil normalisasi pada data penelitian ini disajikan dalam Tabel 5.

Tabel 5. Contoh Hasil Normalisasi

Contoh data	
Hasil <i>Case folding</i> (<i>Input</i>)	Hasil Normalisasi (<i>Output</i>)
buat yang main the forge kalian kalau nambang pake cara nunggu reset batunya tuh gausah nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur gedeg banget berapa kali gw dikatain orang cuman gara2 gw getok ampe ancur suka suka gw njing gw juga paham	buat yang main the forge kalian kalau nambang pake cara nunggu reset batunya tuh tidak perlu nyuruh2 orang lain atau sampe ngatain kalau orang lain getok batunya sampe ancur gedeg banget berapa kali saya dikatain orang cuman gara2 saya getok ampe ancur suka suka saya njing saya juga paham

Klasifikasi IndoBERTweet

Tahap klasifikasi sentimen dilakukan menggunakan model IndoBERTweet dengan memanfaatkan data berlabel yang telah melalui proses *pre-processing*. Alur klasifikasi sentimen yang diterapkan dalam penelitian ini ditunjukkan pada Gambar 7.



Gambar 7. Tahap Klasifikasi IndoBERTWEET

1. *Dataset*

Dataset yang digunakan pada tahap klasifikasi sentimen merupakan data teks yang diperoleh dari Platform X (Twitter) dan telah melalui proses pre-processing serta pelabelan sentimen. Data yang digunakan berbentuk teks hasil normalisasi yang telah dibersihkan dari elemen-elemen yang tidak relevan, sehingga lebih siap untuk diproses oleh model. Setiap data dilengkapi dengan label sentimen yang merepresentasikan kategori positif, negatif, atau netral, yang digunakan sebagai acuan dalam proses pelatihan model. Dataset ini selanjutnya dibagi menjadi data latih dan data uji untuk mendukung proses pelatihan dan evaluasi model IndoBERTweet, sehingga kinerja klasifikasi sentimen dapat diukur secara objektif dan sistematis.

2. *Split Data (Training & Test)*

Tahap *split data* dilakukan untuk membagi dataset ke dalam dua bagian, yaitu data latih (*training data*) dan data uji (*testing data*). Data latih digunakan untuk melatih model IndoBERTweet agar mampu mempelajari pola sentimen dari teks, sedangkan data uji digunakan untuk mengevaluasi kinerja model terhadap data yang belum pernah digunakan dalam proses pelatihan. Pembagian ini bertujuan untuk memastikan bahwa hasil evaluasi model bersifat objektif dan mencerminkan kemampuan generalisasi model.

Pada penelitian ini, dataset dibagi dengan rasio 70% data latih dan 30% data uji. Rasio ini dipilih karena memberikan porsi data uji yang lebih besar sehingga proses evaluasi model dapat dilakukan secara lebih representatif, khususnya pada data media sosial yang bersifat dinamis. Selain itu, penelitian oleh Damayanti (2025a) menunjukkan bahwa rasio 70:30 mampu menghasilkan performa klasifikasi sentimen yang lebih baik dibandingkan rasio 80:20, sehingga rasio ini dianggap sesuai untuk digunakan dalam penelitian ini. Pembagian data dilakukan untuk memisahkan dataset menjadi data latih dan data uji menggunakan rasio 70:30. Proses ini dilakukan secara acak dengan bantuan perangkat lunak agar distribusi label sentimen pada kedua data tetap seimbang.

3. *Tokenizing dan Encoding*

Tahap *Tokenizing dan Encoding*, data teks hasil normalisasi yang telah dibagi menjadi data latih dan data uji diubah ke dalam bentuk token menggunakan tokenizer resmi IndoBERTweet. Setiap teks dipecah menjadi satuan subword untuk menangani variasi kata, termasuk kata tidak baku yang umum muncul pada media sosial. Selain itu, token khusus [CLS] ditambahkan pada awal kalimat sebagai penanda klasifikasi, dan token [SEP] ditambahkan pada akhir kalimat sebagai pemisah urutan teks.

Selanjutnya, dilakukan proses padding dan truncation hingga panjang maksimum tertentu agar seluruh data memiliki panjang sekuens yang seragam. Hasil tokenisasi kemudian dikonversi menjadi representasi numerik berupa input IDs dan attention mask, di mana input IDs merepresentasikan token dalam bentuk angka, sedangkan attention mask berfungsi untuk membedakan token yang diproses dan token hasil padding. Representasi numerik ini selanjutnya digunakan sebagai masukan ke dalam model IndoBERTweet pada tahap pelatihan dan pengujian klasifikasi sentimen. Contoh hasil proses tokenizing dan encoding IndoBERTweet ditampilkan pada Tabel 6.

Tabel 6.Contoh Hasil Tokenizing dan Encoding

Teks	Tokenize	Encode token
buat yang main the	[CLS],buat,yang,main,	3,3815,1497,5539,196
forge kalian kalau	the,for,##ge,kalian,kal	9,2841,3599,5094,228
nambang pake cara	au,nam,##bang,pake,	0,1811,2096,17420,24
nunggu reset	cara,nunggu,rese,##t,	07,31732,25114,930,2
batunya tuh tidak	batu,##nya,tuh,tidak,	970,1519,12910,1580,
perlu nyuruh2 orang	perlu,nyuruh,##2,ora	2506,10172,952,1646,
lain atau sampe	ng,lain,atau,sampe,ng	1690,1647,20398,1201
ngatain kalau orang	atain,kalau,orang,lain	6,2280,1646,1690,885
lain getok batunya	,get,##ok,batu,##nya,	9,1590,2970,1519,203
sampe ancur gedeg	sampe,ancur,gedeg,ba	98,16592,25846,10218
banget berapa kali	nget,berapa,kali,saya,	,6199,1994,1731,9575,
saya dikatakan orang	dikatain,orang,cuman	1646,22713,8006,1731
cuman gara2 saya	,gara2,saya,get,##ok,	,8859,1590,9203,1659
getok ampe ancur	ampe,ancur,suka,suk	2,4346,4346,1731,208
suka suka saya njing	a,saya,njing,saya,juga	50,1731,1614,7486,4
saya juga paham	,paham,[SEP]	

4. *Fine-Tuning*

Pada tahap *fine-tuning*, model pra-latih IndoBERTweet dilatih kembali menggunakan data latih untuk menyesuaikan model dengan tugas klasifikasi sentimen pada data penelitian. Data yang digunakan pada tahap ini merupakan data hasil *tokenizing* dan *encoding*, sehingga teks telah direpresentasikan dalam bentuk numerik yang dapat diproses oleh model.

Selama proses pelatihan, hasil prediksi model dibandingkan dengan label sentimen yang sebenarnya untuk mengukur tingkat kesalahan. Informasi kesalahan tersebut digunakan untuk memperbarui parameter model secara bertahap agar kemampuan model dalam mengklasifikasikan sentimen semakin meningkat. Proses pelatihan dilakukan dengan pengaturan parameter seperti *learning rate*, *batch size*, dan jumlah *epoch* agar model dapat belajar secara optimal dan menghasilkan prediksi sentimen yang lebih akurat. *Learning rate* mengatur seberapa besar perubahan parameter model pada setiap proses pembelajaran, *batch size* menentukan jumlah data yang diproses secara bersamaan dalam satu iterasi pelatihan, sedangkan *epoch* menunjukkan

jumlah pengulangan pelatihan terhadap seluruh data latih. Model hasil *fine-tuning* selanjutnya digunakan pada tahap prediksi sentiment.

5. Prediksi Sentimen

Tahap prediksi sentimen, model IndoBERTweet yang telah melalui proses *fine-tuning* digunakan untuk mengklasifikasikan sentimen pada data uji. Data yang digunakan pada tahap ini merupakan data hasil *tokenizing* dan *encoding* yang sebelumnya tidak dilibatkan dalam proses pelatihan, sehingga prediksi yang dihasilkan dapat mencerminkan kemampuan model dalam menggeneralisasi data baru. Model menghasilkan keluaran berupa probabilitas untuk setiap kelas sentimen, kemudian kelas dengan nilai probabilitas tertinggi dipilih sebagai hasil prediksi sentimen.

Hasil prediksi sentimen ini berupa label sentimen untuk setiap data teks, yang selanjutnya digunakan sebagai dasar dalam proses evaluasi kinerja model. Melalui tahap prediksi sentimen, dapat diketahui bagaimana model mengklasifikasikan opini pengguna ke dalam kategori sentimen yang telah ditentukan berdasarkan pola yang dipelajari selama proses pelatihan.

Evaluasi Model

Setelah proses klasifikasi sentimen menggunakan model IndoBERTweet dilakukan, diperlukan tahap evaluasi untuk menilai kualitas dan kinerja model yang telah dibangun. Tahap evaluasi ini bertujuan untuk mengetahui sejauh mana model mampu mengklasifikasikan teks ulasan pengguna ke dalam tiga kelas sentimen, yaitu positif, negative, dan netral secara tepat. Evaluasi dilakukan dengan membandingkan label hasil prediksi model terhadap label sebenarnya pada data pengujian (*testing data*), sehingga performa model dapat diukur secara kuantitatif.

Evaluasi model pada penelitian ini menggunakan *confusion matrix* sebagai dasar perhitungan metrik evaluasi. *Confusion matrix* merupakan sebuah tabel yang menyajikan ringkasan hasil klasifikasi model dalam bentuk jumlah prediksi yang benar maupun salah untuk setiap kelas sentimen. Pada *confusion matrix*, baris menunjukkan kelas sebenarnya (*actual class*), sedangkan kolom menunjukkan kelas hasil prediksi (*predicted class*). Dengan menggunakan *confusion matrix*, dapat dianalisis pola kesalahan klasifikasi model, seperti kecenderungan model dalam mengklasifikasikan suatu sentimen ke kelas sentimen lainnya.

Tabel 7. Confusion Matrix Klasifikasi Sentimen (3 Kelas)

Actual Class	Prediction class		
	Positive	Negative	Neutral
Positive	True Positive (TP)	False Negative1 (FN _{g1})	False Neutral1 (FN _{t1})
Negative	False Positive1 (FP1)	True Negative (TN _g)	False Neutral2 (FN _{t2})
Neutral	False Positive2 (FP2)	False Negative2 (FN _{g2})	True Neutral (TN _t)

Elemen-elemen yang terdapat pada *confusion matrix* dijelaskan sebagai berikut:

1. *True Positive* (TP) adalah jumlah data yang sebenarnya termasuk ke dalam kelas sentimen positif dan berhasil diprediksi sebagai sentimen positif oleh model. Nilai ini menunjukkan kemampuan model dalam mengenali sentimen positif secara benar.
2. *True Negative* (TNg) adalah jumlah data yang sebenarnya termasuk ke dalam kelas sentimen negatif dan berhasil diprediksi sebagai sentimen negatif oleh model. Nilai ini menggambarkan ketepatan model dalam mengklasifikasikan sentimen negatif.
3. *True Neutral* (TNt) adalah jumlah data yang sebenarnya termasuk ke dalam kelas sentimen netral dan berhasil diprediksi sebagai sentimen netral oleh model. Nilai ini menunjukkan kemampuan model dalam mengenali data yang tidak memiliki kecenderungan sentimen positif maupun negatif.
4. *False Positive1* (FP1) adalah jumlah data dengan sentimen negatif yang keliru diprediksi sebagai sentimen positif, sedangkan *False Positive2* (FP2) adalah jumlah data dengan sentimen netral yang keliru diprediksi sebagai sentimen positif. Kesalahan ini menunjukkan kecenderungan model dalam memberikan prediksi positif yang tidak sesuai.
5. *False Negative1* (FNg1) adalah jumlah data dengan sentimen positif yang keliru diprediksi sebagai sentimen negatif, sedangkan *False Negative2* (FNg2) adalah jumlah data dengan sentimen netral yang keliru diprediksi sebagai sentimen negatif. Kesalahan ini menunjukkan kegagalan model dalam mengenali sentimen negatif secara tepat.
6. *False Neutral1* (FNt1) adalah jumlah data dengan sentimen positif yang keliru diprediksi sebagai sentimen netral, sedangkan *False Neutral2* (FNt2) adalah jumlah data dengan sentimen negatif yang keliru diprediksi sebagai sentimen netral. Kesalahan ini menunjukkan keterbatasan model dalam membedakan sentimen netral dari sentimen lainnya.

Pada klasifikasi multikelas seperti pada penelitian ini, evaluasi performa model dilakukan menggunakan pendekatan one-vs-rest. Setiap kelas sentimen diperlakukan secara bergantian sebagai kelas utama, sementara dua kelas lainnya dianggap sebagai kelas pembanding. Pendekatan ini digunakan dalam perhitungan metrik *precision*, *recall*, dan *F1-score* untuk masing-masing kelas sentimen.

Berdasarkan nilai-nilai yang diperoleh dari *confusion matrix*, selanjutnya dihitung beberapa metrik evaluasi untuk menilai kinerja model, yaitu *accuracy*, *precision*, *recall*, dan *F1-score*. Metrik-metrik ini dipilih karena mampu memberikan gambaran yang komprehensif mengenai performa model dalam melakukan klasifikasi sentimen. Secara umum, masing-masing nilai dapat dihitung menggunakan :

1. *Accuracy*

Accuracy digunakan untuk mengukur proporsi keseluruhan prediksi yang dilakukan secara benar oleh model terhadap seluruh data pengujian. Nilai *accuracy* memberikan gambaran umum mengenai tingkat ketepatan model dalam melakukan klasifikasi.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2. *Precision*

Precision menunjukkan tingkat ketepatan model dalam memprediksi suatu kelas sentimen tertentu. Nilai *precision* yang tinggi

menandakan bahwa sebagian besar data yang diprediksi ke dalam suatu kelas memang benar berasal dari kelas tersebut.

$$Precision = \frac{TP}{TP + FP}$$

3. Recall

Recall menggambarkan kemampuan model dalam menemukan seluruh data yang sebenarnya termasuk ke dalam suatu kelas sentimen tertentu. Nilai *recall* yang tinggi menunjukkan bahwa model mampu menangkap sebagian besar data yang relevan.

$$Recall = \frac{TP}{TP + FN}$$

4. F1-Score

F1-score merupakan rata-rata harmonik antara *precision* dan *recall* yang digunakan untuk menilai keseimbangan antara kedua metrik tersebut. *F1-score* sangat berguna ketika terdapat ketidakseimbangan jumlah data antar kelas sentimen.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Pada penelitian ini, nilai *precision*, *recall*, dan *F1-score* dihitung untuk masing-masing kelas sentimen (Positif, Negatif, dan Netral), menggunakan pendekatan *one-vs-rest*. Nilai *precision* untuk masing-masing kelasnya dapat dihitung dengan menggunakan :

$$Positive Precision = \frac{TP}{TP + FP1 + FP2}$$

$$Negative Precision = \frac{TNg}{TNg + FNg1 + FNg2}$$

$$Neutral Precision = \frac{TNt}{TNt + FNT1 + FNT2}$$

Nilai *recall* dan *F1-score* dihitung dengan menyesuaikan komponen TP, FP, dan FN pada masing-masing kelas sentimen. Selanjutnya, nilai *precision*, *recall*, dan *F1-score* dirata-ratakan menggunakan pendekatan *weighted average*, sehingga proporsi jumlah data pada setiap kelas sentimen tetap diperhitungkan.


Hasil perhitungan metrik evaluasi digunakan untuk menilai seberapa baik model IndoBERTweet dalam melakukan klasifikasi sentimen terhadap teks ulasan pengguna. Model dikatakan memiliki kinerja yang baik apabila mampu menghasilkan nilai *accuracy* dan *F1-score* yang tinggi, serta menunjukkan keseimbangan antara *precision* dan *recall* pada setiap kelas sentimen. Apabila hasil evaluasi belum memenuhi kriteria yang diharapkan, maka dilakukan penyesuaian terhadap parameter pelatihan model, seperti *learning rate*, *batch size*, dan jumlah *epoch*, serta peninjauan kembali kualitas dataset dan tahapan *pre-processing* yang digunakan.

Pemodelan Topik BERTopic

Pada penelitian ini, pemodelan topik diterapkan untuk mengidentifikasi pola dan tema utama yang muncul pada kumpulan unggahan pengguna platform X (Twitter) terkait game Roblox. Metode BERTopic digunakan karena mampu

mengombinasikan representasi teks berbasis transformer dengan teknik reduksi dimensi, klasterisasi, serta pembobotan kata berbasis class-based TF-IDF (c-TF-IDF). Pendekatan ini dinilai lebih sesuai untuk menangani karakteristik teks media sosial yang cenderung pendek, informal, dan beragam secara semantik.

Secara umum, tahapan pemodelan topik menggunakan BERTopic pada penelitian ini ditunjukkan pada Gambar 8.



Gambar 8. Tahap Alur Pemodelan Topik BERTopic

1. Penyusunan Korpus untuk Pemodelan Topik

Tahap awal pemodelan topik adalah penyusunan korpus teks. Korpus merupakan kumpulan dokumen teks yang digunakan sebagai sumber data utama dalam analisis. Pada penelitian ini, korpus dibentuk dari seluruh unggahan pengguna platform X (Twitter) yang telah melalui tahap praproses, seperti pembersihan teks, penanganan simbol khusus, dan normalisasi tertentu. Setiap dokumen dalam korpus merepresentasikan satu unggahan pengguna yang berdiri secara independen.

Penyusunan korpus bertujuan untuk memastikan bahwa data yang digunakan dalam pemodelan topik berada dalam kondisi yang seragam dan siap diolah oleh model. Selain dianalisis secara keseluruhan, korpus dalam penelitian ini juga dapat dikelompokkan berdasarkan kelas sentimen, seperti korpus ulasan positif, netral, dan negatif. Pemisahan ini memungkinkan analisis topik yang lebih spesifik, misalnya untuk mengetahui topik apa saja yang sering muncul pada ulasan bernada negatif dibandingkan dengan ulasan bernada positif.

2. *Embedding* Dokumen

Setelah korpus disusun, setiap dokumen teks diubah menjadi representasi numerik berdimensi tinggi yang dikenal sebagai *embedding*. Proses ini dilakukan menggunakan model *sentence-transformers* yang kompatibel dengan BERTopic. *Embedding* bertujuan untuk menangkap makna semantik dari teks secara kontekstual, sehingga perbedaan kata atau susunan kalimat tidak selalu mengubah makna yang direpresentasikan.

Embedding yang dihasilkan memungkinkan dokumen dengan topik atau makna yang serupa memiliki representasi vektor yang saling berdekatan dalam ruang vektor. Dengan demikian, *embedding* menjadi fondasi penting dalam proses pengelompokan dokumen, karena kedekatan vektor mencerminkan kesamaan konteks antar dokumen.

3. Reduksi Dimensi (UMAP)

Embedding dokumen yang dihasilkan pada tahap sebelumnya umumnya memiliki dimensi yang cukup besar, sehingga kurang efisien untuk digunakan langsung dalam proses klasterisasi. Oleh karena itu, dilakukan tahap reduksi dimensi menggunakan algoritma *Uniform Manifold Approximation and Projection* (UMAP). UMAP digunakan untuk memproyeksikan *embedding* berdimensi tinggi ke dalam ruang berdimensi lebih rendah dengan tetap mempertahankan struktur kedekatan antar dokumen.

Reduksi dimensi bertujuan untuk menyederhanakan struktur data tanpa menghilangkan informasi semantik yang penting. Selain meningkatkan efisiensi komputasi, penggunaan UMAP juga membantu algoritma klasterisasi dalam membentuk kelompok dokumen yang lebih stabil dan terpisah dengan jelas.

4. Klasterisasi (HDBSCAN)

Tahap selanjutnya adalah pengelompokan dokumen hasil reduksi dimensi menggunakan algoritma *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN). Algoritma ini mengelompokkan dokumen berdasarkan kepadatan data dalam ruang vektor, sehingga dokumen yang memiliki kemiripan tinggi akan berada dalam klaster yang sama.

HDBSCAN memiliki keunggulan dibandingkan algoritma klasterisasi lainnya karena tidak mengharuskan penentuan jumlah klaster di awal dan mampu mengidentifikasi dokumen yang bersifat noise. Dokumen yang teridentifikasi sebagai noise merupakan dokumen yang tidak memiliki kedekatan yang cukup kuat dengan klaster manapun. Setiap klaster yang terbentuk pada tahap ini kemudian diperlakukan sebagai satu topik pembahasan.

5. Ekstraksi Kata Kunci topik (c-TF-IDF)

Setelah proses klasterisasi dokumen selesai, setiap klaster yang terbentuk perlu direpresentasikan oleh kata-kata kunci yang mampu menggambarkan topik pembahasan secara jelas. Pada penelitian ini, ekstraksi kata kunci topik dilakukan menggunakan pendekatan *class-based Term Frequency-Inverse Document Frequency* (c-TF-IDF) yang merupakan pengembangan dari metode TF-IDF konvensional.

Berbeda dengan TF-IDF biasa yang menghitung bobot kata pada tingkat dokumen individu, c-TF-IDF memperlakukan seluruh dokumen dalam satu klaster sebagai satu dokumen gabungan. Dengan pendekatan ini, bobot kata dihitung pada tingkat topik, sehingga kata-kata yang paling khas dan membedakan suatu topik dari topik lainnya dapat diidentifikasi dengan lebih baik. Secara umum, metode TF-IDF terdiri dari dua komponen utama, yaitu *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF).

a. *Term Frequency* (TF)

TF mengukur seberapa sering suatu term muncul dalam sebuah dokumen. Rumus TF dapat dituliskan sebagai berikut:

$$TF_{t,d} = \frac{f_{t,d}}{\sum_k f_{k,d}}$$

Dengan:

$f_{t,d}$: adalah jumlah kemunculan term t dalam dokumen d

$\sum_k f_{k,d}$: adalah total seluruh kemunculan term dalam dokumen d

b. *Inverse Document Frequency* (IDF)

IDF mengukur tingkat keunikan suatu term dalam keseluruhan korpus. Semakin jarang sebuah term muncul di banyak dokumen, semakin besar nilai IDF-nya. Rumus IDF dinyatakan sebagai:

$$IDF_t = \log\left(\frac{N}{df_t}\right)$$

Dengan :

N : adalah jumlah seluruh dokumen dalam korpus

df_t : adalah jumlah dokumen yang mengandung term t

c. TF-IDF

Nilai TF-IDF diperoleh dengan mengalikan nilai TF dan IDF:

$$TF - IDF_{t,d} = TF_{t,d} \times IDF_t$$

Pada BERTopic, pendekatan TF-IDF dimodifikasi menjadi c-TF-IDF dengan mengganti dokumen individu menjadi klaster/topik. Seluruh dokumen yang termasuk ke dalam satu klaster digabungkan, kemudian dihitung bobot kata pada tingkat klaster tersebut. Rumus c-TF-IDF untuk suatu term t pada klaster c dirumuskan sebagai berikut:

$$cTF - IDF_{t,c} = \frac{f_{t,c}}{\sum_k f_{k,c}} \times \log\left(\frac{N}{df_t}\right)$$

Dengan :

$cTF - IDF_{t,c}$: adalah bobot term t pada klaster atau topik c

$f_{t,c}$: adalah jumlah kemunculan term t pada seluruh dokumen yang termasuk ke dalam klaster c ;

$\sum_k f_{k,c}$: adalah total frekuensi seluruh term dalam klaster c ;

N : adalah jumlah seluruh dokumen dalam korpus;

df_t : adalah jumlah dokumen dalam korpus yang mengandung term t .

Metode c-TF-IDF digunakan untuk menghitung bobot term berdasarkan frekuensi kemunculannya pada masing-masing topik relatif terhadap distribusinya pada seluruh topik yang terbentuk, sehingga kata-kata yang paling representatif pada setiap topik dapat diidentifikasi secara otomatis. Nilai c-TF-IDF yang tinggi menunjukkan bahwa suatu term Sering muncul dalam satu topik tertentu (nilai TF tinggi), dan Relatif jarang muncul pada dokumen di luar topik tersebut (nilai IDF tinggi). Dengan demikian, term dengan bobot c-TF-IDF tertinggi dianggap paling representatif dalam menggambarkan karakteristik suatu topik. Dalam penelitian ini, sejumlah kata dengan bobot c-TF-IDF tertinggi digunakan sebagai kata kunci utama untuk merepresentasikan masing-masing topik yang dihasilkan oleh BERTopic.

BERTopic tidak menetapkan batas jumlah kata kunci yang harus dipilih untuk setiap topik. Oleh karena itu, pada penelitian ini digunakan pendekatan umum dalam studi pemodelan topik, yaitu memilih beberapa kata dengan bobot c-TF-IDF tertinggi sebagai representasi topik. Pendekatan ini bertujuan untuk menjaga keseimbangan antara kelengkapan informasi dan kemudahan interpretasi topik.

Dengan menggunakan pendekatan c-TF-IDF, pemodelan topik pada penelitian ini tidak hanya menghasilkan klaster dokumen, tetapi juga menyediakan representasi topik yang jelas melalui kata-kata kunci yang memiliki tingkat kekhasan tinggi. Hal ini memudahkan proses interpretasi topik serta mendukung analisis lanjutan yang mengaitkan topik dengan hasil analisis sentimen.

6. Interpretasi Topik

Berdasarkan daftar kata kunci hasil perhitungan c-TF-IDF dan beberapa contoh ulasan pada setiap klaster, peneliti memberikan nama atau deskripsi singkat untuk masing-masing topik. Penamaan topik dilakukan dengan mengamati kata-kata yang paling dominan pada suatu klaster. Sebagai contoh, topik yang didominasi oleh kata bug, error, lag, dan gabisa diberi label

Melalui visualisasi data menggunakan *word cloud*, hasil analisis tidak hanya disajikan dalam bentuk numerik atau tabel, tetapi juga dalam bentuk visual yang lebih intuitif. Visualisasi ini diharapkan dapat membantu pembaca memahami kecenderungan kata dan tema utama yang muncul dalam ulasan pengguna, serta mendukung proses interpretasi dan pembahasan hasil penelitian pada tahap selanjutnya.

DAFTAR PUSTAKA

- Alhafiz, V., & Adiguna, M. A. (2024). *PENGEMBANGAN APLIKASI WEB SCRAPING UNTUK PENGUMPULAN DATA HARGA PRODUK E-COMMERCE MENGGUNAKAN PYTHON (STUDI KASUS: TOKOPEDIA)* (Vol. 2, Issue 2). <https://mypublikasi.com/>
- Alhasan, K., Alhasan, K., & Al Hashimi, S. (2023). Roblox in Higher Education. *International Journal of Emerging Technologies in Learning (IJET)*, 18(19), 32–46. <https://doi.org/10.3991/ijet.v18i19.43133>
- Antons, D., Grünwald, E., Cichy, P., & Salge, T. O. (2020). The application of text mining methods in innovation research: current state, evolution patterns, and development priorities. *R and D Management*, 50(3), 329–351. <https://doi.org/10.1111/radm.12408>
- Blake, E., Carter, Z., & Brooks, O. (2025). *NLP for Extracting Insights From Unstructured Research Data*.
- Chamorro, R. E., Kishimoto, K., Liu, C., Santos, L. H. O., Mori, Y., Yamamoto, G., & Kuroda, T. (2025). BERTopic Implementation for 'X' Data Analysis: Blood Donation in the Japanese Context. *Advanced Biomedical Engineering*, 14, 328–339. <https://doi.org/10.14326/abe.14.328>
- Churchill, R., & Singh, L. (2022). The Evolution of Topic Modeling. *ACM Computing Surveys*, 54(10). <https://doi.org/10.1145/3507900>
- Cunningham, J. L., Shao, K. Z., Pang, R. Y., & Mengist, N. E. (2025). *Advancing NLP Data Equity: Practitioner Responsibility and Accountability in NLP Data Practices*. <https://jaylcunningham.com/work>
- Damayanti, N. M. (2025a). ANALISIS SENTIMEN PUBLIK PADA TAGAR #BTSCOMEBACK DI PLATFORM X MENGGUNAKAN INDOBERTWEET. *Jurnal Informatika Dan Teknik Elektro Terapan*, 13(3). <https://doi.org/10.23960/jitet.v13i3.7176>
- Damayanti, N. M. (2025b). ANALISIS SENTIMEN PUBLIK PADA TAGAR #BTSCOMEBACK DI PLATFORM X MENGGUNAKAN INDOBERTWEET. *Jurnal Informatika Dan Teknik Elektro Terapan*, 13(3). <https://doi.org/10.23960/jitet.v13i3.7176>
- Damayanti, N. M. (2025c). ANALISIS SENTIMEN PUBLIK PADA TAGAR #BTSCOMEBACK DI PLATFORM X MENGGUNAKAN INDOBERTWEET. *Jurnal Informatika Dan Teknik Elektro Terapan*, 13(3). <https://doi.org/10.23960/jitet.v13i3.7176>
- Danang, R., Hendrartono, R., Hendrati, I. M., Wardaya, W., Studi, P., Pembangunan, E., Ekonomi, F., Bisnis, D., Pembangunan, U., Veteran, N. ", & Timur, J. (2024). IMPLEMENTASI WEB CRAWLING PADA WEBSITE BPS JAWA TIMUR PADA DATA INLFASI DI JAWA TIMUR. *UMAT Jurnal Pengabdian Al-Shobar Untuk Masyarakat*, 1(2), 6–13. <https://journal.alshobar.or.id/index.php/umat>
- Das, R., & Singh, T. D. (2023). Multimodal Sentiment Analysis: A Survey of Methods, Trends, and Challenges. *ACM Computing Surveys*, 55(13). <https://doi.org/10.1145/3586075>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. <http://arxiv.org/abs/1810.04805>

- Dumas, D., Organisciak, P., Maio, S., & Doherty, M. (2020). *FOUR TEXT-MINING METHODS FOR MEASURING ELABORATION*. <https://openscoring.du.edu/scoring/>.
- Egger, R., & Yu, J. (2022). A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts. *Frontiers in Sociology*, 7. <https://doi.org/10.3389/fsoc.2022.886498>
- El-Demerdash, A. A., & Abdel- Hamid, N. B. (2025). METAHEURISTIC-DRIVEN HYPERPARAMETER OPTIMIZATION FOR BERT IN SENTIMENT ANALYSIS. *Archives for Technical Sciences*, 2(33), 176–192. <https://doi.org/10.70102/afts.2025.1833.176>
- Fadhel, M. (2024). Depression Detection of Users in Social Media X using IndoBERTweet. *Jurnal Dan Penelitian Teknik Informatika*, 8(2). <https://doi.org/10.33395/v8i2.13354>
- Fadilah, N. (2025). *Visualisasi Data Cerdas: Memanfaatkan Kecerdasan Buatan untuk Wawasan yang Lebih Dalam*.
- Gardazi, N. M., Daud, A., Malik, M. K., Bukhari, A., Alsahfi, T., & Alshemaimri, B. (2025). BERT applications in natural language processing: a review. *Artificial Intelligence Review*, 58(6). <https://doi.org/10.1007/s10462-025-11162-5>
- Grootendorst, M. (2022). *BERTopic: Neural topic modeling with a class-based TF-IDF procedure*. <http://arxiv.org/abs/2203.05794>
- Han, J., Liu, G., & Gao, Y. (2023a). Learners in the Metaverse: A Systematic Review on the Use of Roblox in Learning. In *Education Sciences* (Vol. 13, Issue 3). MDPI. <https://doi.org/10.3390/educsci13030296>
- Han, J., Liu, G., & Gao, Y. (2023b). Learners in the Metaverse: A Systematic Review on the Use of Roblox in Learning. In *Education Sciences* (Vol. 13, Issue 3). MDPI. <https://doi.org/10.3390/educsci13030296>
- Hart, P., Rhodes, E., & West, L. (2025). *Machine Learning-Enhanced NLP for Research Data Interpretation*.
- Hassani, H., Beneki, C., Unger, S., Mazinani, M. T., & Yeganegi, M. R. (2020). Text mining in big data analytics. *Big Data and Cognitive Computing*, 4(1), 1–34. <https://doi.org/10.3390/bdcc4010001>
- Jane, K. (2025). *Natural Language Processing (NLP) in Cybersecurity: Applications of NLP for analyzing security logs and threat reports*.
- Jesudas, B. D., Wilson, F., Mavrovich, R. A., Kindya, S., Yeh, F.-Y., Smith, S., Ravenel, J., Zheng, J., He, Y., Reischer, H. N., Bowker, J. C., Beverley, J., & Duncan, W. D. (2025). *Utilizing BERTopic Modeling for Concept Discovery in the Domain of Gerotranscendence and Solitude*. <https://doi.org/10.21203/rs.3.rs-7383440/v1>
- Julio Salas, H. (2023). Metaverse Virtual Communication Through Roblox Games For Teenagers. *International Journal of Progressive Sciences and Technologies (IJPSAT)*, 42(1), 184–189.
- Khaerunisa, S. (2025a). *The Impact and Potential of Roblox*.
- Khaerunisa, S. (2025b). *The Impact and Potential of Roblox*.
- Khairani, U. (2024). *PERBANDINGAN MODEL INDOBERT DAN INDOBERTTWEET UNTUK MENDETEKSI EMOSI KOMENTAR BERITA PADA MEDIA SOSIAL TUGAS AKHIR*.
- Khairani, U., Mutiawani, V., & Ahmadian, H. (2024). Pengaruh Tahapan Preprocessing Terhadap Model Indobert Dan Indobertweet Untuk Mendeteksi Emosi Pada Komentar Akun Berita Instagram. *Jurnal Teknologi Informasi*

- Dan Ilmu Komputer, 11(4), 887–894.
<https://doi.org/10.25126/jtiik.1148315>
- Koroteev MV. (2021). *BERT: A Review of Applications in Natural Language Processing and Understanding*.
- Koterwa, D., & Świtała, M. (2025). *Enhancing BERTopic with Intermediate Layer Representations*. <http://arxiv.org/abs/2505.06696>
- Koto, F., Lau, J. H., & Baldwin, T. (2021). *IndoBERTweet: A Pretrained Language Model for Indonesian Twitter with Effective Domain-Specific Vocabulary Initialization*. <http://arxiv.org/abs/2109.04607>
- Lathifah, L., Handoyo, E., Yosua, D., & Soetrisno, A. A. (2021). *SISTEM CRAWLING DATA INSTRUMEN AKREDITASI BERBASIS SELENIUM DAN PANDAS* (Vol. 10, Issue 1). <https://ejournal3.undip.ac.id/index.php/transient>
- Lent, H., Galinkin, E., Chen, Y., Pedersen, J. M., Derczynski, L., & Bjerva, J. (2025). *NLP Security and Ethics, in the Wild*. <https://doi.org/10.1162/tac1>
- Liao, H., & Li, X. (2025). Identifying Topics and Trends of China's Research on Third Front Construction Based on BERTopic Modeling. In *Panamerican Mathematical Journal* (Vol. 35, Issue 4s).
- Mao, R., Li, X., Ge, M., & Cambria, E. (2022). MetaPro: A computational metaphor processing model for text pre-processing. *Information Fusion*, 86–87, 30–43. <https://doi.org/10.1016/j.inffus.2022.06.002>
- Marwick, A. E., & Boyd, D. (2011). I tweet honestly, I tweet passionately: Twitter users, context collapse, and the imagined audience. *New Media and Society*, 13(1), 114–133. <https://doi.org/10.1177/1461444810365313>
- Maulana, A. D., & Lhaksmana, K. M. (2023). Sentiment Analysis on Tweets of Kanjuruhan Tragedy Using Deep Learning IndoBERTweet. *JURNAL MEDIA INFORMATIKA BUDIDARMA*, 7(3), 948. <https://doi.org/10.30865/mib.v7i3.6115>
- Mawaddah, S., Naswin, A., & Sulkifli, S. (2025). Pemetaan Lanskap Emosional Di Twitter: Visualisasi Sentimen Netral, Positif, dan Negatif Dengan Word Cloud. *RIGGS: Journal of Artificial Intelligence and Digital Business*, 4(4), 1276–1285. <https://doi.org/10.31004/riggs.v4i4.3650>
- Mufva, P. A., Chandra, K. H., Aji, K. F., Iswanto, I. A., & Joddy, S. (2025). Performance comparison of deep learning approaches for Indonesian twitter hate speech detection using IndoBERTweet embedding. *Procedia Computer Science*, 269, 1663–1671. <https://doi.org/10.1016/j.procs.2025.09.109>
- Muhammad Rayhan Nur, Yudi Wibisono, & Rani Megasari. (2025a). Analisis Sentimen dan Pemodelan Topik pada Post tentang Merek Teknologi di X Menggunakan Fine-tuning IndoBERT dan BERTopic. *Jurnal Komputer Teknologi Informasi Sistem Informasi (JUKTISI)*, 4(2), 743–750. <https://doi.org/10.62712/juktisi.v4i2.508>
- Muhammad Rayhan Nur, Yudi Wibisono, & Rani Megasari. (2025b). Analisis Sentimen dan Pemodelan Topik pada Post tentang Merek Teknologi di X Menggunakan Fine-tuning IndoBERT dan BERTopic. *Jurnal Komputer Teknologi Informasi Sistem Informasi (JUKTISI)*, 4(2), 743–750. <https://doi.org/10.62712/juktisi.v4i2.508>
- Murthy, D. (2025a). Downloaded from www.annualreviews.org. Guest (guest) IP: 36.69.57.24 On: Fri. *Annual Review of Sociology*. <https://doi.org/10.1146/annurev-soc-031021>

- Murthy, D. (2025b). Downloaded from www.annualreviews.org. Guest (guest) IP: 36.69.57.24 On: Fri. *Annual Review of Sociology*. <https://doi.org/10.1146/annurev-soc-031021>
- Nugraha, R., & Febriani, S. (2025a). Analisis Sentimen Topik #Kaburajadulu di Platform X Berbasis Model IndoBERTweet. In *Journal of Mandalika Literature* (Vol. 6, Issue 3).
- Nugraha, R., & Febriani, S. (2025b). Analisis Sentimen Topik #Kaburajadulu di Platform X Berbasis Model IndoBERTweet. In *Journal of Mandalika Literature* (Vol. 6, Issue 3).
- Palomino, M. A., & Aider, F. (2022). Evaluating the Effectiveness of Text Pre-Processing in Sentiment Analysis. *Applied Sciences (Switzerland)*, 12(17). <https://doi.org/10.3390/app12178765>
- Prameswari, F. D., & Wahyono, T. (2025). Model Analisis Sentimen Pengguna Aplikasi Belanja Online Menggunakan Metode Bidirectional Encoder Representations from Transformers (BERT). *Jurnal Algoritma*, 22(2). <https://doi.org/10.33364/algoritma/v.22-2.3035>
- Prihatin Prakoso, B., Ayu Khoirunnisa, F., Yusi Rukmana, F., Sri Prabaningtyas, V., Malik Kasibah, S., Jember, U., Kalimantan Tegalboto No, J., Timur, K., Summersari, K., Jember, K., & Timur, J. (2025). *ANALISIS DAN VISUALISASI DATA COURSE DI UDEMY (DATA COURSE ANALYSIS AND VISUALIZATION AT UDEMY)*.
- Randy Suryono, R. (2025). Sentiment Classification of Indonesian-Language Roblox Reviews Using IndoBERT with SMOTE Optimization. In *Journal of Applied Informatics and Computing (JAIC)* (Vol. 9, Issue 4). <http://jurnal.polibatam.ac.id/index.php/JAIC>
- Rejeb, A., Rejeb, K., Simske, S., & Süle, E. (2025). Industry 5.0 research: an approach using co-word analysis and BERTopic modeling. In *Discover Sustainability* (Vol. 6, Issue 1). Springer Nature. <https://doi.org/10.1007/s43621-025-01252-3>
- Rizkia, A. S., Wufron, W., & Roji, F. F. (2025). Analisis Sentimen Coretax: Perbandingan Pelabelan Data Manual, Transformers-Based, dan Lexicon-Based pada Performa IndoBERT. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 5(3). <https://doi.org/10.57152/malcom.v5i3.2151>
- Rizquina, A. Z., & Ratnasari, C. I. (2023). Implementasi Web Scraping untuk Pengambilan Data Pada Website E-Commerce. *Jurnal Teknologi Dan Sistem Informasi Bisnis*, 5(4), 377–383. <https://doi.org/10.47233/jteksis.v5i4.913>
- Roblox. (2025a). *Roblox Corporation 2025 Proxy Statement and 2024 Annual Report*.
- Roblox. (2025b). *Roblox Corporation (NYSE: RBLX)*.
- Tabassum, A., & Patil, R. R. (2020). A Survey on Text Pre-Processing & Feature Extraction Techniques in Natural Language Processing. *International Research Journal of Engineering and Technology*. www.irjet.net
- Tan, K. L., Lee, C. P., & Lim, K. M. (2023). A Survey of Sentiment Analysis: Approaches, Datasets, and Future Research. In *Applied Sciences (Switzerland)* (Vol. 13, Issue 7). MDPI. <https://doi.org/10.3390/app13074550>
- Twitter. (2019). *NYSE_TWTR_2019*.

- Umar, M. (2021). Sentiment Analysis Techniques and Application-Survey and Taxonomy. *Engineering and Technology Journal*, 04(01). <https://doi.org/10.47191/etj/v6i1.01>
- Vayansky, I., & Kumar, S. A. P. (2020). A review of topic modeling methods. *Information Systems*, 94. <https://doi.org/10.1016/j.is.2020.101582>
- Vel, S. (2021). *Pre-Processing techniques of Text Mining using Computational Linguistics and Python Libraries*. IEEE.
- Wadkar, P., Mundhe, S., Misal, S., & Mahankal, M. (2025). *Leveraging-NLP-for-Medical-Text-Analysis-and-Diagnosis-Support..*
- Wang, Y., O'Connor, K., Flores, I., Berdahl, C. T., Urbanowicz, R. J., Stevens, R., Bauermeister, J. A., & Gonzalez-Hernandez, G. (2024). Mpox Discourse on Twitter by Sexual Minority Men and Gender-Diverse Individuals: Infodemiological Study Using BERTopic. *JMIR Public Health and Surveillance*, 10. <https://doi.org/10.2196/59193>
- Wankhade, M., Rao, A. C. S., & Kulkarni, C. (2022). A survey on sentiment analysis methods, applications, and challenges. *Artificial Intelligence Review*, 55(7), 5731–5780. <https://doi.org/10.1007/s10462-022-10144-1>
- Zhu, Y., & Liu, Y. (2025). *Gibbs-BERTopic: A Hybrid Approach for Short Text Topic Modeling*.
- Zhu, Z. (2025). BERT and Its Applications in Natural Language Understanding. *Applied and Computational Engineering*, 175(1), 99–105. <https://doi.org/10.54254/2755-2721/2025.ast26090>