

USULAN PENELITIAN

**ANALISIS POLA BEBAN KINERJA DOSEN
UNIVERSITAS JAMBI DENGAN PENDEKATAN CROSS
INDUSTRY STANDARD PROCESS FOR DATA MINING
(CRISP-DM)**



**NAZWA EKA HERVY
F1E122096**

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI**

2026

USULAN PENELITIAN

ANALISIS POLA BEBAN KINERJA DOSEN
UNIVERSITAS JAMBI MENGGUNAKAN KERANGKA
KERJA *CROSS INDUSTRY STANDARD PROCESS FOR*
DATA MINING (CRISP-DM)

Diajukan sebagai salah satu syarat dalam melakukan penelitian dalam rangka
penulisan Skripsi pada Program Studi Sistem Informasi



NAZWA EKA HERVY
F1E122096

PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA

FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI
2026

HALAMAN PENGESAHAN

USULAN PENELITIAN

**ANALISIS POLA BEBAN KINERJA DOSEN UNIVERSITAS JAMBI DENGAN
PENDEKATAN *CROSS INDUSTRY STANDARD PROCESS FOR DATA MINING*
(CRISP-DM)**

Oleh:

NAZWA EKA HERVY

F1E122096

Disetujui:

Pembimbing Utama

Pembimbing Pendamping

Edi Saputra, S.T., M.Sc

NIP. 198501082015041003

Miraanty Yudistira, S.SI., M.Kom

NIP. 199403172024062002

Diketahui:

Dekan

Fakultas Sains dan Teknologi

Ketua Jurusan

Teknik Elektro dan Informatika

Drs. Jefri Marzal, M.Sc., D.I.T

NIP. 196806021993031004

Edi Saputra, S.T., M.Sc

NIP. 198501082015041003

DAFTAR ISI

DAFTAR ISI.....	i
DAFTAR GAMBAR.....	iii
DAFTAR TABEL	iv
I. PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	5
1.5 Batasan Masalah	5
II. TINJAUAN PUSTAKA	6
2.1 Perguruan Tinggi.....	6
2.2 Konsep Tri Dharma Perguruan Tinggi	7
2.3 Beban Kerja Dosen (BKD)	10
2.4 Kinerja Dosen dalam Pelaksanaan Tri Dharma	12
2.5 <i>Data mining</i>	13
2.6 CRISP-DM.....	14
2.7 Exploratory Data Analysis dan <i>Preprocessing</i> Data	15
2.8 <i>Clustering</i>	17
2.9 Algoritma <i>K-means clustering</i>	21
2.10 Penelitian Terdahulu	25
III. METODOLOGI PENELITIAN	28
3.1 Jenis Penelitian.....	28
3.2 Kerangka Penelitian	28
3.3 <i>Business understanding</i>	29
3.4 <i>Data understanding</i>	31
3.5 <i>Data preparation</i>	34
3.6 <i>Modeling</i>	36
3.7 <i>Evaluation</i>	41
3.8 <i>Deployment</i>	42

3.9 Perangkat Penelitian	42
3.10 Timeline Kegiatan.....	42
DAFTAR PUSTAKA	44
Bibliography	Error! Bookmark not defined.

DAFTAR GAMBAR

Gambar 1. Tahapan CRISP-DM.....	14
Gambar 2. Kerangka Penelitian.....	29
Gambar 3. <i>K-means clustering</i>	39

DAFTAR TABEL

Tabel 1. Komponen BKD dan Batasan Beban SKS Berdasarkan UU No. 14 Tahun 2005 dan PUBKD 2021.....	11
Tabel 2. Penyesuaian BKD untuk Dosen dengan Tugas Tambahan/Jabatan Fungsional.....	12
Tabel 3. Perbandingan Metode <i>Clustering</i>	18
Tabel 4. Daftar Penelitian Terdahulu.....	25
Tabel 5. Variabel Data yang Dibutuhkan.....	32
Tabel 6. Strategi Penanganan <i>Missing value</i>	34
Tabel 7. Timeline Kegiatan.....	43

I. PENDAHULUAN

1.1 Latar Belakang

Dalam menghadapi tuntutan global terhadap peningkatan kualitas pendidikan tinggi, peran dosen sebagai penggerak utama Tri Dharma Perguruan Tinggi menjadi sangat krusial. Pentingnya posisi dosen ini diperkuat oleh Undang-Undang Nomor 12 Tahun 2012 tentang Pendidikan Tinggi, yang menegaskan bahwa dosen merupakan aktor utama dalam implementasi Tri Dharma Perguruan Tinggi. Kualitas perguruan tinggi ditentukan secara langsung oleh seberapa efektif dosen menjalankan ketiga dharma tersebut secara proporsional dan berkesinambungan (Sulistyaningrum et al., 2025). Dosen tidak hanya dituntut untuk melaksanakan kegiatan pengajaran, tetapi juga melakukan penelitian dan pengabdian kepada masyarakat secara seimbang guna memastikan tercapainya visi perguruan tinggi sebagai pusat pengembangan ilmu pengetahuan, teknologi, dan inovasi yang berdaya saing global.

Menurut Peraturan Menteri Pendidikan, Kebudayaan, Riset, dan Teknologi Nomor 84 Tahun 2021 tentang Beban Kerja Dosen pada Perguruan Tinggi menetapkan bahwa BKD harus mencerminkan pelaksanaan Tri Dharma Perguruan Tinggi secara proporsional dengan beban minimal 12 SKS dan maksimal 16 SKS per semester. Dalam konteks transformasi pendidikan tinggi, proporsionalitas ini tidak hanya bersifat administratif, tetapi menjadi indikator strategis mutu institusi. Ketidakseimbangan pelaksanaan Tri Dharma dapat menghambat karier akademik dosen, menurunkan produktivitas riset, dan mengurangi kontribusi kepada masyarakat serta universitas (Nashrullah et al., 2025). Sebagai tindak lanjut, perguruan tinggi perlu memastikan adanya sistem perencanaan, pemantauan, dan evaluasi BKD yang terintegrasi dan berkelanjutan. Pendekatan ini tidak hanya menjamin kepatuhan terhadap regulasi, tetapi juga mendorong optimalisasi kinerja dosen dalam mendukung pencapaian visi dan daya saing institusi di era transformasi pendidikan tinggi.

Banyak perguruan tinggi di Indonesia masih menghadapi tantangan mendistribusikan beban kerja dosen secara ideal. Dosen cenderung lebih fokus pada pengajaran daripada penelitian dan pengabdian, terutama di universitas daerah dengan keterbatasan sumber daya riset dan beban administrasi tinggi (Simamora et al., 2024). Dosen struktural seperti dekan dan kaprodi menghabiskan waktu signifikan untuk tugas administratif, menyebabkan ketidakseimbangan proporsi Tri Dharma meski wajib minimal 6 SKS pendidikan (Pratama & Agastya, 2026). Situasi ini berpotensi berdampak pada penurunan

produktivitas riset dan kontribusi institusi terhadap pengembangan ilmu pengetahuan serta masyarakat.

Ketimpangan ini menimbulkan tantangan tersendiri bagi manajemen perguruan tinggi, karena keseimbangan Tri Dharma tidak hanya berpengaruh terhadap performa individu dosen, tetapi juga terhadap reputasi akademik dan kinerja kelembagaan secara keseluruhan (Irene, 2023). Dalam konteks sistem pendidikan tinggi Indonesia yang kini diarahkan menuju transformasi berbasis *outcome-based education* (OBE) dan peningkatan daya saing global, diperlukan pendekatan baru yang mampu mengidentifikasi secara akurat bagaimana pola beban kerja dosen terbentuk dan bagaimana variasinya dapat memengaruhi efektivitas institusi dalam menjalankan Tri Dharma Perguruan Tinggi. Pemahaman yang mendalam terhadap pola distribusi ini akan menjadi landasan penting dalam merumuskan kebijakan pengembangan karir, insentif penelitian, dan redistribusi beban kerja yang adil dan seimbang.

Universitas Jambi (UNJA) sebagai perguruan tinggi negeri yang tengah berkembang pesat menghadapi tantangan dalam memastikan keseimbangan kinerja dosen pada setiap aspek Tri Dharma Perguruan Tinggi. Meskipun pelaporan Beban Kerja Dosen (BKD) telah dilakukan secara rutin setiap semester, data tersebut selama ini lebih banyak dimanfaatkan untuk kepentingan administratif, seperti verifikasi kelayakan jabatan fungsional, dan belum diolah menjadi informasi strategis. Banyak perguruan tinggi di Indonesia belum mengoptimalkan data BKD sebagai basis analisis kinerja dosen melalui pendekatan *data mining* dan *clustering* (Dewi et al., 2022). Selain itu, belum tersedia kajian sistematis yang memetakan secara kuantitatif pola distribusi pelaksanaan Tri Dharma Perguruan Tinggi dosen di UNJA, padahal analisis berbasis data berpotensi mengungkap dinamika penting seperti perbedaan beban kerja antara dosen dengan jabatan akademik tinggi dan dosen yang memegang tugas struktural.

Untuk mengatasi kesenjangan tersebut, penelitian ini menggunakan metode *K-means clustering* sebagai pendekatan analitis yang bertujuan untuk mengidentifikasi pola tersembunyi dalam data Beban Kerja Dosen (BKD) di Universitas Jambi. Metode ini termasuk dalam kategori *Unsupervised learning* yang berfungsi untuk mengelompokkan data berdimensi tinggi ke dalam beberapa *cluster* berdasarkan tingkat kemiripan karakteristik antar data (Han et al., 2022). Melalui penerapan algoritma ini, penelitian berupaya mengelompokkan dosen berdasarkan kecenderungan pelaksanaan Tri Dharma Perguruan Tinggi. Hasil analisis *cluster* yang diperoleh diharapkan mampu memberikan gambaran

empiris mengenai distribusi kinerja dosen di Universitas Jambi secara lebih objektif dan terukur.

Sebagian besar penelitian terdahulu mengenai Beban Kerja Dosen (BKD) dan kinerja dosen di Indonesia masih didominasi pendekatan deskriptif dan berorientasi administratif, seperti evaluasi pelaporan BKD serta pengembangan sistem informasi pendukungnya tanpa eksplorasi pola distribusi Tri Dharma (Nugraha & Rosmeida, 2021). Selain itu, penerapan pendekatan berbasis *machine learning*, khususnya *clustering analysis*, dalam memahami dinamika beban kerja dosen di tingkat institusional masih sangat terbatas. Kondisi ini juga terlihat di Universitas Jambi, di mana hingga saat ini belum terdapat penelitian yang secara khusus menggunakan analisis berbasis data untuk mengidentifikasi pola pelaksanaan Tri Dharma Perguruan Tinggi. Pendekatan analitis semacam ini berpotensi memberikan kontribusi signifikan dalam mendukung transformasi akademik serta pengelolaan sumber daya manusia yang lebih strategis dan berkelanjutan di lingkungan universitas.

Kebaruhan penelitian ini terletak pada penerapan metode *K-means clustering* terhadap data aktual Beban Kerja Dosen (BKD) di Universitas Jambi untuk mengeksplorasi pola distribusi kinerja dosen dalam pelaksanaan Tri Dharma Perguruan Tinggi. Pendekatan ini memungkinkan identifikasi pola kecenderungan spesifik dari setiap kelompok dosen, seperti dominasi pada kegiatan pendidikan, penelitian, atau pengabdian kepada masyarakat, yang belum pernah diungkap secara komprehensif dalam laporan administratif BKD sebelumnya. Selain itu, penelitian ini memberikan perspektif baru dengan membandingkan karakteristik kinerja antara dosen fungsional dan dosen struktural, sehingga memperkaya pemahaman mengenai perbedaan orientasi akademik dan administratif di lingkungan universitas.

Untuk memastikan proses analisis data berlangsung secara sistematis dan terstruktur, penelitian ini mengadopsi kerangka kerja *Cross Industry Standard Process for Data mining* (CRISP-DM) sebagai metodologi utama. CRISP-DM merupakan standar industri yang terdiri dari enam tahapan iteratif meliputi pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan *Deployment* (Chapman et al., 2000). Penerapan kerangka kerja ini memungkinkan proses analisis BKD dilakukan secara terstandar mulai dari identifikasi permasalahan hingga interpretasi hasil *cluster* untuk keperluan pengambilan keputusan strategis, sehingga meningkatkan validitas metodologis dan kredibilitas temuan penelitian sebagai dasar rekomendasi kebijakan manajemen kinerja dosen.

Berdasarkan temuan dan analisis tersebut, penelitian ini diharapkan mampu memberikan kontribusi nyata bagi Universitas Jambi dalam mengoptimalkan manajemen kinerja dosen berbasis data dan mendukung arah kebijakan universitas menuju keseimbangan pelaksanaan Tri Dharma Perguruan Tinggi yang berkelanjutan. Dengan memanfaatkan pendekatan analisis data melalui *K-means clustering*, penelitian berjudul **“Analisis Pola Beban Kinerja Dosen Universitas Jambi dengan Pendekatan Cross Industry Standard Process for Data mining (CRISP-DM)”** ini menjadi langkah strategis dalam menyediakan gambaran empiris tentang situasi aktual kinerja dosen, sekaligus menjadi pijakan ilmiah bagi pimpinan universitas dalam merancang kebijakan pengembangan karir dan peningkatan mutu akademik di masa mendatang.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas maka dapat dirumuskan masalah dalam penelitian ini yaitu:

1. Bagaimana pola pemenuhan Beban Kerja Dosen (BKD) berdasarkan keempat komponen utama Tri Dharma Perguruan Tinggi, yaitu pendidikan dan pengajaran, penelitian, pengabdian kepada masyarakat, dan kegiatan penunjang, pada dosen tetap Universitas Jambi?
2. Apakah terdapat perbedaan pola distribusi BKD yang sistematis antar fakultas dan antar jenjang jabatan fungsional dosen di Universitas Jambi?
3. Kelompok pola BKD apa saja yang terbentuk pada dosen tetap Universitas Jambi berdasarkan metode *K-means clustering*, dan bagaimana karakteristik setiap kelompok tersebut ditinjau dari distribusi komponen Tri Dharma?

1.3 Tujuan Penelitian

Adapun tujuan yang ingin dicapai dari penelitian ini adalah:

1. Mengidentifikasi dan mendeskripsikan pola pemenuhan Beban Kerja Dosen (BKD) berdasarkan keempat komponen utama Tri Dharma Perguruan Tinggi, yaitu pendidikan dan pengajaran, penelitian, pengabdian kepada masyarakat, dan kegiatan penunjang, di Universitas Jambi menggunakan pendekatan *Exploratory Data Analysis* (EDA).
2. Menganalisis perbedaan pola BKD antar fakultas dan antar jenjang jabatan fungsional dosen di Universitas Jambi menggunakan pendekatan EDA komparatif.

3. Mengidentifikasi kelompok-kelompok dosen yang terbentuk berdasarkan kesamaan pola BKD serta menganalisis karakteristik setiap kelompok tersebut menggunakan algoritma *K-means clustering*.

1.4 Manfaat Penelitian

1. Manfaat teoritis, menambah khazanah ilmu pengetahuan di bidang *data mining* dan *Unsupervised learning*, khususnya dalam penerapan *K-means clustering* untuk pemodelan kinerja sumber daya manusia di sektor pendidikan tinggi. Penelitian ini juga memperkaya literatur mengenai evaluasi kinerja dosen yang fokus pada analisis proporsionalitas, bukan hanya pada nilai kumulatif.
2. Manfaat Praktis, penelitian ini memberikan manfaat strategis bagi Universitas Jambi (UNJA) dengan menyajikan gambaran empiris dan objektif berbasis *cluster* mengenai pola kinerja Tri Dharma Perguruan Tinggi dosen. Hasil analisis *clusterisasi* ini akan menjadi dasar ilmiah bagi pimpinan UNJA untuk merumuskan Kebijakan BKD Optimal yang lebih adil dan merancang Strategi Pengembangan Karir yang tepat sasaran, sehingga mampu mendorong keseimbangan Tri Dharma Perguruan Tinggi dan mendukung percepatan karir fungsional dosen secara berkelanjutan.

1.5 Batasan Masalah

Untuk menjaga fokus, kedalaman, dan validitas analisis, penelitian ini membatasi ruang lingkup sebagai berikut:

1. Data yang dianalisis mencakup empat unsur utama BKD berdasarkan kerangka Tri Dharma Perguruan Tinggi, yaitu pendidikan dan pengajaran, penelitian, pengabdian kepada masyarakat, dan kegiatan penunjang. Analisis tidak mencakup sub-unsur atau rubrik detail di dalam setiap komponen utama tersebut.
2. Populasi penelitian dibatasi pada Dosen Tetap yang memiliki kewajiban mengisi BKD di lingkungan Universitas Jambi (UNJA) pada semester ganjil dan genap Tahun Akademik 2024/2025.
3. Penelitian ini tidak bertujuan untuk menilai kualitas atau capaian kumulatif kinerja dosen secara subjektif (misalnya, nilai publikasi), melainkan hanya mengeksplorasi pola distribusi proporsional kinerja untuk menjadi dasar rekomendasi kebijakan strategis.
4. Tahap *deployment* penelitian ini dibatasi hingga penyusunan laporan analisis. Visualisasi interaktif menggunakan tools seperti Tableau berada di luar cakupan penelitian ini.

II. TINJAUAN PUSTAKA

2.1 Perguruan Tinggi

Perguruan tinggi merupakan institusi pendidikan tinggi yang menyelenggarakan kegiatan pendidikan, penelitian, dan pengabdian kepada masyarakat sebagai wujud implementasi Tri Dharma Perguruan Tinggi. Menurut Undang-Undang Nomor 12 Tahun 2012 tentang Pendidikan Tinggi, perguruan tinggi adalah satuan pendidikan yang menyelenggarakan pendidikan tinggi dan dapat berbentuk universitas, institut, sekolah tinggi, politeknik, akademi, dan akademi komunitas. Perguruan tinggi memiliki otonomi dalam pengelolaan kelembagaan sebagai pusat penyelenggaraan dan pengembangan pendidikan tinggi, penelitian ilmiah, serta pengabdian kepada masyarakat.

Sebagai institusi akademik, perguruan tinggi memiliki peran strategis dalam menghasilkan sumber daya manusia yang berkualitas dan berkontribusi terhadap pembangunan bangsa. Perguruan tinggi berfungsi sebagai pusat pengembangan ilmu pengetahuan, teknologi, dan seni yang dilaksanakan melalui Tri Dharma Perguruan Tinggi yang mencakup pendidikan dan pengajaran, penelitian dan pengembangan, serta pengabdian kepada masyarakat (Situmeang, 2021). Ketiga pilar ini merupakan tanggung jawab utama yang harus dilaksanakan oleh seluruh dosen sebagai tenaga pendidik profesional.

Dalam menjalankan fungsinya, perguruan tinggi dituntut untuk menerapkan sistem manajemen yang efektif dan efisien. Manajemen perguruan tinggi harus mampu mengintegrasikan berbagai sumber daya yang ada, termasuk sumber daya manusia, untuk mencapai tujuan organisasi secara optimal (Abdillah, 2024). Dosen sebagai aset utama perguruan tinggi memiliki peran sentral dalam melaksanakan Tri Dharma Perguruan Tinggi, sehingga pengukuran dan evaluasi kinerja dosen menjadi aspek penting dalam manajemen perguruan tinggi.

Dosen sebagai pendidik profesional memiliki tugas utama melaksanakan Tri Dharma Perguruan Tinggi yang meliputi pendidikan dan pengajaran, penelitian, serta pengabdian kepada masyarakat. Berdasarkan Undang-Undang Nomor 14 Tahun 2005 tentang Guru dan Dosen, dosen adalah pendidik profesional dan ilmuwan dengan tugas mentransformasikan, mengembangkan, dan menyebarkan ilmu pengetahuan melalui ketiga aspek tersebut. Dalam pelaksanaannya, dosen bertanggung jawab merencanakan dan melaksanakan pembelajaran, melakukan penelitian dan publikasi ilmiah, menerapkan keahliannya untuk memberikan solusi bagi masyarakat, serta dapat mengemban

tugas tambahan seperti menjadi pembimbing mahasiswa, pengelola jurnal, atau memegang jabatan struktural.

Kinerja dosen di perguruan tinggi diatur melalui sistem beban kerja dosen (BKD) sebagaimana diatur dalam Peraturan Menteri Pendidikan dan Kebudayaan Nomor 3 Tahun 2020. Beban kerja dosen merupakan parameter penting dalam mengukur produktivitas dan kinerja dosen yang mencakup kegiatan pendidikan, penelitian, dan pengabdian kepada masyarakat, serta tugas tambahan penunjang lainnya (Nadeak, 2020). Sistem BKD ini membantu perguruan tinggi dalam melakukan monitoring dan evaluasi terhadap pelaksanaan Tri Dharma Dosen secara objektif dan terukur.

Universitas Jambi (UNJA) adalah perguruan tinggi negeri yang berlokasi di Kota Jambi, Provinsi Jambi. Didirikan pada tanggal 1 April 1963 berdasarkan Keputusan Menteri Perguruan Tinggi dan Ilmu Pengetahuan Nomor 25 Tahun 1963, UNJA telah berkembang menjadi salah satu universitas terkemuka di wilayah Sumatera. Saat ini UNJA berstatus sebagai Perguruan Tinggi Negeri Berbadan Hukum (PTN-BH) yang memiliki otonomi lebih luas dalam pengelolaan akademik dan kelembagaan.

UNJA mengelola 11 (sebelas) fakultas yang tersebar di berbagai kampus, yaitu: (1) Fakultas Keguruan dan Ilmu Pendidikan (FKIP); (2) Fakultas Hukum; (3) Fakultas Ekonomi dan Bisnis; (4) Fakultas Pertanian; (5) Fakultas Peternakan; (6) Fakultas Kedokteran dan Ilmu Kesehatan; (7) Fakultas Sains dan Teknologi (FST); (8) Fakultas Ilmu Sosial dan Ilmu Politik (FISIP); (9) Fakultas Teknologi Pertanian; (10) Fakultas Kehutanan; dan (11) Program Pascasarjana. Masing-masing fakultas memiliki karakteristik beban kerja yang berbeda, baik dari sisi intensitas penelitian, kegiatan pengabdian, maupun struktur pengajaran.

2.2 Konsep Tri Dharma Perguruan Tinggi

Tri Dharma Perguruan Tinggi merupakan tiga pilar utama yang wajib dilaksanakan perguruan tinggi di Indonesia, yaitu pendidikan, penelitian, dan pengabdian kepada masyarakat sebagaimana diamanatkan dalam UU No. 12 Tahun 2012. Ketiga dharma ini bersifat integratif dan saling memperkuat dalam mencapai tujuan pendidikan nasional serta meningkatkan daya saing bangsa. Tri Dharma Perguruan Tinggi membentuk karakter akademik dan masyarakat berperadaban (Amalia, 2024).

Implementasi Tri Dharma Perguruan Tinggi membutuhkan sistem informasi yang mampu mendukung pengelolaan dan monitoring secara terintegrasi (Jamaluddin et al., 2022). Selain itu, penguatan Tri Dharma Perguruan Tinggi menjadi semakin penting pada era revolusi industri 4.0,

sehingga kesiapan dosen dalam menjalankan pengajaran, penelitian, dan pengabdian secara simultan dan berkelanjutan menjadi faktor kunci dalam menjawab kebutuhan pembangunan nasional dan meningkatkan kesejahteraan Masyarakat (Gunawan et al., 2020).

A. Dharma Pendidikan dan Pengajaran

Dharma pendidikan dan pengajaran merupakan pilar pertama Tri Dharma Perguruan Tinggi dan menjadi tanggung jawab utama dosen dalam mentransformasikan ilmu kepada mahasiswa. Berdasarkan Pasal 1 UU No. 12 Tahun 2012, pendidikan merupakan usaha sadar dan terencana untuk menciptakan suasana belajar yang memungkinkan peserta didik mengembangkan potensi spiritual, kepribadian, kecerdasan, dan keterampilannya. Kegiatan pendidikan meliputi perkuliahan, tutorial, pembelajaran daring dan luring berbasis *student-centered learning*, pembimbingan seminar, KKN, PKL, magang, pertukaran pelajar, kuliah berbasis penelitian, kegiatan wirausaha, serta pembimbingan tugas akhir sebagaimana diatur dalam Keputusan Dirjen Dikti No. 12/E/KPT/2021.

Beban mengajar dosen juga ditetapkan melalui Pasal 72 UU No. 14 Tahun 2005 dan PP No. 37 Tahun 2009 dengan ketentuan minimal 9 SKS untuk memastikan interaksi akademik yang memadai. Porsi pendidikan dan pengajaran sering mendominasi beban kerja dosen pada perguruan tinggi dengan keterbatasan sumber daya penelitian (Azfirmawarman et al., 2024). Indikator kinerja pendidikan mencakup kualitas proses pembelajaran, capaian pembelajaran mahasiswa, inovasi metode, pengembangan bahan ajar, dan ketepatan penyelenggaraan perkuliahan. Dengan demikian, kualitas pengajaran tidak hanya bergantung pada jumlah SKS, tetapi juga pada efektivitas dosen dalam membimbing mahasiswa mencapai capaian pembelajaran kurikuler.

B. Dharma Penelitian

Dharma penelitian merupakan pilar kedua Tri Dharma Perguruan Tinggi yang menempatkan dosen sebagai ilmuwan yang bertanggung jawab mengembangkan dan menemukan pengetahuan baru, sebagaimana Pasal 1 UU No. 12 Tahun 2012 yang mendefinisikan penelitian sebagai kegiatan ilmiah sistematis untuk memperoleh informasi dan menguji suatu cabang ilmu pengetahuan dan teknologi. Kegiatan penelitian mencakup penelitian dasar, terapan, dan pengembangan, dengan bentuk yang diakui sebagai beban kerja dosen antara lain publikasi ilmiah, karya inovatif atau teknologi tepat guna,

perolehan HKI, serta penelitian berpendanaan pemerintah atau swasta sesuai Keputusan Dirjen Dikti No. 12/E/KPT/2021.

Publikasi ilmiah menjadi luaran utama dan manajemen publikasi berbasis SINTA penting untuk meningkatkan kinerja institusi karena integrasinya dengan basis data seperti Scopus, Google Scholar, dan Garuda (Syarifah et al., 2025). Produktivitas penelitian diukur melalui jumlah publikasi terindeks, sitasi, HKI, serta hibah kompetitif, di mana peningkatan kinerja penelitian merupakan faktor strategis menuju perguruan tinggi berakreditasi unggul (Handayani & Hidayat, 2024). Dengan demikian, peningkatan kualitas dan kuantitas penelitian memerlukan komitmen institusi dan pemangku kepentingan untuk membangun ekosistem riset yang kondusif dan berkelanjutan.

C. Dharma Pengabdian kepada Masyarakat

Dharma pengabdian kepada masyarakat merupakan pilar ketiga Tri Dharma Perguruan Tinggi yang mencerminkan kontribusi perguruan tinggi dalam menerapkan ilmu pengetahuan untuk kesejahteraan masyarakat, sesuai UU No. 12 Tahun 2012 yang mendefinisikannya sebagai kegiatan pemanfaatan ilmu dan teknologi oleh civitas akademika untuk memajukan kesejahteraan dan mencerdaskan kehidupan bangsa. Pengabdian bertujuan mengaplikasikan hasil penelitian dan keilmuan dosen secara langsung kepada masyarakat sehingga memberikan manfaat nyata sekaligus memperkaya pemahaman dosen terhadap permasalahan riil yang dapat menjadi dasar penelitian lanjutan dan pengembangan materi pembelajaran.

Keputusan Dirjen Dikti No. 12/E/KPT/2021 menjelaskan bahwa bentuk pengabdian mencakup pelayanan masyarakat, penyuluhan, pelatihan, lokakarya, ceramah, kegiatan pembangunan sesuai bidang keahlian, serta karya pengabdian yang dipublikasikan, dengan relevansi program terhadap kebutuhan masyarakat sebagai aspek fundamental. Pengabdian harus berbasis identifikasi kebutuhan nyata dan selaras dengan kompetensi dosen agar menghasilkan dampak optimal dan berkelanjutan (Solehuddin et al., 2025). Indikator kinerja pengabdian mencakup jumlah kegiatan, jumlah penerima manfaat, luaran publikasi, dan keberlanjutan dampak pemberdayaan. Dengan demikian, pengabdian yang efektif tidak hanya memberikan solusi jangka pendek, tetapi juga memberdayakan masyarakat agar mampu menyelesaikan permasalahan secara mandiri serta memperkuat hubungan antara perguruan tinggi dan masyarakat dalam kerangka pembangunan berkelanjutan.

D. Kegiatan Penunjang Tri Dharma

Selain ketiga dharma utama, dosen memiliki kewajiban melaksanakan kegiatan penunjang yang memperkuat pelaksanaan Tri Dharma Perguruan Tinggi serta berkontribusi pada peningkatan profesionalisme dan kualitas pengelolaan institusi. Keputusan Dirjen Dikti No. 12/E/KPT/2021 mencakup berbagai bentuk kegiatan penunjang, seperti keanggotaan panitia atau badan di perguruan tinggi dan lembaga pemerintah, keikutsertaan dalam organisasi profesi, peran sebagai delegasi nasional, partisipasi aktif dalam pertemuan ilmiah, penerimaan penghargaan, penulisan buku pelajaran, prestasi bidang olahraga atau seni, serta keterlibatan dalam pengelolaan jurnal ilmiah.

Pengembangan SDM perguruan tinggi tidak hanya ditopang kompetensi akademik, tetapi juga kapasitas manajerial, organisasional, dan kepemimpinan yang dapat diperkuat melalui kegiatan penunjang. Meskipun demikian, alokasi waktu untuk kegiatan tersebut harus proporsional agar tidak mengganggu tugas utama dalam pendidikan, penelitian, dan pengabdian. Dosen yang memegang jabatan struktural seperti rektor, dekan, atau ketua program studi juga memiliki penyesuaian beban kerja, di mana ketentuan Dirjen Dikti No. 12/E/KPT/2021 mewajibkan mereka tetap melaksanakan dharma pendidikan minimal 3 SKS, sementara total beban kerja disesuaikan dengan tingkat tanggung jawab jabatan sehingga seluruh aktivitas penunjang tetap mendukung efektivitas pelaksanaan Tri Dharma Perguruan Tinggi secara menyeluruh.

2.3 Beban Kerja Dosen (BKD)

Beban Kerja Dosen (BKD) merupakan instrumen evaluasi kinerja dosen sebagai pendidik profesional dan ilmuwan yang mencakup pelaksanaan pendidikan, penelitian, pengabdian kepada masyarakat, serta kegiatan penunjang Tri Dharma Perguruan Tinggi. BKD wajib dilaporkan setiap semester sebagai bentuk akuntabilitas, dengan landasan hukum yang diatur dalam UU No. 20 Tahun 2003, UU No. 14 Tahun 2005, UU No. 12 Tahun 2012, PP No. 37 Tahun 2009, PermenPAN-RB No. 17 Tahun 2013, dan Keputusan Dirjen Dikti No. 12/E/KPT/2021. Pasal 72 UU No. 14 Tahun 2005 menetapkan beban kerja dosen minimal 12 SKS dan maksimal 16 SKS per semester, di mana 1 SKS ekuivalen dengan 36 hingga 48 jam kerja yang mencakup pembelajaran, penelitian, pengabdian, dan tugas tambahan. BKD berfungsi memastikan profesionalisme dosen, menyediakan standar kinerja terukur, menjadi dasar penilaian jabatan fungsional dan tunjangan profesi, serta mendukung akuntabilitas pengelolaan SDM.

Kriteria dasar pembentukan BKD mengacu pada Pasal 72 Undang-Undang Nomor 14 Tahun 2005 yang menetapkan beban kerja minimal 12 SKS dan maksimal 16 SKS per semester, di mana 1 SKS ekuivalen dengan 36–48 jam kerja efektif per semester yang mencakup keseluruhan aktivitas Tri Dharma. Tabel 1 berikut menyajikan rincian komponen BKD beserta batasan beban SKS yang berlaku.

Tabel 1. Komponen BKD dan Batasan Beban SKS Berdasarkan UU No. 14 Tahun 2005 dan PUBKD 2021

No	Komponen BKD	Beban SKS	Keterangan
1	Pendidikan dan Pengajaran	Min. 9 SKS	Wajib setiap semester
2	Penelitian	Min. 3 SKS	Wajib setiap semester
3	Pengabdian kepada Masyarakat	Min. 1 SKS	Wajib setiap semester
4	Kegiatan Penunjang	Maks. 2 SKS	Opsional, sesuai kegiatan
Total	BKD Keseluruhan	12 – 16 SKS	Sesuai Pasal 72 UU No. 14/2005

Sumber: UU No. 14/2005 Pasal 72 dan Keputusan Dirjen Dikti No. 12/E/KPT/2021

Komponen BKD terdiri atas unsur pendidikan, penelitian, pengabdian kepada masyarakat, dan kegiatan penunjang, masing-masing dengan nilai ekuivalensi SKS yang berbeda. Pada unsur pendidikan, SKS dihitung berdasarkan jumlah SKS mata kuliah, jumlah mahasiswa, jenjang pendidikan, serta jenis aktivitas pembelajaran. Pada unsur penelitian, nilai SKS bergantung pada jenis dan reputasi luaran, misalnya publikasi jurnal internasional bereputasi (Q1–Q2) bernilai hingga 25 SKS, jurnal SINTA 1–2 bernilai 10 SKS, dan jurnal SINTA 3–6 bernilai 6 SKS. Penilaian kegiatan pengabdian didasarkan pada skala, relevansi, dan luaran, sedangkan kegiatan penunjang seperti kepanitiaan, organisasi profesi, dan pengelolaan jurnal memperoleh nilai SKS yang lebih kecil namun tetap diakui sesuai ketentuan. Transformasi digital BKD diwujudkan melalui Sistem Informasi Sumber Daya Terintegrasi (SISTER) yang memungkinkan pelaporan aktivitas dosen secara *real time*. Dalam SISTER, dosen menyusun Rencana BKD di awal semester dan Laporan BKD di akhir semester, kemudian diverifikasi oleh dua asesor atau tiga jika terjadi perbedaan signifikan.

Dosen yang memegang jabatan fungsional atau tugas tambahan tertentu mendapatkan pengaturan BKD yang berbeda dari dosen fungsional biasa. Berdasarkan Pedoman PUBKD 2021, dosen yang menjabat sebagai Rektor, Wakil Rektor, Dekan, atau Direktur Pascasarjana memiliki kewajiban dharma pendidikan minimal 3 SKS per semester. Ketua Program Studi dan Ketua Jurusan diwajibkan melaksanakan dharma pendidikan minimal 6 SKS per semester.

Pengurangan kewajiban pengajaran ini dimaksudkan untuk mengakomodasi beban kerja administratif yang signifikan yang melekat pada jabatan fungsional tersebut. Tabel 2 merangkum penyesuaian beban BKD untuk dosen dengan tugas tambahan.

Tabel 2. Penyesuaian BKD untuk Dosen dengan Tugas Tambahan/Jabatan Fungsional

Jabatan/Tugas Tambahan	Beban SKS Minimal/Semester	Jabatan Fungsional Umumnya	Dasar Hukum
Rektor	Min. 3 SKS	Guru Besar/Lektor Kepala	PUBKD 2021
Wakil Rektor	Min. 3 SKS	Guru Besar/Lektor Kepala	PUBKD 2021
Dekan/Direktur Pascasarjana	Min. 3 SKS	Lektor Kepala/Guru Besar	PUBKD 2021
Ketua Jurusan/Prodi	Min. 6 SKS	Lektor/Lektor Kepala	PUBKD 2021
Dosen Non-Struktural	Min. 9 SKS	Semua jenjang	UU No. 14/2005 Ps.72

Data BKD tidak hanya berfungsi administratif tetapi juga strategis bagi perguruan tinggi dalam pengambilan keputusan berbasis data. Monitoring BKD memungkinkan identifikasi distribusi beban kerja, ketimpangan pelaksanaan Tri Dharma Perguruan Tinggi, serta kebutuhan pengembangan kapasitas dosen (Sunaengsih et al., 2020). Di Universitas Jambi, sistem SISTER telah digunakan secara penuh untuk mendokumentasikan seluruh aktivitas dosen, mencakup pengajaran, penelitian, pengabdian, dan kegiatan penunjang. Dokumentasi ini menyediakan landasan empiris penting untuk analisis pola kinerja dosen dan mendukung perumusan kebijakan institusional yang lebih efektif dan tepat sasaran.

2.4 Kinerja Dosen dalam Pelaksanaan Tri Dharma

Kinerja dosen merupakan capaian profesional yang mencerminkan pelaksanaan tugas dalam pendidikan, penelitian, dan pengabdian kepada masyarakat. Kinerja dosen dinilai dari kualitas serta kuantitas aktivitas akademik dan dampaknya terhadap mahasiswa, ilmu pengetahuan, dan masyarakat. Dimensi kinerja mencakup kompetensi pedagogik, profesional, sosial, dan kepribadian sebagaimana tercantum dalam Permendiknas Nomor 16 Tahun 2007, yang dipengaruhi oleh faktor internal seperti motivasi dan kompetensi, serta faktor eksternal seperti dukungan institusi dan ketersediaan fasilitas.

Indikator kinerja Tri Dharma mencakup ukuran kuantitatif dan kualitatif pada bidang pendidikan, penelitian, dan pengabdian kepada masyarakat. Pada bidang pendidikan, indikator meliputi beban mengajar, kedisiplinan perkuliahan, perangkat pembelajaran, pembimbingan akademik, serta evaluasi mahasiswa. Pada bidang penelitian, indikator mencakup publikasi nasional dan internasional, pendanaan, sitasi, luaran kekayaan intelektual, dan keterlibatan mahasiswa, dengan kualitas riset yang saat ini dapat dipantau melalui SINTA (Syarifah et al., 2025). Pada bidang pengabdian, indikator meliputi jumlah kegiatan, relevansi program, keberlanjutan dampak, dan kemitraan eksternal, dengan penekanan pada pendekatan pemberdayaan masyarakat.

Pelaksanaan Tri Dharma menghadapi tantangan berupa ketimpangan beban kerja, rendahnya produktivitas penelitian, serta kesulitan dosen dalam menyeimbangkan tugas akademik dan administratif. Dosen cenderung lebih fokus pada pengajaran, terutama di institusi dengan fasilitas riset terbatas, sementara dosen dengan jabatan struktural menghadapi hambatan dalam memenuhi kewajiban akademik meskipun telah diatur dalam Keputusan Dirjen Dikti Nomor 12/E/KPT/2021. Produktivitas penelitian belum merata karena keterbatasan pendanaan, mentoring, dan waktu. Tantangan ini berdampak pada capaian Indikator Kinerja Utama perguruan tinggi, sehingga analisis pola kinerja dosen melalui *data mining* dan *clustering* menjadi penting untuk memahami kondisi aktual dan merumuskan kebijakan strategis peningkatan kualitas Tri Dharma.


2.5 Data mining

Data mining merupakan proses penggalian dan analisis data untuk menemukan pola, hubungan, dan informasi penting dari kumpulan data berukuran besar dan kompleks. *Data mining* sebagai proses penemuan pengetahuan dari data yang tersimpan dalam basis data, data *warehouse*, atau media penyimpanan lainnya dengan menggunakan berbagai algoritma dan teknik komputasi (Arhami & Nasir, 2020). *Data mining* berkaitan erat dengan *Knowledge Discovery in Database (KDD)* yang merupakan proses komprehensif dalam mengekstraksi informasi berharga dari kumpulan data besar.

Penerapan *data mining* dalam pendidikan tinggi semakin berkembang, seperti melalui pemanfaatan *K-means clustering* untuk analisis pola distribusi data, serta peran *data mining* dalam sistem monitoring kinerja dosen. Manfaat *data mining* dalam pendidikan tinggi mencakup identifikasi pola akademik, sistem peringatan dini, optimalisasi sumber daya, evaluasi kebijakan, personalisasi layanan, dan dukungan pengambilan keputusan berbasis data.

2.6 CRISP-DM

Cross Industry Standard Process for Data mining (CRISP-DM) merupakan metodologi standar industri yang paling banyak digunakan dalam proyek *data mining* dan analisis data (Chapman et al., 2000). Kerangka kerja ini menyediakan pendekatan terstruktur yang terdiri dari enam tahapan iterative sebagaimana ditampilkan pada gambar di bawah ini



Gambar 1. Tahapan CRISP-DM

Sumber: Diadaptasi dari (Chapman et al., 2000)

Tahap *Business understanding* berfokus pada pemahaman tujuan proyek dan kebutuhan bisnis, dilanjutkan dengan *Data understanding* untuk eksplorasi dan identifikasi kualitas data. Tahap *Data preparation* meliputi pembersihan, transformasi, dan konstruksi dataset yang siap dimodelkan. Pada tahap *Modeling*, berbagai teknik dan algoritma diterapkan dan parameter dioptimalkan untuk menghasilkan model terbaik. Tahap *Evaluation* mengukur kualitas model terhadap tujuan bisnis sebelum tahap *Deployment* mengimplementasikan hasil untuk pengambilan keputusan. Sifat iteratif CRISP-DM memungkinkan peneliti untuk kembali ke tahap sebelumnya jika hasil evaluasi belum optimal, sehingga meningkatkan kualitas dan validitas analisis. Dalam konteks penelitian ini, CRISP-DM digunakan sebagai kerangka kerja untuk memastikan proses analisis BKD dosen dilakukan secara sistematis mulai dari identifikasi permasalahan hingga interpretasi hasil *clustering*.

2.7 Exploratory Data Analysis dan Preprocessing Data

Exploratory Data Analysis (EDA) merupakan pendekatan analisis yang bertujuan untuk memahami struktur, pola, dan karakteristik data sebelum pemodelan formal dilakukan. Konsep EDA pertama kali diperkenalkan oleh Tukey (1977) sebagai pendekatan yang menekankan visualisasi dan statistik deskriptif untuk mengeksplorasi data secara induktif tanpa asumsi awal yang kaku (Rizki et al., 2024). Dalam konteks data mining, EDA berfungsi sebagai tahap awal yang kritis untuk mendeteksi anomali, memahami distribusi variabel, mengidentifikasi hubungan antar variabel, serta merumuskan hipotesis awal yang akan diuji pada tahap pemodelan. (Isa et al., 2023) menegaskan bahwa EDA merupakan fondasi penting dalam analisis data pendidikan karena memungkinkan peneliti memahami karakteristik distribusi data sebelum menerapkan teknik *machine learning*.

EDA mencakup dua komponen utama: analisis statistik deskriptif dan visualisasi data. Statistik deskriptif meliputi pengukuran tendensi sentral (mean, median, modus), pengukuran dispersi (standar deviasi, varians, rentang interkuartil), serta identifikasi nilai ekstrem melalui deteksi *outlier*. Visualisasi data menggunakan teknik seperti histogram, *box plot*, *scatter plot*, *heatmap* korelasi, dan violin plot untuk mengungkap pola distribusi dan hubungan antar variabel secara grafis. (Pratama & Agastya, 2026) dalam penelitian analisis BKD dosen menggunakan EDA sebagai tahap awal untuk memahami distribusi data sebelum K-Means *clustering* diterapkan, dan hasilnya menunjukkan bahwa EDA mampu mengungkap pola ketimpangan komponen Tri Dharma secara signifikan. Dalam penelitian berbasis data BKD, EDA berperan penting untuk memahami distribusi SKS per komponen Tri Dharma, mengidentifikasi pola ketimpangan, serta membandingkan karakteristik antar kelompok dosen sebelum proses *clustering* dilakukan.

Preprocessing Data

Preprocessing data merupakan serangkaian proses transformasi data mentah menjadi format yang bersih, konsisten, dan siap dianalisis. (Han et al., 2022) mendefinisikan *preprocessing* sebagai tahap yang mencakup data *cleaning*, data *integration*, data *transformation*, dan data *reduction*. Kualitas *preprocessing* secara langsung menentukan kualitas hasil analisis, karena algoritma *clustering* seperti K-Means sangat sensitif terhadap inkonsistensi dan perbedaan skala data.

Penanganan *missing value* merupakan langkah kritis dalam data *cleaning*. Strategi penanganannya bergantung pada pola kemunculan missing data: jika missing sepenuhnya acak (MCAR), imputasi dengan nilai nol atau rata-rata dapat

digunakan; jika missing secara sistematis karena kondisi tertentu (seperti dosen tidak melaksanakan suatu komponen Tri Dharma), maka nilai nol lebih tepat digunakan karena merepresentasikan kondisi riil. (Pratama & Agastya, 2026) dalam penelitian serupa menerapkan strategi pengisian nol untuk *missing value* pada komponen BKD yang tidak dilaporkan, dengan alasan bahwa ketiadaan laporan mencerminkan ketiadaan aktivitas. Deteksi *outlier* dapat dilakukan menggunakan metode IQR (*Interquartile Range*) atau Z-score; (Setyani et al., 2025) merekomendasikan pendekatan IQR untuk data kinerja akademik karena lebih robust terhadap distribusi data yang tidak normal. Dalam konteks data kinerja dosen, nilai ekstrem belum tentu merupakan kesalahan melainkan dapat mencerminkan variasi produktivitas yang nyata, sehingga perlu dibedakan antara *outlier* substantif dan *outlier* akibat kesalahan input.

Normalisasi data adalah proses transformasi nilai numerik ke dalam rentang tertentu agar perbedaan skala antar variabel tidak mendominasi perhitungan jarak pada algoritma K-Means (Han et al., 2022). Metode normalisasi yang umum digunakan adalah *Min-Max Normalization* dan *Z-score Standardization*. *Min-Max Normalization* mentransformasikan nilai ke rentang [0, 1] menggunakan rumus:

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Di mana:

- x : Nilai asli/data mentah dari observasi tertentu dalam dataset
- $x_{\min}$: Nilai minimum dari seluruh dataset pada variabel/fitur tersebut
- $x_{\max}$: Nilai maksimum dari seluruh dataset pada variabel/fitur tersebut
- x' : Nilai baru hasil transformasi normalisasi (rentang 0-1)

Nilai 0 menunjukkan nilai minimum dan 1 menunjukkan nilai maksimum dalam dataset. Metode ini dipilih ketika distribusi data tidak diketahui secara pasti dan ketika interpretasi nilai hasil transformasi secara proporsional lebih diutamakan. *Z-score Standardization* mentransformasikan data menjadi distribusi dengan rata-rata 0 dan standar deviasi 1, lebih cocok digunakan ketika data mengikuti distribusi normal. Perbedaan antara kedua metode ini berdampak pada kualitas *clustering*. (Wongoutong, 2024) menggunakan *Min-Max Normalization* sebelum K-Means dan mendapatkan hasil *clustering* yang lebih stabil dibandingkan tanpa normalisasi. Dalam konteks penelitian analisis BKD, *Min-Max Normalization* lebih sesuai karena menghasilkan nilai yang mudah diinterpretasikan secara proporsional antar komponen Tri Dharma.

2.8 Clustering

Clustering merupakan metode pengelompokan data berdasarkan kesamaan karakteristik tanpa memerlukan label awal. *Clustering* bertujuan menghasilkan kelompok yang memiliki homogenitas internal tinggi dan heterogenitas eksternal yang jelas. Analisis *clustering* memungkinkan eksplorasi pola tersembunyi, segmentasi data, deteksi anomali, reduksi kompleksitas, dan menjadi dasar *preprocessing* untuk analisis lanjutan. *Clustering*, khususnya K-Means, mampu memberikan gambaran distribusi kinerja dosen berdasarkan indikator penilaian. Metode *clustering* sendiri mencakup pendekatan *partitioning*, *hierarchical*, *density-based*, *grid-based*, dan *model-based*, di mana K-Means menjadi salah satu metode paling efektif untuk data tabular seperti BKD.

Unsupervised learning, sebagai kategori pembelajaran mesin yang bekerja dengan data tidak berlabel, berfokus pada penemuan pola natural dalam data (Harahap et al., 2023). *Unsupervised learning* menawarkan fleksibilitas tinggi melalui algoritma seperti K-Means, ANN (*Artificial Neural Network*), dan GMM (*Gaussian Mixture Model*). Perbedaan antara *supervised* dan *unsupervised learning* terletak pada kebutuhan label, tujuan analisis, keluaran model, serta metrik evaluasi (Santoso et al., 2021). Implementasi *unsupervised learning* dalam *clustering* meliputi eksplorasi data, *preprocessing*, pemilihan algoritma, penentuan parameter, eksekusi *clustering*, evaluasi menggunakan indeks seperti Silhouette Score dan Davies-Bouldin Index, serta interpretasi hasil.

(Retnoningsih & Pramudita, 2020) menunjukkan bahwa implementasi algoritma *clustering* dapat dilakukan secara efisien menggunakan *library* Python seperti *scikit-learn*. Aplikasi *unsupervised learning* telah digunakan dalam berbagai penelitian, termasuk analisis kinerja dosen, segmentasi data pandemi, dan analisis big data untuk mendukung pengambilan keputusan. Dalam konteks penelitian ini, *unsupervised learning* melalui algoritma K-Means digunakan untuk mengeksplorasi pola distribusi kinerja Tri Dharma dosen berdasarkan data BKD tanpa asumsi awal mengenai kategori dosen, sehingga pola alami dalam data dapat diidentifikasi secara objektif.

Dalam bidang analisis data tidak berlabel, pemilihan algoritma *clustering* harus mempertimbangkan karakteristik data, keberadaan *noise*, tujuan analisis, serta kebutuhan interpretasi hasil. Berbagai penelitian komparatif menunjukkan bahwa tidak ada satu metode yang sepenuhnya unggul untuk semua kondisi, sehingga analisis perbandingan antar-algoritma sangat penting dilakukan. Pemilihan algoritma yang tepat meningkatkan akurasi pengelompokan hingga 30-40%. Performa K-Means, DBSCAN, dan *Hierarchical Clustering* sangat dipengaruhi struktur data (Sufairoh et al., 2023). Untuk memberikan gambaran

yang lebih jelas mengenai perbedaan karakteristik masing-masing metode *clustering*, berikut disajikan tabel perbandingan metode *clustering* berdasarkan berbagai aspek teknis dan praktis:

Tabel 3. Perbandingan Metode *Clustering*

Aspek	K-Means	DBSCAN	Hierarchical	Fuzzy C-Means
Tipe Pendekatan	Distance-based Mengelompokkan data ke <i>centroid</i> (titik pusat) yang paling dekat	Density-based Area yang padat otomatis menjadi <i>cluster</i> ; area jarang dianggap <i>noise</i>	Hierarchical-based Membangun pohon pengelompokan bertingkat dari bawah ke atas	Fuzzy-based Satu data bisa masuk beberapa <i>cluster</i> sekaligus dengan bobot keanggotaan
Penentuan Jumlah Cluster	Wajib ditentukan di awal (pengguna harus menentukan nilai K sebelum proses)	Otomatis (terbentuk sendiri dari parameter kepadatan, tidak perlu menentukan jumlah)	Fleksibel setelah proses (jumlah dipilih setelah dendrogram terbentuk)	Wajib ditentukan di awal (sama seperti K-Means, nilai C harus diisi sebelum proses)
Efisiensi Komputasi	Sangat Cepat Cocok untuk data besar; iterasi ringan $O(n \cdot k)$	Sedang Efisien untuk data medium; melambat jika data sangat besar	Lambat Kompleksitas $O(n^2) - O(n^3)$; memori besar untuk data banyak	Sedang Lebih berat dari K-Means karena menghitung derajat keanggotaan tiap iterasi
Ketahanan terhadap Outlier	Sensitif <i>Outlier</i> dapat menarik <i>centroid</i> dan merusak hasil cluster	Tahan (Robust) <i>Outlier</i> otomatis dikenali sebagai <i>noise</i> dan dikecualikan	Sensitif <i>Outlier</i> bisa membentuk cluster sendiri dan mengganggu hierarki	Sensitif <i>Outlier</i> tetap mendapat nilai keanggotaan dan mempengaruhi <i>centroid</i>
Interpretabilitas	Sangat Mudah Setiap data masuk tepat 1 cluster dengan batas yang jelas	Kompleks Hasil bergantung 2 parameter (ϵ dan MinPts); sulit dijelaskan ke non-teknis	Mudah Dapat divisualisasikan lewat dendrogram; namun sulit saat data besar	Sedang Nilai keanggotaan 0–1 (parsial) memerlukan interpretasi tambahan

Cocok Dataset	untuk	Data terstruktur,	Data tidak	Dataset kecil–	Data dengan
		jumlah cluster	beraturan yang	menengah yang	batas cluster
		diketahui, dan	mengandung	memerlukan	yang tumpang
		bentuk cluster	<i>noise</i> atau <i>outlier</i>	eksplorasi	tindih
		bulat/seragam	signifikan	struktur antar	(<i>overlapping</i>)
				kelompok	dan tidak
					tegas

Berdasarkan Tabel 3, terlihat bahwa setiap metode *clustering* memiliki karakteristik unik dengan kelebihan dan kekurangan masing-masing. Perbedaan mendasar terletak pada pendekatan pembentukan *cluster*, di mana K-Means menggunakan pendekatan partisi berbasis jarak, DBSCAN menggunakan pendekatan berbasis kepadatan, Hierarchical menggunakan pendekatan hierarkis bertingkat, dan Fuzzy C-Means menggunakan pendekatan probabilistik dengan derajat keanggotaan. Kompleksitas waktu dan skalabilitas menjadi faktor pembeda signifikan, terutama untuk dataset berukuran besar seperti data beban kerja dosen yang melibatkan ratusan hingga ribuan *record*.

Selain itu, sensitivitas terhadap *outlier* dan *noise* menjadi pertimbangan penting dalam konteks data yang telah melalui proses verifikasi dan validasi. Data beban kerja dosen yang telah diverifikasi asesor cenderung memiliki kualitas tinggi dengan *noise* minimal, sehingga keunggulan DBSCAN dalam menangani *noise* menjadi kurang relevan. Di sisi lain, interpretabilitas hasil *clustering* sangat krusial dalam konteks manajerial perguruan tinggi, di mana pemangku kepentingan memerlukan hasil yang mudah dipahami dan dapat ditindaklanjuti secara operasional. Mengingat berbagai pertimbangan tersebut, pemahaman mendalam terhadap karakteristik masing-masing metode menjadi landasan penting dalam pemilihan algoritma yang tepat untuk analisis kinerja dosen.

A. K-means clustering

K-Means merupakan algoritma *distance-based* yang bekerja dengan mempartisi data ke dalam sejumlah *cluster* yang ditentukan sejak awal melalui pembaruan *centroid* secara iteratif. Algoritma ini sangat efektif untuk data numerik terstruktur dengan *cluster* berbentuk relatif bulat serta ukuran *cluster* yang seragam. K-Means bersifat *hard clustering*, sensitif terhadap *outlier*, namun memiliki keunggulan utama berupa efisiensi komputasi yang sangat baik, seperti waktu pemrosesan 0,4 detik. Selain itu, hasil K-Means mudah diinterpretasikan oleh pengguna non-teknis karena menghasilkan *centroid* dan label *cluster* yang jelas. Akurasi dan stabilitasnya juga tercermin pada nilai Silhouette Score tinggi,

mencapai 0,715–0,716 sehingga metode ini sering menjadi pilihan utama untuk segmentasi data terstruktur (Sufairoh et al., 2023).

B. DBSCAN

DBSCAN adalah algoritma *clustering* berbasis kepadatan (*density-based*) yang mampu membentuk *cluster* berbentuk tidak beraturan dan mendeteksi *outlier* melalui parameter radius (ϵ) dan jumlah minimal titik (MinPts). Berbeda dengan K-Means, DBSCAN tidak memerlukan penentuan jumlah *cluster* di awal karena *cluster* terbentuk secara otomatis dari area yang cukup padat. Keunggulan utama DBSCAN adalah ketahanannya terhadap *noise*, sehingga titik dengan densitas rendah dapat ditandai sebagai *noise* atau *outlier*. Namun, performa DBSCAN menurun pada dataset dengan variasi densitas tinggi dan interpretasi hasilnya lebih kompleks. (Saputra & Yusuf, 2024) menunjukkan bahwa Silhouette Score DBSCAN berada pada rentang 0,298–0,700, sangat bergantung pada struktur data, sementara penelitian (Setyani et al., 2025) menunjukkan waktu eksekusi yang lebih lambat dibanding K-Means, yaitu sekitar 0,8 detik untuk dataset berskala besar.

C. Hierarchical Clustering

Hierarchical *Clustering* membangun struktur *cluster* secara bertingkat melalui pendekatan agglomerative atau divisive dan divisualisasikan dalam bentuk dendrogram. Keunggulan utamanya adalah kemampuan membentuk *cluster* tanpa harus menentukan jumlah *cluster* sejak awal, karena pemotongan dendrogram dapat dilakukan pada level tertentu untuk menghasilkan *cluster* akhir. Namun, metode ini memiliki kompleksitas waktu tinggi yang diukur dengan notasi Big O (standar untuk menggambarkan seberapa cepat waktu komputasi bertambah seiring meningkatnya jumlah data (n)). Kompleksitas $O(n^2 \log n)$ hingga $O(n^3)$ berarti jika jumlah data berlipat dua, waktu pemrosesan meningkat empat hingga delapan kali lipat, karena algoritma harus menghitung jarak antar setiap pasang data di setiap tahapan penggabungan sehingga kurang sesuai untuk dataset berukuran besar. Hierarchical juga sensitif terhadap *outlier* yang dapat menghasilkan *cluster* tunggal atau mengganggu struktur hierarki. Meskipun demikian, (Sufairoh et al., 2023) menemukan bahwa *Hierarchical Clustering* dapat mencapai Silhouette Score sangat tinggi yaitu 0,944 pada dataset tertentu.

D. Fuzzy C-Means (FCM)

Fuzzy C-Means merupakan perluasan dari K-Means yang menggunakan konsep *soft clustering*, di mana setiap data memiliki derajat keanggotaan pada setiap *cluster* dengan nilai antara 0 hingga 1. Metode ini sangat bermanfaat untuk dataset yang mengandung tumpang tindih (*overlapping*) sehingga satu data dapat merepresentasikan lebih dari satu pola *cluster* melalui bobot keanggotaan yang berbeda. FCM mengharuskan penentuan jumlah *cluster* dan parameter *fuzziness* (m), serta memiliki waktu komputasi lebih tinggi dibanding K-Means karena memproses derajat keanggotaan pada setiap iterasi. Studi komparatif oleh (Sufairoh et al., 2023) menunjukkan bahwa meskipun FCM unggul dalam fleksibilitas, metode ini sensitif terhadap *outlier* dan kurang efisien untuk dataset besar sehingga penggunaannya lebih tepat untuk data berskala kecil hingga menengah.

Berdasarkan hasil komparatif dari berbagai penelitian, pemilihan K-Means dalam analisis kinerja dosen berbasis data BKD Universitas Jambi merupakan keputusan metodologis yang tepat. Data BKD terdiri dari fitur numerik terstruktur dan tidak mengandung *noise* signifikan karena telah melalui verifikasi asesor, sehingga keunggulan DBSCAN dalam mendeteksi *noise* menjadi kurang relevan dalam konteks ini (Saputra & Yusuf, 2024). K-Means juga paling efisien secara komputasi, seperti ditunjukkan oleh waktu proses 0,4 detik pada penelitian, serta menghasilkan *cluster* yang mudah dipahami oleh pemangku kepentingan non-teknis, yang sejalan dengan temuan. Selain itu, tujuan penelitian ini adalah eksplorasi pola dan segmentasi dosen, bukan deteksi anomali atau pembentukan struktur hierarkis, sehingga K-Means menjadi metode paling sesuai untuk mencapai tujuan penelitian.

2.9 Algoritma K-means clustering

Algoritma *K-means clustering* merupakan salah satu metode *Unsupervised learning* yang paling populer dan banyak digunakan dalam analisis *data mining*. Algoritma ini bekerja dengan cara membagi n observasi ke dalam k *cluster*, di mana setiap observasi termasuk dalam *cluster* dengan mean (*centroid*) terdekat. K-Means adalah algoritma *clustering* dengan metode partisi (*partitioning method*) yang berbasis titik pusat (*centroid*), yang mengarah pada pembagian n objek pengamatan ke dalam k kelompok (*cluster*) dengan tujuan membagi data ke dalam kelompok sehingga data yang berkarakteristik sama dimasukkan ke dalam satu kelompok sementara data yang berkarakteristik berbeda dimasukkan dalam kelompok yang lain (Afidah, 2023). Prinsip dasar K-Means adalah melakukan partisi data berdasarkan jarak Euclidean antara data point dengan *centroid*

cluster, sehingga terbentuk kelompok-kelompok data yang memiliki kemiripan karakteristik tinggi dalam satu *cluster* dan perbedaan yang signifikan antar *cluster*.

K-Means merupakan algoritma yang sederhana namun powerful untuk *clustering*, di mana proses pengelompokan dilakukan dengan cara menentukan jumlah *cluster* terlebih dahulu, kemudian secara iteratif memindahkan data point ke *cluster* yang paling dekat dengan *centroid*-nya (Norshahlan et al., 2023). Algoritma ini memiliki kompleksitas komputasi yang relatif rendah dibandingkan dengan metode *clustering* lain, sehingga sangat efisien untuk diterapkan pada dataset berukuran besar. Kelebihan utama K-Means adalah kesederhanaan konsep, kecepatan konvergensi, dan kemudahan implementasi, yang menjadikannya pilihan utama untuk berbagai aplikasi *clustering* di berbagai domain, termasuk segmentasi data, pengelompokan kinerja, dan analisis pola.

A. Prinsip Kerja dan Tahapan K-Means

Konsep dasar algoritma K-Means berfokus pada minimalisasi fungsi objektif *Within-Cluster Sum of Squares* (WCSS), yang mengukur total jarak kuadrat antara setiap data point dengan *centroid cluster*-nya. Algoritma K-Means bekerja melalui tahapan iteratif yang sistematis: pertama, inisialisasi *centroid* dilakukan dengan memilih k titik awal secara random atau menggunakan metode K-Means++ untuk hasil yang lebih stabil; kedua, *assignment* step di mana setiap data point ditempatkan ke *cluster* dengan *centroid* terdekat berdasarkan perhitungan jarak Euclidean; ketiga, *update step* yang menghitung ulang posisi *centroid* sebagai rata-rata dari semua data point dalam *cluster* tersebut; keempat, iterasi berulang dari *assignment* dan *update* hingga tidak ada lagi perpindahan data antar *cluster* atau perubahan posisi *centroid* sudah sangat kecil (konvergensi tercapai) (Rahman et al., 2025).

B. Penentuan Jumlah Cluster Optimal

Salah satu tantangan utama dalam penerapan K-Means adalah menentukan jumlah *cluster* (k) yang optimal. Tidak ada formula matematis yang pasti untuk menentukan nilai k terbaik, sehingga diperlukan metode evaluasi untuk membantu menemukan nilai k yang paling sesuai dengan struktur data. Penggunaan kombinasi beberapa metode evaluasi untuk memastikan jumlah *cluster* optimal dalam penelitian pengelompokan universitas terbaik di dunia, menunjukkan pentingnya validasi *cluster* sebelum menginterpretasikan hasil.

1. Metode Elbow

Metode Elbow merupakan teknik visual yang umum digunakan untuk menentukan jumlah *cluster* optimal dengan memplot jumlah *cluster* (k) terhadap nilai WCSS (*Within-Cluster Sum of Squares*). Titik “siku” pada grafik menunjukkan k terbaik, yaitu saat penurunan WCSS tidak lagi signifikan. Metode ini diterapkan pada data kemiskinan Provinsi Banten menggunakan RapidMiner dan menemukan bahwa titik elbow memberikan indikasi jelas mengenai jumlah *cluster* yang tepat (Sari et al., 2020). Secara prinsip, penambahan *cluster* memang selalu menurunkan WCSS, tetapi setelah mencapai titik optimal, penurunannya menjadi minimal sehingga kurva terlihat mendatar. Titik tersebut kemudian dijadikan acuan untuk menentukan jumlah *cluster* optimal.

2. Metode Silhouette Score

Silhouette Score mengukur kesesuaian suatu data point dengan *cluster*-nya dibandingkan dengan *cluster* lain, dengan nilai antara -1 hingga $+1$. Nilai mendekati $+1$ menunjukkan data berada pada *cluster* yang tepat, nilai sekitar 0 menunjukkan posisi di perbatasan, sedangkan nilai negatif mengindikasikan kemungkinan salah penempatan. Perhitungan Silhouette Score didasarkan pada dua komponen, yaitu rata-rata jarak data point ke anggota *cluster* yang sama (cohesion) dan rata-rata jarak ke *cluster* terdekat (*separation*). (Rahman et al., 2025) menggunakan kombinasi Elbow Method dan Silhouette Score dalam analisis *clustering* data cuaca, dan hasilnya menunjukkan bahwa Silhouette Score memberikan evaluasi yang lebih objektif dibandingkan Elbow Method yang bersifat visual. Jumlah *cluster* optimal ditentukan dari nilai k yang menghasilkan Silhouette Score tertinggi karena menunjukkan pemisahan *cluster* yang lebih jelas dan kekompakan internal yang lebih baik.

3. Metode Davies-Bouldin Index (DBI)

Davies-Bouldin Index merupakan metrik evaluasi *clustering* yang menilai rata-rata kesamaan maksimal antar *cluster*, dengan prinsip bahwa semakin rendah nilai DBI semakin baik kualitas *clustering*. DBI membandingkan dispersi dalam *cluster* (*intra-cluster distance*) dengan jarak antar *cluster* (*inter-cluster distance*), sehingga nilai rendah menunjukkan *cluster* yang kompak dan terpisah dengan baik. (Hardiani, 2022) dalam studi *Analisis Clustering Kasus COVID-19 di Indonesia Menggunakan Algoritma K-Means* menemukan nilai Davies-Bouldin Index (DBI) terendah $0,47$ pada $k=3$, menunjukkan tiga *cluster* optimal untuk

pengelompokan provinsi berdasarkan kasus positif, sembuh, dan meninggal.

C. Evaluasi Hasil *Clustering*

Setelah proses *clustering* selesai, evaluasi hasil menjadi tahap penting untuk memastikan bahwa *cluster* yang terbentuk memiliki kualitas yang baik dan memberikan insight yang bermakna. Evaluasi *clustering* harus dilakukan secara komprehensif menggunakan *multiple metrics* untuk mendapatkan gambaran yang objektif tentang kualitas *cluster*. Evaluasi tidak hanya fokus pada nilai metrik statistik, tetapi juga pada interpretabilitas dan relevansi praktis dari *cluster* yang terbentuk dalam konteks domain masalah.

Metrik evaluasi internal yang umum digunakan meliputi *Within-Cluster Sum of Squares* (WCSS) yang mengukur total jarak kuadrat dalam *cluster*, Silhouette Score yang mengukur kesesuaian data point dengan *cluster*-nya, Davies-Bouldin Index yang mengukur kesamaan antar *cluster*, dan Calinski-Harabasz Index yang mengukur rasio dispersi antar *cluster* terhadap dispersi dalam *cluster*. (Sari et al., 2020) mendemonstrasikan bahwa penggunaan kombinasi metrik evaluasi memberikan validasi yang lebih *robust* dibandingkan dengan mengandalkan satu metrik saja, sehingga hasil *clustering* dapat dipercaya dan digunakan sebagai dasar pengambilan keputusan.

D. Kelebihan dan Keterbatasan K-Means

Algoritma K-Means memiliki beberapa kelebihan yang menjadikannya populer dalam berbagai aplikasi. Kelebihan utama K-Means: pertama, kesederhanaan konsep dan kemudahan implementasi yang membuatnya accessible bahkan untuk pemula; kedua, efisiensi komputasi yang tinggi dengan kompleksitas waktu $O(n \times k \times i \times d)$ dengan n adalah jumlah data, k adalah jumlah cluster, i adalah jumlah iterasi, dan d adalah jumlah dimensi/fitur, yang berarti algoritma tetap berjalan cepat meskipun dataset berukuran besar karena setiap variabel dikalikan secara linier tanpa pertumbuhan eksponensial; ketiga, konvergensi yang relatif cepat, umumnya dalam jumlah iterasi yang terbatas; keempat, hasil yang mudah diinterpretasikan karena setiap *cluster* direpresentasikan oleh *centroid* yang merupakan rata-rata karakteristik anggotanya; kelima, skalabilitas yang baik untuk dataset dengan jutaan data point (Norshahlan et al., 2023).

Namun demikian, K-Means juga memiliki keterbatasan yang perlu diperhatikan. Kelemahan algoritma ini: pertama, sensitif terhadap inisialisasi *centroid* awal, di mana inisialisasi yang buruk dapat menyebabkan algoritma

terjebak pada local optimum yang sub-optimal; kedua, harus menentukan jumlah *cluster* (k) di awal sebelum menjalankan algoritma; ketiga, sensitif terhadap *outlier* karena menggunakan mean sebagai *centroid*; keempat, hanya efektif untuk data numerik dan tidak dapat langsung diterapkan pada data kategorikal; kelima, mengasumsikan bahwa *cluster* memiliki bentuk bulat (*spherical*) dan ukuran yang relatif seimbang, sehingga kurang efektif untuk data dengan *cluster* berbentuk kompleks atau memiliki densitas yang sangat berbeda.

2.10 Penelitian Terdahulu

Penelitian terdahulu menjadi landasan penting dalam pengembangan kerangka konseptual dan metodologi penelitian ini. Kajian terhadap penelitian-penelitian sebelumnya memberikan pemahaman mengenai penerapan metode *clustering*, khususnya K-Means, dalam berbagai domain analisis data, khususnya evaluasi kinerja dosen. Tinjauan penelitian terdahulu juga membantu mengidentifikasi kesenjangan (*research gap*) yang dapat diisi oleh penelitian ini.

Beberapa penelitian telah menerapkan metode *clustering* untuk menganalisis kinerja dosen berbasis data penilaian mahasiswa dan kuesioner. Selain itu, penerapan K-Means pada domain lain seperti segmentasi pelanggan dan analisis penyebaran kasus kesehatan memberikan referensi metodologis yang dapat diadaptasi untuk analisis data Beban Kerja Dosen (BKD). Berikut ini disajikan rangkuman penelitian terdahulu yang relevan dengan penelitian ini:

Tabel 4. Daftar Penelitian Terdahulu

No	Penulis dan Tahun	Judul Penelitian	Metode	Hasil Penelitian
1	Pratama, M.E., Kusrini, & Artha Agastya, I.M. (2024)	Analisis Laporan BKD Penelitian & PkM Dengan <i>K-means clustering</i>	K-Means ($K=2$, Silhouette Score 0,595)	Fokus: Produktivitas penelitian/PkM UIN Samarinda. Hasil: 214 dosen → <i>Cluster</i> Sedang (88,8%), <i>Cluster</i> Tinggi (11,2%), gap 63x, KPI 105,8%. Kekurangan: Hanya fokus penelitian/PkM, belum analisis Tri Dharma lengkap, tidak bandingkan dosen struktural vs fungsional
2	Dewi, N.L.P.P.,	Penerapan <i>Data mining</i>	K-Means + Davies-	Fokus: Evaluasi kinerja BKD 12 dosen. Hasil: Optimal

	Purnama, I.N., & Utami, N.W. (2022)	<i>Clustering</i> Kinerja Dosen	Bouldin Index	<i>cluster</i> teridentifikasi untuk pengambilan keputusan. Kekurangan: Sampel kecil (12 dosen), belum spesifik Tri Dharma, tidak ada gap analisis antar jabatan dosen
3	Dahnial (2024)	Pengelompokk an Dosen Berdasarkan Karya Ilmiah (unsur BKD)	K-Means	Fokus: Publikasi SINTA dosen. Hasil: 4 <i>cluster</i> (sangat produktif → kurang produktif). Kekurangan: Hanya unsur penelitian BKD, belum integrasi pendidikan/pengabdian, tidak analisis jabatan struktural
4	Simamora (2024)	Kajian Harmonisasi Kerja Dosen	<i>Clustering</i> Analysis	Fokus: BKD universitas lokal. Hasil: Pendidikan 60–70%, penelitian 20–25%. Kekurangan: Analisis deskriptif dominan, belum K-Means formal, tidak eksplorasi gap struktural vs fungsional

Berdasarkan tinjauan penelitian terdahulu, teridentifikasi kesenjangan penelitian (*research gap*) yang menjadi peluang bagi penelitian ini. Penelitian-penelitian sebelumnya menunjukkan bahwa metode *K-means clustering* telah banyak diterapkan untuk menganalisis kinerja dosen, namun dengan fokus dan pendekatan yang berbeda-beda. Pratama et al. (2026) menganalisis 214 dosen UIN Samarinda dengan 2.762 aktivitas BKD penelitian/PkM menggunakan K-Means (K=2, Silhouette Score 0,595), tetapi terbatas pada dua komponen Tri Dharma dan belum membandingkan dosen struktural vs fungsional. (Dewi et al., 2022) menerapkan K-Means pada BKD 12 dosen dengan Davies-Bouldin Index namun sampel terlalu kecil dan belum spesifik Tri Dharma lengkap, sementara (Simamora et al., 2024) hanya deskriptif tanpa *clustering* formal. (Dahnial, 2024) telah mengembangkan sistem monitoring kinerja dosen berbasis data BKD, namun belum mengintegrasikan teknik *data mining* untuk mengeksplorasi pola distribusi kinerja secara mendalam.

Kesenjangan utama yang teridentifikasi adalah belum adanya penelitian yang secara komprehensif menganalisis pola distribusi kinerja dosen berdasarkan ketiga komponen Tri Dharma Perguruan Tinggi (pendidikan, penelitian, dan pengabdian kepada masyarakat) secara simultan menggunakan data BKD di konteks perguruan tinggi regional seperti Universitas Jambi. Data BKD memiliki keunggulan berupa objektivitas yang lebih tinggi karena berbasis pada capaian nyata dan terverifikasi, berbeda dengan data kuesioner kepuasan mahasiswa yang bersifat perseptual. Penelitian ini berkontribusi mengisi kesenjangan tersebut dengan menerapkan *K-means clustering* pada data BKD untuk mengidentifikasi pola distribusi kinerja Tri Dharma dosen secara komprehensif dan terintegrasi. Hasil penelitian diharapkan dapat memberikan informasi yang berguna bagi manajemen perguruan tinggi dalam merancang program pengembangan dosen yang lebih tepat sasaran berdasarkan pola kinerja aktual yang teridentifikasi melalui analisis data.

III. METODOLOGI PENELITIAN


3.1 Jenis Penelitian

Penelitian ini menggunakan pendekatan kuantitatif karena seluruh analisis yang dilakukan berlandaskan pada pengolahan data numerik yang bersifat terukur. Pendekatan kuantitatif secara umum bertujuan untuk menelaah fenomena melalui data-data numerik yang diolah menggunakan teknik statistika atau komputasi berbasis angka. (Djamba & Neuman, 2014) menyatakan bahwa penelitian kuantitatif berfokus pada pengukuran variabel secara sistematis melalui prosedur yang terstandar, sehingga pendekatan ini sesuai dengan karakteristik data yang digunakan dalam penelitian ini.

Pendekatan penelitian ini juga bersifat deskriptif eksploratif. Pendekatan deskriptif digunakan untuk menggambarkan fenomena apa adanya tanpa melakukan manipulasi variabel atau pengujian hipotesis, sedangkan sifat eksploratif bertujuan menelusuri pola atau kecenderungan yang belum teridentifikasi sebelumnya. Metode *clustering* seperti K-Means efektif digunakan dalam penelitian eksploratif untuk menemukan struktur atau pola tersembunyi dalam suatu dataset (Gayatri & Yudhanegara, 2025). Dalam penelitian ini, algoritma K-Means dimanfaatkan untuk mengungkap pola distribusi kinerja Tri Dharma dosen berdasarkan data BKD pada periode penelitian. Kombinasi pendekatan deskriptif dan eksploratif tersebut memberikan dasar metodologis yang kuat untuk analisis data yang bersifat penemuan pola dan non-inferensial.

3.2 Kerangka Penelitian

Kerangka penelitian ini dirancang secara sistematis dan terstruktur untuk menganalisis pola beban kinerja dosen. Penelitian mengadopsi metodologi CRISP-DM (*Cross-Industry Standard Process for Data mining*), sebuah standar industri yang telah terbukti efektif dalam proyek *data mining* dan *analytics* (Schröer et al., 2021). CRISP-DM dipilih karena memberikan panduan komprehensif dan sistematis mulai dari pemahaman konteks bisnis hingga implementasi hasil analisis. Sifat iteratifnya memungkinkan peneliti untuk kembali ke tahap sebelumnya jika diperlukan perbaikan, sehingga menghasilkan analisis yang optimal dan kredibel. Kerangka penelitian ini terdiri dari beberapa tahapan utama sebagaimana ditunjukkan pada Gambar 2:



Gambar 2. Kerangka Penelitian
Sumber: Diadaptasi dari (Schröder et al., 2021)

3.3 *Business understanding*

Tahap *Business Understanding* merupakan fase awal dalam kerangka CRISP-DM yang berfokus pada pemahaman konteks permasalahan secara konseptual dan institusional. Pada tahap ini, penelitian tidak langsung berorientasi pada data, melainkan pada identifikasi kebutuhan analitis, tujuan penelitian, serta relevansi hasil terhadap pengambilan keputusan. Dalam konteks penelitian ini, pemahaman bisnis diarahkan pada bagaimana pola pemenuhan Beban Kerja Dosen (BKD) dapat dianalisis secara sistematis untuk mendukung evaluasi kinerja akademik di Universitas Jambi. Oleh karena itu, tahap ini dilakukan melalui studi literatur dan wawancara dengan pemangku kepentingan untuk memastikan bahwa proses analitik yang dilakukan selaras dengan kebutuhan institusi.

A. Studi Literatur

Studi literatur dilakukan untuk menelaah penelitian-penelitian terdahulu yang berkaitan dengan analisis kinerja dosen, Beban Kerja Dosen (BKD), serta penerapan metode *clustering* di lingkungan perguruan tinggi. Penelusuran dilakukan melalui berbagai basis data akademik dengan menggunakan kata kunci seperti *analisis BKD dosen*, *clustering kinerja dosen*, *K-Means pada data Tri Dharma*, dan *analisis beban kerja dosen perguruan tinggi*. Berdasarkan hasil

telaah literatur, sebagian besar penelitian terdahulu yang menerapkan teknik *clustering* pada data BKD berfokus pada pengelompokan dosen berdasarkan dominasi komponen Tri Dharma, yaitu mengidentifikasi kecenderungan kontribusi dosen pada bidang pendidikan, penelitian, atau pengabdian kepada masyarakat. Pendekatan tersebut umumnya bertujuan untuk mengklasifikasikan profil dosen berdasarkan aktivitas utama yang paling menonjol.

Namun demikian, penelitian-penelitian tersebut masih terbatas pada analisis dominasi komponen secara umum dan belum secara mendalam mengeksplorasi variasi pola BKD berdasarkan konteks struktural institusi. Secara khusus, belum banyak penelitian yang menganalisis perbedaan pola distribusi BKD antar fakultas, serta perbedaan pola distribusi BKD berdasarkan jenjang jabatan fungsional dosen. Kesenjangan tersebut menunjukkan bahwa analisis BKD belum sepenuhnya mempertimbangkan dimensi organisasi dan hierarki jabatan sebagai faktor yang dapat memengaruhi proporsionalitas beban kerja. Oleh karena itu, penelitian ini dirancang untuk mengisi kesenjangan tersebut melalui pendekatan analitik yang lebih komprehensif, yaitu *Exploratory Data Analysis* (EDA) untuk mengidentifikasi pola distribusi BKD berdasarkan fakultas dan jabatan fungsional, serta metode *K-means clustering* untuk mengungkap kelompok dosen yang terbentuk secara alami berdasarkan pola pemenuhan BKD di Universitas Jambi.

B. Wawancara dengan Pemangku Kepentingan

Selain studi literatur, penelitian ini juga akan melakukan pengumpulan data kontekstual melalui wawancara dengan pemangku kepentingan di Universitas Jambi. Wawancara dilakukan untuk memperoleh pemahaman yang lebih komprehensif mengenai dinamika pengelolaan Beban Kerja Dosen (BKD) dari sudut pandang manajerial. Metode yang digunakan adalah wawancara semi-terstruktur, yaitu wawancara yang disusun berdasarkan pedoman pertanyaan utama namun tetap memberikan ruang bagi informan untuk mengembangkan jawaban sesuai pengalaman dan perspektifnya. Pendekatan ini dipilih agar peneliti memperoleh informasi yang sistematis sekaligus mendalam.

Secara spesifik, wawancara akan dilaksanakan dengan dua orang Dekan yang mewakili karakteristik bidang ilmu berbeda, yaitu satu Dekan dari fakultas bidang humaniora dan satu Dekan dari fakultas bidang eksakta. Pemilihan ini bertujuan untuk menangkap variasi kebijakan dan praktik pengelolaan BKD yang mungkin dipengaruhi oleh karakteristik disiplin ilmu. Wawancara akan difokuskan pada beberapa aspek utama, yaitu:

- (1) mekanisme dan kebijakan pengelolaan BKD di tingkat fakultas;
- (2) tantangan yang dihadapi dosen dalam memenuhi komponen Tri Dharma secara proporsional; serta
- (3) ekspektasi pimpinan fakultas terhadap pemanfaatan hasil analisis data BKD dalam mendukung pengambilan kebijakan.
- (4) tantangan pimpinan fakultas dalam mengambil keputusan kebijakan akademik terkait pengelolaan dan penyeimbangan pelaksanaan Tri Dharma Perguruan Tinggi.

Hasil wawancara akan digunakan sebagai data pendukung untuk memperkaya tahap *Business understanding* dalam kerangka CRISP-DM, sehingga analisis kuantitatif yang dilakukan memiliki relevansi kontekstual terhadap kebutuhan institusi.

3.4 Data understanding

Tahap *Data Understanding* pada penelitian ini diawali dengan proses pengajuan permohonan pengambilan data BKD kepada pihak UPATIK di Universitas Jambi. Setelah data diperoleh secara resmi, dilakukan eksplorasi awal untuk memahami struktur, format, dan karakteristik dataset yang tersedia. Eksplorasi ini mencakup peninjauan tipe data, kelengkapan variabel, konsistensi format pelaporan, serta gambaran umum distribusi nilai. Pemahaman terhadap kondisi awal data sangat penting untuk memastikan bahwa proses pembersihan dan pemodelan pada tahap berikutnya dilakukan berdasarkan struktur data yang benar dan valid.

A. Sumber dan Variabel Data

Data yang digunakan dalam penelitian ini adalah data sekunder yang bersumber dari Sistem Informasi Sumber Daya Terintegrasi (SISTER) milik Kementerian Pendidikan Tinggi, Sains, dan Teknologi. SISTER merupakan platform resmi nasional tempat seluruh dosen melaporkan aktivitas Tri Dharma mereka setiap semester. Pengambilan data dilakukan melalui permohonan resmi kepada UPATIK (Unit Penunjang Akademik Teknologi Informasi dan Komunikasi) Universitas Jambi selaku pengelola lokal sistem SISTER di lingkungan UNJA. Data yang diminta mencakup laporan BKD dosen tetap Universitas Jambi pada Tahun Akademik 2024/2025 (semester ganjil dan genap). Spesifikasi variabel yang dibutuhkan adalah sebagai berikut:

Tabel 5. Variabel Data yang Dibutuhkan

Kelompok Variabel	Nama Variabel	Deskripsi
Identitas Dosen	Fakultas	Nama fakultas tempat dosen bernaung
	Program Studi	Nama program studi dosen
	Jabatan Fungsional	Jenjang jabatan akademik dosen
Data BKD	SKS BKD Pendidikan	Jumlah SKS dari komponen pendidikan & pengajaran (sesuai laporan BKD)
	SKS Lebih Pendidikan	SKS dari komponen pendidikan yang melebihi batas perhitungan standar
	SKS BKD Penelitian	Jumlah SKS dari komponen penelitian
	SKS Lebih Penelitian	SKS penelitian melebihi batas standar
	SKS BKD Pengabdian	Jumlah SKS dari komponen pengabdian kepada masyarakat
	SKS Lebih Pengabdian	SKS pengabdian melebihi batas standar
	SKS BKD Penunjang	Jumlah SKS dari kegiatan penunjang Tri Dharma
	SKS Lebih Penunjang	SKS penunjang melebihi batas standar

B. Eksplorasi Data Awal

Setelah data BKD diperoleh dari UPATIK Universitas Jambi, dilakukan eksplorasi awal data menggunakan bahasa pemrograman Python pada platform Google Colab. Tahap ini bertujuan untuk memahami struktur, kualitas, dan

karakteristik data sebelum memasuki proses pembersihan dan pemodelan. Adapun *library* yang dilakukan dalam proses eksplorasi data awal yaitu:

- a. Pandas
 - a. Fungsi: Manipulasi dan analisis data berbentuk tabel (dataframe).
 - b. Kegunaan: Membaca file data BKD, melihat struktur dataset, menghitung statistik deskriptif, mendeteksi *missing value*, dan mengidentifikasi data duplikat.
- b. NumPy
 - a. Fungsi: Komputasi numerik dan operasi matematika berbasis array.
 - b. Kegunaan: Mendukung perhitungan numerik seperti total SKS dan pembentukan variabel turunan.
- c. Matplotlib
 - a. Fungsi: Visualisasi data statis.
 - b. Kegunaan: Membuat histogram distribusi SKS, scatter plot, serta grafik Elbow Method pada tahap pemodelan.
- d. Seaborn
 - a. Fungsi: Visualisasi statistik yang lebih informatif.
 - b. Kegunaan: Membuat heatmap korelasi, *box plot* per fakultas atau jabatan, serta violin plot distribusi data.

Pertama, dilakukan identifikasi kualitas data dengan menghitung jumlah dan persentase *missing value* pada setiap kolom. Pemeriksaan ini penting untuk menentukan apakah diperlukan penanganan khusus seperti imputasi atau penghapusan data. Selain itu, dilakukan deteksi baris duplikat guna memastikan tidak terdapat data ganda yang dapat memengaruhi hasil analisis. Tahap berikutnya adalah menghitung statistik deskriptif untuk seluruh variabel numerik, khususnya komponen SKS pendidikan, penelitian, pengabdian, dan penunjang. Statistik ini memberikan gambaran mengenai nilai rata-rata, variasi data, rentang nilai minimum dan maksimum, serta distribusi kuartil yang menjadi dasar dalam memahami karakteristik umum beban kerja dosen.

Selain analisis numerik, dilakukan pula visualisasi awal untuk melihat pola distribusi data secara grafis. Histogram digunakan untuk melihat sebaran SKS tiap komponen Tri Dharma, sementara *box plot* dan *violin plot* digunakan untuk membandingkan distribusi BKD berdasarkan fakultas maupun jenjang jabatan fungsional. *Heatmap* korelasi dimanfaatkan untuk mengidentifikasi hubungan antar variabel numerik. Melalui eksplorasi awal ini, peneliti memperoleh pemahaman komprehensif mengenai kondisi data BKD yang akan

menjadi dasar dalam menentukan strategi pembersihan data, normalisasi, serta pemodelan *clustering* pada tahap selanjutnya.

3.5 *Data preparation*

Tahap *Data Preparation* merupakan proses transformasi dataset mentah menjadi data yang siap dianalisis secara komputasional. Setelah karakteristik data dipahami pada tahap sebelumnya, dilakukan serangkaian proses pembersihan dan penyesuaian untuk meningkatkan kualitas dan konsistensi data. Tahap ini krusial dalam penelitian berbasis *clustering* karena algoritma pengelompokan sangat sensitif terhadap kesalahan input dan perbedaan skala variabel. Dengan demikian, data preparation menjadi fondasi teknis yang menentukan keakuratan pembentukan *cluster* serta validitas interpretasi pola beban kerja dosen yang dihasilkan.

A. *Data cleaning*

Tahap *data cleaning* bertujuan memastikan dataset bebas dari inkonsistensi, kesalahan input, dan anomali yang dapat memengaruhi kualitas analisis serta hasil *clustering*.

1) Penanganan *Missing value*

Missing value pada data BKD dapat muncul karena beberapa kondisi yang berbeda, sehingga strategi penanganannya tidak dapat disamaratakan.

Tabel 6. Strategi Penanganan *Missing value*

Sumber <i>Missing value</i>	Contoh Kolom	Kemungkinan Penyebab	Strategi Penanganan
Identitas dosen	Jabatan Fungsional	Tidak semua dosen telah memiliki jabatan fungsional resmi	Isi dengan kategori 'Belum Ada Jabatan' atau 'Tanpa Jabatan'
SKS komponen BKD	SKS BKD Pengabdian, SKS BKD Penelitian	Dosen tidak melakukan kegiatan pada komponen tersebut di semester berjalan	Isi dengan nilai 0 (nol), karena ketiadaan kegiatan berarti kontribusi nol, bukan data yang hilang

SKS Lebih	SKS Lebih	Dosen	tidak	Isi dengan nilai 0 (nol)
	Pendidikan, dll.	memiliki SKS yang melebihi batas		

2) Data Duplikat

Duplikasi data dapat terjadi akibat kesalahan ekspor dari sistem atau pencatatan ganda pada periode semester yang sama. Dalam penelitian ini, identifikasi duplikat dilakukan berdasarkan kombinasi ID_Dosen dan Semester untuk memastikan setiap dosen hanya memiliki satu entri pada periode tertentu. Proses identifikasi dan penghapusan duplikat dilakukan menggunakan *library* Pandas pada Python, khususnya melalui fungsi deteksi dan penghapusan baris duplikat. Apabila ditemukan data ganda, hanya satu entri yang dipertahankan untuk menjaga konsistensi dan keakuratan dataset. Langkah ini penting agar proses analisis tidak bias akibat perhitungan ganda terhadap beban kerja dosen yang sama.

3) Penjumlahan SKS BKD dan SKS Lebih

Pada tahap *data cleaning* juga dilakukan penggabungan nilai SKS BKD dan SKS Lebih untuk setiap komponen (Pendidikan, Penelitian, Pengabdian, dan Penunjang). Penggabungan ini dilakukan karena SKS Lebih tetap merepresentasikan kontribusi nyata dosen, meskipun secara administratif tidak seluruhnya diperhitungkan dalam batas formal BKD. Dengan menjumlahkan kedua komponen tersebut, diperoleh nilai total beban kerja yang lebih representatif terhadap aktivitas akademik dosen. Proses penjumlahan kolom dilakukan menggunakan *library* Pandas, dengan membentuk kolom baru berupa total SKS per komponen serta total keseluruhan SKS BKD. Hasil agregasi ini kemudian menjadi variabel numerik utama yang digunakan dalam tahap analisis dan proses *clustering*.

4) Deteksi *Outlier*

Dalam konteks BKD, nilai ekstrem tidak selalu menunjukkan kesalahan, karena dapat mencerminkan variasi produktivitas dosen yang memang berbeda secara nyata. Pada penelitian ini, deteksi *outlier* dilakukan menggunakan metode *Interquartile Range* (IQR). Perhitungan kuartil serta penentuan batas bawah dan batas atas dilakukan dengan bantuan *library* Pandas, sedangkan visualisasi distribusi data menggunakan *box plot* melalui Matplotlib dan Seaborn untuk

mendukung analisis eksploratif. Penanganan *outlier* dilakukan secara selektif dengan mempertimbangkan konteks data, yaitu:

- a. *Outlier* yang bersifat substantif (misalnya dosen dengan produktivitas penelitian sangat tinggi) → dipertahankan karena merepresentasikan kondisi riil.
- b. *Outlier* akibat kesalahan input (misalnya nilai negatif atau tidak logis) → dikoreksi atau dihapus.

B. Normalisasi Data

Normalisasi data diperlukan sebelum proses *K-means clustering* dilakukan, karena algoritma K-Means menggunakan jarak Euclidean yang sangat sensitif terhadap perbedaan skala. Tanpa normalisasi, komponen dengan nilai SKS yang secara umum lebih tinggi akan mendominasi perhitungan jarak dibandingkan komponen yang nilainya kecil (misalnya penunjang yang hanya 1–2 SKS). Penelitian ini menggunakan metode *Min-Max Scaling* melalui *library Scikit-learn*. Metode ini mengubah setiap nilai ke dalam rentang [0, 1] menggunakan rumus:

$$X_{\text{scaled}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Di mana X adalah nilai asli, $X_{\min}$ adalah nilai minimum kolom tersebut, dan $X_{\max}$ adalah nilai maksimum kolom tersebut. Nilai 0 berarti dosen memiliki SKS terendah dalam komponen itu di antara seluruh populasi, sedangkan nilai 1 berarti SKS tertinggi.

3.6 Modeling

Tahap *Modeling* merupakan inti dari proses *data mining*, di mana teknik analitik diterapkan untuk menjawab rumusan masalah penelitian. Pada fase ini, data yang telah dipersiapkan dianalisis melalui pendekatan eksploratif dan algoritmik guna mengungkap pola yang tidak terlihat secara langsung. Tahap ini dimulai dari eksplorasi deskriptif hingga pembentukan *cluster* menggunakan algoritma K-Means. Pendekatan ini memastikan bahwa hasil pengelompokan tidak hanya bersifat komputasional, tetapi juga memiliki dasar interpretasi yang kuat secara empiris.

A. Exploratory Data Analysis

Exploratory Data Analysis (EDA) pada tahap *modeling* diarahkan secara langsung untuk menjawab dua rumusan masalah penelitian yang telah ditetapkan. Analisis ini tidak hanya berfungsi sebagai eksplorasi awal, tetapi sebagai pendekatan analitik sistematis untuk mengungkap pola pemenuhan BKD

serta mengidentifikasi perbedaan karakteristik beban kerja antar kelompok. Oleh karena itu, EDA dalam penelitian ini dibagi ke dalam dua fokus utama, yaitu analisis pemenuhan BKD secara keseluruhan dan analisis perbandingan antar fakultas serta jabatan fungsional. Hasil dari kedua analisis ini menjadi dasar empiris sebelum dilakukan proses *clustering*, sehingga pengelompokan yang dihasilkan memiliki pijakan kontekstual yang kuat terhadap permasalahan penelitian.

1) Analisis Pemenuhan BKD

Fokus pertama EDA bertujuan memahami bagaimana dosen-dosen UNJA secara keseluruhan memenuhi keempat komponen BKD-nya. Analisis ini menjawab pertanyaan: seberapa besar rata-rata kontribusi dosen pada masing-masing dharma, apakah ada komponen yang secara umum tidak terpenuhi, dan bagaimana proporsi tiap komponen terhadap total beban kerja. Untuk menjawab pertanyaan tersebut, dilakukan empat langkah analisis berikut.

1. Statistik deskriptif per komponen. Nilai rata-rata, median, standar deviasi, minimum, dan maksimum dihitung untuk setiap komponen Total SKS menggunakan fungsi `describe()` dari *library* Pandas. Hasil langkah ini memberikan gambaran awal tentang sebaran nilai BKD dosen secara agregat, sekaligus menjadi acuan untuk mengidentifikasi komponen mana yang cenderung rendah atau tinggi secara umum.
2. Analisis distribusi. Sebaran nilai SKS setiap komponen divisualisasikan menggunakan histogram dilengkapi kurva densitas (*Kernel Density Estimation*) yang dibuat menggunakan Seaborn. Garis vertikal rata-rata dan median ditambahkan pada setiap plot untuk membantu membaca arah kemiringan distribusi. Langkah ini menjawab pertanyaan apakah distribusi SKS setiap komponen cenderung memusat, condong ke kiri (banyak dosen dengan nilai rendah), atau condong ke kanan (sebagian kecil dosen dengan nilai sangat tinggi).
3. Analisis proporsi komponen BKD. Persentase kontribusi rata-rata setiap komponen terhadap total BKD dihitung menggunakan Pandas, kemudian divisualisasikan dalam bentuk *stacked bar chart* menggunakan Matplotlib. Visualisasi ini memperlihatkan komposisi rata-rata BKD dosen secara sekilas, sehingga dominasi komponen pendidikan dibandingkan penelitian atau pengabdian, misalnya, dapat langsung terbaca secara visual. Langkah ini menjadi landasan empiris untuk menilai proporsionalitas pelaksanaan Tri Dharma secara institusional.
4. Identifikasi pola defisit. Langkah terakhir dalam fokus ini adalah menghitung proporsi dosen yang tidak memenuhi ambang batas

minimum pada setiap komponen BKD, misalnya dosen dengan SKS penelitian di bawah 3 SKS atau dosen dengan SKS pengabdian yang sama sekali kosong. Perhitungan dilakukan menggunakan `Pandas` dengan menyaring baris yang nilainya berada di bawah batas yang ditetapkan, lalu dibagi dengan total jumlah dosen untuk mendapatkan persentasenya. Hasil dari langkah ini secara langsung menjawab rumusan masalah pertama dengan memberikan gambaran konkret tentang seberapa banyak dosen yang pelaksanaan Tri Dharmanya masih belum proporsional.

2) Analisis Perbandingan Antar Kelompok

Fokus kedua EDA bertujuan mengungkap apakah pola BKD dosen berbeda secara sistematis antar fakultas dan antar jenjang jabatan fungsional. Pertanyaan ini penting karena perbedaan karakteristik kelembagaan antar fakultas, serta perbedaan tuntutan akademik antar jenjang jabatan, berpotensi menciptakan profil BKD yang khas. Analisis dilakukan melalui dua dimensi pengelompokan berikut.

1. Perbandingan antar Fakultas. Data dikelompokkan berdasarkan nama fakultas menggunakan fungsi `groupby()` dari `Pandas`, lalu rata-rata SKS per komponen dihitung untuk setiap fakultas. Hasilnya divisualisasikan dalam bentuk `grouped bar chart` menggunakan `Matplotlib`, di mana setiap batang mewakili rata-rata satu komponen BKD dan setiap kelompok batang mewakili satu fakultas. Visualisasi ini memungkinkan perbandingan antar-fakultas secara langsung dan mudah dibaca, sehingga dapat diidentifikasi apakah terdapat fakultas yang memiliki profil BKD sangat berbeda dari yang lain.
2. Perbandingan antar Jabatan Fungsional. Dengan cara yang serupa, data dikelompokkan berdasarkan jenjang jabatan fungsional (Asisten Ahli, Lektor, Lektor Kepala, dan Profesor), lalu rata-rata SKS per komponen dihitung untuk setiap jenjang. Untuk dimensi jabatan ini, dipilih *violin plot* dari *library Seaborn* sebagai alat visualisasi utama. *Violin plot* dipilih karena tidak hanya menampilkan nilai rata-rata, tetapi juga memperlihatkan bentuk distribusi data secara penuh untuk setiap kelompok, sehingga perbedaan pola sebaran nilai BKD antar jenjang jabatan dapat terlihat dengan lebih kaya dan informatif dibandingkan sekadar membandingkan angka rata-rata.

B. *K-means clustering*

Setelah EDA mengungkap gambaran deskriptif pola BKD, tahap selanjutnya adalah *K-means clustering* untuk menjawab rumusan masalah ketiga, yaitu mengidentifikasi kelompok-kelompok dosen yang terbentuk secara alami berdasarkan kesamaan pola BKD mereka. Proses *clustering* dilaksanakan melalui empat langkah berurutan: pemilihan fitur, penentuan jumlah *cluster* optimal, pelaksanaan *clustering*, dan analisis serta interpretasi hasil. Seluruh proses diimplementasikan menggunakan *library Scikit-learn* dalam Python, yang menyediakan implementasi K-Means, metrik evaluasi *clustering*, dan alat normalisasi data secara terintegrasi.



Gambar 3. *K-means clustering*

1) Pemilihan Fitur

Fitur yang digunakan dalam proses *clustering* adalah nilai Total SKS per komponen BKD yang telah dinormalisasi, yaitu Total SKS Pendidikan (X1), Total SKS Penelitian (X2), Total SKS Pengabdian (X3), dan Total SKS Penunjang (X4). Keempat fitur ini merepresentasikan pola kontribusi nyata dosen pada setiap komponen Tri Dharma dan menjadi dasar pengelompokan.

i. Penentuan Jumlah *Cluster* Optimal (k)

K-Means mengharuskan jumlah *cluster* (k) ditentukan sebelum proses *clustering* dijalankan. Penelitian ini menggunakan Silhouette Score sebagai metode penentuan k optimal. Silhouette Score dipilih karena menghasilkan nilai numerik yang objektif dan dapat langsung dibandingkan antar nilai k . Silhouette Score mempertimbangkan dua aspek kualitas *clustering*: seberapa dekat setiap titik data dengan anggota *cluster*-nya sendiri (*cohesion*) dan seberapa jauh ia dari *cluster* terdekat lainnya (*separation*).

Proses penentuan k dilakukan dengan menjalankan K-Means untuk setiap nilai k dari 2 hingga 8. Batas bawah $k=2$ ditetapkan karena $k=1$ tidak menghasilkan pengelompokan yang bermakna. Adapun batas atas $k=8$ ditetapkan bukan berdasarkan jumlah data, melainkan berdasarkan pertimbangan bahwa pola BKD dosen secara substantif hanya memiliki variasi yang terbatas. Meskipun jumlah dosen yang dianalisis dapat mencapai ratusan hingga ribuan, jumlah *pola* BKD yang secara nyata berbeda dan bermakna untuk keperluan kebijakan diperkirakan jauh lebih sedikit dari itu. Penetapan rentang

2–8 juga konsisten dengan praktik yang lazim digunakan pada penelitian *clustering* serupa di bidang pendidikan tinggi. Apabila Silhouette Score tertinggi ditemukan pada nilai k di ujung rentang ($k=7$ atau $k=8$), rentang pencarian akan diperluas hingga $k=12$ untuk memastikan nilai k optimal yang sesungguhnya tidak terlewat.

Untuk setiap nilai k yang diuji, Silhouette Score dihitung menggunakan fungsi `silhouette_score()` dari modul `sklearn.metrics`. Nilai k yang menghasilkan Silhouette Score tertinggi dipilih sebagai k optimal. Hasil perhitungan untuk setiap nilai k divisualisasikan dalam grafik garis menggunakan Matplotlib, sehingga puncak nilai pada grafik tersebut secara visual langsung menunjukkan k yang paling optimal.

ii. *Clustering*

Setelah nilai k ditentukan, proses *clustering* dijalankan menggunakan kelas *KMeans* dari modul `sklearn.cluster`. Terdapat dua konfigurasi penting yang diterapkan: pertama, metode inisialisasi *centroid* menggunakan *K-Means++* yang menempatkan *centroid* awal secara lebih cerdas dibandingkan inisialisasi acak murni, sehingga mengurangi risiko konvergensi ke solusi yang suboptimal; kedua, *clustering* diulang sebanyak 10 kali ($n_init=10$) dengan inisialisasi yang berbeda-beda, dan hasil terbaik berdasarkan nilai WCSS terkecil yang diambil sebagai hasil final. Kedua konfigurasi ini bertujuan memastikan stabilitas dan konsistensi hasil *clustering*.

Hasil akhir dari langkah ini adalah penambahan kolom baru bernama *Cluster* pada dataset, yang berisi nomor *cluster* untuk setiap baris data dosen. Nomor *cluster* tersebut kemudian menjadi dasar seluruh analisis di langkah berikutnya.

iii. Analisis dan Interpretasi Hasil *Clustering*

Setelah setiap dosen mendapatkan label *cluster*-nya, dilakukan analisis mendalam untuk memahami karakteristik setiap *cluster*. Analisis ini mencakup tiga sub-langkah berikut.

- a. Penyusunan profil *cluster*. Untuk setiap *cluster*, dihitung nilai rata-rata dan distribusi dari keempat fitur SKS menggunakan fungsi `groupby()` dari `Pandas`. Tabel profil ini memperlihatkan secara langsung komponen mana yang mendominasi setiap *cluster* dan komponen mana yang rendah, sehingga karakter unik setiap kelompok dosen dapat terbaca dengan jelas.
- b. Analisis komposisi *cluster*. Distribusi keanggotaan setiap *cluster* ditelaah berdasarkan dua variabel identitas, yaitu Jabatan Fungsional dan

Fakultas, menggunakan tabel silang (*crosstab*) dari *Pandas*, serta divisualisasikan dalam bentuk *heatmap* menggunakan *Seaborn*. Analisis komposisi ini menjawab pertanyaan seperti: apakah dosen dengan jabatan Profesor cenderung berkumpul di satu *cluster* tertentu? Atau apakah *cluster* dengan penelitian tinggi lebih banyak dihuni dosen dari fakultas tertentu?

- c. Pemberian label deskriptif. Berdasarkan profil dan komposisi yang telah dianalisis, setiap *cluster* diberi nama deskriptif yang mencerminkan karakteristik dominannya. Contohnya: *cluster* dengan SKS Pendidikan sangat tinggi dan SKS Penelitian rendah dapat diberi label “Pengajar Dominan”; *cluster* dengan SKS Penelitian tinggi dapat disebut “Peneliti Aktif”; dan *cluster* dengan distribusi yang relatif seimbang dapat dinamai “Proporsional”. Pemberian label ini bersifat interpretatif dan merupakan bagian dari kontribusi analitik penelitian, karena mengubah angka statistik menjadi gambaran yang bermakna bagi pemangku kebijakan universitas.

3.7 Evaluation

Dari sisi teknis, kualitas *clustering* dievaluasi menggunakan Silhouette Score, yakni metrik yang sama digunakan pada tahap penentuan k optimal. Pada tahap ini, nilai Silhouette Score untuk k final dilaporkan secara eksplisit sebagai konfirmasi formal bahwa *cluster* yang terbentuk layak diinterpretasikan lebih lanjut. *Clustering* dinyatakan memenuhi syarat apabila Silhouette Score mencapai nilai $\geq 0,40$. Apabila nilai yang diperoleh berada di bawah ambang batas tersebut, proses *clustering* ditinjau ulang, antara lain dengan memperluas rentang nilai k yang diuji atau mengevaluasi kembali proses normalisasi data.

Dari sisi bisnis, evaluasi dilakukan melalui *domain validation* guna memastikan bahwa *cluster* yang terbentuk tidak hanya valid secara statistik, tetapi juga bermakna dalam konteks pengelolaan BKD. Proses ini dilakukan dengan memverifikasi apakah profil setiap *cluster* masuk akal secara kontekstual, misalnya dengan memeriksa apakah *cluster* yang memiliki nilai SKS penelitian tinggi memang didominasi oleh dosen berjabatan Lektor Kepala atau Profesor, serta apakah pola yang terbentuk konsisten dengan temuan EDA sebelumnya. Distribusi keanggotaan *cluster* berdasarkan jabatan fungsional dan fakultas divisualisasikan menggunakan *heatmap* sebagai dasar interpretasi hasil *clustering* secara menyeluruh.

3.8 Deployment

Sesuai dengan batasan masalah yang telah ditetapkan, tahap *Deployment* dalam penelitian ini dibatasi pada penyusunan laporan analisis yang komprehensif. Tahap ini tidak mencakup pengembangan dashboard interaktif maupun sistem visualisasi berbasis web, karena keduanya berada di luar cakupan penelitian ini.

Laporan analisis yang disusun mencakup dua komponen utama, yaitu: (1) rangkuman temuan EDA mengenai pola distribusi dan ketimpangan BKD dosen; dan (2) profil karakteristik setiap *cluster* yang terbentuk beserta label deskriptif yang merepresentasikan pola dominannya.

3.9 Perangkat Penelitian

Perangkat penelitian yang digunakan dalam penelitian ini terdiri dari perangkat keras dan perangkat lunak yang mendukung proses analisis data dan penyusunan laporan penelitian. Adapun perangkat yang digunakan adalah sebagai berikut:

- 1) Perangkat keras yang digunakan adalah laptop ASUS Vivobook dengan spesifikasi:
 - a. Processor: Intel® Core™ i5-1235U (12th Gen, 1.30 GHz)
 - b. RAM: 16 GB
 - c. *System Type*: 64-bit Operating System, x64-based processor
 - d. *Operating System*: Windows 11 Home Single Language
- 2) Perangkat lunak yang digunakan dalam penelitian ini terdiri atas:
 - a. Google Colab sebagai platform komputasi berbasis cloud untuk menjalankan Python
 - b. Windows 11 sebagai sistem operasi utama perangkat

3.10 Timeline Kegiatan

Penelitian ini direncanakan berlangsung selama tiga hingga empat bulan, mencakup seluruh enam tahapan dalam kerangka kerja CRISP-DM secara berurutan dan iteratif. Durasi aktual dapat menyesuaikan kondisi di lapangan, terutama pada tahap pengambilan data yang bergantung pada proses perizinan di UPATIK Universitas Jambi. Sebagai acuan perencanaan, rincian jadwal pelaksanaan setiap tahapan disajikan pada Tabel 7 berikut.

DAFTAR PUSTAKA

- Abdillah, F. (2024). Peran Perguruan Tinggi Dalam Meningkatkan Sumber Daya Manusia. *EDUCAZIONE:: Jurnal Multidisiplin*, 1(1), 13–24. <https://doi.org/10.51213/jmm.v3i1.46>
- Afidah, N. N. (2023). Penerapan Metode Clustering dengan Algoritma K-means untuk Pengelompokan Data Migrasi Penduduk Tiap Kecamatan di Kabupaten Rembang. *PRISMA, Prosiding Seminar Nasional Matematika*, 6, 729–738. <https://journal.unnes.ac.id/sju/index.php/prisma/>
- Amalia, N. (2024). Akademik Dan Masyarakat Berpradaban. *Karimah Tauhid*, 3(4), 4654–4663.
- Azfirmawarman, D., Adnan, M. F., & Khaidir, A. (2024). Kemerdekaan Dosen dalam Beban Kerja dan Karir: Konsep Tata Kelola Institusi dan Reformasi Administrasi di Perguruan Tinggi. *Jurnal Ilmiah Ilmu Administrasi*, 14(1), 38–47. <https://doi.org/10.33592/jiia.v14i1.4651>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). Step-by-step data mining guide. *SPSS Inc*, 78, 1–78. <http://www.crisp-dm.org/CRISPWP-0800.pdf>
- Dahnial. (2024). Penerapan Metode Clustering K-Means Terhadap Dosen Berdasarkan Publikasi Jurnal Nasional Dan Terakreditasi Sinta Implementation of K-Means Clustering Method To Lecturers Based on Publications of National Journals and Accredited Sinta. *JSI: Jurnal Sistem Informasi (E-Journal)*, 16(1), 219–236.
- Djamba, Y. K., & Neuman, W. L. (2014). Social Research Methods: Qualitative and Quantitative Approaches. In *Teaching Sociology* (Vol. 30, Issue 3). <https://doi.org/10.2307/3211488>
- Gayatri, D., & Yudhanegara, M. R. (2025). K-Means Clustering for the Relationship Between Mathematical Problem Solving Ability and Mathematical Communication Ability. *Indonesian Journal of Applied Mathematics and Statistics*, 2(2), 67–80. <https://doi.org/10.71385/idjams.v2i2.27>
- Gunawan, Mardhia, D., Yahya, F., Kautsari, N., & Masniadi, R. (2020). PENYULUHAN TENTANG PELUANG DAN TANTANGAN PENERAPAN TRI DHARMA PERGURUAN TINGGI DI ERA REVOLUSI INDUSTRI 4.0. *Jurnal Pendidikan Dan Pengabdian Masyarakat*, 3(2), 84–89.
- Han, J., Pei, J., & Tong, H. (2022). Data Mining: Concepts and Techniques, Fourth Edition. In *Data Mining: Concepts and Techniques, Fourth Edition*. <https://doi.org/10.1016/C2013-0-18660-6>
- Handayani, Y., & Hidayat, N. (2024). Strategi Peningkatan Kinerja Dosen dalam Mewujudkan Perguruan Tinggi Berakreditasi Unggul. *JIIP - Jurnal Ilmiah Ilmu Pendidikan*, 7(12), 14003–14008. <https://doi.org/10.54371/jiip.v7i12.6426>
- Harahap, A. A., Raihan, M., Amani, N., & Andini, P. R. (2023). *Comparison of Unsupervised Learning Techniques for Clustering Data on the Number of Villages in Indonesia Perbandingan Teknik Unsupervised Learning untuk Pengelompokan Data Jumlah Desa Di Indonesia*. 163–170.
- Hardiani, T. (2022). Analisis Clustering Kasus Covid 19 di Indonesia Menggunakan Algoritma K-Means. *Jurnal Nasional Pendidikan Teknik Informatika (JANAPATI)*, 11(2), 156–165. <https://doi.org/10.23887/janapati.v11i2.45376>

- Irene, J. (2023). Profesionalisme Dosen Dalam Tridarma Perguruan Tinggi. *AT-TAWASSUTH: Jurnal Ekonomi Islam*, VIII(1), 1–19.
- Isa, I. G. T., Zulkarnaini, Novianti, L., Elfaladonna, F., & Agustri, S. (2023). Exploratory Data Analysis (EDA) dalam Dataset Penerimaan Mahasiswa Baru Universitas XYZ Palembang. *Smart Comp: Jurnalnya Orang Pintar Komputer*, 12(3), 600–609. <https://doi.org/10.30591/smartcomp.v12i3.4125>
- Jamaluddin, Arianti, B. D. D., Novianti, B. H., & Asrobi, M. (2022). Desain Sistem Informasi Tri Dharma Perguruan Tinggi Universitas Hamzanwadi Tri Dharma Perguruan Tinggi merupakan tiga pilar utama yang menjadi salah satu komponen dalam mencapai visi misi setiap perguruan tinggi [1][2]. Tridharma Perguruan Tinggi terd. *Infotek: Jurnal Informatika Dan Teknologi*, 5(2), 392–401.
- Nadeak, B. (2020). Deskripsi Kinerja Dosen Perguruan Tinggi Swasta Di Indonesia. *Monograf*, 98. www.penerbitwidina.com
- Nashrullah, M., Qausya, Nursalim, M., Budiyanto, & Lestari, G. D. (2025). Innovation in Strategies for Faculty Development and Career Advancement. *Indonesian Journal of Innovation Studies*, 26(1), 1–16. <https://doi.org/10.21070/ijins.v26i1.1319>
- Norshahlan, M., Jaya, H., & Kustini, R. (2023). Penerapan Metode Clustering Dengan Algoritma K-means Pada Pengelompokan Data Calon Siswa Baru. *Jurnal Sistem Informasi Triguna Dharma (JURSI TGD)*, 2(6), 1042. <https://doi.org/10.53513/jursi.v2i6.9148>
- Nugraha, M., & Rosmeida, M. (2021). Perancangan Sistem Informasi Beban Kerja Dosen Berbasis Web dengan UML. *Jurnal Algoritma*, 18(1), 141–150. <https://doi.org/10.33364/algoritma/v.18-1.866>
- Pratama, M. E., & Agastya, I. M. A. (2026). Analisis Laporan Beban Kerja Dosen Pada Bidang Penelitian dan PKM Dengan Menggunakan K-Means Clustering. *Jurnal Sistem Informasi Universitas Suryadarma*, 13(1), 162–179. <https://doi.org/10.35968/jsi.v13i1.1762>
- Rahman, F. K., Sanjaya, J. S., Handayani, L., & Insani, F. (2025). Penerapan Algoritma K-Means Clustering pada Kinerja Mesin Screw press. *Bulletin of Information Technology (BIT)*, 6(2), 59–70. <https://doi.org/10.47065/bit.v5i2.1783>
- Retnoningsih, E., & Pramudita, R. (2020). Mengenal Machine Learning Dengan Teknik Supervised Dan Unsupervised Learning Menggunakan Python. *Bina Insani Ict Journal*, 7(2), 156. <https://doi.org/10.51211/biict.v7i2.1422>
- Rizki, I. N., Prayoga, D., Puspita, M. L., & Huda, M. Q. (2024). Implementasi Exploratory Data Analysis Untuk Analisis Dan Visualisasi Data Penderita Stroke Kalimantan Selatan Menggunakan Platform Tableau. *Jurnal Informatika Dan Teknik Elektro Terapan*, 12(1). <https://doi.org/10.23960/jitet.v12i1.3856>
- Santoso, P., Abijono, H., & Anggreini, N. L. (2021). *ALGORITMA SUPERVISED LEARNING DAN UNSUPERVISED*. 4(2), 315–318.
- Saputra, A., & Yusuf, R. (2024). Perbandingan Algoritma DBSCAN dan K-MEANS dalam Segmentasi Pelanggan Pengguna Transportasi Publik Transjakarta Menggunakan Metode RFM: Comparison of the DBSCAN and K-MEANS Algorithms in Segmenting Customers Using Public Transportation of Transjakarta Usin. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 4(4), 1346–1361. <https://journal.irpi.or.id/index.php/malcom/article/view/1516>

- Sari, Y. R., Sudewa, A., Lestari, D. A., & Jaya, T. I. (2020). Penerapan Algoritma K-Means Untuk Clustering Data Kemiskinan Provinsi Banten Menggunakan Rapidminer. *CESS (Journal of Computer Engineering, System and Science)*, 5(2), 192. <https://doi.org/10.24114/cess.v5i2.18519>
- Schröer, C., Kruse, F., & Gómez, J. M. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science*, 181(2019), 526–534. <https://doi.org/10.1016/j.procs.2021.01.199>
- Setyani, T., Nopijani Heidy, H., Sari, K., Indriani, Y., & Sulistiani, H. (2025). Perbandingan Kinerja Algoritma K-Means dan DBSCAN dalam Segmentasi Nasabah Berdasarkan Data Pemasaran Bank. *Prosiding Seminar Nasional Teknologi Komputer Dan Sains*, 3(1), 376–382. <https://doi.org/10.47065/mis.v2i3>
- Simamora, R. B., Irwadi, I., & Leonid, M. (2024). Kajian Harmonisasi dan Inovasi Kerja Dosen: Studi Kasus di Perguruan Tinggi Swasta di Kota Medan. *Jurnal Ilmiah Mahasiswa Perbankan Syariah (JIMPA)*, 4(2), 761–780. <https://doi.org/10.36908/jimpa.v4i2.456>
- Situmeang, S. M. T. (2021). Meningkatkan Pengetahuan Masyarakat Melalui Penelitian dan Pengabdian Masyarakat Sebagai Wujud Tri Dharma Perguruan Tinggi. *Penelitian Dan Pengabdian Inovatif Pada Masa Pandemi Covid-19*, 1090–1098.
- Solehuddin, M., Hasan, S., Yusri, Y. F., Syufi, Y., Siburian, R. H. S., Fahrudin, A., & Syahputra, H. (2025). Pelatihan Penyusunan Proposal Hibah Penelitian Dan. *Community Development Journal*, 6(1), 1421–1425.
- Sufairoh, I., Rani, A. C., Amalia, K., & Rolliawati, D. (2023). Perbandingan Hasil Analisis Clustering Metode K-Means, DBSCAN Dan Hierarchical Pada Data Marketplace Electronic Phone. *JOINS (Journal of Information System)*, 8(1), 97–105. <https://doi.org/10.33633/joins.v8i1.8016>
- Sulistyaningrum, D., Diana, T., Nurhastuti, Suryato, A., Zulfa, & Suryadi. (2025). Penguatan Jejaring Kolaborasi Dosen Antar Perguruan Tinggi untuk Optimalisasi Implementasi Tri Dharma. *Jurnal Pengabdian Masyarakat Indonesia*, 5, 345–359.
- Sunaengsih, C., Karlina, D. A., & Mulana, M. (2020). Jurnal Pasca Dharma Pengabdian. *Jurnal Pasca Dharma Pengabdian Masyarakat*, 1(2), 53–56. <https://ejournal.upi.edu/index.php/JPDPM/article/view/24002>
- Syarifah, Ali, M., Samad, A., Azza, F. N., Hasriani, M., & Susiana. (2025). Implementasi K-Means Clustering untuk Mengelompokkan Data Produktivitas Penelitian Dosen di Una ' im Yapis Wamena Implementation of K-Means Clustering to Group Research Productivity Data of Lecturers at Una ' im Yapis Wamena. 8(2), 69–76.
- Wongoutong, C. (2024). The impact of neglecting feature scaling in k-means clustering. *PLoS ONE*, 19(12), 1–19. <https://doi.org/10.1371/journal.pone.0310839>