

**ANALISIS KLUSTER TINGKAT PENGANGGURAN
MENGUNAKAN ALGORITMA K-MEANS
(STUDI KASUS: PROVINSI SUMATERA SELATAN)**

SKRIPSI



SULFIYANDI

F1E121083

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI**

2025

SURAT PERNYATAAN

Yang bertanda tangan di bawah ini, saya:

Nama : Sulfiyandi

Nim : F1E121083

Program Studi : Sistem Informasi

Dengan ini saya menyatakan dengan sesungguhnya bahwa skripsi yang saya ajukan merupakan hasil karya ilmiah yang saya susun sendiri secara mandiri. Sepanjang pengetahuan saya, di dalam naskah ini tidak terdapat bagian atau keseluruhan karya orang lain yang saya ambil tanpa menyebutkan sumbernya, baik berupa gagasan, pendapat, maupun temuan, kecuali yang secara jelas telah saya rujuk sesuai dengan kaidah penulisan ilmiah yang berlaku.

Saya juga menegaskan bahwa tanda tangan yang tercantum pada lembar pengesahan adalah benar dan asli. Apabila di kemudian hari terbukti terdapat pelanggaran dalam bentuk plagiarisme, pemalsuan tanda tangan, atau penyimpangan lainnya, maka saya bersedia menerima segala sanksi sesuai dengan peraturan akademik dan ketentuan hukum yang berlaku.

Demikian pernyataan ini saya buat dengan sebenar-benarnya untuk dapat digunakan sebagaimana mestinya.

Jambi, 18 Desember 2025

Yang menyatakan

Sulfiyandi

F1E121083

**ANALISIS KLUSTER TINGKAT PENGANGGURAN
MENGUNAKAN ALGORITMA K-MEANS
(STUDI KASUS: PROVINSI SUMATERA SELATAN)**

SKRIPSI

Diajukan sebagai salah satu syarat untuk memperoleh
Gelar Sarjana pada Program Studi Sistem Informasi



SULFIYANDI

F1E121083

**PROGRAM STUDI SISTEM INFORMASI
JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA**

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS JAMBI**

2025

HALAMAN PENGESAHAN

Skripsi dengan judul **ANALISIS KLUSTER TINGKAT PENGANGGURAN MENGGUNAKAN ALGORITMA K-MEANS (STUDI KASUS: PROVINSI SUMATERA SELATAN)** yang disusun oleh Sulfiyandi, NIM: F1E121083 telah di pertahankan di depan tim penguji pada tanggal 10 Juni 2025 dan dinyatakan lulus.

Susunan Tim Penguji:

Ketua	: Ulfa Khaira, S.Komp., M.Kom.
Sekretaris	: Mutia Fadhila Putri, M.Kom.
Anggota	: Rizqa Raaiqa Bintana, S.T., M.Kom.
	: Akhiyar Waladi, S.Komp., M.Kom.

Disetujui:

Pembimbing Utama

Pembimbing Pendamping

Ulfa Khaira, S.Komp., M.Kom.
NIP. 198912292019032018

Mutia Fadhila Putri, M.Kom.
NIP. 199612162022032016

Diketahui:

Dekan Fakultas
Sains dan Teknologi

Ketua Jurusan Teknik Elektro
Dan Informatika

Drs. Jefri Marzal, M.Sc., D.I.T.
NIP. 196806021993031004

Edi Saputra, S.T., M.Sc.
NIP. 198501082015041003

RINGKASAN

Pengangguran merupakan salah satu permasalahan ketenagakerjaan yang dapat memengaruhi kondisi sosial dan ekonomi suatu wilayah. Provinsi Sumatera Selatan memiliki tingkat pengangguran yang bervariasi pada setiap kabupaten/kota, sehingga perlu dianalisis untuk melihat pola kemiripan karakteristik wilayah secara menyeluruh. Penelitian ini bertujuan untuk mengelompokkan kabupaten/kota di Provinsi Sumatera Selatan berdasarkan empat indikator utama, yaitu Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM) menggunakan algoritma K-Means.

Data yang digunakan merupakan data sekunder dari Badan Pusat Statistik (BPS) periode 2019–2023. Proses analisis mencakup normalisasi data menggunakan metode Z-Score, penentuan jumlah cluster optimal dengan metode *Elbow*, serta evaluasi kualitas clustering melalui *Davies-Bouldin Index* (DBI) dan *Silhouette Coefficient*. Hasil evaluasi menunjukkan bahwa jumlah cluster optimal adalah empat cluster ($k=4$) untuk tahun 2019–2022 dan tiga cluster ($k=3$) untuk tahun 2023, seiring meningkatnya kemiripan nilai indikator pada beberapa wilayah.

Hasil pengelompokan memperlihatkan pola yang konsisten dari tahun ke tahun. Kota Palembang selalu membentuk cluster tersendiri. Kota Prabumulih dan Lubuklinggau cenderung berada dalam kelompok yang sama, menunjukkan stabilitas struktur sosial ekonominya. Sebagian besar kabupaten masuk ke dalam cluster menengah atau maju, menandakan adanya kesamaan karakteristik indikator ketenagakerjaan dan pembangunan antardaerah. Evaluasi *Davies-Bouldin Index* dan *Silhouette Coefficient* juga mengkonfirmasi bahwa struktur cluster yang terbentuk memiliki kualitas pemisahan yang baik. Secara keseluruhan, hasil penelitian ini diharapkan dapat memberikan masukan strategis bagi pemerintah daerah dalam merumuskan kebijakan ketenagakerjaan dan pembangunan wilayah. Dengan memahami kesamaan karakteristik berdasarkan indikator TPT, TPAK, PDRB, dan IPM. Pemerintah dapat menentukan prioritas yang lebih tepat sasaran, mengoptimalkan potensi wilayah, serta mempercepat pemerataan pembangunan di Provinsi Sumatera Selatan.

RIWAYAT HIDUP



Sulfiyandi lahir di Musi Banyuasin, pada tanggal 03 Juni 2003. Penulis merupakan anak pertama dari 2 bersaudara dari pasangan Sukamto dan Yurnilam. Berikut ini merupakan jalur Pendidikan formal yang pernah ditempuh penulis:

1. SD Negeri 2 Sumber Harum, tahun 2009-2011
2. SD Negeri Srimulyo, tahun 2011-2015
3. SMP Negeri 3 Tungkal Jaya, tahun 2015-2018
4. SMA Negeri 2 Tungkal Jaya, tahun 2018-2021

Pada tahun 2021, penulis melanjutkan pendidikan jenjang Strata 1 dan tercatat sebagai mahasiswa di Program Studi Sistem Informasi, Jurusan Teknik Elektro dan Informatika, Fakultas Sains dan Teknologi, Universitas Jambi melalui jalur SBMPTN. Selama menempuh pendidikan S1, penulis aktif dalam bidang akademik maupun non-akademik. Penulis mengikuti organisasi Himpunan Mahasiswa Sistem Informasi sebagai anggota. Dalam menambah wawasan dalam dunia kerja serta menerapkan ilmu, penulis telah mengikuti kegiatan magang di Dinas Komunikasi dan Informatika Provinsi Jambi, tepatnya di Layanan *E-Government* pada bagian *Jambi Data & Analytic Center* (JDAC).

PRAKATA

Puji syukur penulis ucapkan atas kehadiran Allah Swt atas limpahan rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan skripsi yang berjudul **“ANALISIS KLUSTER TINGKAT PENGANGGURAN MENGGUNAKAN ALGORITMA K-MEANS (STUDI KASUS: PROVINSI SUMATERA SELATAN)”** sebagai salah satu persyaratan untuk kelulusan pendidikan jenjang S1 Program Studi Sistem Informasi, Fakultas Sains dan Teknologi, Universitas Jambi.

Penulis menyadari bahwa dalam penyelesaian skripsi ini masih jauh dari kata sempurna. Oleh karena itu, kritik dan saran penulis terima dengan senang hati dan penulis juga menyadari bahwa penulisan skripsi ini tidak dapat terselesaikan tanpa bantuan, dukungan, dan dorongan dari berbagai pihak. Maka dari itu, atas segala bentuk jasa yang telah diberikan, Penulis mengucapkan terima kasih kepada:

1. Allah Swt. sebab berkat rahmat, karunia serta hidayah-Nya penulis dapat menyelesaikan tugas akhir dengan baik.
2. Kedua orang tua tercinta, Bapak Sukamto dan Ibu Yurnilam, S.Pd.SD. yang telah memberikan dukungan baik secara mental, fisik dan finansial, serta bekerja keras mendidik agar penulis menjadi manusia yang pantang menyerah, bertanggung jawab dan bermanfaat bagi banyak orang.
3. Bapak Prof. Dr. Helmi, S.H., M.H. selaku Rektor Universitas Jambi.
4. Bapak Drs. Jefri Marzal, M.Sc., D.I.T. selaku Dekan Fakultas Sains dan Teknologi Universitas Jambi.
5. Bapak Edi Saputra, S.T., M.Sc selaku Ketua Jurusan Teknik Elektro dan Informatika Fakultas Sains dan Teknologi, Universitas Jambi.
6. Reni Aryani, S.Kom., M.S.I. selaku Ketua Program Studi Sistem Informasi, Fakultas Sains dan Teknologi, Universitas Jambi.
7. Ibu Ulfa Khaira, S.Komp., M.Kom. dan Ibu Mutia Fadhila Putri, M.Kom., selaku Dosen pembimbing skripsi yang telah banyak memberikan arahan, dukungan, dan motivasi dalam penyusunan skripsi.
8. Tim Penguji Skripsi, Bapak Edi Saputra, S.T., M.Sc. dan Ibu Rizqa Raaiqa Bintana, S.T., M.Kom. yang telah memberikan masukan dan pengarahan untuk kesempurnaan skripsi ini.
9. Bapak Daniel Arsa, S.Kom., M.S.I. selaku Dosen Pembimbing Akademik yang senantiasa memberikan bantuan, motivasi dan pengarahan selama masa studi.
10. Seluruh Dosen di Program Studi Sistem Informasi Universitas Jambi atas segala ilmu dan bimbingannya selama masa studi.

11. Ayu Indryani, S.Kom. sebagai support system yang telah memberikan semangat dan dukungan selama ini, terimakasih untuk segala masukan, nasihat, serta motivasinya sehingga penulis dapat menyelesaikan skripsi ini dengan tepat waktu.
12. Supriyanto sebagai adik penulis yang telah memberikan semangat agar penulis dapat menyelesaikan skripsi.
13. Seluruh keluarga besar Sistem Informasi angkatan 2021, khususnya sahabat-sahabat dan rekan seperjuangan selama masa kuliah dan masa magang. Semoga keberhasilan ini menjadi langkah awal menuju kesuksesan kita bersama.
14. Terima kasih kepada diri sendiri, karena telah mampu terus berusaha keras dan berjuang sejauh ini untuk bertanggung jawab menyelesaikan apa yang telah dimulai. Semoga kedepannya menjadi pribadi yang lebih baik lagi dan terus pantang menyerah dengan impian yang dikejar.

Semoga atas jasa-jasa baik yang telah diberikan menjadi amalan yang mulia di sisi Allah Swt. dan mendapatkan balasan yang setimpal. Penulis menyadari bahwa dalam penyusunan laporan tugas akhir ini masih jauh dari kata kesempurnaan baik dari penyajian materi maupun penggunaan bahasa, untuk itu kritik dan saran yang bersifat membangun sangat penulis harapkan. Semoga laporan tugas akhir ini dapat menambah wawasan dan pengetahuan bagi pembaca.

Jambi, 18 Desember 2025

Sulfiyandi

F1E121083

DAFTAR ISI

HALAMAN PENGESAHAN	i
RINGKASAN	ii
RIWAYAT HIDUP	iii
PRAKATA	iv
DAFTAR ISI	vi
DAFTAR TABEL	viii
DAFTAR GAMBAR	ix
DAFTAR LAMPIRAN	xi
I. PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Batasan Penelitian	4
1.5 Manfaat Penelitian	4
II. TINJAUAN PUSTAKA	5
2.1 Pengangguran	5
2.2 Indikator/Variabel Tingkat Pengangguran	6
2.3 Data Mining	12
2.4 Clustering	15
2.5 Elbow Method	23
2.6 Davies-Bouldin Index (DBI)	24
2.7 Silhouette Coefficient	25
2.8 Visualisasi Data	27
2.9 Penelitian Terdahulu	31
III. METODOLOGI PENELITIAN	35
3.1 Tempat dan Waktu Penelitian	35
3.2 Jenis Penelitian	35

3.3	Alat dan Bahan	36
3.4	Indikator/Variabel Penelitian.....	37
3.5	Tahapan Penelitian.....	38
3.6	Studi Literatur	39
3.7	Pengumpulan Data.....	40
3.8	Preprocessing Data.....	42
3.9	Implementasi K-Means	44
3.10	Evaluasi	51
3.11	Interpretasi Hasil.....	62
3.12	Visualisasi.....	63
IV.	HASIL DAN PEMBAHASAN.....	66
4.1	Package yang digunakan	66
4.2	Preprocessing Data.....	67
4.3	Proses K-Means Clustering.....	71
4.4	Interpretasi Hasil	84
4.5	Visualisasi	100
V.	KESIMPULAN DAN SARAN.....	108
5.1	Kesimpulan.....	108
5.2	Saran.....	108
	DAFTAR PUSTAKA	109
	LAMPIRAN	117

DAFTAR TABEL

Table 1. Penentuan Nilai Minimum dan Maksimum IPM	10
Table 2. Perbandingan Algoritma Clustering.....	21
Table 3. Penelitian Terdahulu	31
Table 4. Waktu Penelitian	35
Table 5. Variabel Utama	41
Table 6. Data Hasil Normalisasi tahun 2019	44
Table 7. Centroid Iterasi Pertama tahun 2019	45
Table 8. Hasil Clustering Iterasi Pertama tahun 2019.....	46
Table 9. Centroid baru Iterasi Kedua tahun 2019.....	48
Table 10. Hasil Iterasi kedua tahun 2019	48
Table 11. Centroid baru Iterasi Ketiga tahun 2019	49
Table 12. Hasil Iterasi Ketiga tahun 2019	49
Table 13. Centroid baru Iterasi Ke-empat tahun 2019.....	50
Table 14. Hasil Iterasi Ke-empat tahun 2019	50
Table 15. Scatter Tiap Cluster tahun 2019.....	54
Table 16. Jarak antar centroid ($M_{i,j}$) tahun 2019	55
Table 17. Rasio Antar Cluster ($R_{ij} = (S_i + S_j) / M_{ij}$) tahun 2019	56
Table 18. Nilai Maksimum per Cluster (D_i) tahun 2019	57
Table 19. Hasil Perhitungan $a(i)$, $b(i)$, $s(i)$ tahun 2019	61
Table 20. Identitas Cluster tahun 2019–2022	85
Table 21. Identitas Cluster tahun 2023.....	86
Table 22. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2019.....	87
Table 23. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2020.....	89
Table 24. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2021.....	92
Table 25. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2022.....	94
Table 26. Hasil Pusat Cluster K-Means $k=3$ Data Tahun 2023.....	96

DAFTAR GAMBAR

Gambar 1. Persentase (TPT) Di Indonesia	7
Gambar 2. Bidang Ilmu Data Mining.....	13
Gambar 3. Tahapan <i>Knowledge Discovery in Database</i> (KDD)	14
Gambar 4. Diagram Alir dari Algoritma Clustering K-Means	23
Gambar 5. Metode Visualisasi Data.....	27
Gambar 6. Contoh Bar Chart Vertikal	28
Gambar 7. Contoh Bar Chart Horizontal	29
Gambar 8. Contoh Line Chart	29
Gambar 9. Contoh Pie Chart	30
Gambar 10. Contoh Map Chart.....	30
Gambar 11. Tahapan Penelitian.....	39
Gambar 12. Tampilan Beranda Web BPS Sumsel	41
Gambar 13. Tampilan Dataset di Excel	42
Gambar 14. Contoh Grafik Elbow	52
Gambar 15. Contoh Visualisasi Bar Chart Jumlah Kab/Kota per Cluster	64
Gambar 16. Boxplot distribusi tiap fitur berdasarkan cluster	64
Gambar 17. Contoh Visualisasi Map	65
Gambar 18. Data Awal tahun 2019.....	68
Gambar 19. Missing Values tahun 2019	69
Gambar 20. Seleksi Variabel tahun 2019	70
Gambar 21. Normalisasi Z-Score tahun 2019.....	71
Gambar 22. Grafik Elbow tahun 2019.....	72
Gambar 23. Grafik Elbow tahun 2020.....	72
Gambar 24. Grafik Elbow tahun 2021.....	73
Gambar 25. Grafik Elbow tahun 2022.....	73
Gambar 26. Grafik Elbow tahun 2023.....	74
Gambar 27. Evaluasi DBI dan Silhouette tahun 2019	75
Gambar 28. Evaluasi DBI dan Silhouette tahun 2020	75
Gambar 29. Evaluasi DBI dan Silhouette tahun 2021	75
Gambar 30. Evaluasi DBI dan Silhouette tahun 2022	76
Gambar 31. Evaluasi DBI dan Silhouette tahun 2023	76
Gambar 32. Hasil Clustering tahun 2019	78
Gambar 33. Hasil Clustering tahun 2020	78
Gambar 34. Hasil Clustering tahun 2021	78
Gambar 35. Hasil Clustering tahun 2022	79
Gambar 36. Hasil Clustering tahun 2023	79
Gambar 37. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2019	80

Gambar 38. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2020	80
Gambar 39. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2021	80
Gambar 40. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2022	80
Gambar 41. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2023	81
Gambar 42. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2019	81
Gambar 43. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2020	81
Gambar 44. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2021	81
Gambar 45. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2022	82
Gambar 46. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2023	82
Gambar 47. Daftar Anggota Cluster tahun 2019	82
Gambar 48. Daftar Anggota Cluster tahun 2020.....	83
Gambar 49. Daftar Anggota Cluster tahun 2021.....	83
Gambar 50. Daftar Anggota Cluster tahun 2022.....	84
Gambar 51. Daftar Anggota Cluster tahun 2023.....	84
Gambar 52. Visualisasi Barchart tahun 2019.....	100
Gambar 53. Visualisasi Boxplot tahun 2019	101
Gambar 54. Visualisasi Peta tahun 2019	101
Gambar 55. Visualisasi Peta tahun 2020	102
Gambar 56. Visualisasi Peta tahun 2021	103
Gambar 57. Visualisasi Peta tahun 2022	104
Gambar 58. Visualisasi Peta tahun 2023	105

DAFTAR LAMPIRAN

Lampiran 1. Dataset Pengangguran tahun 2019-2023	117
Lampiran 2. Package dan source Anaconda Navigator	118

I. PENDAHULUAN

1.1 Latar Belakang

Pengangguran menjadi salah satu bagian dari permasalahan utama dalam negara berkembang. Pengangguran di negara berkembang seperti Indonesia dapat disebabkan oleh beberapa faktor, diantaranya laju pertumbuhan penduduk yang tinggi, ketersediaan lapangan pekerjaan yang tidak berimbang, ketidaksiapan penduduk usia produktif dalam menghadapi pesatnya kemajuan teknologi, tingkat pendidikan, perubahan struktur perekonomian, dan besaran upah (Priastiwi & Herniawati, 2019). Pengangguran adalah suatu nilai yang menunjukkan jumlah penduduk usia kerja yang sedang mencari pekerjaan, atau sedang mempersiapkan usaha, atau merasa tidak mungkin mendapatkan pekerjaan, atau sudah punya pekerjaan tetapi belum memulai bekerja (Sutris et al., 2023).

Pengangguran menjadi ancaman masalah yang ditakuti dalam sebuah negara, ketika pengangguran jumlah meningkat, sumber daya manusia yang akan terbuang sia-sia, akan mengarah pada penurunan tingkat pendapatan yang dihasilkan oleh Masyarakat (Arifatul Ulya et al., 2023). Rendahnya tingkat pertumbuhan penciptaan lapangan kerja untuk menampung tenaga kerja menyebabkan munculnya masalah baru di suatu daerah seperti; menurunnya tingkat kesejahteraan, produktivitas dan pendapatan masyarakat, sehingga berdampak pada kemiskinan, kriminalitas, dan ketimpangan standar hidup. Oleh karena itu, penting untuk menggali pengetahuan lebih dalam dari data pengangguran sebagai dasar pengambilan keputusan dan penentuan kebijakan oleh pemerintah mengantisipasi munculnya masalah baru akibat pengangguran di suatu daerah (Maliki et al., 2022).

Badan Pusat Statistik (Badan Pusat Statistik, 2023) merilis data Tingkat Pengangguran Terbuka (TPT) pada tahun 2023. Dari grafik tingkat pengangguran terbuka menurut provinsi di Indonesia pada tahun 2023 dapat diketahui provinsi yang memiliki tingkat pengangguran terbuka tertinggi dan terendah di seluruh provinsi di Indonesia. BPS menjelaskan bahwa TPT tertinggi pada tahun 2023 terdapat pada provinsi Banten Sebesar 7,97% dan TPT terendah terdapat pada provinsi Sulawesi Barat sebesar 3.04%, dari grafik tersebut menampilkan perbedaan TPT di masing-masing provinsi dalam rentang satu tahun yang bergerak sangat dinamis dapat dilihat dari angka TPT provinsi tertinggi dan terendah tiap tahun berbeda-beda.

Provinsi Sumatera Selatan juga mengalami fluktuasi tingkat pengangguran dari tahun ke tahun. Misalnya, pada tahun 2020 TPT mengalami peningkatan

menjadi 5,51% dari sebelumnya 4,53% di tahun 2019. Kemudian pada tahun 2021 mengalami sedikit penurunan menjadi 4,98%, dilanjutkan dengan penurunan bertahap menjadi 4,63% pada 2022, dan akhirnya mencapai 4,11% pada tahun 2023 (Badan Pusat Statistik Sumatera Selatan, 2023). Perubahan ini menunjukkan bahwa analisis diperlukan untuk memahami pola pengangguran serta faktor-faktor yang mempengaruhinya. maka perlu adanya penelitian lebih mendalam yang berkaitan dengan tingkat pengangguran beserta indikator yang berpengaruh terhadap perubahan tingkat pengangguran. Salah satunya adalah dengan menggunakan metode pengelompokan. Metode pengelompokan yang sering digunakan dalam penelitian adalah clustering analysis (Akramunnisa & Fajriani, 2020).

Clustering merupakan metode dalam data mining yang berfungsi untuk mengelompokkan data berdasarkan kemiripan karakteristiknya. Salah satu algoritma yang sering digunakan adalah K-Means (Gustientiedina et al., 2019). Metode clustering atau pengelompokan data memiliki tujuan untuk membagi dataset menjadi beberapa kelompok berdasarkan kesamaan variabel atau atribut. Dimana data dikelompokkan berdasarkan pusat cluster (*centroid*) yang paling dekat dengan data tersebut (Aldino et al., 2021). Sedangkan pada metode K-Means bertujuan untuk menstrukturkan data dengan meningkatkan kesamaan data dalam kelompok yang ditentukan dan mengurangi kesamaan data antar cluster (Aytaç, 2020). Dengan menggunakan teknik ini, kita dapat mengidentifikasi pola-pola yang tersembunyi dalam data, sehingga dapat membantu dalam pengambilan keputusan dan memahami karakteristik data yang sedang dianalisis (Kurnia et al., 2019).

Beberapa penelitian terdahulu menunjukkan bahwa data mining dapat digunakan dengan baik dalam mengelompokkan Tingkat pengangguran. Penelitian yang dilakukan oleh (Tanjung et al., 2021) dalam jurnal yang berjudul “Penerapan Metode K-Means Pada Pengelompokan Pengangguran Di Indonesia” menunjukkan hasil diperoleh 13 provinsi dengan cluster tinggi yang menjadi pusat perhatian bagi pemerintah untuk memperluas lapangan pekerjaan untuk pengangguran pada provinsi tersebut. Penelitian dengan judul “Pengelompokan Kabupaten/Kota Berdasarkan Indikator Tingkat Pengangguran Menggunakan Algoritma K-Means Clustering (Studi Kasus: Provinsi Jawa Barat)” yang dilakukan oleh (Putrie & Sanjaya, 2021) dengan menunjukkan hasil terdapat 18 Kabupaten/Kota dengan rata-rata pengangguran paling rendah, cluster 1 (kedua) terdapat 6 Kabupaten/Kota dengan rata-rata pengangguran rendah, cluster 2 (ketiga) terdapat 1 Kabupaten dengan rata-rata pengangguran tinggi dan cluster 3 (keempat) terdiri dari 2 Kota dengan rata-rata pengangguran sedang.

Algoritma K-Means dipilih dalam penelitian ini karena kesesuaiannya dengan karakteristik data yang digunakan, yaitu data numerik dari 17 kabupaten/kota di Provinsi Sumatera Selatan selama periode 2019 hingga 2023, yang mencakup indikator Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM). K-Means merupakan metode *unsupervised learning* yang sederhana, efisien secara komputasi, dan telah banyak digunakan dalam penelitian sosial ekonomi, terutama dalam segmentasi wilayah. Kelebihan algoritma ini adalah kemampuannya mengelompokkan data ke dalam cluster berdasarkan kemiripan karakteristik melalui perhitungan jarak Euclidean, serta hasil clustering yang dapat diinterpretasikan secara visual dan statistik melalui pusat cluster (centroid) tiap kelompok (M. Ikotun et al., 2023). Penentuan jumlah cluster optimal dalam penelitian ini dilakukan dengan bantuan metode *Elbow*, *Davies-Bouldin Index*, dan *Silhouette Coefficient* yang semakin memperkuat validitas hasil. Selain itu, algoritma ini cocok digunakan secara berulang untuk masing-masing tahun, sehingga sangat relevan untuk menganalisis pola dan perubahan tingkat pengangguran dari tahun ke tahun di wilayah Provinsi Sumatera Selatan. Dengan mengidentifikasi cluster wilayah berdasarkan kemiripan indikator pengangguran, hasil penelitian ini diharapkan dapat memberikan dasar ilmiah bagi pemerintah daerah dalam merumuskan kebijakan yang lebih tepat sasaran.

Oleh karena itu, dalam penelitian ini clustering akan dilakukan setiap tahun dari 2019-2023, kemudian hasil clustering dari tiap tahun akan dibandingkan. Pendekatan ini bertujuan untuk mengidentifikasi bagaimana pola perubahan tingkat pengangguran terjadi di Sumatera Selatan dari waktu ke waktu. Dengan membandingkan hasil clustering tiap tahun, dapat diketahui apakah suatu daerah mengalami perbaikan, stagnasi, atau justru memburuk dalam hal pengangguran. Berdasarkan permasalahan yang dijelaskan di atas, maka penelitian ini mengangkat judul “ANALISIS KLUSTER TINGKAT PENGANGGURAN MENGGUNAKAN ALGORITMA K-MEANS (STUDI KASUS: PROVINSI SUMATERA SELATAN)”.

1.2 Rumusan Masalah

Rumusan masalah dari penelitian ini adalah sebagai berikut:

1. Bagaimana mengimplementasikan algoritma K-Means untuk clustering tingkat pengangguran di Provinsi Sumatera Selatan setiap tahunnya dari 2019-2023?

2. Bagaimana pola perubahan cluster tingkat pengangguran di Provinsi Sumatera Selatan dari tahun ke tahun?
3. Berapa jumlah cluster yang optimal pada tingkat pengangguran di Provinsi Sumatera Selatan?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Mengimplementasikan algoritma K-Means dalam melakukan clustering tingkat pengangguran di Provinsi Sumatera Selatan setiap tahun dari 2019-2023.
2. Menganalisis perubahan cluster tingkat pengangguran dari tahun ke tahun untuk memahami tren yang terjadi.
3. Mengidentifikasi jumlah cluster optimal tingkat pengangguran di Provinsi Sumatera Selatan.

1.4 Batasan Penelitian

Batasan masalah dari penelitian ini adalah sebagai berikut:

1. Data yang digunakan dalam penelitian ini diperoleh dari website resmi Badan Pusat Statistik Provinsi Sumatera Selatan.
2. Periode penelitian yang dianalisis adalah dari tahun 2019-2023.
3. Analisis kluster dilakukan setiap tahun secara terpisah, dan hasil clustering dibandingkan dari tahun ke tahun.

1.5 Manfaat Penelitian

Manfaat dari penelitian ini adalah sebagai berikut:

1. Manfaat Teoritis
 - a. Penelitian ini berkontribusi dalam pengembangan ilmu data mining, khususnya dalam teknik clustering dengan algoritma K-Means.
 - b. Menyediakan referensi bagi penelitian selanjutnya terkait analisis pengangguran menggunakan metode clustering.
2. Manfaat Praktis
 - a. Memberikan wawasan bagi akademisi dan mahasiswa dalam memahami penerapan algoritma K-Means untuk analisis data sosial ekonomi.
 - b. Dapat digunakan sebagai bahan ajar dalam mata kuliah terkait analisis data dan data mining. Memberikan pemahaman yang lebih efektif untuk penanggulangan pengangguran.

II. TINJAUAN PUSTAKA

2.1 Pengangguran

Pengangguran adalah orang yang tidak bekerja sama sekali, sedang mencari pekerjaan, bekerja kurang dari dua hari selama seminggu, atau seseorang yang sedang berusaha mendapatkan pekerjaan yang layak (Wikipedia, 2024). Seseorang atau kelompok orang yang sedang tidak memiliki pekerjaan atau tidak memiliki penghasilan tetap dianggap sebagai pengangguran. Sedangkan angkatan kerja yang sedang berusaha mencari pekerjaan dan mempersiapkan suatu usaha bisa dikategorikan sebagai pengangguran terbuka (Muharni & Andriyanto, 2022). Pengangguran terbuka didefinisikan ketika seseorang yang termasuk dalam usia kerja sedang mencari pekerjaan, sedang mempersiapkan usaha, atau tidak mencari pekerjaan karena merasa tidak mungkin mendapatkan pekerjaan. Selain itu, pengangguran terbuka juga mencakup orang yang telah memiliki pekerjaan tetapi belum mulai bekerja (Wardah Bonitta & Primandari, 2024). Suatu masalah dalam sebuah daerah jika terdapat tingkat penganggurannya yang tinggi yang akan berdampak di bidang sosial maupun ekonomi (Kahfi, Umbara, et al., 2022). Lapangan pekerjaan yang sedikit untuk pelamar tenaga kerja akan mengakibatkan timbulnya isu-isu di suatu wilayah seperti penurunan tingkat kemakmuran, efisien kerja, dan penghasilan penduduk, yang pada gilirannya akan berpengaruh terhadap kemiskinan, tingkat kejahatan, dan disparitas standar hidup (Hendri Doni et al., 2023). Salah satu ukuran utama kesejahteraan ekonomi adalah tingkat pengangguran (Nurjanah et al., 2024).

Menurut (Adriyanto et al., 2020) pengangguran dapat dikelompokkan menjadi beberapa bagian:

- Pengangguran struktural adalah pengangguran yang terjadi karena adanya perubahan struktur perekonomian. Penduduk tidak mempunyai keahlian untuk memasuki sektor baru sehingga mereka menganggur.
- Pengangguran siklus adalah pengangguran yang terjadi karena menurunnya kegiatan perekonomian sehingga berkurangnya permintaan masyarakat (*agregat demand*).
- Pengangguran musiman adalah pengangguran yang terjadi karena adanya pergantian musim.
- Pengangguran teknologi adalah pengangguran karena adanya penggunaan alat-alat teknologi yang semakin modern yang menggantikan tenaga kerja manusia.

2.2 Indikator/Variabel Tingkat Pengangguran

Menurut (Saputri & Muttakin, 2022) Variabel Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM) merupakan indikator/variabel yang digunakan untuk mengukur tingkat pengangguran, karena indikator tersebut mencerminkan kondisi ketenagakerjaan, perekonomian daerah, serta kualitas hidup masyarakat yang saling berkaitan dalam menggambarkan tingkat pengangguran di suatu wilayah. Oleh karena itu, Mengacu pada penelitian yang akan dilakukan, peneliti menggunakan indikator tersebut untuk mengetahui pola perubahan cluster pengangguran di Provinsi Sumatera Selatan.

a. Tingkat Pengangguran Terbuka (TPT)

Tingkat Pengangguran Terbuka (TPT) merupakan persentase jumlah pengangguran terhadap total angkatan kerja, TPT adalah indikator yang digunakan untuk mengukur tenaga kerja yang tidak terserap oleh pasar kerja dan menggambarkan kurang termanfaatkannya pasokan tenaga kerja (BADAN PUSAT STATISTIK, 2025). Dengan kata lain, tingkat pengangguran dapat diartikan sebagai rasio antara jumlah penduduk yang bekerja dan mereka yang sedang mencari pekerjaan atau belum mendapatkan pekerjaan (Alifah & Imaningsih, 2023). Jumlah penduduk yang besar berimplikasi langsung terhadap peningkatan jumlah angkatan kerja. Semakin banyak penduduk usia produktif yang memasuki pasar tenaga kerja, semakin tinggi pula tekanan terhadap kemampuan ekonomi suatu wilayah dalam menyediakan lapangan pekerjaan yang memadai. (Dewi, 2020).

Rumus TPT sebagai berikut:

$$TPT = \frac{\text{Jumlah Pengangguran}}{\text{Jumlah angkatan kerja}} \times 100\% \quad (1)$$

Contoh:


Jumlah Pengangguran diprovinsi Sumsel tahun 2018 = 175.087 jiwa

Jumlah angkatan kerja diprovinsi Sumsel tahun 2018 = 4.138.957 jiwa

$$TPT = \frac{175.087}{4.138.957} \times 100\%$$

$$TPT = 0,423022 \times 100\% = 4,23\%$$

TPT 4,23% menunjukkan sumber daya manusia belum terserap dalam lapangan kerja.



Gambar 1. Persentase (TPT) Di Indonesia

b. Tingkat Partisipasi Angkatan Kerja (TPAK)

TPAK merupakan suatu perbandingan yang dilakukan pada jumlah angkatan kerja terhadap jumlah penduduk yang memasuki usia kerja, Angkatan kerja dibedakan kedalam dua kelompok yaitu kelompok kerja dan kelompok pengangguran yang sedang dalam proses pencarian pekerjaan, dan yang tergolong kedalam kelompok, bukan angkatan kerja yaitu orang yang sedang menempuh dunia persekolahan, pengurus rumah tangga, serta kelompok penerima pendapatan (Maulana et al., 2023). TPAK mengindikasikan besarnya penduduk usia kerja yang aktif secara ekonomi (Abda Salsabila et al., 2022).

Rumus TPAK Sebagai Berikut:

$$TPAK = \frac{\text{Jumlah Angkatan Kerja}}{\text{Jumlah Penduduk Usia Kerja}} \times 100\% \quad (2)$$

Contoh:

Jumlah angkatan kerja diprovinsi Sumsel tahun 2018 = 4.138.957 jiwa

Jumlah penduduk usia kerja diprovinsi Sumsel tahun 2018 = 5.673.255 jiwa

$$TPAK = \frac{4.138.957}{5.673.255} \times 100\%$$

$$TPAK = 0.729555 \times 100\% = 72,0\%$$

TPAK 72% menunjukkan pasokan tenaga kerja telah aktif dalam perekonomian.

c. Produk Domestik Regional Bruto (PDRB)

Produk Domestik Regional Bruto (PDRB) adalah salah satu ukuran penting dalam mengukur kesejahteraan ekonomi suatu wilayah atau daerah. PDRB menggambarkan nilai total produksi barang dan jasa dalam suatu wilayah dalam periode tertentu, biasanya dalam setahun. PDRB mencakup semua jenis kegiatan ekonomi yang terjadi di wilayah tersebut, termasuk kegiatan sektor pertanian, perikanan, industri, perdagangan, jasa, dan sektor lainnya. PDRB juga dapat dibagi menjadi beberapa sektor ekonomi seperti sektor pertanian, industri, dan jasa. PDRB digunakan sebagai salah satu indikator penting dalam mengukur pertumbuhan ekonomi suatu wilayah. Dengan melihat perubahan PDRB dari tahun ke tahun, dapat dilihat apakah suatu wilayah mengalami pertumbuhan atau stagnasi ekonomi (Imelda et al., 2021).

Rumus PDRB sebagai berikut:

1. Pendekatan Produksi

Menghitung nilai tambah bruto dari seluruh sektor ekonomi.

$$PDRB = \sum (Nilai Tambah Bruto Tiap Sektor) \quad (3)$$

2. Pendekatan Pendapatan

Menghitung jumlah pendapatan yang diterima oleh faktor-faktor produksi.

$$PDRB = Upah + Sewa + Bunga + Laba + Pajak Tidak Langsung - Subsidi \quad (4)$$

3. Pendekatan Pengeluaran

Menghitung total pengeluaran akhir seluruh pelaku ekonomi.

$$PDRB = C + I + G + (X - M) \quad (5)$$

Keterangan:

- C : Konsumsi Rumah Tangga
- I : Investasi atau pembentukan modal tetap bruto
- G : Pengeluaran pemerintah
- X : Ekspor barang dan jasa antar daerah
- M : Impor barang dan jasa antar daerah

Contoh:

1. Pendekatan Produksi

Pendekatan ini menjumlahkan seluruh nilai tambah bruto (NTB) dari berbagai sektor ekonomi seperti sektor ekonomi Pertanian, Kehutanan, dan

Perikanan, Industri Pengolahan, Konstruksi, Perdagangan Besar dan Eceran, Transportasi serta Pergudangan.

Total PDRB (ADBH)

$$PDRB = 25,000.00 + 20,000.00 + 15,000.00 + 6,000.00 = 86,000.00$$

PDRB = 86,000.00 miliar

2. Pendekatan Pendapatan

Pendekatan ini menjumlahkan seluruh pendapatan yang diterima oleh faktor-faktor produksi seperti Komponen Pendapatan Upah dan Gaji, Sewa Tanah dan Bangunan, Bunga Modal, Laba Usaha, Pajak Tidak Langsung, dan Subsidi.

Total PDRB (ADBH)

$$PDRB = 35,000.00 + 3,000.00 + 5,000.00 + 20,000.00 + 8,000.00 - 1,000.00 = 70,000.00$$

PDRB = 70.000 (miliar)

3. Pendekatan Pengeluaran

Pendekatan ini menghitung PDRB berdasarkan total pengeluaran akhir seluruh pelaku ekonomi seperti Konsumsi rumah tangga, Investasi/ Pembentukan Modal Tetap Bruto, Pengeluaran pemerintah, Ekspor antar daerah, Impor antar daerah.

Total PDRB (ADBH)

$$PDRB = 35,000.00 + 3,000.00 + 5,000.00 + 20,000.00 + 8,000.00 - 1,000.00 = 70,000.00$$

PDRB = 70,000.00 miliar

PDRB 70,000.00 miliar menunjukkan kemampuan produksi dan aktivitas ekonomi dalam setahun.

d. Indeks Pembangunan Manusia (IPM)

Keberhasilan dalam mencapai peningkatan kualitas manusia bisa diukur dengan peningkatan Indeks Pembangunan Manusia (IPM), yang merupakan indikator yang menandakan tercapainya kenaikan di bidang ekonomi, pendidikan serta Kesehatan (Mahroji, 2019). Pengertian dari Pembangunan Manusia (IPM) adalah indikator yang menggabungkan komponen indeks pendapatan, kesehatan, dan pendidikan, merupakan indikator gabungan digunakan untuk mengevaluasi kualitas sumber daya manusia dan metode peningkatan kesejahteraan Masyarakat (Aulia et al., 2024). Indeks Pembangunan Manusia (IPM) berpengaruh terhadap tingkat pengangguran dengan yang terjadi di keadaan sebenarnya Indeks Pembangunan Manusia (IPM) yang setiap tahunnya

meningkat tetapi kurangnya lapangan pekerjaan yang tersedia sehingga masih tingginya tingkat pengangguran yang ada (Diaz Danindra et al., 2022).

Menurut (Badan Pusat Statistik, 2023) IPM merupakan indikator penting untuk mengukur keberhasilan dalam upaya membangun kualitas hidup manusia (masyarakat/penduduk). Untuk melihat capaian IPM antar wilayah dapat dilihat melalui pengelompokan IPM ke dalam beberapa kategori, yaitu:

- $IPM < 60$ (rendah) Kondisi ini menunjukkan bahwa pembangunan manusia di wilayah tersebut masih tertinggal. Akses terhadap pendidikan, kesehatan, dan standar hidup relatif terbatas.
- $60 \leq IPM < 70$ (sedang) Kondisi ini menunjukkan bahwa pembangunan manusia mulai berkembang, namun masih memerlukan peningkatan terutama dalam mutu pendidikan dan kesejahteraan ekonomi.
- $70 \leq IPM < 80$ (tinggi) Kondisi ini menunjukkan bahwa kualitas sumber daya manusia sudah baik, dengan tingkat pendidikan, kesehatan, dan kesejahteraan yang relatif merata.
- $IPM \geq 80$ (sangat tinggi) Kondisi ini menunjukkan bahwa pembangunan manusia di wilayah tersebut sudah sangat maju, penduduk memiliki akses luas terhadap layanan pendidikan, kesehatan, dan standar hidup yang tinggi.

Pengelompokan ini bertujuan untuk mengorganisasikan wilayah-wilayah menjadi kelompok-kelompok yang sama dalam hal pembangunan manusia. Semakin tinggi nilai IPM suatu negara/daerah, menunjukkan pencapaian pembangunan manusianya semakin baik.

Rumus IPM sebagai berikut:

1. Normalisasi Tiap Indikator

Masing-masing indikator diubah menjadi indeks dengan rumus:

$$Index\ Dimensi = \frac{Nilai\ Aktual - Nilai\ Minimum}{Nilai\ Maksimum - Nilai\ Minimum} \quad (6)$$

Nilai minimum dan maksimum ditentukan oleh UNDP atau BPS (bukan dari data provinsi, tetapi nilai acuan internasional/nasional).

Contoh menurut BPS:

Table 1. Penentuan Nilai Minimum dan Maksimum IPM

Indikator	Nilai Minimum	Nilai Maksimum
AHH	20 tahun	85 tahun
HLS	0 tahun	18 tahun

RLS	0 tahun	15 tahun
PPP	Rp 1.000.000	Rp 25.000.000

Catatan:

AHH = Angka Harapan Hidup Saat Lahir

HLS = Harapan Lama Sekolah

RLS = Rata-rata Lama Sekolah

PPP = Pengeluaran Perkapita

2. Hitung Indeks Setiap Dimensi

- Indeks Kesehatan

$$I_{Kesehatan} = \frac{AHH - AHH_{min}}{AHH_{maks} - AHH_{min}} \quad (7)$$

- Indeks Pendidikan

$$I_{Pendidikan} = \sqrt{\left(\frac{RLS}{15}\right) \times \left(\frac{HLS}{18}\right)} \quad (8)$$

- Indeks Pengeluaran

$$I_{Pengeluaran} = \frac{\ln(Pengeluaran) - \ln(1.000.000)}{\ln(25.000.000) - \ln(1.000.000)} \quad (9)$$

3. Hitung IPM

Ketiga indeks kemudian digabungkan menggunakan rata-rata geometrik:

$$IPM = (I_{Kesehatan} \times I_{Pendidikan} \times I_{Pengeluaran})^{1/3} \times 100 \quad (10)$$

Contoh:

Misal suatu daerah memiliki data:

AHH = 70 tahun

RLS = 10 tahun

HLS = 14 tahun

Pengeluaran Per Kapita = RP 12.000.000

Langkah-Langkah:

- Indeks Kesehatan

$$I_{Kesehatan} = \frac{70 - 20}{85 - 20} = 0,769$$

- Indeks Pendidikan

$$I_{Pendidikan} = \sqrt{\left(\frac{10}{15}\right) \times \left(\frac{14}{18}\right)} = \sqrt{0,6667 \times 0,7778} = 0,720$$

- Indeks Pengeluaran

$$I_{\text{Pengeluaran}} = \frac{\ln(12.000.000) - \ln(1.000.000)}{\ln(25.000.000) - \ln(1.000.000)} = 0,777$$

Hitung IPM

$$IPM = (0,769 \times 0,720 \times 0,777)^{\frac{1}{3}} \times 100 = 75,2$$

IPM = 75,2 %

IPM sebesar 75.2 % sehingga termasuk dalam kategori tinggi, Kondisi ini menunjukkan bahwa kualitas sumber daya manusia sudah baik, dengan tingkat pendidikan, kesehatan, dan kesejahteraan yang relatif merata.


2.3 Data Mining

Data mining mulai ada sejak 1990-an sebagai cara yang benar dan tepat untuk mengambil pola dan informasi yang digunakan untuk menemukan hubungan antara data untuk melakukan pengelompokkan ke dalam satu atau lebih cluster sehingga objek-objek yang berada dalam satu cluster akan mempunyai kesamaan yang tinggi antara satu dengan lainnya (Dongga et al., 2023). Data mining adalah sekumpulan teknik untuk menemukan pengetahuan yang sebelumnya tidak diketahui dalam basis data yang besar. Pola yang ditemukan tersebut bisa digunakan untuk membantu pengambilan sebuah keputusan (Utami & Paramitha, 2021). Dengan kata lain Data Mining merupakan sebuah proses pengumpulan atau pemrosesan data dengan tujuan untuk mengekstraksi informasi darinya. Saat mengumpulkan dan mengekstrak informasi, kita dapat menggunakan perangkat lunak yang menggunakan perhitungan statistik dan teknologi kecerdasan buatan (AI) (Kusuma Arum et al., 2024).

Secara garis besar, data mining dapat dikelompokkan menjadi 2 kategori utama, yaitu:

1. *Descriptive mining*, yaitu proses untuk menemukan karakteristik penting dari data dalam satu basis data. Teknik data mining yang termasuk *descriptive mining* adalah *clustering*, *asosiation*, dan *sequential mining*.
2. *Predictive*, yaitu proses untuk menemukan pola dari data dengan menggunakan beberapa variable lain di masa depan. Salah satu teknik yang terdapat dalam *predictive mining* adalah *klasifikasi*.

Secara sederhana data mining biasa dikatakan sebagai proses penyaring atau “*menambang*” pengetahuan dari sejumlah data yang besar.



Gambar 2. Bidang Ilmu Data Mining

Sumber: (Armayani et al., 2021)

Data Mining dibagi menjadi beberapa kelompok berdasarkan tugas yang dapat dilakukan (Larose & Larose, 2015), yaitu:

- **Deskripsi (*Description*)**
Terkadang peneliti dan analis secara sederhana ingin mencoba mencari cara untuk menggambarkan pola dan kecenderungan yang terdapat dalam data. Deskripsi dari pola dan kecenderungan sering memberikan kemungkinan penjelasan untuk suatu pola atau kecenderungan.
- **Estimasi (*Estimation*)**
Estimasi hampir sama dengan klasifikasi, kecuali variabel target estimasi lebih ke arah numerik daripada ke arah kategori. Model dibangun menggunakan record lengkap yang menyediakan nilai dari variabel target sebagai nilai prediksi.
- **Prediksi (*Prediction*)**
Prediksi hampir sama dengan *klasifikasi* dan *estimasi*, kecuali bahwa dalam prediksi nilai dari hasil akan ada di masa datang.
- **Klasifikasi (*Classification*)**
Dalam klasifikasi, terdapat target variable kategori. Sebagai contoh, penggolongan pendapatan dapat dipisahkan dalam tiga kategori, yaitu pendapatan tinggi, pendapatan sedang, dan pendapatan rendah.


- Pengklasteran (*Clustering*)

Pengklasteran adalah metode pengelompokan catatan (record) atau pengamatan berdasarkan atribut yang serupa, membentuk kelas-kelas objek yang memiliki kemiripan. Sebuah cluster sendiri merupakan kumpulan catatan yang karakteristiknya mirip satu sama lain, namun berbeda signifikan dengan catatan di cluster lainnya.

- Asosiasi (*Association*)

Tugas asosiasi dalam Data Mining adalah menemukan atribut yang muncul dalam satu waktu. Data mining sering juga disebut *knowledge discovery in database* (KDD) atau *pattern recognition*. KDD merupakan suatu proses komprehensif yang mencakup pengumpulan dan pemanfaatan data historis untuk mengeksplorasi keteraturan, pola, atau korelasi yang ada dalam kumpulan data berukuran besar, yang pada akhirnya mengarah pada penemuan informasi baru yang bermanfaat. Sementara itu, istilah *pattern recognition* atau pengenalan pola, memiliki tujuan spesifik untuk menggali pengetahuan yang tersembunyi di dalam tumpukan data yang sedang dianalisis atau dihadapi (Rais et al., 2021).

Adapun tahapan yang dilakukan berdasarkan kepada *Knowledge Discovery Data* (KDD) adalah sebagai berikut:



Gambar 3. Tahapan *Knowledge Discovery in Database* (KDD)

Sumber: (Wibowo & Sasongko, 2022)

a. *Data Selection*

Proses ini bertujuan untuk membuat himpunan data target, pemilihan himpunan data, atau memfokuskan pada subset variabel atau sampel data, dimana penemuan (*discovery*) akan dilakukan. Pemilihan (*seleksi*) data dari sekumpulan data operasional perlu dilakukan sebelum tahap penggalian informasi dalam KDD dimulai. Data hasil seleksi yang akan digunakan untuk

proses data mining, disimpan dalam suatu berkas, terpisah dari basis data operasional.

b. Preprocessing

Dalam proses preprocessing data, dilakukan pembersihan data dari *missing value* dan *outlier*. Selain itu proses lainnya adalah cleaning mencakup antara lain membuang duplikasi data, memeriksa data yang inkonsisten, dan memperbaiki kesalahan pada data, seperti kesalahan cetak (*tipografi*).

c. Transformation

Untuk menentukan variabel target dan peubah dilakukan pada tahap ini. Pencarian fitur-fitur yang berguna untuk mempresentasikan data bergantung kepada goal yang ingin dicapai. Ini merupakan proses transformasi pada data yang telah dipilih, sehingga data tersebut sesuai untuk proses data mining. Proses ini merupakan proses kreatif dan sangat tergantung pada jenis atau pola informasi yang akan dicari dalam basis data.

d. Data Mining

Proses dari data mining adalah merupakan proses dari proses KDD itu sendiri. Proses dalam *discovery knowledge* bisa dilakukan dengan cara misalnya *klasifikasi*, *regresi*, *clustering*, dll. Pemilihan algoritma data mining untuk pencarian (*searching*), Proses Data mining yaitu proses mencari pola atau informasi menarik dalam data terpilih dengan menggunakan teknik atau metode tertentu. Teknik, metode, atau algoritma dalam data mining sangat bervariasi. Pemilihan metode atau algoritma yang tepat sangat bergantung pada tujuan dan proses KDD secara keseluruhan.

e. Interpretation/Evaluation

Penerjemahan pola-pola yang dihasilkan dari proses data mining merupakan tahap penting dalam memperoleh pemahaman yang lebih mendalam terhadap data. Pola informasi yang diperoleh perlu disajikan dalam bentuk yang mudah dipahami oleh pihak yang berkepentingan. Tahap ini juga merupakan bagian dari proses Knowledge Discovery in Database (KDD) yang mencakup kegiatan untuk memeriksa apakah pola atau informasi yang ditemukan sesuai atau bertentangan dengan fakta maupun hipotesis yang telah ada sebelumnya.

2.4 Clustering

Clustering adalah salah satu teknik analisa data mining (Sanjaya & Fitriyani, 2019). Clustering merupakan suatu proses pengelompokkan record suatu, observasi, atau mengelompokkan kelas yang memiliki kesamaan objek (Sindi et al., 2020). Cara kerjanya adalah dengan memisah beberapa kelompok data yang memiliki ciri khas masing-masing, Dimana objeknya bisa berupa

manusia, peristiwa dan lainnya yang didistribusikan ke dalam sebuah kelompok sehingga menjadi beberapa tingkatan yang akan saling terhubung diantara cluster, lemah dan kuatnya di antara anggota cluster yang berbeda akan terlihat pada anggota cluster yang sama (Amrullah et al., 2019).

Clustering adalah metode dari bagian pendekatan *unsupervised learning* (Fajriana, 2021). *Unsupervised learning* merupakan metode yang dapat diimplementasikan pada pembelajaran mesin yang mana hanya membutuhkan data saja sebagai inputan. Jenis dari teknik ini yaitu *clustering* dan *dimensionality reduction*. Cara kerja clustering yaitu dengan cara mengelompokkan bentuk data/*behavior* datanya berdasarkan kemiripan dari data sedangkan *dimensionality reduction* bertujuan untuk membuat data menjadi data yang dapat divisualisasikan. Adapun *Supervised learning* dimana jenis dari teknik *supervised learning* yaitu *classification* dan *regression*. *Classification* yang mana bentuk labelnya yaitu kategori sedangkan *regression* yang mana bentuk labelnya yaitu bilangan real. Tujuan dari teknik ini yaitu agar bisa memberikan target terhadap keluaran dengan cara membandingkan pada pengalaman belajar dari masa lalu (Fahmi, 2023). *Supervised learning* dan *unsupervised learning* merupakan teknik dalam *Machine Learning* (ML), *Machine learning* adalah bagian dari kecerdasan buatan (AI) yang membantu komputer atau mesin pengajaran belajar dari semua data sebelumnya dan membuat keputusan yang cerdas. Kerangka kerja *machine learning* memerlukan penangkapan dan pemeliharaan serangkaian informasi yang kaya dan mengubahnya menjadi basis pengetahuan terstruktur untuk penggunaan yang berbeda diberbagai bidang, salah satunya di bidang Pendidikan (Fathurohman, 2021).

Clustering dapat dikelompokkan menjadi beberapa jenis yaitu (Choirun Nafis Afisah et al., 2019):

A. Hierarchical

Hierarchical clustering adalah analisis pengelompokan yang hasil pengelompokannya disajikan secara berjenjang dari n , $(n-1)$ sampai terdapat satu kelompok. Metode *hierarchical clustering* secara umum dibagi menjadi dua yaitu metode *agglomerative* dan *divisive*. Terdapat beberapa teknik metode *agglomerative* diantaranya metode *single linkage*, *complete linkage*, *average linkage*, dan *ward's* (Johnson, 2007).

1. Single Linkage

Single Linkage adalah pengelompokan yang dilakukan dengan menggabungkan pengamatan objek yang memiliki kesamaan terdekat. Jika ditentukan matriks jarak $D = \{d_{ij}\}$ dan objek koresponden adalah U dan V , jadi

untuk membentuk cluster (UV), maka harus ditentukan jarak antara (UV) dengan cluster lain misalnya W , dengan cara sebagai berikut.

$$d_{(UV)W} = \min \{d_{UW}, d_{VW}\} \quad (11)$$

Keterangan:

d_{UW} = Jarak antara U dan W

d_{VW} = Jarak antara V dan W

$d_{(UV)W}$ = Jarak minimum antara objek UV dan W

2. Complete Linkage

Complete linkage merupakan bagian dari metode *Hierarchical clustering* dimana pengelompokkannya dengan mencari jarak paling jauh diantara pengamatan suatu objek. Rumus yang digunakan untuk menentukan jarak antara (UV) dengan cluster lainnya adalah seperti berikut (Butar Butar, 2023).

$$d_{(uv)k} = \max \{d_{uk}, d_{vk}\} \quad (12)$$

Keterangan:

d_{UK} = Jarak antara objek U dan K

d_{VK} = Jarak antara objek V dan K

$d_{(UV)K}$ = Jarak paling maksimum antara objek UV dengan objek K

3. Average Linkage

Average linkage merupakan perlakuan antara dua cluster sebagai jarak rata-rata antara semua pasangan item dimana salah satu pasangan item milik masing-masing cluster. Dimulai dengan mencari matriks $D = \{dik\}$ untuk menentukan objek, misalnya U dan V , objek ini akan bergabung dalam cluster (UV). Rumus Jarak antara UV dan cluster W adalah sebagai berikut.

$$d_{(UV)W} = \frac{\sum_i \sum_k d_{ik}}{N_{(UV)}N_W} \quad (13)$$

Keterangan:

d_{ik} = Jarak antara objek i dalam cluster (UV) dan objek k dalam cluster W

$N_{(UV)}$ = Jumlah item dalam cluster (UV)

N_W = Jumlah item dalam cluster (W)

4. Ward's

Metode *Ward* merupakan bagian dari metode *Hierarchical clustering* dimana pengelompokkannya berdasarkan nilai *Sum of Squares Error* (SSE) yang terkecil dan dijadikan satu cluster. Cara ini lebih memperhatikan keragaman dari suatu data yaitu mencari keragaman yang paling kecil yang berada dalam satu cluster. Rumus yang digunakan untuk mencari SSE adalah seperti berikut.

$$SSE = \sum_{j=1}^n (\sum_{i=1}^{n_j} Z_{uv}^2 - \frac{1}{n_j} (\sum_{i=1}^{n_j} Z_{uv})^2) \quad (14)$$

Keterangan:

- Z_{UV} = Nilai objek ke- U pada kelompok ke- W
 n = Jumlah pada kelompok tiap tahap
 n_j = Jumlah kelompok ke- U pada kelompok ke- V

B. Non-hierarchical

Non-hierarchical adalah salah satu metode pengelompokan dimana objek akan dikelompokkan ke dalam k kelompok yang telah ditentukan sebelumnya (Prasetyo, 2012). Kemudian untuk metode dalam *non-hierarchical clustering* terdapat subclass yaitu *partition clustering*, *density based*, *grid base*, dll. Pendekatan *partition clustering* ini terdiri dari beberapa metode misalnya K-Means, K-Medoids, dll (Khabaza, 2022).

1. K-Means

K-Means merupakan bagian dari metode *hierarchical clustering* yang termasuk pada pendekatan partisi. Tujuannya adalah untuk mencari jumlah jarak yang paling kecil diantara suatu titik data. Penentuan jumlah cluster pada metode ini harus di inisialisasikan terlebih dahulu sebelum dilakukan pengelompokkan. Berikut adalah Langkah-langkahnya (Tempola & Assagaf, 2018).

- Inisialisasikan jumlah cluster yang akan dibentuk
- Memutuskan titik yang akan dijadikan centroid secara random
- Membuat keputusan disetiap titik yang ada dengan centroid paling dekat, setelah ditentukan paling dekat akan terbentuk cluster yang sudah diinisialisasikan
- cari varians dan ubah titik pusat baru ditiap clusternya
- lakukan iterasi titik pusat dari tiap cluster sampai centroid tidak berubah

2. K-Medoids

K-Medoids clustering atau disebut dengan istilah *Partitioning Around Medoids* adalah pengembangan dari metode k-means clustering. Salah satu kelebihan dari metode ini adalah mampu mengatasi adanya data yang diindikasikan sebagai outlier yang dapat mempengaruhi distribusi data yang sebenarnya. Tahapan dalam menggunakan metode k-medoids clustering ini adalah sebagai berikut (Nurkholik, 2022).

- Inisialisasikan jumlah cluster (k) yang akan dibentuk
- Memilih random medoid di awal sebanyak jumlah cluster (k)

- c. Mencari jarak dari setiap objek ke medoid awal, lalu mencari jarak terdekat dan jumlahkan total keseluruhannya.
- d. Iterasi dengan medoid yang baru
- e. Cari simpangan data
- f. Jika simpangan data kurang dari nol, maka lakukan Penggantian objek dengan membuat kumpulan k yang baru sebagai titik medoid
- g. Terus lakukan perulangan dari langkah yang ketiga sampai ke lima dan berhenti saat tidak adanya perubahan pada anggota medoid.

3. DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) adalah metode dalam *non-hierarchical* clustering yang masuk dalam pendekatan *Density Based* dan bertujuan untuk menemukan tingkat kepadatan yang paling tinggi. Dalam DBSCAN tidak mencari jumlah cluster terlebih dahulu, namun menentukan berapa jarak antar titik dalam satu cluster yang dijadikan sebagai tetangga atau disebut dengan (*Eps*) dan berapa banyak titik minimal yang harus ada dalam suatu cluster atau disebut dengan (*MinPts*) (Adha et al., 2021).

Tahapannya adalah sebagai berikut:

- a. Inisialisasikan nilai dari *MinPts* dan *Eps*
- b. Pemilihan titik awal secara random
- c. Menghitung jarak dari titik satu ke titik lain, dimana titiknya sudah dalam rentang jarak (*Eps*) yang sudah ditentukan diawal dengan menggunakan jarak *Euclidean*
- d. Maka akan terbentuk sebuah cluster dengan *Eps* dan *MinPts* yang diinisialisasikan Langkah 1
- e. Jika terdapat titik yang tidak memenuhi jarak (*Eps*) yang ditentukan tadi, maka akan dilanjutkan ke titik yang lain
- f. Kemudian lakukan terus perulangan langkah 3 sampai 4

Metode K-Means

Teknik Clustering K-Means merupakan salah satu prosedur dalam pemecahan masalah clustering sederhana yang bersifat tanpa arahan (*unsupervised*). Misalkan D adalah sebuah dataset dari n objek, dan k adalah jumlah cluster yang akan dibentuk, algoritma partisi mengatur objek-objek tersebut ke dalam partisi k ($k \leq n$), dimana setiap partisi menggambarkan sebuah cluster. Setiap cluster dibentuk untuk mengoptimalkan kriteria partisi, seperti fungsi perbedaan berdasarkan jarak, sehingga objek-objek di dalam sebuah cluster adalah mirip, sedangkan objek-objek pada cluster yang tidak selaras adalah tidak seperti dalam hal atribut dataset (Jusia & Irfan, 2019). Tujuannya adalah untuk mempartisi data menjadi suatu kelompok (Yang & Sinaga, 2019).

Clustering juga dapat diartikan metode segmentasi data yang diimplementasikan dalam beberapa bidang, di antaranya marketing, analisa masalah bisnis segmentasi pasar dan prediksi, pola dalam bidang computer vision, zonasi wilayah hingga identifikasi obyek dan pengolahan citra (Aditya et al., 2020).

Algoritma K-Means merupakan bagian dari metode clustering dengan teknik *unsupervised* yang mempartisi data kedalam dua atau lebih kelompok (Rahmawati & Faisal, 2019). K-means cukup populer dan banyak digunakan karena algoritma-nya sederhana (Syahputra, 2022). Algoritma K-Means merupakan salah satu algoritma *clustering* yang menggunakan pendekatan pembagian jarak (*distance-based partitioning*) dalam proses pengelompokan data. Keunggulan algoritma ini terletak pada kemudahannya untuk dipahami dan diterapkan, serta kemampuannya menghasilkan pengelompokan yang efektif. Oleh karena itu, algoritma K-Means banyak digunakan dalam berbagai bidang penelitian, khususnya yang berkaitan dengan analisis data numerik dan eksplorasi pola tersembunyi dalam data (DIng et al., 2021).

K-Means merupakan salah satu metode pengelompokan data non-hierarki (*partisi*) yang berfungsi untuk membagi sekumpulan data ke dalam dua kelompok atau lebih berdasarkan kemiripan karakteristik yang dimilikinya. Algoritma ini bekerja dengan mengukur kedekatan antar data menggunakan fungsi jarak tertentu, di mana jarak antar data umumnya dihitung menggunakan rumus Euclidean Distance. Setiap data akan dikelompokkan ke dalam cluster yang memiliki jarak terdekat dengan pusat kelompok atau centroid (Wahyudi et al., 2020). Hasil akhir dari proses ini berupa sejumlah kelompok data atau cluster yang memiliki kesamaan ciri atau pola tertentu. Algoritma K-Means memiliki beberapa keunggulan, antara lain mudah diimplementasikan, memiliki kompleksitas waktu dan ruang yang relatif kecil, serta efisien dalam proses komputasi. Selain itu, metode ini mampu menghasilkan pengelompokan yang optimal apabila data yang digunakan bersifat compact, hyperspherical, dan memiliki pemisahan antar fitur yang jelas (Selvi et al., 2022) Sifat efisien inilah yang membuat algoritma K-Means banyak digunakan dalam berbagai penelitian yang memerlukan proses klasifikasi atau pengelompokan berbasis data numerik dalam jumlah besar. Metode K-Means hanya dapat diterapkan pada variabel atau atribut numerik karena proses perhitungannya bergantung pada nilai jarak antar data. Dengan kata lain, algoritma ini bekerja dengan membagi data menjadi beberapa cluster berdasarkan kedekatan nilai antar objek, sehingga semakin kecil jarak antar data dalam satu cluster, semakin tinggi pula tingkat keseragaman data tersebut (Meliza & Susanti, 2024) Dengan karakteristik tersebut, K-Means menjadi salah satu metode yang paling banyak digunakan

dalam analisis data, termasuk pada penelitian yang melibatkan pengelompokan wilayah atau fenomena sosial ekonomi berdasarkan kesamaan indikator tertentu..

Table 2. Perbandingan Algoritma Clustering

Algoritma	Karakteristik	Kelebihan	Kekurangan
K-Means (Ulfah Siregar, 2022)	Berbasis centroid, membagi data ke dalam K cluster dengan meminimalkan jarak Euclidean.	Sederhana, cepat, efisien untuk dataset menengah-besar, hasil cluster kompak & mudah diinterpretasi	Sensitif terhadap pemilihan centroid awal, tidak cocok untuk data dengan bentuk cluster non-linier
K-Medoids (Ulvi & Ikhsan, 2024)	Mirip K-Means, tetapi menggunakan medoid (titik aktual) sebagai pusat cluster	Lebih robust terhadap <i>outlier</i> dibanding K-Means	Komputasi lebih lambat pada dataset besar
Hierarchical Clustering (Ramadhan et al., 2023)	Membentuk dendrogram dengan pendekatan agglomerative/divisive	Tidak perlu menentukan jumlah cluster di awal; bisa menggambarkan hubungan antar data	Tidak efisien untuk dataset besar, hasil sulit diubah setelah terbentuk
DBSCAN (Putri et al., 2021)	Berbasis kepadatan, membentuk cluster berdasarkan jarak & densitas	Dapat menemukan cluster berbentuk arbitrer dan mendeteksi <i>noise/outlier</i>	Sulit menentukan parameter (ϵ , MinPts); kurang efektif untuk data berdimensi tinggi

Berdasarkan tabel di atas, algoritma K-Means dinilai paling sesuai untuk digunakan dalam penelitian ini karena mampu membentuk kelompok data yang kompak dengan proses komputasi yang relatif cepat. Hal ini sangat mendukung

pengolahan data berukuran menengah, seperti indikator ketenagakerjaan pada tingkat kabupaten/kota di Provinsi Sumatera Selatan. Dibandingkan dengan algoritma lainnya, K-Means memiliki keunggulan dalam kesederhanaan implementasi serta efisiensi dalam mengolah data numerik, sehingga mampu menghasilkan hasil pengelompokan (*clustering*) yang optimal dan mudah diinterpretasikan. Dengan demikian, penggunaan algoritma K-Means diharapkan dapat membantu mengidentifikasi pola dan karakteristik wilayah di Provinsi Sumatera Selatan.

Menurut (Sianipar et al., 2020) Langkah untuk melakukan analisis metode K-Means adalah sebagai berikut:

1. Tentukan k sebagai jumlah cluster yang ingin dibentuk lalu tetapkan pusat cluster
2. Hitung jarak setiap data ke pusat cluster menggunakan persamaan *Euclidean distance*

$$d_{ik} = \sqrt{\sum_j^m (C_{ij} - C_{jk})^2} \quad (15)$$

Keterangan:

x_{ij} = Pusat cluster
 c_{jk} = Data indikator tingkat pengangguran
 d_{ik} = Jarak setiap objek

3. Melompokkan data ke dalam cluster yang dengan jarak yang paling pendek menggunakan persamaan

$$\text{Min} \sum_{k=1}^k d_{ik} = \sqrt{\sum_j^m (C_{ij} - C_{jk})^2} \quad (16)$$


4. Hitung pusat cluster yang baru menggunakan persamaan

$$C_{kj} = \frac{\sum_{i=1}^p x_{ij}}{p} \quad (17)$$

Dimana:

X_{ij} = Kluster ke- k
 p = Banyaknya anggota cluster ke- k .

5. Ulangi langkah 2 sampai dengan 4 hingga sudah tidak ada lagi data yang berpindah ke kluster yang lain.



Gambar 4. Diagram Alir dari Algoritma Clustering K-Means

Sumber: (Mayoana Fitri et al., 2023)

2.5 Elbow Method

Metode *Elbow* atau *siku* adalah metode penentuan jumlah kelompok yang tepat melalui persentasi hasil perbandingan antara jumlah cluster satu dengan jumlah cluster yang lain. Metode *Elbow* memberikan Gambaran penggunaan skor cluster dan menambah skor cluster sebagai model data dalam menentukan cluster terbaik. Optimasi nilai cluster (k) akan didapatkan dengan biaya yang digunakan (Ayu et al., 2019). Metode *Elbow* melakukan proses evaluasi dengan membandingkan hasil antara penjumlahan cluster yang akan membentuk suatu titik terakhir dan cluster nilai digunakan sebagai model data untuk cluster

terbaik. Hasil dari proses perhitungan digunakan untuk proses dalam membandingkan jumlah cluster (Sholeh & Aeni, 2023). Berikut merupakan definisi rumus fungsi dari biaya yang digunakan dalam algoritma K-Prototype:

$$SSE = \sum_{k=1}^k \sum_{i=1}^n ||Xi - Uk||^2 \quad (18)$$

Dimana:

Xi = Nilai atribut dari data ke i

Uk = Nilai atribut titik pusat kluster i

2.6 Davies-Bouldin Index (DBI)

Davies-Bouldin Index (DBI) juga disebut reliabilitas klasifikasi, indeks *Davies-Bouldin Index* (DBI) diperkenalkan oleh David L. Davies dan Donald W. Bouldin pada tahun 1979 didefinisikan sebagai rasio rata-rata jarak dalam cluster antar cluster untuk setiap cluster dengan cluster tetangga terdekatnya (Sopyan et al., 2022). Davies-Bouldin yaitu metode evaluasi internal yang menghitung ukuran evaluasi kelompok berdasarkan nilai kohesi dan separasi. Dalam pengelompokan, kohesi merupakan jumlah kedekatan data dengan centroid cluster yang diikutinya, sementara separasi berdasarkan pada jarak antara cluster centroid. cluster dengan jarak *intra-cluster* yang kecil dan jarak *antar-cluster* besar akan memiliki eksponen Davies-Bouldin yang rendah. Clustering yang menghasilkan himpunan cluster dengan *Davies-Bouldin Index* terkecil dianggap sebagai algoritma terbaik (Gustrianda & Mulyana, 2022).

Berikut langkah untuk mencari nilai DBI (Puji Astuti et al., 2022) :

1. Mencari nilai SSW (*Sum Of Square Between Cluster*) menggunakan rumus:

$$SSW_i = \frac{1}{mi} \sum_{j=i}^{mi} d(x_j, c_i) \quad (19)$$

Keterangan :

SSW = *Sum Of Square Within Cluster*

mi = Banyak data pada kelompok

xj = Data pada kelompok

ci = Titik pusat kelompok ke- i

$d(xj, cj)$ = Jarak data terhadap titik pusat

2. Mencari nilai SSB (*Sum Of Square Within Cluster*) menggunakan rumus:

$$SSB_{ij} = d(c_i, c_j) = \sqrt{(x_{ci} - x_{cj})^2 + (y_{ci} - y_{cj})^2} \quad (20)$$

Keterangan:

SSB = *Sum Of Square Between Cluster*

$d(c_i, c_j)$ = Jarak titik pusat satu dengan yang lain

3. Mencari nilai Rasio dengan persamaan berikut:

$$R_{ij} = \frac{SSW_i + SSW_j}{SSB_{ij}} \quad (21)$$

Keterangan:

R_{ij} = Nominal perbandingan kelompok i dan kelompok j

SSW_i = *Sum Of Square Within Cluster* ke i

SSW_j = *Sum Of Square Within Cluster* ke j

SSB_{ij} = *Sum Of Square Between Cluster* ke i dan j

4. Mencari nilai DBI (*Davies Bouldi Index*) dengan persamaan berikut:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{i \neq j} (R_{ij}) \quad (22)$$

Keterangan:

K = Banyak kelompok yang dipakai

R_{ij} = Rasio antar kelompok i dan kelompok j

Max = Perolehan rasio terbesar antar kelompok

2.7 Silhouette Coefficient

Metode ini merupakan metode evaluasi clustering yang menggabungkan metode cohesion dan separation. Cohession diukur dengan menghitung seluruh objek yang terdapat dalam sebuah cluster dan separation diukur dengan menghitung jarak rata-rata setiap objek dalam sebuah cluster dengan cluster terdekatnya (Paembonan & Abduh, 2021). Pengujian dilakukan setelah mencapai kovergensi 0 dimana hasil pengelompokan terakhir sama dengan pengelompokan sebelumnya. Dengan kata lain, tidak ada data yang berpindah cluster. Langkah dalam menghitung *Silhouette coefficient* dimulai dengan mencari jarak rata-rata data ke- i dengan semua data di cluster yang sama, disini diasumsikan bahwa data ke- i berada di cluster A . Rumus dari $a(i)$ ditulis dalam persamaan:

$$a(i) = \frac{1}{|A| - 1} \sum_{j \in A, j \neq i} d(i, j) \quad (23)$$

Dimana:

A = Banyaknya data di cluster A

Selanjutnya menghitung nilai $b(i)$ yang merupakan nilai minimum dari jarak rata-rata data ke- i dengan semua data di cluster berbeda. Diasumsikan bahwa cluster berbeda selain A adalah cluster C . Maka perhitungan jarak rata-rata data ke- i dengan semua data di cluster C ditulis sebagai berikut.

$$d(i, C) = \frac{1}{|C|} \sum_{j \in C}^k d(i, j) \quad (24)$$

Dimana:

C = Banyaknya data di cluster C

Setelah menghitung $d(i, C)$ untuk semua cluster $C \neq A$, selanjutnya memilih nilai jarak paling minimum sebagai nilai $b(i)$.

$$b(i) = \min_{C \neq A} d(i, j) \quad (25)$$

Jika cluster B memiliki nilai jarak minimum, maka $d(i, B) = b(i)$ yang disebut sebagai tetangga dari data ke- i dan merupakan cluster terbaik kedua untuk data ke- i setelah cluster A . Setelah $a(i)$ dan $b(i)$ diketahui, maka proses terakhir adalah menghitung *silhouette coefficient*.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i) - b(i)\}} \quad (26)$$

Nilai $s(i)$ berada diantara -1 dan 1, dimana setiap nilai diinterpretasi sebagai berikut:

$s(i) \ 1$ = data ke- i digolongkan dengan baik (dalam A)

$s(i) \ 0$ = data ke- i berada ditengah antara dua cluster (A dan B)

$s(i) \ -1$ = data ke- i digolongkan dengan lemah (dekat ke cluster B daripada A)

Nilai *silhouette* untuk keseluruhan data dengan jumlah cluster k , dapat didefinisikan sebagai $sil(k)$ yaitu rata-rata *silhouette value* untuk semua cluster yang dihitung dengan persamaan.

$$sil(c) = sil(k) \frac{1}{|k|} \sum_{i=1}^k sil(ci) \quad (27)$$

Dimana:

$Sil(k)$ = Nilai *silhouette* semua cluster

$|k|$ = Banyaknya cluster k


$Sil(ci)$ = Rata-rata nilai *silhouette*

2.8 Visualisasi Data

Visualisasi data yang efektif harus mampu menjelaskan secara memadai data yang disajikan dan menggugah rasa ingin tahu pembaca. Visualisasi ditujukan untuk khalayak yang lebih luas, membantu orang mengeksplorasi secara visual dan menemukan struktur, hubungan, dan konteks yang sulit didefinisikan agar dapat dengan cepat memahami, menafsirkan, dan memperoleh wawasan penting (Arista Putri et al., 2024).

Visualisasi Data yang baik diperlukan proses yang tepat, Berikut adalah proses visualisasi data (Madyatmadja et al., 2022).

- a. *Acquire*, pada proses ini data dikumpulkan dari berbagai sumber, baik dari internet maupun dari file penyimpanan.
- b. *Parse*, pada proses ini dilakukan pemberian struktur data dan pesan ke dalam data yang diolah.
- c. *Filter*, pada proses ini dilakukan pemilihan data dengan menghapus data yang tidak sesuai dengan tujuan awal.
- d. *Mine*, pada proses ini dilakukan analisis data mining sesuai tujuan awal. Proses ini bersifat pilihan.
- e. *Represent*, pada proses ini data dibuat kedalam bentuk elemen visual berupa bagan, grafik, dan peta.
- f. *Refine*, pada proses ini elemen visual diberikan grafik dasar dengan berbagai visual encoding. Proses ini bersifat pilihan.
- g. *Interact*, pada proses ini grafik statis menjadi grafik dinamis. Proses ini juga bersifat pilihan.




Gambar 5. Metode Visualisasi Data

Visualisasi data merupakan salah satu bentuk komunikasi informasi yang bertujuan untuk menyampaikan hasil pengolahan data secara lebih jelas, ringkas, dan mudah dipahami oleh pihak yang menerima informasi. Melalui visualisasi, data yang kompleks dapat disajikan dalam bentuk grafik, diagram, atau peta yang memudahkan pembaca dalam mengenali pola, tren, serta hubungan antar variabel. Visualisasi data juga berperan penting dalam mengkomunikasikan temuan dan wawasan kepada pemangku kepentingan yang mungkin tidak memiliki latar belakang analitis yang mendalam, sehingga mereka tetap dapat memahami inti dari hasil analisis yang disampaikan. Dengan demikian, keberhasilan suatu visualisasi data tidak hanya diukur dari keindahan tampilannya, tetapi juga dari sejauh mana informasi yang disajikan mampu diterima, dipahami, dan digunakan untuk mendukung pengambilan keputusan secara efektif. (Zahra et al., 2023).


Berikut ini merupakan beberapa contoh teknik visualisasi data yang umum digunakan (Priskilla et al., 2021):

1. Bar Chart

Grafik batang atau sering juga disebut histogram adalah grafik yang menyajikan data dalam bentuk batang baik secara vertikal maupun horizontal. Grafik batang menyajikan informasi mengenai perbedaan nilai dari beberapa entitas melalui perbedaan panjang, ukuran, dan warna. Grafik batang dapat disajikan secara vertikal maupun horizontal. Grafik batang vertikal digunakan untuk menampilkan data secara kronologis atau menampilkan data negatif di bawah sumbu x. Sedangkan grafik batang horizontal biasanya digunakan untuk menampilkan data dengan label kategori yang panjang.




Gambar 6. Contoh *Bar Chart Vertikal*



Gambar 7. Contoh *Bar Chart Horizontal*

2. Line Chart


Grafik garis merupakan jenis grafik yang menampilkan data dengan cara menghubungkan titik-titik data dalam periode waktu tertentu. Pada gambar memperlihatkan bahwa grafik garis terdiri dari sumbu X dan sumbu Y. Sumbu X biasanya digunakan untuk menunjukkan rentang waktu pengamatan sedangkan sumbu Y untuk menunjukkan nilai hasil pengamatan dari setiap waktu.



Gambar 8. Contoh *Line Chart*

3. Pie Chart


Diagram lingkaran digunakan untuk mempresentasikan proporsi data dari setiap klasifikasi yang ada dan membandingkannya berdasarkan besarnya. *Pie chart* digunakan untuk membuat perbandingan sebagian atau seluruh data. Penggunaan *pie chart* akan lebih baik apabila digunakan untuk kategori yang sedikit, yaitu sekitar 5 bagian.



Gambar 9. Contoh *Pie Chart*

4. Map Chart

Grafik peta merupakan salah satu jenis grafik yang sekarang banyak digunakan. Tampilan visual yang menarik karena menggunakan peta dalam merepresentasikan data. Dalam grafik ini, penggunaan map tidak hanya untuk menunjukkan sebuah lokasi, melainkan menunjukkan nilai data pada lokasitertentu dalam sebuah area pada peta. Grafik ini sangat cocok digunakan untuk menunjukkan persebaran data pada suatu wilayah. Sebagai contoh persebaran jumlah mahasiswa baru di Indonesia.



Gambar 10. Contoh *Map Chart*

2.9 Penelitian Terdahulu

Penelitian terdahulu yang berkaitan dengan penelitian ini adalah sebagai berikut:

Table 3. Penelitian Terdahulu

No	Penulis	Judul Penelitian	Metode	Hasil
1	(Tanjung et al., 2021)	Penerapan Metode K-Means Pada Pengelompokan Pengangguran Di Indonesia	K-Means	Menggunakan tools Rapidminer 5.3 diperoleh hasil yang sama dengan analisis perhitungan metode dimana diperoleh 13 provinsi dan Jumlah record yang digunakan sebanyak 34 provinsi dengan menghasilkan 2 cluster yakni cluster tinggi sebanyak 13 provinsi dan cluster rendah sebanyak 21 provinsi.
2	(Arifatul Ulya et al., 2023)	Pengelompokan Tingkat Pengangguran Terbuka di Jawa Tengah Menggunakan Metode K – Means Clustering	K-Means	Menghasilkan pusat cluster, jarak dan cluster yang sama serta tidak terjadi perubahan. Hasil pengelompokan pada cluster 1 sebanyak 9 Kab/Kota, cluster 2 sebanyak 8 Kab/Kota, cluster 3 sebanyak 12 Kab/Kota, dan Cluster 4 sebanyak 6 Kab/Kota Jawa Tengah. Nilai akurasi dari cluster yang terbentuk sebesar 66.8%
3	(Pulungan et al., 2019)	PENERAPAN ALGORITMA K-MEDOIDS UNTUK MENGELOMPOK	K-Medoids	Menggunakan metode K-Medoids dengan bantuan aplikasi rapidminer 5.3. Sebagai perhitungan perbandingannya, Dengan

		KAN PENDUDUK 15 TAHUN KEATAS MENURUT LAPANGAN PEKERJAAN UTAMA		menggunakan 2 cluster yaitu, cluster tinggi dan cluster rendah. di peroleh cluster tinggi sebanyak 3 lapangan pekerjaan utama dan cluster sebanyak 14 lapangan pekerjaan utama.
4	(Rahmadayanti et al., 2023)	Pengklasterisasi- an Data Penyakit Hipertensi dengan Menggunakan Metode K-Means	K-Means	Menggunakan CRISP-DM dengan proses business understanding, data understanding, data preparation, modeling, evaluation dan deployment. Memberikan informasi mengenai hasil 2 cluster, yaitu cluster 0 Normal dan cluster 1 Hipertensi.
5	(Sutris et al., 2023)	Penerapan Algoritma K-Medoids Untuk Pengelompokan Pengangguran Umur 25 tahun Keatas Di Sumatera Utara	K-Medoids	Menggunakan metode K- Medoids ini menghasilkan berupa 3 (tiga) buah cluster yaitu cluster tinggi, cluster sedang dan cluster rendah. Tiga cluster tersebut, yaitu 14 kabupaten di cluster nol, 2 Kabupaten di cluster satu, dan 17 Kabupaten di Cluster dua.
6	(Badri & Habibi, 2022)	Implementasi Metode K-Means Clustering Analysis pada Pengelompokan Pengangguran di	K-Means	Menghasilkan 2 kelompok yaitu kelompok satu dengan kreteria tingkat pengangguran tinggi dan kelompok dua dengan kreteria pengangguran rendah sehingga

		Indonesia sebagai Dampak dari Pandemi Covid-19		menghasilkan nilai Mean Square kurang dari 0,05 maka terbukti bahwa kluster yang terbentuk antara kluster 1 dan kluster 2 adalah menunjukkan hasil signifikan yang cukup baik.
7	(Putrie & Sanjaya, 2021)	Pengelompokan Kabupaten/Kota Berdasarkan Indikator Tingkat Pengangguran Menggunakan Algoritma K-Means Clustering (Studi Kasus: Provinsi Jawa Barat)	K-Means	Menghasilkan 4 cluster, yaitu cluster 0 terdapat 18 kabupaten/ kota Cluster 1 terdapat 2 kabupaten/ kota. Cluster 2 terdapat 1 kabupaten, dan cluster 3 terdapat 2 Kota dan evaluasi menggunakan metode Davies Bouldin Index pada rapid miner menghasilkan Davies Bouldin sebesar 0.328 artinya hasilnya baik karena hasilnya 0 (non-negatif).
8	(Akramun nisa & Fajriani, 2020)	K-MEANS Clustering Analysis Pada Persebaran Tingkat Pengangguran Kabupaten/Kota Di Sulawesi Selatan	K-Means	Menunjukkan bahwa dari 24 kabupaten/kota di Sulawesi Selatan terbagi menjadi dua kelompok, yaitu kelompok tingkat pengangguran tinggi dan rendah. Kelompok dengan tingkat pengangguran tinggi terdiri dari 3 wilayah, yaitu Palopo, Parepare, dan Makassar. 21 wilayah yang lain termasuk pada kelompok

				dengan tingkat pengangguran rendah.
9	(Sembiring et al., 2021)	PENERAPAN METODE ALGORITMA K-MEANS CLUSTERING UNTUK PEMETAAN PENYEBARAN PENYAKIT DEMAM BERDARAH DENGUE (DBD)	K-Means	Menunjukkan hasil terdapat 3 cluster untuk tingkat penyebaran penyakit DBD yakni cluster 1 dengan kategori sedang, cluster 2 dengan kategori tinggi dan cluster 3 dengan kategori rendah. Performance yang dihasilkan menggunakan Davies Bouldin Index (DBI) adalah sebesar 1.044 yang menunjukkan K=3 sebagai jumlah kelompok yang paling optimum dibandingkan K lainnya.
10	(Maliki et al., 2022)	Perbandingan Tingkat Pengangguran Terbuka Provinsi di Indonesia Berbasis Metode K-Means Clustering	K-Means	Menunjukkan hasil terdapat 23 provinsi pada cluster 1 (TPT rendah) dan 11 provinsi di cluster 2 (TPT tinggi). Hanya Provinsi Riau yang naik ke cluster 1 (TPT rendah), dan hanya provinsi Sumatera Barat yang turun ke cluster 2 (TPT Tinggi). Hasil penelitian bukan hanya menghasilkan jumlah provinsi di cluster tinggi dan rendah tapi juga mengetahui provinsi yang pindah ke cluster yang lebih tinggi atau sebaliknya pada masing-masing data TPT.

III. METODOLOGI PENELITIAN

3.1 Tempat dan Waktu Penelitian

Penelitian ini dilaksanakan di Program Studi Sistem Informasi, Jurusan Teknik Elektro dan Informatika, Fakultas Sains dan Teknologi, Universitas Jambi. Jl. Jambi-Muara Bulian No. KM. 15, Mendalo Darat, Kec. Jambi Luar Kota, Kab. Muaro Jambi. Penelitian ini dilaksanakan selama 4 bulan, mulai dari Jun 2025 hingga Sep 2025.

Table 4. Waktu Penelitian

Kegiatan	Apr 2025	Mei 2025	Jun 2025	Jul 2025	Agu 2025	Sep 2025	Okt 2025	Nov 2025
Penulisan Proposal								
Pengumpulan Data								
Pengolahan Data								
Penulisan Laporan Hasil Penelitian								

3.2 Jenis Penelitian

Penelitian ini termasuk dalam jenis penelitian kuantitatif dengan pendekatan deskriptif. Pendekatan kuantitatif digunakan karena seluruh proses penelitian melibatkan data numerik yang dapat diukur dan dianalisis secara statistik. Data yang digunakan dalam penelitian ini bersumber dari Badan Pusat Statistik (BPS) Provinsi Sumatera Selatan dalam bentuk angka-angka yang merepresentasikan variabel Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM) selama periode 2019–2023. Pendekatan deskriptif digunakan untuk menggambarkan kondisi tingkat pengangguran di setiap kabupaten/kota berdasarkan hasil pengelompokan (clustering) menggunakan algoritma K-Means. Melalui pendekatan ini, hasil penelitian disajikan dalam bentuk deskripsi, tabel, grafik, dan peta visualisasi yang menggambarkan karakteristik masing-masing cluster.

Metode yang digunakan dalam penelitian ini adalah data mining, khususnya teknik clustering dengan algoritma K-Means. Teknik ini digunakan

untuk mengelompokkan wilayah berdasarkan kesamaan karakteristik indikator ketenagakerjaan dan pembangunan manusia. Hasil dari proses clustering kemudian dianalisis untuk mengetahui pola dan tren tingkat pengangguran di Provinsi Sumatera Selatan dari tahun ke tahun. Penelitian ini bersifat aplikatif, karena penerapan metode K-Means diharapkan dapat memberikan manfaat praktis bagi pemerintah daerah dalam memahami pola pengangguran di setiap wilayah, serta sebagai dasar dalam perumusan kebijakan ketenagakerjaan yang lebih efektif dan tepat sasaran. Selain itu, penelitian ini juga bersifat eksploratif, karena bertujuan menemukan pola tersembunyi dan hubungan antar variabel yang belum teridentifikasi sebelumnya melalui proses pengelompokan data.

Jenis penelitian ini dipilih karena sesuai dengan tujuan untuk menghasilkan analisis berbasis data yang objektif, sistematis, dan terukur. Pendekatan kuantitatif memungkinkan analisis numerik yang akurat, sementara pendekatan deskriptif memberikan gambaran yang mudah dipahami mengenai hasil pengelompokan tingkat pengangguran di Provinsi Sumatera Selatan. Dengan demikian, hasil penelitian diharapkan dapat menjadi dasar informasi yang berguna bagi peneliti lain maupun pihak pembuat kebijakan dalam upaya menekan angka pengangguran dan meningkatkan kesejahteraan masyarakat.

3.3 Alat dan Bahan

Perangkat keras (*Hardware*) dan perangkat lunak (*Software*) yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Perangkat keras (*Hardware*)
 - a. Laptop Acer dengan processor 11th Gen Intel® Core™ i5-1135G7 @ 2.40GHz 2.42 GHz, RAM 16 GB, dan system type 64-bit operating system, x64-based processor.
2. Perangkat lunak (*Software*)
 - a. Sistem Operasi Windows 11.
 - b. Anaconda Navigator sebagai platform distribusi Python. Perangkat lunak ini memudahkan pengelolaan *library* dan *dependencies* yang diperlukan dalam pengembangan model, serta menjamin konsistensi versi *packages* yang digunakan.
 - c. Jupyter Lab sebagai *Integrated Development Environment* (IDE) dalam penelitian ini. Platform ini dipilih karena menyediakan antarmuka interaktif yang memungkinkan pengembangan dan pengujian kode secara real-time, visualisasi data dan dokumentasi kode yang terstruktur dengan format markdown, dan eksekusi kode secara modular melalui sistem *cell-based execution*.

- d. *Microsoft Excel 2019* sebagai tools untuk penyimpanan dan pengorganisasian data.
- e. *Microsoft Word 2019* sebagai tools untuk mengolah kata dengan meliputi membuat, menyunting, hingga membuat suatu format dokumen.

3.4 Indikator/Variabel Penelitian

Penelitian ini menggunakan beberapa indikator atau variabel yang berperan penting dalam menganalisis dan mengelompokkan wilayah kabupaten/kota di Provinsi Sumatera Selatan berdasarkan kondisi ketenagakerjaan dan pembangunan manusia. Pemilihan variabel dilakukan dengan mempertimbangkan relevansi terhadap tingkat pengangguran serta kontribusinya dalam menggambarkan kondisi sosial ekonomi masyarakat. Variabel yang digunakan dalam penelitian ini meliputi Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM). Berikut Indikator/Variabel utama tersebut:

a. Tingkat Pengangguran Terbuka (TPT)

TPT menggambarkan persentase angkatan kerja yang belum memperoleh pekerjaan tetapi aktif mencari pekerjaan. Nilai TPT yang tinggi menunjukkan bahwa meskipun terdapat jumlah angkatan kerja yang cukup, kesempatan kerja belum cukup atau belum optimal disediakan oleh pasar tenaga kerja wilayah tersebut. Sebagai indikator, TPT memiliki signifikansi dalam menilai efektivitas kebijakan ketenagakerjaan dan dinamika penyerapan tenaga kerja (Agung Utomo & Wisika Prajanti, 2022). variabel TPT digunakan untuk mengelompokkan kabupaten/kota di Provinsi Sumatera Selatan berdasarkan tingkat ketidakserapan tenaga kerja, sehingga wilayah-wilayah dengan TPT tinggi akan cenderung berada dalam cluster tersendiri yang menunjukkan tantangan pasar tenaga kerja yang lebih besar.

b. Tingkat Partisipasi Angkatan Kerja (TPAK)

TPAK merupakan rasio atau persentase penduduk usia kerja yang termasuk dalam angkatan kerja, baik yang sudah bekerja maupun yang sedang mencari pekerjaan terhadap total penduduk usia kerja. Variabel ini mencerminkan seberapa besar proporsi masyarakat produktif yang secara aktif terlibat dalam aktivitas ekonomi (Akbar Asyari et al., 2024). Semakin tinggi nilai TPAK menunjukkan potensi tenaga kerja yang lebih besar dan partisipasi ekonomi yang lebih luas. TPAK digunakan sebagai variabel pembeda untuk mengelompokkan wilayah berdasarkan seberapa luas masyarakat usia kerja terlibat dalam pasar tenaga kerja. Kombinasi TPAK dengan TPT memungkinkan

identifikasi wilayah yang tidak hanya memiliki banyak angkatan kerja tetapi juga memiliki tingkat pengangguran yang berbeda.

c. Produk Domestik Regional Bruto (PDRB)

PDRB per kapita menunjukkan jumlah nilai barang dan jasa yang dihasilkan oleh suatu wilayah dibagi jumlah penduduknya. Variabel ini mencerminkan kapasitas ekonomi wilayah dan tingkat kesejahteraan relatif masyarakatnya. Penelitian menunjukkan bahwa PDRB per kapita berkorelasi dengan indikator-ketenagakerjaan dan pembangunan manusia (Munawir & Saharuddin, 2023). PDRB per kapita digunakan untuk mengelompokkan wilayah berdasarkan kekuatan ekonomi mereka. Dengan demikian, PDRB per kapita menjadi variabel penting untuk memahami tingkat potensi ekonomi suatu kabupaten/kota di Provinsi Sumatera Selatan.


d. Indeks Pembangunan Manusia (IPM)

Indeks Pembangunan Manusia (IPM) merupakan indikator komposit yang menggambarkan kualitas hidup manusia di suatu wilayah melalui tiga dimensi utama, yaitu pendidikan, kesehatan, dan standar hidup layak. Indikator ini berperan penting dalam menilai tingkat kesejahteraan masyarakat serta keberhasilan suatu daerah dalam meningkatkan kualitas sumber daya manusianya. Kualitas sumber daya manusia yang baik pada umumnya berbanding lurus dengan meningkatnya produktivitas kerja, daya saing tenaga kerja, serta peluang masyarakat untuk terserap dalam dunia kerja secara lebih optimal. IPM memiliki pengaruh yang signifikan terhadap analisis pembangunan daerah, karena tingginya nilai IPM sering kali mencerminkan kemampuan suatu wilayah dalam menyediakan akses pendidikan yang lebih baik, layanan kesehatan yang memadai, serta taraf hidup yang layak bagi penduduknya (Ayu Safitri et al., 2020).

3.5 Tahapan Penelitian

Penelitian ini memerlukan tahapan kerja yang sistematis dan terstruktur agar seluruh proses analisis dapat berjalan dengan baik dan menghasilkan output yang akurat. Dalam penyusunannya, penelitian ini mengadaptasi tahapan *Knowledge Discovery in Database* (KDD) sebagai dasar alur penelitian, mulai dari proses pengumpulan data, pembersihan data, transformasi menggunakan normalisasi Z-Score, penentuan jumlah cluster optimal dengan *Elbow Method*, *Davies-Bouldin Index*, dan *Silhouette Coefficient*, hingga penerapan algoritma K-Means untuk mengelompokkan kabupaten/kota berdasarkan indikator sosial ekonomi terkait pengangguran. Jenis penelitian yang digunakan adalah penelitian kuantitatif deskriptif, di mana pendekatan kuantitatif membantu

memproses data numerik secara objektif, sedangkan aspek deskriptif berfungsi untuk memberikan gambaran interpretatif terkait pola-pola yang terbentuk pada setiap cluster. Melalui pendekatan kuantitatif deskriptif ini, penelitian diharapkan mampu menjelaskan kondisi dan dinamika tingkat pengangguran di Provinsi Sumatera Selatan secara lebih terukur, sistematis, dan mudah dipahami.



Gambar 11. Tahapan Penelitian

3.6 Studi Literatur

Permasalahan pengangguran memberikan dampak yang signifikan terhadap kondisi sosial dan ekonomi masyarakat, termasuk di Provinsi Sumatera Selatan. Tingkat pengangguran di provinsi menunjukkan fluktuasi dari tahun ke tahun, yang mencerminkan dinamika perkembangan ekonomi dan sosial di setiap

wilayah. Permasalahan ini tidak hanya dapat dilihat dari jumlah penduduk yang menganggur, tetapi juga dari sebarannya di berbagai kabupaten/kota serta faktor-faktor yang memengaruhinya, seperti Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM). Ke-empat indikator tersebut saling berkaitan dan berperan penting dalam menggambarkan kondisi ketenagakerjaan dan kesejahteraan masyarakat di suatu daerah. Pendekatan konvensional dalam menganalisis data pengangguran umumnya hanya berfokus pada angka atau tren secara umum, sehingga belum mampu memberikan gambaran menyeluruh mengenai pola sebaran dan keterkaitan antar wilayah. Untuk memperoleh pemahaman yang lebih komprehensif, diperlukan metode analisis berbasis data yang mampu mengidentifikasi pola tersembunyi dan hubungan antar variabel. Salah satu pendekatan yang relevan adalah teknik data mining, yang memungkinkan peneliti menemukan informasi dan pengetahuan baru dari kumpulan data yang besar dan kompleks.

Dalam penelitian ini, digunakan metode clustering sebagai salah satu teknik data mining untuk mengelompokkan daerah berdasarkan kesamaan karakteristik indikator ketenagakerjaan. Algoritma K-Means dipilih karena merupakan salah satu metode clustering yang paling populer, sederhana, dan efisien dalam menangani jumlah data yang besar. Algoritma ini bekerja dengan mengelompokkan data ke dalam beberapa cluster berdasarkan tingkat kemiripan antar atribut, sehingga daerah-daerah yang memiliki karakteristik serupa akan berada dalam satu kelompok yang sama. Sejumlah penelitian terdahulu juga telah membuktikan efektivitas algoritma K-Means dalam mengelompokkan data ketenagakerjaan di berbagai daerah, baik pada tingkat provinsi maupun kabupaten/kota. Untuk memperoleh hasil yang valid dan akurat, penelitian ini juga melibatkan tahapan preprocessing seperti normalisasi data guna menyeragamkan skala antar variabel, serta evaluasi model menggunakan metode seperti Indeks *Davies-Bouldin* dan *Silhouette Coefficient*. Kedua metode evaluasi tersebut digunakan untuk menilai seberapa baik hasil pengelompokan yang dihasilkan oleh algoritma. Melalui penerapan metode ini, penelitian diharapkan dapat memberikan kontribusi dalam memahami pola dan karakteristik pengangguran di Provinsi Sumatera Selatan secara lebih mendalam.


3.7 Pengumpulan Data

Tahap pengumpulan data merupakan Langkah awal yang sangat penting dalam penelitian ini. Data yang digunakan diperoleh dari Website resmi Badan Pusat Statistik Sumatera Selatan (<https://sumsel.bps.go.id/id>), Data tersebut

didapatkan secara terpisah-pisah dan dikumpulkan menjadi satu dalam format excel. Dataset yang digunakan dalam penelitian ini berisi 340 data dengan 6 variabel. Data ini mencakup informasi detail tingkat pengangguran di Provinsi Sumatera Selatan. Seperti nama Kabupaten/kota, Tahun, Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM) dari tahun 2019-2023 di Provinsi Sumatera Selatan. Variabel utama yang dianalisis mencakup:

Table 5. Variabel Utama

Variabel	Deskripsi
Tingkat Pengangguran Terbuka (TPT)	Mengukur sumber daya manusia yang belum terserap dalam lapangan kerja.
Tingkat Partisipasi Angkatan Kerja (TPAK)	Mengukur pasokan tenaga kerja telah aktif dalam perekonomian
Produk Domestik Regional Bruto (PDRB)	Mengukur kemampuan produksi dan aktivitas ekonomi dalam setahun.
Indeks Pembangunan Manusia (IPM)	Mengukur kualitas hidup manusia



Gambar 12. Tampilan Beranda Web BPS Sumsel

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
1	Kabupaten/Kota	Tahun	TPT	TPAK	PDRB	IPM													
2	Ogan Komering Ulu	2019	4,58	68,53	14647,67	69,45													
3	Ogan Komering Ilir	2019	2,98	70,96	28752,47	66,96													
4	Muara Enim	2019	4,84	70,21	57333,51	68,88													
5	Lahat	2019	3,68	71,14	17130,2	67,62													
6	Musi Rawas	2019	2,93	71,39	19062,78	66,92													
7	Musi Banyuasin	2019	4,15	66,16	65811	67,83													
8	Banyu Asin	2019	3,94	63,36	28655,74	66,9													
9	Ogan Komering Ulu Selatan	2019	2,99	76,82	8785,71	65,43													
10	Ogan Komering Ulu Timur	2019	3,46	66,84	14935,85	69,34													
11	Ogan Ilir	2019	3,29	72,61	11159,4	67,22													
12	Empat Lawang	2019	2,66	71,72	4991,08	65,1													
13	Penakal Abab Lematang Ilir	2019	4,14	73,49	7083,68	64,33													
14	Musi Rawas Utara	2019	3,81	70,39	7103,69	64,32													
15	Kota Palembang	2019	8,01	60,97	154220,32	78,44													
16	Kota Prabumulih	2019	6,12	69,3	7791,06	74,4													
17	Kota Pagar Alam	2019	2,48	69,26	2791,62	68,44													
18	Kota Lubuklinggau	2019	4,71	70,65	6643,68	74,81													
19																			
20																			
21																			
22																			
23																			

Gambar 13. Tampilan Dataset di Excel

3.8 Preprocessing Data

Tahap berikutnya adalah proses preprocessing data, pada proses ini perlu dilakukannya pembersihan data (*Data Cleaning*). Preprocessing data merupakan tahap pengolahan data mentah menjadi format yang siap digunakan untuk pemodelan. Tahap ini meliputi beberapa proses penting.

1. Data Cleaning

Pada tahap ini dilakukan pengecekan terhadap kelengkapan data. Hasil pemeriksaan menunjukkan bahwa data sudah bersih dan tidak mengandung nilai kosong (*missing value*).

2. Seleksi Variabel

Variabel yang digunakan dalam penelitian ini terdiri dari empat indikator yang memengaruhi tingkat pengangguran, yaitu:

- Tingkat Pengangguran Terbuka (TPT)
- Tingkat Partisipasi Angkatan Kerja (TPAK)
- Produk Domestik Regional Bruto (PDRB)
- Index Pembangunan Manusia (IPM)

3. Normalisasi Data

Normalisasi data merupakan tahapan penting yang dilakukan untuk menyetarakan skala nilai antar variabel, sehingga tidak ada satu variabel pun yang mendominasi dalam proses perhitungan jarak pada algoritma K-Means. Proses ini sangat diperlukan karena algoritma K-Means menggunakan perhitungan jarak Euclidean (*Euclidean Distance*) dalam menentukan pembentukan cluster. Apabila data tidak dinormalisasi, variabel yang memiliki skala nilai lebih besar dapat memberikan pengaruh yang tidak proporsional

terhadap hasil pengelompokan. Pada penelitian ini, teknik normalisasi yang digunakan Adalah Normalisasi Z-Score, yang berfungsi untuk mengubah data ke dalam bentuk standar, yaitu memiliki nilai rata-rata (mean) sebesar 0 dan standar deviasi sebesar 1.

- Rata-rata (*mean*)

Rata-rata adalah nilai tengah dari sekumpulan data.

Rumus:

$$\mu = \frac{\sum_{i=1}^n X_i}{n} \quad (28)$$

Keterangan:

X_i = nilai data ke- i

N = jumlah data

- Standar Deviasi (*SD*)

Standar deviasi adalah ukuran penyebaran data terhadap rata-rata.

Rumus:

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (X_i - \mu)^2}{n}} \quad (29)$$

- Rumus Normalisasi Z-Score:

$$Z = \frac{X - \mu}{\sigma} \quad (30)$$

Keterangan:

Z = Nilai hasil normalisasi (*Z-Score*)

X = Nilai asli data

μ = Nilai rata-rata (*mean*) dari seluruh data pada variabel tersebut

σ = Nilai standar deviasi dari variabel tersebut

Langkah-langkah Penerapan Normalisasi Z-Score:

1. Menghitung rata-rata (μ) dari setiap variabel, seperti TPT, TPAK, PDRB, dan IPM.
2. Menghitung standar deviasi (σ) dari masing-masing variabel.
3. Menghitung nilai Z untuk setiap data menggunakan rumus di atas.
4. Nilai Z inilah yang kemudian digunakan dalam proses clustering, sehingga Semua variabel memiliki kontribusi yang seimbang dalam perhitungan jarak.

Contoh Penerapan:

Sebagai contoh, pada data tahun 2019:

Kabupaten/Kota = Ogan Komering Ulu

Variabel = TPT

Nilai asli TPT : X = 4,58

Rata-rata TPT : $(\sigma) = 4,045$

Standar deviasi TPT $(\sigma) = 1,336$

Maka nilai Z-Score dihitung sebagai:

$$Z = \frac{4,58-4,045}{1,336} = \frac{0,535}{1,336} = 0,400$$

Nilai 0,400 menunjukkan bahwa TPT Ogan Komering Ulu berada sedikit di atas rata-rata, dalam satuan standar deviasi.

Hasil normalisasi ini diterapkan pada seluruh variabel dan seluruh kabupaten/kota untuk setiap tahun (2019–2023) sebelum dilakukan proses clustering menggunakan algoritma K-Means.

Table 6. Data Hasil Normalisasi tahun 2019

Kabupaten/Kota	Tahun	Z TPT	Z TPAK	Z PDRB	Z IPM
Ogan Komering Ulu	2019	0,400006284	-0,304131385	-0,337606436	0,222733752
Ogan Komering Ilir	2019	-0,796932211	0,36450446	0,051792638	-0,43843874
Muara Enim	2019	0,594508789	0,158135372	0,840845337	0,071381013
Lahat	2019	-0,27327162	0,414033041	-0,269069846	-0,2631882
Musi Rawas	2019	-0,834336539	0,482822737	-0,215716033	-0,449059984
Musi Banyuasin	2019	0,078329063	-0,956257703	1,074888127	-0,207426664
Banyu Asin	2019	-0,078769114	-1,726702298	0,049122159	-0,454370607
Ogan Komering Ulu Selatan	2019	-0,789451345	1,976934933	-0,499440832	-0,844701355
Ogan Komering Ulu Timur	2019	-0,437850663	-0,76914973	-0,32965049	0,193525329
Ogan Ilir	2019	-0,565025378	0,818516453	-0,433909049	-0,369400648
Empat Lawang	2019	-1,03631991	0,573625135	-0,604201297	-0,932326625
Penukal Abab Lematang Ilir	2019	0,070848198	1,060656183	-0,546429723	-1,136785589
Musi Rawas Utara	2019	-0,176020367	0,207663953	-0,545877296	-1,1394409
Kota Palembang	2019	2,965943182	-2,384331791	3,515653493	2,609858532
Kota Prabumulih	2019	1,552059585	-0,092259122	-0,526900689	1,537112803
Kota Pagar Alam	2019	-1,170975491	-0,103265473	-0,664923015	-0,04545268
Kota Lubuklinggau	2019	0,497257536	0,279205237	-0,558577048	1,645980562

3.9 Implementasi K-Means

Setelah melalui tahap preprocessing data, Langkah selanjutnya mengimplementasikan algoritma K-Means pada dataset yang telah dinormalisasi. Implementasi ini dilakukan secara terpisah untuk masing-masing tahun, yaitu dari tahun 2019-2023, dengan tujuan untuk menganalisis pola pengangguran dan perubahan cluster dari tahun ke tahun di Provinsi Sumatera Selatan. Berikut langkah-langkah implementasinya:

1. Langkah pertama menentukan jumlah cluster yang diinginkan. Dalam kasus ini, kita memilih $k=4$ karena ingin membagi data ke dalam empat kelompok berdasarkan TPT, TPAK, PDRB dan IPM.
2. Pada tahap ini, nilai centroid untuk iterasi awal dipilih secara acak (*random*). Dalam contoh ini, kita memilih titik pertama, kedua, ketiga dan keempat. Dari dataset sebagai centroid awal:

Table 7. Centroid Iterasi Pertama tahun 2019

Centroid baru	Z_TPT	Z_TPAK	Z_PDRB	Z_IPM
Cluster 0 (C0)	-0,796932211	0,36450446	0,051792638	-0,43843874
Cluster 1 (C1)	0,594508789	0,158135372	0,840845337	0,071381013
Cluster 2 (C2)	-0,27327162	0,414033041	-0,269069846	-0,2631882
Cluster 3 (C3)	0,400006284	-0,304131385	-0,337606436	0,222733752

3. Menghitung Jarak antara Centroid dan Setiap Objek, Jarak antara titik centroid dan setiap objek dihitung menggunakan *Euclidean Distance* dengan rumus berikut:

$$De = \sum_{j=1}^N (X_{ij} - C_j)^2 \quad (31)$$

Di mana:

De = Jarak *Euclidean* antara titik data X_i dengan centroid C

$\sum_{j=1}^N$ = Penjumlahan dari semua dimensi fitur (jumlah variable atau atribut) dari 1 hingga n

X_{ij} = Nilai fitur ke- j untuk data ke- i

C_j = Nilai centroid ke- j untuk variabel ke- j

$(X_{ij} - C_j)^2$ = Selisih kuadrat antara nilai data dan nilai centroid pada dimensi ke- j

Contoh perhitungan Jarak

Hitung jarak Musi Rawas ke C0, C1, C2 dan C3:

Musi Rawas = (-0,834336539, 0,482822737, -0,215716033, -0,449059984)

Jarak Musi Rawas ke Centroid C0 (Ogan Komering Ilir):

$$\begin{aligned}
 &= \sqrt{(-0,834336539 - (-0,796932211))^2 + (0,482822737 - 0,36450446)^2 +} \\
 &\quad \sqrt{(-0,215716033 - 0,051792638)^2 + (-0,449059984 - (-0,43843874))^2} \\
 &= \sqrt{(-0,037404328)^2 + (0,118318277)^2 + (-0,267508671)^2 + (-0,010621244)^2} \\
 &= \sqrt{0,001399908 + 0,013999214 + 0,071560889 + 0,000112810} = \sqrt{0,087072821} = 0,295081041
 \end{aligned}$$

Jarak Musi Rawas ke Centroid C1 (Muara Enim):

$$\begin{aligned}
 &= \sqrt{(-0,834336539 - 0,594508789)^2 + (0,482822737 - 0,158135372)^2 +} \\
 &\quad \sqrt{(-0,215716033 - 0,840845337)^2 + (-0,449059984 - 0,071381013)^2} \\
 &= \sqrt{(-1,428845328)^2 + (0,324687365)^2 + (-1,05656137)^2 + (-0,520440997)^2} \\
 &= \sqrt{2,041598971 + 0,105421884 + 1,116321928 + 0,270858831} = \sqrt{3,534201614} = 1,879947237
 \end{aligned}$$

Jarak Musi Rawas ke Centroid C2 (Lahat):

$$\begin{aligned}
 &= \sqrt{(-0,834336539 - (-0,27327162))^2 + (0,482822737 - 0,414033041)^2 +} \\
 &\quad \sqrt{(-0,215716033 - (-0,269069846))^2 + (-0,449059984 - (-0,2631882))^2} \\
 &= \sqrt{(-0,561064919)^2 + (0,068789696)^2 + (0,053353813)^2 + (-0,185871784)^2} \\
 &= \sqrt{0,314793843 + 0,004732022 + 0,002846629 + 0,034548320} = \sqrt{0,356920814} = 0,597428501
 \end{aligned}$$

Jarak Musi Rawas ke Centroid C3 (Ogan Komering Ulu):

$$\begin{aligned}
 &= \sqrt{(-0,834336539 - 0,400006284)^2 + (0,482822737 - (-0,304131385))^2 +} \\
 &\quad \sqrt{(-0,215716033 - (-0,337606436))^2 + (-0,449059984 - 0,222733752)^2} \\
 &= \sqrt{(1,234342823)^2 + (0,786954122)^2 + (0,121890403)^2 + (-0,671793736)^2} \\
 &= \sqrt{1,523602204 + 0,619296790 + 0,014857279 + 0,451306823} = \sqrt{2,609063096} = 1,615259451
 \end{aligned}$$

4. Setiap data akan dikelompokkan ke dalam cluster yang memiliki jarak paling minimum terhadap titik pusat (centroid). Berdasarkan hasil perhitungan, jarak antara data Kabupaten Musi Rawas dengan centroid C0 memiliki nilai paling kecil dibandingkan dengan centroid lainnya. Oleh karena itu, Kabupaten Musi Rawas dikategorikan ke dalam Cluster 0. Hal ini menunjukkan bahwa karakteristik data Kabupaten Musi Rawas pada tahun 2019 memiliki kemiripan yang lebih tinggi dengan profil wilayah Ogan Komering Ilir, dibandingkan dengan wilayah lain seperti Ogan Komering Ulu, Muara Enim, dan Lahat.

Table 8. Hasil Clustering Iterasi Pertama tahun 2019

Kabupaten/Kota	Jarak Ke C0	Jarak Ke C1	Jarak Ke C2	Jarak Ke C2	Masuk Cluster
Ogan Komering Ulu	1,571151284	1,28964259	1,099945765	0	3
Ogan Komering Ilir	0	1,691513109	0,640577069	1,571151284	0
Muara Enim	1,691513109	0	1,470501522	1,28964259	1
Lahat	0,640577069	1,470501522	0	1,099945765	2
Musi Rawas	0,295079648	1,879947238	0,597428503	1,615259449	0
Musi Banyuasin	1,90015419	1,280946206	1,952089175	1,645880871	1
Banyu Asin	2,211145606	2,215661646	2,181370184	1,691438205	3
Ogan Komering Ulu Selatan	1,751826375	2,803382139	1,760776015	2,789924924	0
Ogan Komering Ulu Timur	1,399638819	1,819506365	1,280337843	0,95872976	3
Ogan Ilir	0,707516824	1,897342846	0,535891904	1,597348308	2
Empat Lawang	0,880506226	2,434712054	1,080634837	2,05881683	0
Penukal Abab Lematang Ilir	1,443339314	2,114938027	1,173303386	1,965423658	2
Musi Rawas Utara	1,121937539	1,996311004	0,946830061	1,578808951	2
Kota Palembang	6,557879248	5,068166053	6,395458274	5,608675662	1

Kota Prabumulih	3,156593938	2,235777225	2,625971478	1,770745963	3
Kota Pagar Alam	1,013329391	2,33800205	1,130300172	1,639326373	0
Kota Lubuklinggau	2,529734777	2,112312115	2,083418704	1,556983916	3

5. Menghitung Centroid Baru, Setelah semua data dikelompokkan, centroid baru dihitung sebagai rata-rata dari setiap fitur dalam cluster:

$$C_j = \frac{N}{N^i} \sum_{k=1}^{N^i} X_{kj} \quad (32)$$

Di mana:

C_j = Centroid untuk fitur ke- j

N^i = Jumlah data dalam cluster ke- i

X_{kj} = Nilai fitur ke- j dari data ke- k dalam cluster

6. Mengulangi Proses Hingga Konvergensi

Proses ini di ulang:

- a. Menghitung ulang centroid

Contoh perhitungan centroid baru

Anggota Cluster 0:

- Ogan Komering Ilir
- Musi Rawas
- Ogan Komering Ulu Selatan
- Empat Lawang
- Kota Pagar Alam

Centroid baru diperoleh dengan menjumlahkan nilai setiap variabel, yaitu Z_{TPT} , Z_{TPAK} , Z_{PDRB} , dan Z_{IPM} , kemudian membaginya dengan jumlah anggota pada masing-masing cluster; proses ini dilakukan secara berulang pada Cluster 1, Cluster 2, dan Cluster 3 untuk memperoleh titik pusat (centroid) baru yang mewakili rata-rata karakteristik setiap kelompok data.

Contoh perhitungan variabel pada Cluster 0:

Z_{TPTc0}

$$\begin{aligned}
 &= \frac{-0,796932211 + (-0,834336539) + (-0,789451345) + (-1,03631991) + (-1,170975491)}{5} \\
 &= \frac{-4,628015496}{5} = -0,925603099
 \end{aligned}$$

Z_{TPAKc0}

$$= \frac{0,36450446 + 0,482822737 + 1,976934933 + 0,573625135 + (-0,103265473)}{5}$$

$$= \frac{3,294621792}{5} = 0,658924358$$

Z_{PDRBc0}

$$= \frac{0,051792638 + (-0,215716033) + (-0,499440832) + (-0,604201297) + (-0,664923015)}{5}$$

$$= \frac{-1,932488539}{5} = -0,386497708$$

Z_{IPMc0}

$$= \frac{-0,43843874 + (-0,449059984) + (-0,844701355) + (-0,932326625) + (-0,04545268)}{5}$$

$$= \frac{-2,709979384}{5} = -0,541995877$$

Table 9. Centroid baru Iterasi Kedua tahun 2019

Centroid baru	Z_TPT	Z_TPAK	Z_PDRB	Z_IPM
Cluster 0 (C0)	-0,925603099	0,658924358	-0,386497708	-0,541995877
Cluster 1 (C1)	1,212927011	-1,060818041	1,810462319	0,824604294
Cluster 2 (C2)	-0,235867292	0,625217407	-0,448821479	-0,727203834
Cluster 3 (C3)	0,386540726	-0,52260746	-0,340722501	0,628996368

b. Menghitung jarak data ke centroid

Langkah selanjutnya yaitu menghitung ulang jarak menggunakan centroid baru Iterasi kedua.

c. Mengelompokkan ulang data

Table 10. Hasil Iterasi kedua tahun 2019

Kabupaten/Kota	Jarak Ke C0	Jarak Ke C1	Jarak Ke C2	Jarak ke C3	Masuk Cluster
Ogan Komering Ulu	1,808844483	2,491959536	1,477421601	0,461489045	3
Ogan Komering Ilir	0,553228508	3,280133393	0,846619666	1,865760325	0
Muara Enim	2,108110984	1,837332556	1,791275611	1,487850448	3
Lahat	0,759625658	3,145110271	0,541866292	1,453882789	2

Musi Rawas	0,277749575	3,507382828	0,714243538	1,918140582	0
Musi Banyuasin	2,421627138	1,704230811	2,278517532	1,72817936	1
Banyu Asin	2,570172212	2,617246011	2,424580783	1,729745787	3
Ogan Komering Ulu Selatan	1,363846007	4,621655129	1,466275404	3,134907656	0
Ogan Komering Ulu Timur	1,6797384	2,790784984	1,687305815	0,964448997	3
Ogan Ilir	0,433039119	3,62710125	0,523407171	1,926024852	0
Empat Lawang	0,468281022	4,080186619	0,842380202	2,39445377	0
Penukal Abab Lematang Ilir	1,238408937	3,899613733	0,678944697	2,401392703	2
Musi Rawas Utara	1,071378847	3,598337295	0,597738883	2,00480178	2
Kota Palembang	7,04034876	3,304476354	6,794264031	5,377246994	1
Kota Prabumulih	3,323476327	2,650292717	2,974000888	1,550152147	3
Kota Pagar Alam	0,982454451	3,67211516	1,38441293	1,77811472	0
Kota Lubuklinggau	2,643023117	2,931697747	2,510228456	1,317907154	3

Karena pada hasil iterasi kedua terdapat perpindahan anggota pada Muara Enim dan Ogan Ilir, yang sebelumnya pada iterasi pertama Muara Enim berada pada anggota cluster 1 berpindah ke anggota cluster 3 serta Ogan Ilir yang sebelumnya berada pada cluster 2 berpindah ke anggota cluster 0. Sehingga hasil yang di dapatkan belum konvergen, Proses berhenti ketika centroid tidak berubah atau perpindahan anggota cluster berhenti.

Untuk iterasi ketiga, lakukan dengan menggunakan cara sebelumnya, dengan menjumlahkan variabel dengan banyaknya anggota, menghitung jarak dengan centroid baru, dan mengelompokkan data.

Table 11. Centroid baru Iterasi Ketiga tahun 2019

Centroid baru	Z_TPT	Z_TPAK	Z_PDRB	Z_IPM
Cluster 0 (C0)	-0,865506812	0,685523041	-0,394399598	-0,513230005
Cluster 1 (C1)	1,522136123	-1,670294747	2,29527081	1,201215934
Cluster 2 (C2)	-0,12614793	0,560784392	-0,453792288	-0,846471563
Cluster 3 (C3)	0,42120207	-0,409150321	-0,143794528	0,536060475

Table 12. Hasil Iterasi Ketiga tahun 2019

Kabupaten/Kota	Jarak Ke C0	Jarak Ke C1	Jarak Ke C2	Jarak ke C3	Masuk Cluster
Ogan Komering Ulu	1,767995304	3,318892538	1,477029694	0,383685977	3
Ogan Komering Ilir	0,55896033	4,152125661	0,954245391	1,752225986	0
Muara Enim	2,0681836	2,755998834	1,788857812	1,239875373	3
Lahat	0,70899774	4,035868402	0,646160353	1,347002933	2
Musi Rawas	0,279472015	4,383759099	0,84983845	1,829652469	0

Musi Banyuasin	2,416317917	2,463338301	2,255763674	1,566795751	3
Banyu Asin	2,576424512	3,217488142	2,375185511	1,733229637	3
Ogan Komering Ulu Selatan	1,339565611	5,535513678	1,564461792	3,031843013	0
Ogan Komering Ulu Timur	1,674114154	3,543905011	1,721304181	1,009675164	3
Ogan Ilir	0,360865932	4,523901355	0,697876229	1,839520744	0
Empat Lawang	0,511230853	4,953767865	0,926591539	2,336311835	0
Penukal Abab Lematang Ilir	1,195583666	4,806853717	0,61769184	2,289892584	2
Musi Rawas Utara	1,057745926	4,467802739	0,470629351	1,925125943	2
Kota Palembang	7,010436144	2,463338301	6,777717485	5,298041842	1
Kota Prabumulih	3,266654948	3,250933793	2,9882546	1,590010957	3
Kota Pagar Alam	1,00374149	4,474970505	1,489575204	1,799535322	0
Kota Lubuklinggau	2,590630298	3,632243036	2,586738997	1,372437593	3

Karena pada hasil iterasi ketiga juga terdapat perpindahan anggota pada Musi Banyuasin, yang sebelumnya pada iterasi kedua berada pada anggota cluster 1 berpindah ke anggota cluster 3. Sehingga perlu dilanjutkan ke iterasi ke-empat.

Table 13. Centroid baru Iterasi Ke-empat tahun 2019

Centroid baru	Z_TPT	Z_TPAK	Z_PDRB	Z_IPM
Cluster 0 (C0)	-0,865506812	0,685523041	-0,394399598	-0,513230005
Cluster 1 (C1)	2,965943182	-2,384331791	3,515653493	2,609858532
Cluster 2 (C2)	-0,12614793	0,560784392	-0,453792288	-0,846471563
Cluster 3 (C3)	0,372220212	-0,487308518	0,030302994	0,429848027

Table 14. Hasil Iterasi Ke-empat tahun 2019

Kabupaten/Kota	Jarak Ke C0	Jarak Ke C1	Jarak Ke C2	Jarak ke C3	Masuk Cluster
Ogan Komering Ulu	1,767995304	5,608675662	1,477029694	0,461063552	3
Ogan Komering Ilir	0,55896033	6,557879248	0,954245391	1,687271896	0
Muara Enim	2,0681836	5,068166053	1,788857812	1,118699028	3
Lahat	0,70899774	6,395458274	0,646160353	1,341267915	2
Musi Rawas	0,279472015	6,778111985	0,84983845	1,797202965	0
Musi Banyuasin	2,416317917	4,926676603	2,255763674	1,342967787	3
Banyu Asin	2,576424512	5,577552261	2,375185511	1,587981444	3
Ogan Komering Ulu Selatan	1,339565611	7,821675137	1,564461792	3,054027054	0
Ogan Komering Ulu Timur	1,674114154	5,900818121	1,721304181	0,959720906	3
Ogan Ilir	0,360865932	6,870298784	0,697876229	1,854157333	0
Empat Lawang	0,511230853	7,368032181	0,926591539	2,316825624	0
Penukal Abab Lematang Ilir	1,195583666	7,126526456	0,61769184	2,296515038	2

Musi Rawas Utara	1,057745926	6,866123758	0,470629351	1,891614636	2
Kota Palembang	7,010436144	0	6,777717485	5,217874092	1
Kota Prabumulih	3,266654948	4,974504162	2,9882546	1,756301854	3
Kota Pagar Alam	1,00374149	6,844359519	1,489575204	1,799497708	0
Kota Lubuklinggau	2,590630298	5,542314819	2,586738997	1,558504321	3

Hasil akhir menunjukkan Algoritma K-Means berhasil mengelompokkan wilayah berdasarkan kemiripan nilai TPT, TPAK, PDRB, dan IPM. Proses iterasi dihentikan pada iterasi ke-empat karena tidak terjadi lagi perpindahan cluster (*konvergen*). Pembagian cluster ini akan digunakan untuk evaluasi lanjutan seperti Elbow, DBI, dan Silhouette Coefficient.

3.10 Evaluasi

Dalam penelitian ini, jumlah cluster (k) ditentukan menggunakan *Elbow Method*. Menggunakan validasi *Indeks Davies-Bouldin* (DBI) dan *Silhouette Coefficient*. *Indeks Davies-Bouldin* (DBI) digunakan untuk menilai kualitas clustering berdasarkan rasio antara jarak dalam cluster dan jarak antar cluster. Sedangkan *Silhouette Coefficient* digunakan untuk mengukur kualitas pengelompokan dengan memperhatikan jarak antar cluster. DBI terkecil sebagai algoritma terbaik dan nilai Silhouette yang tinggi.

A. Metode Elbow

Metode Elbow digunakan untuk membantu menentukan jumlah cluster (k) yang optimal dalam algoritma K-Means. Tujuan utama dari metode ini adalah untuk mencari titik optimal di mana penambahan jumlah cluster tidak memberikan peningkatan signifikan dalam kualitas clustering, khususnya dalam menurunkan nilai within-cluster sum of squares (WCSS). Metode Elbow bekerja dengan menghitung nilai WCSS (*Within-Cluster Sum of Squares*) untuk berbagai nilai k . WCSS mengukur total jarak kuadrat antara titik data dengan pusat clusternya. Semakin kecil nilai WCSS, semakin rapat data dalam cluster tersebut.

Rumus perhitungan WCSS adalah:

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} ||x - c_i||^2 \quad (33)$$

Keterangan:

- k = Jumlah cluster
- C_i = Anggota dari cluster ke- i
- c_i = Centroid cluster ke- i
- x = Titik data dalam cluster

1. Langkah-langkah Metode Elbow

- Lakukan proses K-Means untuk beberapa nilai k , misalnya dari $k=1$ hingga $k=10$
- Hitung nilai WCSS untuk setiap nilai k
- Plotkan grafik WCSS terhadap k
- Identifikasi titik Elbow, yaitu titik di mana penurunan nilai WCSS mulai melambat secara signifikan. Titik ini menandai jumlah cluster optimal

2. Interpretasi Grafik Elbow

Pada grafik, akan terlihat bahwa semakin besar nilai K , maka WCSS akan menurun. Namun, setelah titik tertentu, penurunan WCSS menjadi tidak signifikan. Titik ini disebut sebagai "*titik siku*" atau "*elbow point*", dan dianggap sebagai jumlah cluster terbaik.

3. Kelebihan dan Kekurangan Metode Elbow


Kelebihan:

- Mudah dipahami dan diterapkan.
- Tidak memerlukan label data.

Kekurangan:

- Penentuan titik elbow bersifat subjektif, terutama jika grafik tidak menunjukkan perubahan yang jelas.
- Tidak selalu bekerja baik pada data yang sangat kompleks atau berdimensi tinggi.

- Implementasi dalam Penelitian Dari grafik di bawah ini terlihat bahwa penurunan nilai SSE mulai melambat setelah $k=4$, sehingga ditetapkan jumlah cluster optimal adalah 4 cluster.



Gambar 14. Contoh Grafik Elbow

B. Davies-Bouldin Index (DBI)

Setelah proses clustering dilakukan menggunakan algoritma K-Means, perlu dilakukan evaluasi untuk menilai kualitas hasil clustering yang dihasilkan. Salah satu metode evaluasi yang digunakan *Davies-Bouldin Index* (DBI). Evaluasi ini bertujuan untuk mengetahui seberapa baik pemisahan antar cluster dan seberapa rapat data dalam masing-masing cluster. *Davies-Bouldin Index* (DBI) evaluasi internal yang mengukur validitas dari hasil clustering tanpa perlu mengetahui label data sebenarnya. DBI didasarkan pada rasio antara jarak antar pusat cluster (*inter-cluster distance*) dan sebaran dalam cluster (*intra-cluster distance*).

Nilai DBI didefinisikan sebagai:

$$DBI = \frac{1}{k} \sum_{j=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{i,j}} \right) \quad (34)$$

Keterangan:

K = Jumlah Cluster

S_i = Rata-rata jarak antara titik-titik dalam cluster ke centroid-nya
(disebut *scatter cluster i*)

$M_{i,j}$ = Jarak *Euclidean* antara centroid cluster i dan centroid cluster j

1. Langkah Perhitungan DBI

Langkah-langkah perhitungan *Davies-Bouldin Index* dalam penelitian ini adalah sebagai berikut:

$$S_i = \frac{1}{n_i} \sum_{x \in C_i} \|x - c_i\| \quad (35)$$

Dimana:

C_i = Himpunan anggota cluster ke- i

c_i = Centroid cluster ke- i

n_i = Jumlah anggota cluster ke- i

- Hitung Jarak Antar Centroid $M_{i,j}$.

Dihitung jarak antara centroid dari dua cluster yang berbeda menggunakan rumus *Euclidean*:

$$M_{i,j} = \|c_i - c_j\| \quad (36)$$

- Hitung Nilai $R_{i,j}$ untuk Setiap Pasangan Cluster.

Hitung rasio scatter gabungan dibandingkan jarak antar centroid:

$$R_{i,j} = \frac{S_i + S_j}{M_{i,j}} \quad (37)$$

Ambil Nilai Maksimum $R_{i,j}$ dari Setiap Cluster i .

Untuk setiap cluster i , ambil nilai maksimum dari $R_{i,j}$ untuk semua $j \neq i$. Ini menggambarkan seberapa baik cluster i terpisah dari cluster lainnya.

- Hitung Rata-rata dari Nilai Maksimum tersebut sebagai DBI.

Akhirnya, nilai DBI diperoleh dengan menghitung rata-rata dari semua nilai maksimum $R_{i,j}$ tersebut.

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} R_{i,j} \quad (38)$$

2. Interpretasi Nilai DBI

- Nilai DBI yang lebih kecil menunjukkan kualitas clustering yang lebih baik, artinya cluster lebih rapat dan terpisah jelas dari yang lain.
- Sebaliknya, nilai DBI yang lebih besar menunjukkan hasil clustering yang buruk karena antar cluster terlalu berdekatan atau data dalam cluster terlalu tersebar.

3. Contoh Hasil Evaluasi

Berikut ini adalah contoh hasil evaluasi menggunakan DBI untuk clustering dengan $k=4$:

- Hitung cluster tiap cluster (S_i)

Rumus:

$$S_i = \frac{1}{|C_i|} \sum_{x \in C_i} d(x, c_i) \quad (39)$$

Data dari iterasi 4:

Cluster 0 (6 anggota)

S0

$$\begin{aligned} &= \frac{0,55896033 + 0,279472015 + 1,339565611 + 0,360865932 + 0,511230853 + 1,00374149}{6} \\ &= \frac{4,053836231}{6} = 0,675639371 \end{aligned}$$

S1 = 0

S2 = 0,578160514

S3 = 1,255034127

Table 15. Scatter Tiap Cluster tahun 2019

Cluster	Anggota	Scatter (S_i)
0	6	0,675639371

1	1	0
2	3	0,578160514
3	7	1,255034127

- Hitung jarak antar centroid ($M_{i,j}$)

Rumus:

$$M_{i,j} = \sqrt{\sum_{k=1}^m (c_{i,k} - c_{j,k})^2} \quad (40)$$

Centroid akhir iterasi ke 4:

Cluster 0 (-0,865506812. 0,685523041. -0,394399598. -0,513230005)

Cluster 1 (2,965943182. -2,384331791. 3,515653493. 2,609858532)

Cluster 2 (-0,12614793. 0,560784392. -0,453792288. -0,846471563)

Cluster 3 (0,372220212. -0,487308518. 0,030302994. 0,429848027)

- Hitung $M_{0,1}$ (Jarak C0 ke C1)

$$\begin{aligned}
 M_{0,1} &= \sqrt{(C_{0,1} - C_{1,1})^2 + (C_{0,2} - C_{1,2})^2 + (C_{0,3} - C_{1,3})^2 + (C_{0,4} - C_{1,4})^2} \\
 M_{0,1} &= \sqrt{(-0,865506812 - 2,965943182)^2 + (0,685523041 - (-2,384331791))^2 + \\
 &\quad (-0,394399598 - 3,515653493)^2 + (-0,513230005 - 2,609858532)^2} \\
 &= \sqrt{(-3,831449994)^2 + (3,069854832)^2 + (-3,910053091)^2 + (-3,123088537)^2} \\
 &= \sqrt{14,680009056 + 9,424008689 + 15,288515174 + 9,753682009} \\
 M_{0,1} &= \sqrt{49.147276080} = 7,010436144 \\
 M_{0,2} &= \sqrt{0.676789055} = 0,822671693 \\
 M_{0,3} &= \sqrt{3.977287036} = 1,994309534 \\
 M_{1,2} &= \sqrt{45.933563392} = 6,777717485 \\
 M_{1,3} &= \sqrt{27.231073914} = 5,217874092 \\
 M_{2,3} &= \sqrt{3.210212884} = 1,791716194
 \end{aligned}$$

Table 16. Jarak antar centroid ($M_{i,j}$) tahun 2019

Pasangan (i,j)	($M_{i,j}$)
C0 – C1	7,010436144
C0 – C2	0,822671693
C0 – C3	1,994309534
C1 – C2	6,777717485
C1 – C3	5,217874092
C2 – C3	1,791716194

- Hitung rasio antar cluster ($R_{i,j}$)

Rumus:

$$R_{i,j} = \frac{S_i + S_j}{M_{i,j}} \quad (41)$$

Cluster 0 & 1

$$R_{0,1} = \frac{S_0 + S_1}{M_{0,1}} = \frac{0,675639371 + 0}{7.010436144} = 0,096376224$$

Cluster 0 & 2

$$= 1,524058619$$

Cluster 0 & 3

$$= 0,968091194$$

Cluster 1 & 2

$$= 0,085303129$$

Cluster 1 & 3

$$= 0,240525950$$

Cluster 2 & 3

$$= 1,023150121$$

Table 17. Rasio Antar Cluster ($R_{ij} = (S_i + S_j) / M_{ij}$) tahun 2019

Pasangan (i,j)	Perhitungan	$R(i,j)$
C0 – C1	$(0,675639371+0) / 7.010436144$	0,096376224
C0 – C2	$(0,675639371+1,524058619) / 0,822671693$	1,524058619
C0 – C3	$(0,675639371+1,255034127) / 1,994309534$	0,968091194
C1 – C2	$(0+0,578160514) / 6,777717485$	0,085303129
C1 – C3	$(0+1,255034127) / 5,217874092$	0,240525950
C2 – C3	$(0,578160514+1,255034127) / 1,791716194$	1,023150121

- Nilai Maksimum per Cluster (D_i)

Rumus:

$$D_i = \max_{j \neq i} (R_{i,j}) \quad (42)$$

Hitung detail per cluster

Cluster 0 dibandingkan dengan C1, C2, C3 → ambil nilai R yang melibatkan C0:

$$R_{0,1} = 0,096376224$$

$$R_{0,2} = 1,524058619$$

$$R_{0,3} = 0,968091194$$

$$D_0 = \max(0,096376224.1,524058619.0,968091194) = 1,524058619$$

Cluster 1 dibandingkan dengan C0, C2, C3 → ambil nilai R yang melibatkan C1:

$$D_1 = \max(0,096376224.0,085303129.0,240525950) = 0,240525950$$

Cluster 2 dibandingkan dengan C0, C1, C3 → ambil nilai R yang melibatkan C2:

$$D_2 = \max(1,524058619.0,085303129.1,023150121) = 1,524058619$$

Cluster 3 dibandingkan dengan C0, C1, C2 → ambil nilai R yang melibatkan C3:

$$D_3 = \max(0,968091194.0,240525950.1,023150121) = 1,023150121$$

Table 18. Nilai Maksimum per Cluster (D_i) tahun 2019

Cluster	Nilai ($R_{i,j}$) terbesar	D_i
C0	$\max(0,096376224.1,524058619.0,968091194)$	1,524058619
C1	$\max(0,096376224.0,085303129.0,240525950)$	0,240525950
C2	$\max(1,524058619.0,085303129.1,023150121)$	1,524058619
C3	$\max(0,968091194.0,240525950.1,023150121)$	1,023150121

- *Davies-Bouldin Index* (DBI) akhir

Rumus:

$$DBI = \frac{1}{k} \sum_{i=1}^k D_i \quad (43)$$

$$DBI = \frac{D_0 + D_1 + D_2 + D_3}{4}$$

$$\begin{aligned}
 DBI &= \frac{1,524058619 + 0,240525950 + 1,524058619 + 1,023150121}{4} \\
 &= 1,077948327
 \end{aligned}$$

Berdasarkan hasil perhitungan manual *Davies-Bouldin Index* (DBI) pada data tahun 2019 dengan jumlah cluster optimal $k=4$, diperoleh nilai DBI sebesar 1,077948327. Nilai ini menunjukkan bahwa kualitas clustering masih kurang optimal karena DBI yang baik seharusnya mendekati nol. Dengan kata lain, masih terdapat beberapa cluster yang letaknya berdekatan sehingga pemisahan antar cluster belum sepenuhnya jelas.

C. Metode Silhouette Coefisient

Metode Silhouette digunakan untuk mengevaluasi kualitas hasil clustering dengan cara mengukur seberapa mirip sebuah data dengan cluster-nya sendiri dibandingkan dengan cluster lain. Evaluasi ini membantu dalam menilai kohesi (keserupaan dalam cluster) dan separasi (perbedaan antar cluster) secara

bersamaan, serta untuk menentukan jumlah cluster (k) yang paling optimal. Silhouette adalah metode evaluasi internal yang memberikan nilai pada setiap data berdasarkan jaraknya dengan anggota dalam cluster yang sama dan jaraknya terhadap anggota cluster lain yang paling dekat. Skor *Silhouette* untuk sebuah titik data i dihitung menggunakan rumus:

$$s(i) = \frac{b(i) - a(i)}{\max \{a(i), b(i)\}} \quad (44)$$

Keterangan:

- $a(i)$ = Rata-rata jarak antara titik i dengan semua titik lain dalam cluster yang sama
- $b(i)$ = Rata-rata jarak antara titik i dengan semua titik dalam cluster terdekat (cluster selain tempat titik i berada, yang paling dekat)

Nilai Silhouette $s(i)$ berada pada rentang:

- +1 = Data sangat cocok dengan cluster-nya dan jauh dari cluster lain
- 0 = Data berada di antara dua cluster
- 1 = Data lebih cocok dimasukkan ke cluster lain

1. Langkah-Langkah Perhitungan Skor Silhouette

- Hitung nilai $a(i)$ = Rata-rata jarak antara data i dan semua anggota dalam cluster-nya sendiri.
- Hitung nilai $b(i)$ = Rata-rata jarak data i ke semua titik dalam cluster lain yang terdekat.
- Hitung nilai Silhouette untuk setiap data i menggunakan rumus di atas.
- Hitung rata-rata skor Silhouette seluruh data untuk mendapatkan skor keseluruhan cluster.

2. Interpretasi Nilai Silhouette

Nilai rata-rata Silhouette seluruh data (*mean Silhouette score*) digunakan untuk menilai kualitas clustering:

Contoh:

Jika rata-rata skor Silhouette untuk hasil clustering dengan $k=3$ adalah 0.65, maka kualitas cluster tergolong cukup baik, artinya data cukup rapat dalam cluster masing-masing dan cukup terpisah dari cluster lainnya.

3. Implementasi dalam Penelitian

Tahap perhitungan Silhouette tahun 2019

Rumus

Untuk setiap kabupaten/kota i :

- Hitung rata-rata jarak ke cluster sendiri $a(i)$:

$$a(i) = \frac{1}{|C_i| - 1} \sum_{x \in C_i} d(i, x) \quad (45)$$

Misalnya kita ambil Kabupaten Ogan Komering Ilir (*Cluster 0*):

Data Ogan Komering Ilir

(-0,796932211. 0,36450446. 0,051792638. -0,43843874)

Anggota cluster 0 (Ogan Komering Ilir, Musi Rawas, Ogan Komering Ulu Selatan, Ogan Ilir, Empat Lawang dan Kota Pagar Alam)

Data Musi Rawas

(-0,834336539. 0,482822737. -0,215716033. -0,449059984)

Hitung jarak *Euclidean*

$$d(i, j) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2 + (x_4 - y_4)^2}$$

$$\begin{aligned} d &= \sqrt{(-0,796932211 - (-0,834336539))^2 + (0,36450446 - 0,482822737)^2 +} \\ &\quad \sqrt{(0,051792638 - (-0,215716033))^2 + (-0,43843874 - (-0,449059984))^2} \\ &= \sqrt{(0,037404328)^2 + (-0,118318277)^2 + (0,267508671)^2 + (0,010621244)^2} \\ &= \sqrt{0,001399083 + 0,013999214 + 0,071560889 + 0,000112810} \\ &= \sqrt{0,087071996} = 0,295079643 \end{aligned}$$

Ogan Komering Ilir, Ogan Komering Ulu Selatan

$$d = \sqrt{3,068895644} = 1,751826374$$

Ogan Komering Ilir, Ogan Ilir

$$d = \sqrt{0,500589184} = 0,707533985$$

Ogan Komering Ilir, Empat Lawang

$$d = \sqrt{0,775291213} = 0,880506225$$

Ogan Komering Ilir, Kota Pagar Alam

$$d = \sqrt{1,026836455} = 1,013329392$$

Lalu, Hitung Rata-rata:

Jarak Ogan Komering Ilir ke anggota cluster sendiri

$$= \frac{0,295079643 + 1,751826374 + 0,707533985 + 0,880506225 + 1,013329392}{5}$$

$$= 0,929651693$$

- Hitung rata-rata jarak ke cluster lain b(i):

$$b(i) = \min_{C \neq C_i} \frac{1}{|C|} \sum_{x \in C} d(i, x) \quad (46)$$

Untuk tiap cluster selain cluster-nya sendiri, hitung rata-rata jarak dari titik i ke semua anggota cluster tersebut. Pilih yang paling kecil $\rightarrow$ itulah $b(i)$.

Data Ogan Komering Ilir

(-0,796932211. 0,36450446. 0,051792638. -0,43843874)

Cluster asal: C0

Ke Cluster C1

Data Kota Palembang

(2,965943182. -2,384331791. 3,515653493. 2,609858532)

Jarak *Euclidean* = 6.557879248

Karena hanya 1 anggota:

$$d_{C_1} = 6.557879248$$

Ke Cluster C2

Jarak Ogan Komering Ilir, Lahat = 0,640577069

Jarak Ogan Komering Ilir, Penukal Abab Lematang Ilir = 1,443339314

Jarak Ogan Komering Ilir, Musi Rawas Utara = 1,121937539

Rata-rata:

$$d_{C_2} = \frac{0,640577069 + 1,443339314 + 1,121937539}{3} = 1,068617974$$

Ke Cluster C3

Jarak Ogan Komering Ilir, Ogan Komering Ulu = 1,571151284

Jarak Ogan Komering Ilir, Muara Enim = 1,691513109

Jarak Ogan Komering Ilir, Musi Banyuasin = 1,90015419

Jarak Ogan Komering Ilir, Banyu Asin = 2,211145606

Jarak Ogan Komering Ilir, Ogan Komering Ulu Timur = 1,399638819

Jarak Ogan Komering Ilir, Kota Prabumulih = 3,156593938

Jarak Ogan Komering Ilir, Kota Lubuklinggau = 2,529734777

Rata-rata:

$$d_{C_3} = \frac{1,571151284 + 1,691513109 + 1,90015419 + 2,211145606 + 1,399638819}{5}$$

$$= \frac{3,156593938 + 2,529734777}{2} = 2,065704532$$

Ambil Minimum:

$$b(i) = \min(d_{C_1}, d_{C_2}, d_{C_3})$$

$$b(i) = \min(6.557879248, 1,068617974, 2,065704532) = 1,068617974$$

- Hitung silhouette score per titik:

$$s(i) = \frac{b(i) - a(i)}{\max a(i)b(i)} \quad (47)$$

Misal Untuk Ogan Komering Ilir

$a(i) = 0,929651693$

$b(i) = 1,068617974$

maka:

$$s = \frac{1,068617974 - 0,929651693}{\max (0,929651693.1,068617974)} = \frac{0,138966281}{1,068617974} = 0,130042994$$

Langkah selanjutnya, hitungkan semua $s(i)$ (1–17) berdasarkan tabel $a(i)$ dan $b(i)$ lalu ambil rata-rata nya. Berdasarkan hasil perhitungan manual dari 17 kabupaten/kota di Provinsi Sumatera Selatan tahun 2019 dengan jumlah cluster $k=4$, diperoleh nilai rata-rata *Silhouette Coefficient* sebesar 0,17811241. Nilai tersebut berada di antara dua cluster, yang berarti hasil pengelompokan sudah terbentuk namun masih terdapat beberapa data yang berada cukup dekat dengan batas antar cluster. Dengan kata lain, sebagian wilayah memiliki karakteristik yang mirip dengan wilayah di cluster lain, sehingga batas pemisahan antar kelompok belum sepenuhnya kuat.

Meskipun demikian, hasil ini tetap menunjukkan bahwa proses pengelompokan menggunakan algoritma K-Means telah berhasil membentuk empat kelompok wilayah berdasarkan variabel Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM), sesuai dengan pola kedekatan data antar kabupaten/kota di Sumatera Selatan.

Table 19. Hasil Perhitungan $a(i)$, $b(i)$, $s(i)$ tahun 2019

Cluster	Kabupaten/Kota	$a(i)$	$b(i)$	$s(i)$
C0	Ogan Komering Ilir	0,929651693	1,068617974	0,130042994
C0	Musi Rawas	0,784198752	0,98704567	0,205509151
C0	Ogan Komering Ulu Selatan	1,65919948	1,649398961	-0,005906776
C0	Ogan Ilir	0,887093976	0,876879831	-0,011514164
C0	Empat Lawang	0,977633643	1,089350365	0,102553527
C0	Kota Pagar Alam	1,296943463	1,557131305	0,167094349
C1	Kota Palembang	0	5,371243954	1
C2	Lahat	1,060066724	0,957601417	-0,096659299
C2	Penukal Abab Lematang Ilir	0,473415031	1,389515469	0,659294883

C2	Musi Rawas Utara	0,586651693	1,267095167	0,537010551
C3	Ogan Komering Ulu	1,485570218	1,548059458	0,040366176
C3	Muara Enim	1,825641024	1,860583518	0,018780395
C3	Musi Banyuasin	1,919511647	2,306223067	0,167681707
C3	Banyu Asin	2,102849137	2,418279433	0,130435834
C3	Ogan Komering Ulu Timur	1,690528131	1,744127797	0,030731501
C3	Kota Prabumulih	2,276031866	3,031018583	0,249086799
C3	Kota Lubuklinggau	2,107220649	1,482226029	-0,296596666

4. Kelebihan dan Kekurangan Metode Silhouette

Kelebihan:

- Memberikan penilaian numerik yang objektif terhadap kualitas cluster.
- Menggabungkan evaluasi kohesi dan separasi dalam satu metrik.

Kekurangan:

- Perhitungan cukup kompleks dan memerlukan jarak antar semua titik data.
- Kurang akurat jika data memiliki bentuk cluster *non-linier* atau ukuran cluster sangat berbeda.

3.11 Interpretasi Hasil

Hasil dari proses penelitian ini akan menghasilkan pola perubahan cluster tingkat pengangguran di Provinsi Sumatera Selatan dari tahun ke tahun dengan menggunakan algoritma K-Means yang telah di evaluasi untuk memastikan kualitas hasil clustering. Interpretasi hasil ini berdasarkan tahap evaluasi dan visualisasi data.

1. Identifikasi Karakteristik Cluster

Peneliti akan menghitung nilai rata-rata dari masing-masing variabel (TPT, TPAK, PDRB, IPM) dalam setiap cluster. Dengan membandingkan nilai-nilai rata-rata ini, akan diidentifikasi wilayah mana saja yang tergolong dalam kategori pengangguran dengan TPT, TPAK, PDRB, dan IPM yang tinggi, sedang, dan rendah. Cluster dengan rata-rata TPT tinggi akan diinterpretasikan sebagai wilayah dengan masalah pengangguran yang lebih serius.

2. Analisis Distribusi Wilayah per Cluster

Visualisasi bar chart akan digunakan untuk melihat distribusi jumlah kabupaten/kota dalam setiap cluster. Jika ditemukan bahwa mayoritas wilayah masuk dalam satu cluster, hal ini dapat menjadi indikasi bahwa sebagian besar wilayah memiliki karakteristik sosial ekonomi yang serupa. Sebaliknya, jika distribusinya merata, maka menunjukkan adanya keragaman kondisi antar wilayah.

3. Analisis Distribusi Variabel per Cluster

Visualisasi boxplot akan digunakan untuk menunjukkan sebaran nilai dari masing-masing variabel (TPT, TPAK, PDRB, dan IPM) dalam setiap cluster. Melalui boxplot, dapat terlihat nilai tengah (median), rentang, dan potensi keberadaan outlier di masing-masing cluster. Hasil visualisasi ini menunjukkan bahwa setiap cluster memiliki pola distribusi yang berbeda-beda terhadap variabel-variabel yang dianalisis. Sebagai contoh, cluster dengan median TPT yang tinggi cenderung menunjukkan tingkat pengangguran yang lebih serius dibandingkan cluster lainnya. Dengan demikian, boxplot memberikan gambaran yang lebih mendalam mengenai karakteristik statistik masing-masing kelompok wilayah hasil clustering.

4. Analisis Sebaran Spasial

Visualisasi menggunakan peta interaktif berbasis Folium memberikan representasi geografis dari hasil clustering. Setiap wilayah ditandai dengan warna yang berbeda sesuai dengan keanggotaannya dalam cluster tertentu. Representasi ini membantu dalam mengamati pola penyebaran spasial antar cluster di wilayah Provinsi Sumatera Selatan. Peta juga mengungkap adanya wilayah-wilayah yang memiliki karakteristik berbeda dari wilayah sekitarnya, tercermin dari keanggotaannya dalam cluster yang berbeda meskipun secara geografis berdekatan.

5. Perbandingan Hasil Clustering Antar Tahun


Penelitian ini dilakukan terhadap data tahunan dari tahun 2019 hingga 2023. Oleh karena itu, peneliti akan membandingkan hasil clustering dari masing-masing tahun untuk mengamati perubahan atau konsistensi pola pengangguran dan karakteristik sosial ekonomi antar kabupaten/kota di Provinsi Sumatera Selatan. Perbandingan ini dilakukan dengan menganalisis perubahan jumlah dan komposisi anggota dalam setiap cluster dari tahun ke tahun. Jika sebuah wilayah berpindah dari cluster pengangguran tinggi ke cluster yang lebih rendah, maka hal ini dapat mengindikasikan adanya perbaikan kondisi ekonomi dan sosial. Sebaliknya, jika sebuah wilayah berpindah ke cluster dengan kondisi yang lebih buruk, maka ini menjadi perhatian dalam perumusan kebijakan.

3.12 Visualisasi

Visualisasi hasil langkah penting dalam mendukung pemahaman terhadap pola pengelompokan yang dihasilkan oleh algoritma K-Means. Dalam penelitian ini, beberapa bentuk visualisasi akan diterapkan untuk memberikan gambaran visual mengenai hasil clustering yang diperoleh.

a. Bar Chart


Bar chart akan digunakan untuk menampilkan jumlah kabupaten/kota dalam masing-masing cluster. Visualisasi ini akan memperlihatkan distribusi anggota cluster secara kuantitatif.



Gambar 15. Contoh Visualisasi Bar Chart Jumlah Kab/Kota per Cluster

b. Boxplot

Boxplot akan digunakan untuk menggambarkan distribusi nilai masing-masing variabel (TPT, TPAK, PDRB, dan IPM) di dalam setiap cluster yang terbentuk. Visualisasi ini memberikan informasi yang lebih mendalam tentang karakteristik internal dari masing-masing cluster.




Gambar 16. Boxplot distribusi tiap fitur berdasarkan cluster

c. Map (Peta)

Visualisasi peta interaktif berbasis Folium akan digunakan untuk menampilkan hasil pengelompokan wilayah kabupaten/kota di Provinsi Sumatera Selatan dalam bentuk polygon area yang diberi warna sesuai dengan cluster masing-masing. Warna pada peta berfungsi sebagai pembeda keanggotaan cluster, misalnya biru untuk Cluster 0, oranye untuk Cluster 1, hijau untuk Cluster 2, dan merah untuk Cluster 3. Setiap wilayah juga dilengkapi tooltip yang memuat informasi nama Kabupaten/kota, nomor cluster, serta ringkasan nilai indikator TPT, TPAK, PDRB, dan IPM sehingga memudahkan pengguna melihat karakteristik wilayah tanpa harus merujuk pada tabel data.

Visualisasi ini akan memberikan konteks geografis terhadap hasil clustering, tidak hanya menunjukkan kemiripan data antar wilayah, tetapi juga bagaimana kemiripan tersebut tersebar di wilayah Provinsi Sumatera Selatan. Melalui peta ini, pola spasial dapat diamati, seperti apakah wilayah dalam cluster yang sama cenderung berdekatan secara geografis atau tersebar acak. Dengan demikian, peta berfungsi sebagai alat bantu analisis yang memperkaya interpretasi hasil clustering karena menghubungkan pola data dengan persebaran geografisnya secara langsung.



Gambar 17. Contoh Visualisasi Map

IV. HASIL DAN PEMBAHASAN

4.1 Package yang digunakan

Dalam penelitian ini, berbagai *package* digunakan untuk mendukung proses pengolahan data, analisis clustering, evaluasi model, dan visualisasi hasil. Adapun *package* yang digunakan dalam penelitian ini adalah sebagai berikut:

1. “*Numpy*” Digunakan sebagai dasar perhitungan numerik, manipulasi array, dan operasi matematis yang mendukung proses komputasi pada normalisasi Z-Score serta perhitungan jarak pada algoritma K-Means. Walaupun tidak diimport secara eksplisit, NumPy digunakan secara internal oleh *Pandas* dan *Scikit-Learn*.
2. “*Pandas*” Digunakan untuk membaca, mengelola, menampilkan, dan memanipulasi data tabular seperti file .xlsx. Pada penelitian ini, *Pandas* dipakai untuk membaca dataset tingkat pengangguran, melakukan seleksi variabel, menampilkan informasi data, serta menggabungkan hasil clustering dengan nama kabupaten/kota.
3. “*matplotlib.pyplot*” Digunakan untuk membuat visualisasi data statis seperti grafik Elbow Method, bar chart, dan boxplot. *Matplotlib* memberikan fleksibilitas dalam pengaturan ukuran grafik, judul, sumbu, serta elemen visual lainnya.
4. “*Seaborn*” Digunakan untuk membuat visualisasi data statistik dengan tampilan yang lebih estetik dan informatif. Dalam penelitian ini, *Seaborn* digunakan untuk membuat countplot distribusi jumlah daerah per cluster serta boxplot penyebaran variabel TPT, TPAK, PDRB, dan IPM berdasarkan cluster.
5. “*sklearn.cluster.KMeans*” Digunakan untuk melakukan analisis klaster menggunakan algoritma K-Means. Package ini menjadi inti proses pembentukan cluster kabupaten/kota berdasarkan variabel TPT, TPAK, PDRB, dan IPM untuk tahun penelitian.
6. “*sklearn.preprocessing.StandardScaler*” Digunakan untuk melakukan normalisasi data menggunakan metode Z-Score agar seluruh variabel berada pada skala yang sebanding. Normalisasi diperlukan karena PDRB memiliki satuan jauh lebih besar dibandingkan variabel lain.
7. “*sklearn.metrics.davies_bouldin_score*” dan “*sklearn.metrics.silhouette_score*” Digunakan untuk mengevaluasi hasil clustering menggunakan *Davies–Bouldin Index (DBI)* dan *Silhouette Coefficient*. Kedua metrik ini berfungsi menilai kualitas pemisahan cluster serta tingkat kemiripan antar cluster.

8. “*GeoPandas*” Digunakan untuk membaca dan memproses data spasial dari file GeoJSON. *GeoPandas* membantu menggabungkan batas wilayah kabupaten/kota dengan hasil cluster sehingga dapat divisualisasikan secara spasial.
9. “*JSON*” Digunakan untuk Digunakan untuk membaca file GeoJSON yang berisi informasi geometri wilayah kabupaten/kota. File ini kemudian diproses menjadi *GeoDataFrame* untuk keperluan pemetaan.
10. “*Folium*” Digunakan untuk membangun peta interaktif berbasis *Leaflet*. Dalam penelitian ini, *Folium* digunakan untuk menampilkan peta cluster tingkat pengangguran Sumatera Selatan lengkap dengan pewarnaan wilayah, tooltip informasi, legenda warna, dan penyimpanan peta dalam format HTML yang dapat dibuka melalui browser.
11. “*folium.features.GeoJsonTooltip*” Digunakan untuk menampilkan label informasi pada peta seperti nama kabupaten/kota, nomor cluster, dan deskripsi cluster dalam bentuk *popup tooltip*.
12. *Pengaturan Display Pandas* Pada penelitian ini dilakukan konfigurasi khusus terhadap tampilan output *Pandas* seperti menampilkan seluruh kolom/baris, mengatur lebar tampilan, dan mengatur presisi angka. Pengaturan ini bertujuan agar hasil tabel analisis dapat ditampilkan dengan jelas tanpa terpotong.

Seluruh *package* yang digunakan dalam penelitian ini berperan penting dalam membangun alur analisis yang sistematis, mulai dari pengolahan data awal, normalisasi, penentuan jumlah cluster optimal, pembentukan cluster menggunakan algoritma K-Means, evaluasi kualitas hasil cluster, hingga penyajian visualisasi dalam bentuk grafik dan peta interaktif. Kombinasi *Pandas*, *Scikit-Learn*, *Seaborn*, *Matplotlib*, *GeoPandas*, dan *Folium* memungkinkan penelitian ini menghasilkan analisis clustering yang lengkap, komprehensif, dan informatif.

4.2 Preprocessing Data

Tahap preprocessing merupakan proses krusial dalam analisis data karena menentukan kualitas hasil akhir dari algoritma K-Means yang digunakan dalam penelitian ini. Preprocessing dilakukan untuk memastikan bahwa data berada dalam kondisi bersih, lengkap, serta memiliki skala yang sebanding sehingga layak digunakan sebagai dasar pembentukan cluster. Tahapan preprocessing pada penelitian ini meliputi: Loading data, Pemeriksaan missing values, Seleksi variabel, dan Normalisasi data menggunakan metode Z-Score. Penjelasan rinci tiap tahapan adalah sebagai berikut.

4.2.1 Loading Data

Data penelitian yang digunakan merupakan data tingkat pengangguran tahun 2019-2023 yang diperoleh dari Badan Pusat Statistik (BPS) Provinsi Sumatera Selatan. Data tersebut berisi empat variabel utama, yaitu Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM), serta satu kolom identitas wilayah yaitu Kabupaten/Kota.

Pembacaan data dilakukan menggunakan fungsi `read_excel()` dari library *Pandas*, ini bertujuan memastikan bahwa seluruh data tertarik ke dalam Python dengan benar dan tidak mengalami kerusakan format atau kehilangan tipe data.

```
df = pd.read_excel('data_pengangguran_2019.xlsx')
```

```
=== Data Awal ===
```

	Kabupaten/Kota	Tahun	TPT	TPAK	PDRB	IPM
0	Ogan Komering Ulu	2019	4.58	68.53	14647.67	69.45
1	Ogan Komering Ilir	2019	2.98	70.96	28752.47	66.96
2	Muara Enim	2019	4.84	70.21	57333.51	68.88
3	Lahat	2019	3.68	71.14	17130.20	67.62
4	Musi Rawas	2019	2.93	71.39	19062.78	66.92
5	Musi Banyuasin	2019	4.15	66.16	65811.00	67.83
6	Banyu Asin	2019	3.94	63.36	28655.74	66.90
7	Ogan Komering Ulu Selatan	2019	2.99	76.82	8785.71	65.43
8	Ogan Komering Ulu Timur	2019	3.46	66.84	14935.85	69.34
9	Ogan Ilir	2019	3.29	72.61	11159.40	67.22
10	Empat Lawang	2019	2.66	71.72	4991.08	65.10
11	Penukal Abab Lematang Ilir	2019	4.14	73.49	7083.68	64.33
12	Musi Rawas Utara	2019	3.81	70.39	7103.69	64.32
13	Kota Palembang	2019	8.01	60.97	154220.32	78.44
14	Kota Prabumulih	2019	6.12	69.30	7791.06	74.40
15	Kota Pagar Alam	2019	2.48	69.26	2791.62	68.44
16	Kota Lubuklinggau	2019	4.71	70.65	6643.68	74.81

Gambar 18. Data Awal tahun 2019

Pada tahap ini, data ditransformasikan dari format Excel menjadi DataFrame sehingga dapat diolah secara komputasional. Memahami struktur awal data sangat penting, sebab penyusunan cluster tidak hanya membutuhkan nilai numerik, tetapi juga keterhubungan setiap variabel dengan kondisi sosial ekonomi kabupaten/kota. Apabila terjadi kesalahan atau ketidaksesuaian struktur data pada tahap ini, maka akan berdampak langsung pada kualitas hasil cluster.

4.2.2 Pemeriksaan Missing Values

Tahap berikutnya adalah memeriksa apakah terdapat nilai kosong (*missing values*) pada setiap kolom dalam dataset. Missing values sangat berpengaruh terhadap hasil clustering. K-Means tidak dapat memproses data yang tidak lengkap, karena perhitungan jarak *Euclidean* membutuhkan nilai numerik untuk semua variabel. Pemeriksaan dilakukan menggunakan fungsi:

```
df.isnull().sum()
```

```
=== Missing Values per Kolom ===
Kabupaten/Kota      0
Tahun                0
TPT                  0
TPAK                  0
PDRB                  0
IPM                   0
dtype: int64
```

Gambar 19. Missing Values tahun 2019

Hasil pemeriksaan menunjukkan bahwa seluruh variabel memiliki nilai lengkap tidak ada (*missing values*). Hal ini menguntungkan karena analisis dapat langsung dilakukan tanpa perlu melakukan imputasi, interpolasi, ataupun penghapusan data. Kelengkapan data memperkuat reliabilitas penelitian karena setiap kabupaten/kota memiliki informasi lengkap terkait karakteristik tenaga kerja dan tingkat kesejahteraan masyarakat.

4.2.3 Seleksi Variabel Penelitian

Tidak semua kolom dalam dataset digunakan dalam proses clustering. Seperti kolom tahun tidak digunakan karena tidak mengandung nilai data dan hanya sebagai penanda periode waktu. sehingga perlu dilakukan seleksi variabel untuk mengambil variabel yang benar-benar relevan terhadap tujuan penelitian. Variabel yang dipilih dan digunakan dalam pembentukan cluster adalah:

1. Tingkat Pengangguran Terbuka (TPT) Menggambarkan persentase penduduk yang belum terserap dalam lapangan kerja.
2. Tingkat Partisipasi Angkatan Kerja (TPAK) Menggambarkan tingkat partisipasi penduduk usia kerja dalam kegiatan ekonomi.
3. Produk Domestik Regional Bruto (PDRB) Menggambarkan tingkat aktivitas ekonomi daerah dalam satuan miliar rupiah.
4. Indeks Pembangunan Manusia (IPM) Mencerminkan kualitas hidup masyarakat dari aspek pendidikan, kesehatan, dan ekonomi.

Seleksi variabel dilakukan dengan kode:

```
features = ["TPT", "TPAK", "PDRB", "IPM"]
data_selected = df[features]
```

===	Data Setelah Seleksi Variabel				===
	TPT	TPAK	PDRB	IPM	
0	4.58	68.53	14647.67	69.45	
1	2.98	70.96	28752.47	66.96	
2	4.84	70.21	57333.51	68.88	
3	3.68	71.14	17130.20	67.62	
4	2.93	71.39	19062.78	66.92	
5	4.15	66.16	65811.00	67.83	
6	3.94	63.36	28655.74	66.90	
7	2.99	76.82	8785.71	65.43	
8	3.46	66.84	14935.85	69.34	
9	3.29	72.61	11159.40	67.22	
10	2.66	71.72	4991.08	65.10	
11	4.14	73.49	7083.68	64.33	
12	3.81	70.39	7103.69	64.32	
13	8.01	60.97	154220.32	78.44	
14	6.12	69.30	7791.06	74.40	
15	2.48	69.26	2791.62	68.44	
16	4.71	70.65	6643.68	74.81	

Gambar 20. Seleksi Variabel tahun 2019

Pemilihan variabel yang tepat memungkinkan proses clustering menghasilkan kelompok yang benar-benar merepresentasikan kondisi sosial ekonomi kabupaten/kota,

4.2.4 Normalisasi Data dengan Metode Z-Score

Tahap terakhir dalam preprocessing adalah normalisasi data. Normalisasi dilakukan karena variabel TPT, TPAK, IPM, dan terutama PDRB memiliki skala angka yang berbeda sangat jauh. Misalnya, PDRB memiliki satuan ribuan hingga ratusan ribu miliar, sedangkan TPT hanya memiliki nilai dalam satuan persentase. Perbedaan skala yang terlalu besar dapat menyebabkan algoritma K-Means lebih condong mengikuti variabel berskala besar, sehingga cluster yang dihasilkan tidak mencerminkan kondisi sebenarnya.

Proses normalisasi dilakukan menggunakan **StandardScaler()**:

```
scaler = StandardScaler()
data_normalized = scaler.fit_transform(data_selected)
```

Hasil normalisasi kemudian dikonversi ke DataFrame baru dan ditambahkan identitas wilayah:

```
df_normalized = pd.DataFrame(data_normalized, columns=features)
df_normalized["Kabupaten/Kota"] = df["Kabupaten/Kota"].values
```

=== Data Setelah Normalisasi Z-Score ===					Kabupaten/Kota
	TPT	TPAK	PDRB	IPM	
0	0.400006	-0.304131	-0.337606	0.222734	Ogan Komering Ulu
1	-0.796932	0.364504	0.051793	-0.438439	Ogan Komering Ilir
2	0.594509	0.158135	0.840845	0.071381	Muara Enim
3	-0.273272	0.414033	-0.269070	-0.263188	Lahat
4	-0.834337	0.482823	-0.215716	-0.449060	Musi Rawas
5	0.078329	-0.956258	1.074888	-0.207427	Musi Banyuasin
6	-0.078769	-1.726702	0.049122	-0.454371	Banyu Asin
7	-0.789451	1.976935	-0.499441	-0.844701	Ogan Komering Ulu Selatan
8	-0.437851	-0.769150	-0.329650	0.193525	Ogan Komering Ulu Timur
9	-0.565025	0.818516	-0.433909	-0.369401	Ogan Ilir
10	-1.036320	0.573625	-0.604201	-0.932327	Empat Lawang
11	0.070848	1.060656	-0.546430	-1.136786	Penukal Abab Lematang Ilir
12	-0.176020	0.207664	-0.545877	-1.139441	Musi Rawas Utara
13	2.965943	-2.384332	3.515653	2.609859	Kota Palembang
14	1.552060	-0.092259	-0.526901	1.537113	Kota Prabumulih
15	-1.170975	-0.103265	-0.664923	-0.045453	Kota Pagar Alam
16	0.497258	0.279205	-0.558577	1.645981	Kota Lubuklinggau

Gambar 21. Normalisasi Z-Score tahun 2019

Normalisasi Z-Score memastikan bahwa seluruh variabel berada pada skala yang sama, yaitu memiliki rata-rata 0 dan standar deviasi 1. Dengan demikian, tidak ada variabel yang mendominasi perhitungan jarak dalam algoritma K-Means.

4.3 Proses K-Means Clustering

Tahap ini merupakan inti dari penelitian, yaitu proses pengelompokan kabupaten/kota di Provinsi Sumatera Selatan dari tahun 2019-2023 berdasarkan empat indikator sosial ekonomi, yaitu persentase penduduk yang belum terserap dalam lapangan kerja (TPT), persentase pasokan tenaga kerja yang aktif berpartisipasi dalam perekonomian (TPAK), kemampuan produksi dan aktivitas ekonomi daerah dalam satuan miliar rupiah (PDRB), serta Indeks Pembangunan Manusia (IPM). Proses clustering dilakukan secara sistematis mulai dari pemilihan jumlah cluster optimal hingga pembentukan cluster final menggunakan algoritma K-Means.


4.3.1 Penentuan Jumlah Cluster Optimal (Elbow Method)

Penentuan jumlah cluster optimal dilakukan menggunakan *Elbow Method*. Metode ini melihat perubahan nilai *inertia* untuk setiap nilai *k*. *Inertia* merupakan total jarak setiap data terhadap centroid cluster-nya. Nilai *inertia* yang semakin kecil menunjukkan semakin kompaknya cluster.


```
inertia = []
K_range = range(1, 10)

for k in K_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(df_normalized[features])
```


```
inertia.append(kmeans.inertia_)
```




Gambar 22. Grafik Elbow tahun 2019




Gambar 23. Grafik Elbow tahun 2020



Gambar 24. Grafik Elbow tahun 2021



Gambar 25. Grafik Elbow tahun 2022



Gambar 26. Grafik Elbow tahun 2023

Pemilihan jumlah cluster pada titik *elbow* bertujuan memperoleh cluster yang tidak terlalu sedikit (terlalu umum) dan tidak terlalu banyak (terlalu kompleks). Berdasarkan Grafik Elbow bahwa tahun 2019-2022 $k=4$ menunjukkan titik siku yang jelas, sehingga dipilih sebagai jumlah cluster optimal. Namun, berbeda dengan tahun-tahun sebelumnya pada tahun 2023 grafik elbow menunjukkan $k=3$ sebagai jumlah cluster optimal, sehingga perlu evaluasi lanjutan menggunakan *Davies–Bouldin Index* (DBI) dan *Silhouette Coefficient* untuk memperkuat hasil penentuan jumlah cluster optimal.

4.3.2 Evaluasi Davies–Bouldin Index (DBI) dan Silhouette Coefficient

Untuk memvalidasi pilihan jumlah cluster, dilakukan evaluasi menggunakan dua metrik:

1. *Davies–Bouldin Index* (DBI)

Mengukur tingkat kemiripan antar cluster. Nilai semakin kecil menunjukkan cluster semakin terpisah dengan baik.

2. *Silhouette Coefficient*

Mengukur seberapa baik objek berada dalam cluster-nya. Nilai mendekati 1 menandakan kualitas cluster yang baik.


```

for k in range(2, 11):
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = kmeans.fit_predict(df_normalized[features])

    dbi = davies_bouldin_score(df_normalized[features], labels)
    silhouette = silhouette_score(df_normalized[features], labels)

```

```

=== Evaluasi Nilai K ===

```

	K	Davies-Bouldin Index	Silhouette Score
0	2	0.211202	0.643416
1	3	0.785096	0.342807
2	4	0.697165	0.381596
3	5	0.753483	0.295574
4	6	0.932300	0.242076
5	7	0.658805	0.247136
6	8	0.599308	0.236838
7	9	0.494903	0.219617
8	10	0.475885	0.199315

Gambar 27. Evaluasi DBI dan Silhouette tahun 2019

```

=== Evaluasi Nilai K ===

```

	K	Davies-Bouldin Index	Silhouette Score
0	2	0.248334	0.593936
1	3	0.986599	0.211246
2	4	0.684154	0.334640
3	5	0.617521	0.382756
4	6	0.591703	0.418811
5	7	0.580659	0.438338
6	8	0.531162	0.418984
7	9	0.421716	0.400292
8	10	0.391646	0.406088

Gambar 28. Evaluasi DBI dan Silhouette tahun 2020

```

=== Evaluasi Nilai K ===

```

	K	Davies-Bouldin Index	Silhouette Score
0	2	0.219205	0.633826
1	3	0.756444	0.266686
2	4	0.681659	0.336352
3	5	0.887006	0.289253
4	6	0.679525	0.298636
5	7	0.500537	0.336496
6	8	0.456820	0.312985
7	9	0.386991	0.266371
8	10	0.348776	0.257233

Gambar 29. Evaluasi DBI dan Silhouette tahun 2021

```

=== Evaluasi Nilai K ===
  K  Davies-Bouldin Index  Silhouette Score
0  2          0.262049      0.572388
1  3          0.789184      0.285015
2  4          0.626850      0.321176
3  5          0.615166      0.336872
4  6          0.647405      0.329882
5  7          0.579446      0.310160
6  8          0.718734      0.269470
7  9          0.628160      0.245856
8  10         0.525418      0.230539

```

Gambar 30. Evaluasi DBI dan Silhouette tahun 2022

```

=== Evaluasi Nilai K ===
  K  Davies-Bouldin Index  Silhouette Score
0  2          0.977334      0.436230
1  3          0.508155      0.357621
2  4          0.945057      0.243686
3  5          0.690383      0.325760
4  6          0.755273      0.275308
5  7          0.719733      0.259339
6  8          0.662583      0.256674
7  9          0.547798      0.265166
8  10         0.544659      0.230942

```

Gambar 31. Evaluasi DBI dan Silhouette tahun 2023

1. Pada tahun 2019, DBI terendah berada pada $k=2$ (0.2112) dan Silhouette tertinggi juga pada $k=2$ (0.6434). Namun, $k=2$ dianggap terlalu sederhana karena hanya membagi wilayah menjadi dua kelompok sehingga kurang mampu menangkap variasi antar kabupaten/kota.
 - DBI $k=4$ (0.6971), berada dalam rentang stabil dibandingkan DBI lain.
 - Silhouette $k=4$ (0.3816), lebih tinggi dibandingkan Silhouette lain.

Sehingga, $k=4$ dipilih karena memberikan keseimbangan terbaik antara pemisahan cluster dan segmentasi wilayah yang lebih detail.
2. Pada tahun 2020, DBI cenderung menurun pada k yang lebih besar, dan Silhouette tertinggi berada pada $k=7$ (0.4383). Namun, jumlah cluster yang terlalu banyak $k=7$ akan menghasilkan pembagian yang terlalu terpecah dan kurang relevan dalam analisis.
 - DBI $k=4$ (0.6842), lebih rendah dibandingkan $k=3$ (0.9866).
 - Silhouette $k=4$ (0.3346), lebih baik dibandingkan $k=3$.

Dengan demikian, $k=4$ memberikan struktur cluster yang seimbang tidak terlalu sedikit dan tidak terlalu banyak sehingga dipilih sebagai jumlah cluster optimal tahun 2020.

3. Pada tahun 2021, $k=2$ memiliki Silhouette tertinggi (0.6338), namun kembali dianggap terlalu sederhana untuk menggambarkan perbedaan karakteristik wilayah. Sementara itu, DBI terbaik untuk struktur yang tidak terlalu sederhana dicapai oleh $k=4$ (0.6816), lebih baik dibandingkan DBI lain.

- DBI $k=4$ (0.6816), berada dalam rentang stabil dibandingkan DBI lain.
- Silhouette $k=4$ (0.3364), lebih baik dibandingkan Silhouette lain.

Oleh karena itu, $k=4$ dipilih sebagai jumlah cluster optimal tahun 2021 karena memberikan keseimbangan antara pemisahan cluster dan relevansi segmentasi wilayah.

4. Pada tahun 2022, Silhouette tertinggi berada pada $k=2$ (0.5724), namun seperti tahun sebelumnya, $k=2$ dinilai terlalu sederhana untuk keperluan analisis. DBI terbaik diperoleh pada $k=4$ (0.6268), lebih baik dibandingkan $k=3$ (0.7891).

- DBI $k=4$ (0.6268), lebih rendah dari $k=3$
- Silhouette $k=4$ (0.3212), lebih baik dibandingkan $k=3$ dan masih dalam rentang stabil.

Dengan kombinasi DBI dan Silhouette yang konsisten, $k=4$ dipilih sebagai jumlah cluster optimal tahun 2022.

5. Pada tahun 2023, pola evaluasi berbeda dari tahun sebelumnya. DBI terbaik terdapat pada $k=3$ (0.5082), menunjukkan pemisahan cluster yang paling baik. Silhouette tertinggi berada pada $k=2$ (0.4362), namun $k=2$ kembali dianggap terlalu sederhana untuk kebutuhan segmentasi wilayah.

- DBI $k=3$ (0.5082), lebih stabil dibandingkan seluruh DBI lain.
- Silhouette $k=3$ (0.3576), lebih baik dari silhouette lain.

Sehingga, $k=3$ dipilih sebagai jumlah cluster optimal tahun 2023 karena memberikan keseimbangan terbaik antara pemisahan cluster dan kekompakan struktur tanpa menyederhanakan wilayah secara berlebihan.

4.3.3 Pembentukan Cluster Final Menggunakan K-Means

Setelah jumlah cluster ditentukan, K-Means dijalankan menggunakan $k=4$ untuk tahun 2019-2022 dan $k=3$ untuk tahun 2023.

```
kmeans_final = KMeans(n_clusters=4, random_state=42, n_init=10)
labels_final = kmeans_final.fit_predict(df_normalized[features])
```

Hasil label cluster kemudian digabungkan dengan nama kabupaten/kota sehingga membentuk tabel **df_clustered**.

=== Hasil Clustering Tahun 2019 ===					
TPT	TPAK	PDRB	IPM	Cluster	Kabupaten/Kota
0.400006	-0.304131	-0.337606	0.222734	0	Ogan Komering Ulu
-0.796932	0.364504	0.051793	-0.438439	2	Ogan Komering Ilir
0.594509	0.158135	0.840845	0.071381	0	Muara Enim
-0.273272	0.414033	-0.269070	-0.263188	2	Lahat
-0.834337	0.482823	-0.215716	-0.449060	2	Musi Rawas
0.078329	-0.956258	1.074888	-0.207427	0	Musi Banyuasin
-0.078769	-1.726702	0.049122	-0.454371	0	Banyu Asin
-0.789451	1.976935	-0.499441	-0.844701	2	Ogan Komering Ulu Selatan
-0.437851	-0.769150	-0.329650	0.193525	0	Ogan Komering Ulu Timur
-0.565025	0.818516	-0.433909	-0.369401	2	Ogan Ilir
-1.036320	0.573625	-0.604201	-0.932327	2	Empat Lawang
0.070848	1.060656	-0.546430	-1.136786	2	Penukal Abab Lematang Ilir
-0.176020	0.207664	-0.545877	-1.139441	2	Musi Rawas Utara
2.965943	-2.384332	3.515653	2.609859	1	Kota Palembang
1.552060	-0.092259	-0.526901	1.537113	3	Kota Prabumulih
-1.170975	-0.103265	-0.664923	-0.045453	2	Kota Pagar Alam
0.497258	0.279205	-0.558577	1.645981	3	Kota Lubuklinggau

Gambar 32. Hasil Clustering tahun 2019

=== Hasil Clustering Tahun 2020 ===					
TPT	TPAK	PDRB	IPM	Cluster	Kabupaten/Kota
0.587154	0.100916	-0.337468	0.171492	1	Ogan Komering Ulu
-0.893217	-1.415375	0.060169	-0.548142	0	Ogan Komering Ilir
-0.016968	-0.491159	0.834784	-0.015499	0	Muara Enim
-0.408831	0.473491	-0.271122	-0.117495	1	Lahat
-0.893217	0.476379	-0.216002	-0.522644	1	Musi Rawas
-0.076836	0.132686	1.066889	-0.301653	1	Musi Banyuasin
-0.109491	-1.747515	0.054913	-0.604807	0	Banyu Asin
-0.898660	0.381069	-0.497968	-0.873961	1	Ogan Komering Ulu Selatan
-0.610205	0.447497	-0.324629	0.134661	1	Ogan Komering Ulu Timur
-0.011525	-0.037716	-0.433235	-0.171326	1	Ogan Ilir
-0.719056	1.657642	-0.604748	-0.922126	1	Empat Lawang
-0.648303	2.180401	-0.548562	-1.148783	1	Penukal Abab Lematang Ilir
1.060656	0.496596	-0.546793	-0.967457	1	Musi Rawas Utara
2.682534	-1.369164	3.518599	2.602385	2	Kota Palembang
0.930035	-0.216783	-0.528303	1.500267	3	Kota Prabumulih
-1.323178	-1.097676	-0.666654	0.058164	0	Kota Pagar Alam
1.349110	0.028712	-0.559872	1.726924	3	Kota Lubuklinggau

Gambar 33. Hasil Clustering tahun 2020

=== Hasil Clustering Tahun 2021 ===					
TPT	TPAK	PDRB	IPM	Cluster	Kabupaten/Kota
0.142040	-0.139390	-0.352070	0.184974	2	Ogan Komering Ulu
-0.647664	-0.235548	0.048466	-0.512556	2	Ogan Komering Ilir
0.374901	-0.273325	1.038677	-0.053207	2	Muara Enim
-0.348994	-0.283628	-0.251191	-0.146778	2	Lahat
-0.764095	0.056362	-0.231121	-0.532404	2	Musi Rawas
-0.151568	-0.407260	1.118085	-0.251691	2	Musi Banyuasin
-0.227501	-1.657324	0.042187	-0.563595	2	Banyu Asin
-0.536296	1.993273	-0.512225	-0.932208	0	Ogan Komering Ulu Selatan
-0.561607	0.324233	-0.338813	0.153783	2	Ogan Komering Ulu Timur
-0.617291	-0.647657	-0.447167	-0.209159	2	Ogan Ilir
-0.951397	0.664222	-0.619147	-0.954892	0	Empat Lawang
-0.343932	0.949264	-0.563968	-1.164718	0	Penukal Abab Lematang Ilir
1.230413	-0.232114	-0.558366	-0.906688	2	Musi Rawas Utara
2.946501	-2.210237	3.427130	2.643340	1	Kota Palembang
0.795064	-0.328273	-0.542818	1.463778	3	Kota Prabumulih
-1.341186	1.316728	-0.680860	0.094238	0	Kota Pagar Alam
1.002614	1.110674	-0.576798	1.687781	3	Kota Lubuklinggau

Gambar 34. Hasil Clustering tahun 2021

=== Hasil Clustering Tahun 2022 ===					
TPT	TPAK	PDRB	IPM	Cluster	Kabupaten/Kota
0.143702	-0.295101	-0.379971	0.156042	1	Ogan Komering Ulu
-0.282314	-0.554708	-0.017524	-0.478796	1	Ogan Komering Ilir
-0.036023	0.320003	1.712092	-0.096193	1	Muara Enim
-0.102589	-0.100981	-0.157154	-0.116031	1	Lahat
-1.500456	-0.491561	-0.276890	-0.515639	1	Musi Rawas
0.150359	-0.009768	1.033093	-0.320086	1	Musi Banyuasin
-0.521949	-1.600152	-0.013089	-0.541146	1	Banyu Asin
-1.560364	0.427588	-0.538794	-1.000270	1	Ogan Komering Ulu Selatan
0.409963	-0.755845	-0.375195	0.133369	1	Ogan Komering Ulu Timur
-1.347356	2.324354	-0.475084	-0.186884	3	Ogan Ilir
-0.388819	0.001926	-0.636690	-0.983266	1	Empat Lawang
0.090450	2.024988	-0.585311	-1.124971	3	Penukal Abab Lematang Ilir
0.742788	0.443959	-0.577599	-0.878404	1	Musi Rawas Utara
2.679833	-1.562731	3.140669	2.644381	2	Kota Palembang
0.716162	0.130560	-0.563211	1.496571	0	Kota Prabumulih
-0.368849	0.453314	-0.692980	0.153208	1	Kota Pagar Alam
1.175461	-0.755845	-0.596362	1.658115	0	Kota Lubuklinggau

Gambar 35. Hasil Clustering tahun 2022

=== Hasil Clustering Tahun 2023 ===					
TPT	TPAK	PDRB	IPM	Cluster	Kabupaten/Kota
0.276126	0.210865	-0.373944	0.166975	1	Ogan Komering Ulu
-0.355373	-0.663645	-0.000314	-0.508468	1	Ogan Komering Ilir
0.128776	0.294902	1.649117	-0.072423	1	Muara Enim
-0.229073	0.767610	-0.165137	-0.123722	1	Lahat
-1.253504	-0.921008	-0.282301	-0.588267	1	Musi Rawas
-0.811455	0.200360	0.983295	-0.365969	1	Musi Banyuasin
-0.271173	-2.412664	0.000587	-0.545517	1	Banyu Asin
-1.351738	0.969823	-0.535161	-1.007212	1	Ogan Komering Ulu Selatan
0.156843	1.224560	-0.364885	0.132775	1	Ogan Komering Ulu Timur
-1.148255	0.397322	-0.470901	-0.163622	1	Ogan Ilir
-0.453606	0.142585	-0.632503	-1.001512	1	Empat Lawang
0.177893	1.975641	-0.583376	-1.084161	1	Penukal Abab Lematang Ilir
0.963758	-0.458805	-0.576300	-0.841914	1	Musi Rawas Utara
2.633721	-1.144231	3.195458	2.603696	2	Kota Palembang
0.921658	-0.857980	-0.560704	1.563458	0	Kota Prabumulih
-0.720239	0.533882	-0.689686	0.189774	1	Kota Pagar Alam
1.335641	-0.259217	-0.593245	1.646107	0	Kota Lubuklinggau

Gambar 36. Hasil Clustering tahun 2023

Algoritma K-Means berhasil mengelompokkan kabupaten/kota berdasarkan kemiripan nilai-nilai TPT, TPAK, PDRB, dan IPM. Karena data telah dinormalisasi, maka kontribusi setiap variabel menjadi seimbang. Dengan demikian, pembentukan cluster tidak dikuasai oleh variabel berskala besar seperti PDRB, dan tetap mempertimbangkan variasi pada TPT, TPAK, dan IPM.

4.3.4 Nilai Rata-Rata Tiap Cluster (Z-Score & Denormalisasi)

Setelah cluster terbentuk, tahap selanjutnya adalah menghitung nilai rata-rata tiap variabel pada setiap cluster. Perhitungan dilakukan dalam dua bentuk, yaitu (1) rata-rata pada data hasil normalisasi Z-Score, dan (2) rata-rata pada data yang telah dikembalikan ke skala awal (denormalisasi). Nilai rata-rata pada data yang sudah dinormalisasi digunakan untuk melihat pola kemiripan secara matematis, sedangkan nilai rata-rata pada data yang sudah didenormalisasi

digunakan untuk menghasilkan interpretasi substantif yang lebih mudah dipahami berdasarkan konteks nyata.

Kode Normalisasi dilakukan sebagai berikut:

```
df_normalized_with_cluster = df_normalized.copy()
df_normalized_with_cluster["Cluster"] = df_clustered["Cluster"].values

cluster_summary_z =
df_normalized_with_cluster.groupby("Cluster")[features].mean()
```

```
=== Rata-rata Tiap Fitur per Cluster (Normalisasi) ===
      TPT      TPAK      PDRB      IPM
Cluster
0      0.111245 -0.719621  0.259520 -0.034831
1      2.965943 -2.384332  3.515653  2.609859
2     -0.619054  0.643943 -0.414197 -0.624311
3      1.024659  0.093473 -0.542739  1.591547
```

Gambar 37. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2019

```
=== Rata-rata Tiap Fitur per Cluster (Normalisasi) ===
      TPT      TPAK      PDRB      IPM
Cluster
0     -0.585714 -1.187931  0.070803 -0.277571
1     -0.261882  0.630896 -0.271364 -0.471929
2      2.682534 -1.369164  3.518599  2.602385
3      1.139573 -0.094036 -0.544087  1.613595
```

Gambar 38. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2020

```
=== Rata-rata Tiap Fitur per Cluster (Normalisasi) ===
      TPT      TPAK      PDRB      IPM
Cluster
0     -0.793203  1.230872 -0.594050 -0.739395
1      2.946501 -2.210237  3.427130  2.643340
2     -0.157137 -0.349565  0.006869 -0.283732
3      0.898839  0.391200 -0.559808  1.575780
```

Gambar 39. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2021

```
=== Rata-rata Tiap Fitur per Cluster (Normalisasi) ===
      TPT      TPAK      PDRB      IPM
Cluster
0      0.945812 -0.312642 -0.579786  1.577343
1     -0.276213 -0.180110 -0.076725 -0.373934
2      2.679833 -1.562731  3.140669  2.644381
3     -0.628453  2.174671 -0.530197 -0.655927
```

Gambar 40. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2022

```

=== Rata-rata Tiap Fitur per Cluster (Normalisasi) ===

```

	TPT	TPAK	PDRB	IPM
Cluster				
0	1.128649	-0.558599	-0.576974	1.604783
1	-0.349359	0.161531	-0.145822	-0.415233
2	2.633721	-1.144231	3.195458	2.603696

Gambar 41. Normalisasi Rata-rata Tiap Fitur per Cluster tahun 2023

Kode denormalisasi dilakukan sebagai berikut:

```

cluster_summary_denorm = pd.DataFrame(
    scaler.inverse_transform(cluster_summary_z.values),
    columns=features,
    index=cluster_summary_z.index
)

```

Hasil ringkasan denormalisasi kemudian menjadi dasar interpretasi kondisi sosial ekonomi setiap cluster.

```

=== Rata-rata Tiap Fitur per Cluster (Denormalisasi) ===

```

	TPT	TPAK	PDRB	IPM
Cluster				
0	4.19	67.02	36276.75	68.48
1	8.01	60.97	154220.32	78.44
2	3.22	71.98	11873.40	66.26
3	5.42	69.97	7217.37	74.61

Gambar 42. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2019

```

=== Rata-rata Tiap Fitur per Cluster (Denormalisasi) ===

```

	TPT	TPAK	PDRB	IPM
Cluster				
0	3.86	66.04	29679.12	69.92
1	4.45	72.34	17221.77	69.23
2	9.86	65.41	155203.91	80.08
3	7.03	69.83	7292.65	76.59

Gambar 43. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2020

```

=== Rata-rata Tiap Fitur per Cluster (Denormalisasi) ===

```

	TPT	TPAK	PDRB	IPM
Cluster				
0	2.72	73.95	6362.59	68.53
1	10.11	63.93	162032.80	80.46
2	3.98	69.35	29625.70	70.14
3	6.06	71.50	7688.20	76.69

Gambar 44. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2021

```

=== Rata-rata Tiap Fitur per Cluster (Denormalisasi) ===
      TPT   TPAK   PDRB   IPM
Cluster
0      5.60  69.83  8448.17  77.42
1      3.76  70.39  31523.77  70.54
2      8.20  64.48  179106.80  81.19
3      3.23  80.46  10722.83  69.55

```

Gambar 45. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2022

```

=== Rata-rata Tiap Fitur per Cluster (Denormalisasi) ===
      TPT   TPAK   PDRB   IPM
Cluster
0      5.34  69.74   9033.92  78.22
1      3.24  72.48  30238.85  71.13
2      7.49  67.51  194569.60  81.72

```

Gambar 46. Denormalisasi Rata-rata Tiap Fitur per Cluster tahun 2023

4.3.5 Daftar Anggota Cluster

Kode berikut digunakan untuk menampilkan anggota tiap cluster:

```

for I in sorted(df_clustered["Cluster"].unique()):
    daerah_cluster=df_clustered[df_clustered["Cluster"]==i]["Kabupaten/Kota"].tolist()

```

```

Cluster 0:
- Ogan Komering Ulu
- Muara Enim
- Musi Banyuasin
- Banyu Asin
- Ogan Komering Ulu Timur

Cluster 1:
- Kota Palembang

Cluster 2:
- Ogan Komering Ilir
- Lahat
- Musi Rawas
- Ogan Komering Ulu Selatan
- Ogan Ilir
- Empat Lawang
- Penukal Abab Lematang Ilir
- Musi Rawas Utara
- Kota Pagar Alam

Cluster 3:
- Kota Prabumulih
- Kota Lubuklinggau

```

Gambar 47. Daftar Anggota Cluster tahun 2019


```

Cluster 0:
- Ogan Komering Ilir
- Muara Enim
- Banyu Asin
- Kota Pagar Alam

Cluster 1:
- Ogan Komering Ulu
- Lahat
- Musi Rawas
- Musi Banyuasin
- Ogan Komering Ulu Selatan
- Ogan Komering Ulu Timur
- Ogan Ilir
- Empat Lawang
- Penukal Abab Lematang Ilir
- Musi Rawas Utara

Cluster 2:
- Kota Palembang

Cluster 3:
- Kota Prabumulih
- Kota Lubuklinggau

```

Gambar 48. Daftar Anggota Cluster tahun 2020

```

Cluster 0:
- Ogan Komering Ulu Selatan
- Empat Lawang
- Penukal Abab Lematang Ilir
- Kota Pagar Alam

Cluster 1:
- Kota Palembang

Cluster 2:
- Ogan Komering Ulu
- Ogan Komering Ilir
- Muara Enim
- Lahat
- Musi Rawas
- Musi Banyuasin
- Banyu Asin
- Ogan Komering Ulu Timur
- Ogan Ilir
- Musi Rawas Utara

Cluster 3:
- Kota Prabumulih
- Kota Lubuklinggau

```

Gambar 49. Daftar Anggota Cluster tahun 2021

```

Cluster 0:
- Kota Prabumulih
- Kota Lubuklinggau

Cluster 1:
- Ogan Komering Ulu
- Ogan Komering Ilir
- Muara Enim
- Lahat
- Musi Rawas
- Musi Banyuasin
- Banyu Asin
- Ogan Komering Ulu Selatan
- Ogan Komering Ulu Timur
- Empat Lawang
- Musi Rawas Utara
- Kota Pagar Alam

Cluster 2:
- Kota Palembang

Cluster 3:
- Ogan Ilir
- Penukal Abab Lematang Ilir

```

Gambar 50. Daftar Anggota Cluster tahun 2022

```

Cluster 0:
- Kota Prabumulih
- Kota Lubuklinggau

Cluster 1:
- Ogan Komering Ulu
- Ogan Komering Ilir
- Muara Enim
- Lahat
- Musi Rawas
- Musi Banyuasin
- Banyu Asin
- Ogan Komering Ulu Selatan
- Ogan Komering Ulu Timur
- Ogan Ilir
- Empat Lawang
- Penukal Abab Lematang Ilir
- Musi Rawas Utara
- Kota Pagar Alam

Cluster 2:
- Kota Palembang

```

Gambar 51. Daftar Anggota Cluster tahun 2023

4.4 Interpretasi Hasil

Pada bagian ini membahas hasil pengelompokan wilayah berdasarkan variabel Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja

(TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM) pada periode 2019–2023 menggunakan algoritma K-Means. Sebelum memasuki interpretasi per tahun, terlebih dahulu ditetapkan identitas masing-masing cluster. Penetapan ini didasarkan pada pola rata-rata seluruh variabel dari tahun 2019-2023 sehingga setiap cluster memiliki karakter yang konsisten pada setiap tahun pengamatan.

4.4.1 Penetapan Identitas Cluster

Penetapan identitas cluster dilakukan untuk memberikan pemaknaan yang jelas terhadap hasil pengelompokan wilayah berdasarkan variabel Tingkat Pengangguran Terbuka (TPT), Tingkat Partisipasi Angkatan Kerja (TPAK), Produk Domestik Regional Bruto (PDRB), dan Indeks Pembangunan Manusia (IPM). Identitas ini ditentukan berdasarkan pola rata-rata indikator pada pusat cluster yang terbentuk setiap tahun. Karena nilai k optimal yang diperoleh berbeda antara tahun 2019–2022 ($k=4$) dan tahun 2023 ($k=3$), maka penetapan identitas cluster juga harus dipisahkan agar tidak menimbulkan kekeliruan dalam interpretasi karakteristiknya.

Pada periode 2019–2022, empat cluster konsisten terbentuk dengan pola pusat cluster yang relatif stabil, sehingga identitas cluster dapat ditetapkan secara seragam. Sementara itu, pada tahun 2023, pengurangan jumlah cluster menjadi tiga kelompok menyebabkan perubahan struktur karakteristik cluster, sehingga identitas cluster tahun 2023 perlu disajikan tersendiri. Pemisahan ini dilakukan untuk memastikan bahwa interpretasi yang diberikan benar-benar sesuai dengan hasil pengelompokan aktual pada setiap tahun.

A. Identitas Cluster Tahun 2019–2022 ($k = 4$)

Pada tahun 2019-2022, hasil evaluasi model (DBI dan Silhouette Score) menunjukkan bahwa empat cluster merupakan struktur relatif stabil dan mampu menangkap variasi sosial ekonomi antar wilayah. Pada periode ini, pola pusat cluster juga cenderung konsisten. Berdasarkan kecenderungan nilai TPT, TPAK, PDRB, dan IPM. Identitas cluster yang terbentuk dapat dilihat pada Tabel 20 berikut.

Table 20. Identitas Cluster tahun 2019–2022

Cluster	Identitas	Karakteristik
Cluster 0	Menengah/Stabil	Seluruh indikator berada pada kisaran menengah, tidak ekstrem, tinggi atau rendah. kondisi sosial ekonomi relatif seimbang dan stabil.

Cluster 1	Produktif	PDRB tinggi dan IPM tinggi, mencerminkan kapasitas ekonomi besar dan kualitas sumber daya manusia baik sehingga mendukung produktivitas wilayah.
Cluster 2	Maju	TPAK tinggi, TPT rendah, serta kemampuan ekonomi dan sumber daya manusia yang kompetitif. menunjukkan struktur sosial ekonomi yang lebih berkembang.
Cluster 3	Ekonomi Terbatas	PDRB paling rendah secara konsisten. mencerminkan kapasitas ekonomi yang kecil meskipun indikator lain berada pada tingkat menengah.

Dengan demikian, periode 2019–2022 menunjukkan pola cluster yang kuat dan stabil, karena setiap cluster mempertahankan karakter khasnya

B. Identitas Cluster Tahun 2023 ($k=3$)

Pada tahun 2023, jumlah cluster optimal berubah menjadi $k=3$, berbeda dari empat tahun sebelumnya. Pengurangan jumlah cluster ini berdampak langsung pada identitas cluster, karena ketika jumlah kelompok berkurang, beberapa karakter yang sebelumnya terpisah kini tergabung menjadi satu kelompok. Hal ini menyebabkan pergeseran identitas cluster, bukan karena kesalahan perhitungan, tetapi karena karakteristik data tahun 2023 menunjukkan pola yang lebih sederhana.

Table 21. Identitas Cluster tahun 2023

Cluster	Identitas	Karakteristik
Cluster 0	Ekonomi Terbatas	PDRB paling rendah secara konsisten. mencerminkan kapasitas ekonomi yang kecil meskipun indikator lain berada pada tingkat menengah.
Cluster 1	Maju	TPAK tinggi, TPT rendah, serta kemampuan ekonomi dan sumber daya manusia yang kompetitif. menunjukkan struktur sosial ekonomi yang lebih berkembang.
Cluster 2	Produktif	PDRB tinggi dan IPM tinggi, mencerminkan kapasitas ekonomi besar dan kualitas sumber daya manusia baik sehingga mendukung produktivitas wilayah.

Dengan demikian, tahun 2023 memiliki struktur cluster yang berbeda karena:

- Identitas Menengah/Stabil tidak lagi muncul sebagai cluster khusus.
- Struktur Maju dan Menengah berbaur sehingga membentuk identitas baru.
- Produktivitas (PDRB dan IPM tinggi) tetap menjadi cluster tersendiri.
- Ekonomi Terbatas tetap menjadi cluster tersendiri.

Perubahan identitas cluster bukan disebabkan oleh perbedaan metode, tetapi merupakan akibat logis dari berkurangnya variasi data dan penyederhanaan jumlah cluster dari empat menjadi tiga. Ini menghasilkan pola baru yang lebih ringkas namun tetap konsisten secara statistik.

4.4.2 Interpretasi Hasil Clustering Tahun 2019

Berikut ini merupakan rata-rata nilai dari masing-masing variabel tingkat pengangguran tahun 2019 berdasarkan pusat cluster yang terbentuk dari proses K-Mens Clustering:

Table 22. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2019

Variabel	Cluster 0	Cluster 1	Cluster 2	Cluster 3
TPT	4,15%	8,01%	3,22%	5,42%
TPAK	67,02%	60,97%	71,98%	69,97%
PDRB	36.276,75 miliar	154.220,32 miliar	11.873,40 miliar	7.217,37 miliar
IPM	68,48%	78,44%	66,26%	74,61%

Berikut adalah kesimpulan yang dapat diambil dari Tabel 21:

- Cluster 0 (Menengah/Stabil)

Menunjukkan karakteristik wilayah dengan kondisi sosial ekonomi yang berada pada tingkat moderat. Identitas ini terlihat dari nilai variabel yang tidak menunjukkan kondisi ekstrem, baik pada aspek ketenagakerjaan, kapasitas ekonomi, maupun kualitas pembangunan manusia. Secara umum, cluster ini mencerminkan wilayah dengan kemampuan pembangunan yang stabil, di mana seluruh indikator berada pada kisaran menengah dan tidak memperlihatkan kecenderungan yang terlalu tinggi ataupun terlalu rendah.

Dalam cluster ini, nilai TPT sebesar 4,15%, TPAK sebesar 67,02%, PDRB sebesar 36.276,75 miliar, dan IPM sebesar 68,48% membentuk pola yang selaras dengan karakter menengah/stabil. Komposisi ini menunjukkan bahwa tekanan pasar tenaga kerja berada pada tingkat rendah, partisipasi angkatan kerja berada

pada kategori cukup, kapasitas ekonomi masih berada pada skala menengah, dan kualitas pembangunan manusia berada pada tingkat sedang. Kondisi ini menegaskan bahwa wilayah dalam cluster 0 termasuk kelompok yang memiliki stabilitas sosial ekonomi tanpa keunggulan yang dominan, namun juga tidak menghadapi tekanan pembangunan yang signifikan.

- Cluster 1 (Produktif)

Menunjukkan karakteristik wilayah dengan potensi produktivitas yang lebih tinggi dibandingkan cluster lainnya. Identitas ini didukung oleh kapasitas ekonomi yang besar dan kualitas pembangunan manusia yang tinggi, sehingga mencerminkan wilayah dengan daya dorong produktivitas yang kuat. Secara umum, cluster ini menggambarkan wilayah yang lebih mampu menggerakkan aktivitas ekonomi dan pembangunan manusia secara lebih efektif.

Dalam cluster ini, nilai PDRB sebesar 154.220,32 miliar dan IPM sebesar 78,44% menjadi penanda utama identitas produktif karena menunjukkan kapasitas ekonomi yang besar dan kualitas SDM yang tinggi. Sementara itu, nilai TPT sebesar 8,01% dan TPAK sebesar 60,97% menggambarkan dinamika ketenagakerjaan yang tetap mendukung aktivitas ekonomi meskipun bukan yang terkuat secara relatif. Komposisi indikator tersebut menegaskan bahwa kekuatan utama cluster ini terletak pada skala ekonomi dan kualitas manusia yang tinggi, sehingga wilayah-wilayah dalam cluster 1 dikategorikan sebagai kelompok dengan potensi produktivitas pembangunan yang lebih besar.

- Cluster 2 (Maju)

Menunjukkan karakteristik wilayah yang termasuk dalam kategori maju, ditandai oleh struktur ketenagakerjaan yang kuat melalui nilai TPAK yang tinggi dan TPT yang rendah. Identitas ini mencerminkan kelompok wilayah yang memiliki kapasitas pembangunan yang baik karena aktivitas pasar tenaga kerja berlangsung lebih efektif serta tekanan pengangguran berada pada tingkat rendah.

Dalam cluster ini, nilai TPT sebesar 3,22% dan TPAK sebesar 71,98% menunjukkan dinamika ketenagakerjaan yang solid, di mana partisipasi tenaga kerja berada pada tingkat tinggi dan tekanan pasar tenaga kerja berada pada tingkat rendah. Nilai PDRB sebesar 11.873,40 miliar dan IPM sebesar 66,26% berada pada tingkat menengah namun tetap selaras dengan karakter wilayah yang sedang berkembang menuju kondisi yang lebih maju. Komposisi indikator tersebut memperlihatkan bahwa wilayah dalam cluster 2 memiliki pondasi pembangunan yang kuat, khususnya pada aspek ketenagakerjaan, sehingga dikategorikan sebagai kelompok wilayah yang lebih maju dibandingkan cluster lainnya.

- Cluster 3 (Ekonomi Terbatas)

Menunjukkan karakteristik wilayah dengan kapasitas ekonomi yang terbatas, ditandai oleh nilai PDRB yang paling rendah dibandingkan seluruh cluster. Identitas ini mencerminkan wilayah yang memiliki keterbatasan dalam aktivitas produksi dan kapasitas pendapatan regional, sehingga membutuhkan penguatan pada aspek ekonomi untuk mendukung pembangunan sosial dan ketenagakerjaan secara lebih optimal.

Dalam cluster ini, nilai PDRB sebesar 7.217,37 miliar menjadi indikator utama yang menunjukkan kapasitas ekonomi yang rendah. Sementara itu, nilai TPT sebesar 5,42%, TPAK sebesar 69,97%, dan IPM sebesar 74,61% menunjukkan bahwa beberapa aspek ketenagakerjaan dan kualitas pembangunan manusia berada pada tingkat menengah. Komposisi nilai tersebut memperlihatkan bahwa kendala utama wilayah dalam cluster 3 bukan pada kualitas SDM atau partisipasi kerja, tetapi pada skala ekonomi yang kecil. Dengan demikian, cluster ini dikategorikan sebagai kelompok wilayah dengan kapasitas ekonomi terbatas dan membutuhkan penguatan ekonomi sebagai prioritas.

4.4.3 Interpretasi Hasil Clustering Tahun 2020

Berikut ini merupakan rata-rata nilai dari masing-masing variabel tingkat pengangguran tahun 2020 berdasarkan pusat cluster yang terbentuk dari proses K-Mens Clustering:

Table 23. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2020

Variabel	Cluster 0	Cluster 1	Cluster 2	Cluster 3
TPT	3,86%	4,45%	9,86%	7,03%
TPAK	66,04%	72,34%	65,41%	69,83%
PDRB	29.679,12 miliar	17.221,77 miliar	155.203,91 miliar	7.292,65 miliar
IPM	69,92%	69,23%	80,08%	76,59%

Berikut adalah kesimpulan yang dapat diambil dari Tabel 22:

- Cluster 0 (Menengah/Stabil)

Menunjukkan karakteristik wilayah dengan kondisi sosial ekonomi yang berada pada tingkat moderat. Identitas ini terlihat dari nilai variabel yang tidak menunjukkan kondisi ekstrem pada aspek ketenagakerjaan, kapasitas ekonomi, maupun kualitas pembangunan manusia. Secara keseluruhan, cluster ini menggambarkan wilayah dengan kondisi sosial ekonomi yang stabil meskipun

berada dalam situasi pandemi COVID-19 yang mulai berdampak pada aktivitas ekonomi dan ketenagakerjaan. Keseimbangan indikator dalam cluster ini memperlihatkan bahwa wilayahnya tidak mengalami tekanan berlebihan, namun juga tidak memiliki keunggulan signifikan pada sektor tertentu.

Dalam cluster ini, nilai TPT sebesar 3,86%, TPAK sebesar 66,04%, PDRB sebesar 29.679,12 miliar, dan IPM sebesar 69,92% mencerminkan kondisi moderat yang konsisten dengan identitas Menengah/Stabil. Dibandingkan tahun 2019, terjadi penurunan PDRB yang cukup terasa, mencerminkan melemahnya kegiatan ekonomi akibat pembatasan sosial, penurunan produktivitas, dan terganggunya rantai pasok selama pandemi. TPAK juga mengalami sedikit penurunan karena sebagian penduduk keluar dari pasar kerja sementara akibat ketidakpastian ekonomi. Meskipun demikian, stabilitas TPT yang tetap moderat menunjukkan bahwa wilayah dalam cluster ini relatif mampu mempertahankan keseimbangan kondisi ketenagakerjaan di tengah gangguan pandemi.

- Cluster 1 (Produktif)

Menggambarkan wilayah dengan potensi produktivitas yang cukup tinggi dibanding cluster lain, ditandai oleh kualitas SDM yang baik serta tingkat partisipasi tenaga kerja yang kuat. Identitas produktif pada tahun 2020 tetap terlihat meskipun kondisi ekonomi nasional melemah, karena wilayah dalam cluster ini masih didukung oleh basis ekonomi yang lebih baik dibanding kelompok lain. Secara umum, cluster ini mencerminkan wilayah yang berdaya saing dan tetap mampu mempertahankan produktivitas tenaga kerja di tengah tekanan pandemi.

Nilai TPT sebesar 4,45%, TPAK sebesar 72,34%, PDRB sebesar 17.221,77 miliar, dan IPM sebesar 69,23% menggambarkan adanya pergeseran kondisi dibanding tahun 2019. PDRB mengalami penurunan cukup signifikan akibat perlambatan aktivitas ekonomi yang terjadi secara nasional selama pandemi COVID-19, sementara peningkatan TPT mencerminkan berkurangnya kesempatan kerja akibat penutupan usaha dan penurunan kapasitas produksi. Meskipun terjadi tekanan ekonomi, nilai TPAK yang tetap tinggi menunjukkan bahwa penduduk di wilayah ini masih aktif berpartisipasi dalam pasar kerja, mencerminkan daya saing tenaga kerja yang tetap terjaga meskipun peluang kerja menurun.

- Cluster 2 (Maju)

Menunjukkan karakteristik wilayah yang memiliki kapasitas pembangunan cukup baik, ditandai dengan struktur ketenagakerjaan yang aktif serta kemampuan ekonomi dan kualitas SDM yang kompetitif. Identitas cluster ini pada tahun 2020 tetap mencerminkan wilayah dengan perkembangan sosial

ekonomi yang relatif kuat, meskipun pandemi memberikan dampak yang berbeda pada pasar kerja dan perekonomian antarwilayah.

Nilai TPT sebesar 9,86%, TPAK sebesar 65,41%, PDRB sebesar 155.203,91 miliar, dan IPM sebesar 80,08% menggambarkan kondisi yang unik. Berbeda dari tahun 2019, TPT meningkat tajam akibat pandemi yang mengakibatkan terganggunya pasar tenaga kerja dan meningkatnya jumlah penduduk yang kehilangan pekerjaan. Namun, PDRB yang masih sangat besar dan IPM tinggi mencerminkan bahwa wilayah dalam cluster ini tetap memiliki kapasitas ekonomi dan kualitas SDM yang unggul. Tingginya PDRB menunjukkan bahwa sektor industri dan perdagangan di wilayah ini tetap mendominasi meskipun menghadapi tekanan pandemi, sehingga identitas cluster sebagai wilayah “Maju” tetap konsisten.

- Cluster 3 (Ekonomi Terbatas)

Menggambarkan wilayah dengan kapasitas ekonomi yang terbatas, ditandai oleh nilai PDRB yang paling rendah dibanding seluruh cluster. Identitas ini sesuai dengan karakteristik wilayah yang bergantung pada sektor ekonomi berskala kecil sehingga lebih rentan terhadap guncangan ekonomi, termasuk dampak pandemi COVID-19. Meskipun demikian, indikator ketenagakerjaan dan kualitas SDM dalam cluster ini tidak selalu lemah dan berada pada kategori menengah, sehingga keterbatasan utama terletak pada skala ekonominya, bukan pada kompetensi penduduknya.

Nilai TPT sebesar 7,03%, TPAK sebesar 69,83%, PDRB sebesar 7.292,65 miliar, dan IPM sebesar 76,59% menunjukkan perubahan yang mencerminkan dampak pandemi pada wilayah dengan kemampuan ekonomi terbatas. Penurunan PDRB yang terjadi menunjukkan bahwa sektor usaha kecil dan menengah paling terdampak oleh pembatasan aktivitas ekonomi. Peningkatan TPT juga mencerminkan kerentanan kelompok ini terhadap tekanan ketenagakerjaan karena pelaku usaha kecil lebih cepat mengurangi tenaga kerja saat aktivitas ekonomi melemah. Meskipun demikian, TPAK dan IPM yang tetap berada pada kategori menengah menegaskan bahwa kualitas SDM dan keinginan masyarakat untuk tetap bekerja tidak menjadi masalah utama, melainkan kapasitas ekonomi wilayah yang masih sangat terbatas.

4.4.4 Interpretasi Hasil Clustering Tahun 2021

Berikut ini merupakan rata-rata nilai dari masing-masing variabel tingkat pengangguran tahun 2021 berdasarkan pusat cluster yang terbentuk dari proses K-Mens Clustering:

Table 24. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2021

Variabel	Cluster 0	Cluster 1	Cluster 2	Cluster 3
TPT	2,72%	10,11%	3,98%	6,06%
TPAK	73,95%	63,93%	69,35%	71,50%
PDRB	6.362,59 miliar	162.032,80 miliar	29.635,70 miliar	7.688,20 miliar
IPM	68,53%	80,46%	70,14%	76,69%

Berikut adalah kesimpulan yang dapat diambil dari Tabel 23:

- Cluster 0 (Menengah/Stabil)

Mencerminkan wilayah dengan kondisi sosial ekonomi pada kategori menengah, ditandai oleh indikator yang tidak menunjukkan nilai ekstrem baik dari sisi ketenagakerjaan, ekonomi, maupun kualitas pembangunan manusia. Identitas ini sejalan dengan karakter Menengah/Stabil, di mana wilayah memiliki keseimbangan antar variabel tanpa keunggulan yang dominan atau kelemahan yang terlalu besar. Pada tahun 2021 tahun kedua pandemi COVID-19 cluster ini tetap menunjukkan pola stabil meskipun tekanan ekonomi masih terasa.

Dalam cluster ini, nilai TPT sebesar 2,72%, TPAK sebesar 73,95%, PDRB sebesar 6.362,59 miliar, dan IPM sebesar 68,53% mencerminkan kondisi moderat yang konsisten. Jika dibandingkan tahun 2020, TPT mengalami penurunan sebagai tanda membaiknya kesempatan kerja di masa pemulihan awal pandemi. Sebaliknya, PDRB menurun signifikan karena sebagian besar wilayah dalam cluster ini adalah daerah dengan skala ekonomi kecil yang paling terdampak pembatasan aktivitas sosial dan penurunan produktivitas. TPAK yang meningkat menunjukkan bahwa masyarakat mulai kembali memasuki pasar kerja setelah sempat turun pada tahun 2020. Indikator-indikator tersebut memperlihatkan bahwa meskipun pemulihan ekonomi berjalan lambat, stabilitas sosial ekonomi tetap terjaga dalam kelompok ini.

- Cluster 1 (Produktif)

Menggambarkan wilayah dengan kapasitas ekonomi dan kualitas SDM yang tinggi, sejalan dengan identitas Produktif yang ditandai oleh PDRB besar dan IPM tinggi. Meskipun pandemi masih memberikan tekanan ekonomi nasional, wilayah dalam cluster ini tetap menunjukkan daya saing dan kemampuan mempertahankan produktivitas. Cluster ini juga merupakan kelompok yang umumnya berfungsi sebagai pusat pertumbuhan ekonomi di provinsi sehingga ketahanannya terhadap krisis relatif lebih baik dibanding kelompok lainnya.

Dalam cluster ini, nilai TPT sebesar 10,11%, TPAK sebesar 63,93%, PDRB sebesar 162.032,80 miliar, dan IPM sebesar 80,46% menunjukkan adanya dampak signifikan pandemi terhadap dinamika ketenagakerjaan. TPT meningkat tajam dibanding tahun 2020, mencerminkan tekanan besar pada pasar kerja perkotaan, terutama sektor formal yang mengalami pengurangan tenaga kerja. Namun, tingginya PDRB dan IPM memperlihatkan bahwa kapasitas ekonomi dan kualitas SDM tetap sangat kuat, sehingga identitas Produktif tidak berubah. Penurunan TPAK menunjukkan bahwa sebagian masyarakat memilih keluar dari pasar kerja karena ketidakpastian ekonomi, tetapi secara keseluruhan wilayah dalam cluster ini tetap menjadi pusat produktivitas regional.

- Cluster 2 (Maju)

Memperlihatkan karakteristik wilayah dengan struktur ketenagakerjaan yang baik, ditandai oleh TPT yang relatif rendah dan TPAK yang tinggi. Identitas Maju menggambarkan wilayah yang memiliki pondasi sosial ekonomi cukup kuat dengan aktivitas pasar kerja yang lebih sehat dibanding cluster lain. Pada tahun 2021, wilayah dalam cluster ini tetap menunjukkan perkembangan positif meskipun tekanan pandemi masih berlangsung, terutama karena kemampuan adaptasi terhadap perubahan kondisi ekonomi.

Dalam cluster ini, nilai TPT sebesar 3,98%, TPAK sebesar 69,35%, PDRB sebesar 29.625,70 miliar, dan IPM sebesar 70,14% menunjukkan dinamika yang relatif stabil. Dibandingkan tahun 2020, TPT menurun dan TPAK meningkat, mencerminkan membaiknya kondisi ketenagakerjaan dan mulai pulihnya aktivitas ekonomi. PDRB mengalami kenaikan yang menandakan bahwa sektor usaha di wilayah ini mulai kembali beroperasi secara lebih optimal. Dengan indikator ketenagakerjaan yang membaik dan kapasitas ekonomi yang meningkat, cluster ini tetap mempertahankan karakter sebagai wilayah yang lebih maju secara sosial ekonomi.

- Cluster 3 (Ekonomi Terbatas)

Mencerminkan wilayah yang memiliki kapasitas ekonomi paling terbatas, ditandai oleh nilai PDRB terendah dibanding cluster lainnya. Identitas ini menunjukkan bahwa wilayah dalam cluster ini masih menghadapi tantangan dalam memperluas aktivitas produksi dan mengembangkan kapasitas ekonomi daerah. Meskipun demikian, indikator ketenagakerjaan seperti TPAK dan TPT tetap berada pada kategori menengah sehingga keterbatasan tidak terletak pada kualitas tenaga kerja melainkan pada skala ekonomi wilayah.

Dalam cluster ini, nilai TPT sebesar 6,06%, TPAK sebesar 71,50%, PDRB sebesar 7.688,20 miliar, dan IPM sebesar 76,69% menunjukkan bahwa wilayah dalam cluster ini mulai memasuki fase pemulihan ekonomi. Dibandingkan tahun

2020, TPT menurun seiring dengan kembali bergerak sektor usaha kecil dan perdagangan lokal. PDRB juga meningkat meskipun tetap jauh lebih rendah dibanding cluster lainnya, karena pemulihan ekonomi di wilayah berkapasitas kecil berjalan lebih lambat. TPAK yang tinggi mencerminkan tingginya keinginan masyarakat untuk tetap bekerja, meskipun peluang kerja belum sepenuhnya pulih. Kondisi ini memperlihatkan bahwa wilayah dalam cluster ini membutuhkan penguatan ekonomi untuk mendorong pemulihan yang lebih merata.

4.4.5 Interpretasi Hasil Clustering Tahun 2022

Berikut ini merupakan rata-rata nilai dari masing-masing variabel tingkat pengangguran tahun 2022 berdasarkan pusat cluster yang terbentuk dari proses K-Mens Clustering:

Table 25. Hasil Pusat Cluster K-Means $k=4$ Data Tahun 2022

Variabel	Cluster 0	Cluster 1	Cluster 2	Cluster 3
TPT	5,60%	3,76%	8,20%	3,23%
TPAK	69,83%	70,39%	64,48%	80,46%
PDRB	8.448,17 miliar	31.523,77 miliar	179.106,80 miliar	10.722,83 miliar
IPM	77,42%	70,54%	81,19%	69,55%

Berikut adalah kesimpulan yang dapat diambil dari Tabel 24:

- Cluster 0 (Menengah/Stabil)

Menunjukkan karakteristik wilayah dengan kondisi sosial ekonomi yang moderat dan seimbang. Identitas Menengah/Stabil terlihat dari nilai-nilai indikator yang berada pada kisaran menengah tanpa menunjukkan kecenderungan ekstrem, baik dalam aspek ketenagakerjaan, kapasitas ekonomi, maupun kualitas pembangunan manusia. Kondisi sosial ekonomi yang tidak terlalu tinggi tetapi juga tidak terlalu rendah menunjukkan bahwa wilayah dalam cluster ini memiliki stabilitas serta kemampuan adaptasi yang cukup baik dalam menghadapi perubahan kondisi pascapandemi.

Dalam cluster ini, nilai TPT sebesar 5,60%, TPAK sebesar 69,83%, PDRB sebesar 8.448,17 miliar, dan IPM sebesar 77,42% mencerminkan kondisi menengah yang konsisten dengan identitas cluster. Dibandingkan tahun 2021, terjadi peningkatan TPT yang disebabkan oleh belum sepenuhnya pulihnya pasar kerja setelah pandemi, sementara peningkatan IPM memperlihatkan adanya perbaikan kualitas pendidikan dan kesehatan. PDRB meningkat dari tahun

sebelumnya tetapi tetap berada pada kategori menengah sehingga tidak mengubah identitas cluster. TPAK yang relatif stabil menunjukkan bahwa masyarakat mulai kembali aktif dalam kegiatan ekonomi meskipun proses pemulihan belum merata antarwilayah.

- Cluster 1 (Produktif)

Menggambarkan wilayah yang memiliki kapasitas ekonomi dan kualitas SDM yang baik, sesuai dengan identitas Produktif yang ditandai oleh PDRB dan IPM yang relatif tinggi. Wilayah dalam cluster ini menunjukkan potensi produktivitas pembangunan yang stabil, mencerminkan kemampuan daerah dalam mempertahankan kegiatan ekonomi meskipun dampak pandemi masih terasa pada beberapa sektor. Identitas produktif terlihat dari kemampuan wilayah dalam menjaga kinerja pembangunan manusia serta menjaga daya saing ketenagakerjaan.

Dalam cluster ini, nilai TPT sebesar 3,76%, TPAK sebesar 70,39%, PDRB sebesar 31.523,77 miliar, dan IPM sebesar 70,54% menunjukkan adanya pemulihan yang lebih baik dibandingkan tahun 2021. TPT menurun cukup signifikan, menandakan membaiknya pasar tenaga kerja setelah dua tahun mengalami tekanan pandemi. PDRB meningkat dan menunjukkan bahwa kegiatan ekonomi kembali berjalan lebih optimal, khususnya pada sektor perdagangan dan jasa. TPAK yang meningkat memperlihatkan bahwa penduduk semakin aktif berpartisipasi dalam pasar kerja. Sementara peningkatan IPM menandakan perbaikan pada aspek pendidikan dan kesehatan, sehingga identitas Produktif tetap sangat jelas dalam cluster ini.

- Cluster 2 (Maju)

Mencerminkan wilayah yang memiliki kemampuan pembangunan kuat baik dari sisi ekonomi maupun ketenagakerjaan. Identitas Maju ditandai dengan nilai TPT yang relatif rendah, TPAK yang memadai, serta PDRB dan IPM yang berada pada kategori tinggi. Wilayah dalam cluster ini merupakan daerah dengan struktur ketenagakerjaan yang sehat serta kapasitas ekonomi yang terus berkembang, sehingga tetap menunjukkan karakter wilayah yang kompetitif.

Dalam cluster ini, nilai TPT sebesar 8,20%, TPAK sebesar 64,48%, PDRB sebesar 179.106,80 miliar, dan IPM sebesar 81,19% menunjukkan dinamika pembangunan yang kuat. Dibandingkan tahun 2021, PDRB meningkat signifikan sebagai tanda pemulihan ekonomi yang sangat cepat, terutama pada sektor industri dan perdagangan besar. IPM juga meningkat dan menunjukkan kualitas SDM yang terus membaik. Meskipun TPT meningkat akibat penyesuaian pasar kerja setelah pandemi, tingginya PDRB dan IPM tetap mengukuhkan identitas wilayah sebagai cluster Maju. Peningkatan TPT ini lebih disebabkan oleh

penyerapan tenaga kerja yang belum sepenuhnya stabil meskipun aktivitas ekonomi pulih.

- Cluster 3 (Ekonomi Terbatas)

Menunjukkan karakteristik wilayah dengan kapasitas ekonomi yang terbatas, ditandai oleh nilai PDRB yang relatif rendah dibandingkan cluster lainnya. Identitas Ekonomi Terbatas mencerminkan wilayah yang memiliki skala ekonomi kecil dan ketergantungan pada sektor usaha mikro dan kecil. Meskipun beberapa indikator ketenagakerjaan dan kualitas manusia berada pada kategori menengah, keterbatasan utama cluster ini tetap berada pada kapasitas ekonomi daerah.

Dalam cluster ini, nilai TPT sebesar 3,23%, TPAK sebesar 80,46%, PDRB sebesar 10.722,83 miliar, dan IPM sebesar 69,55% menunjukkan adanya upaya pemulihan yang cukup baik. Dibandingkan tahun 2021, TPT mengalami penurunan cukup besar yang menunjukkan bahwa pasar kerja mulai membaik, terutama pada sektor informal dan UMKM. TPAK sangat tinggi menunjukkan bahwa penduduk memiliki dorongan kuat untuk bekerja meskipun peluang ekonomi terbatas. PDRB meningkat namun tetap berada pada kategori rendah sehingga identitas Ekonomi Terbatas tidak berubah. IPM yang sedikit menurun menunjukkan bahwa wilayah ini membutuhkan penguatan pada aspek pendidikan dan kesehatan agar dapat meningkatkan kualitas SDM dalam jangka panjang.

4.4.6 Interpretasi Hasil Clustering Tahun 2023

Berikut ini merupakan rata-rata nilai dari masing-masing variabel tingkat pengangguran tahun 2023 berdasarkan pusat cluster yang terbentuk dari proses K-Mens Clustering:

Table 26. Hasil Pusat Cluster K-Means $k=3$ Data Tahun 2023

Variabel	Cluster 0	Cluster 1	Cluster 2
TPT	5,34%	3,24%	7,49%
TPAK	69,74%	72,48%	67,51%
PDRB	9.033,92 miliar	30.238,85 miliar	194.569,60 miliar
IPM	78,22%	71,13%	81,72%

Berikut adalah kesimpulan yang dapat diambil dari Tabel 25:

- Cluster 0 (Ekonomi Terbatas)

Menunjukkan karakteristik wilayah dengan kapasitas ekonomi yang rendah, ditandai oleh nilai PDRB yang paling kecil dibandingkan cluster lainnya. Identitas Ekonomi Terbatas menggambarkan wilayah yang belum memiliki kekuatan ekonomi yang memadai untuk mendorong pembangunan secara optimal. Meskipun indikator ketenagakerjaan dan kualitas manusia berada pada tingkat menengah, keterbatasan utama cluster ini tetap terletak pada skala ekonomi yang kecil sehingga aktivitas produksi dan kemampuan fiskal daerah relatif terbatas. Identitas ini menunjukkan bahwa wilayah yang termasuk dalam cluster ini perlu penguatan pada sektor ekonomi agar mampu bersaing dengan wilayah lain.

Dalam cluster ini, nilai TPT sebesar 3,38%, TPAK sebesar 75,63%, PDRB sebesar 11.039,38 miliar, dan IPM sebesar 69,50% mencerminkan bahwa kondisi ketenagakerjaan relatif membaik dibandingkan tahun 2022, terlihat dari penurunan tingkat pengangguran. Partisipasi angkatan kerja yang meningkat menandakan bahwa penduduk semakin aktif mencari pekerjaan seiring pulihnya aktivitas ekonomi pascapandemi. Namun demikian, nilai PDRB yang tetap berada pada kategori rendah menjadi faktor penentu identitas cluster ini, karena kemampuan ekonomi wilayah belum menunjukkan peningkatan signifikan. IPM yang relatif stabil menunjukkan bahwa kualitas pembangunan manusia belum mengalami perubahan besar, sehingga identitas Ekonomi Terbatas tetap konsisten pada tahun 2023.

- Cluster 1 (Maju)

Menggambarkan wilayah dengan struktur ketenagakerjaan dan kapasitas pembangunan yang kuat. Identitas Maju ditandai oleh nilai TPT yang rendah serta TPAK yang cukup tinggi, menunjukkan bahwa proses penyerapan tenaga kerja berlangsung lebih efektif. Selain itu, nilai IPM yang cukup tinggi juga menjadi indikator bahwa kualitas SDM di wilayah ini lebih baik dibanding cluster lainnya. Walaupun PDRB tidak sebesar cluster Produktif, kombinasi ketenagakerjaan yang sehat dan kualitas manusia yang baik membuat wilayah dalam cluster ini memiliki kemampuan pembangunan yang kompetitif.

Pada cluster ini, nilai TPT sebesar 3,03%, TPAK sebesar 68,40%, PDRB sebesar 30.271,52 miliar, dan IPM sebesar 72,45% memperlihatkan peningkatan dari tahun 2022, terutama pada indikator ketenagakerjaan. Penurunan TPT menunjukkan bahwa pasar kerja pulih dengan lebih stabil setelah pandemi, sementara TPAK yang moderat menggambarkan normalisasi tingkat partisipasi penduduk dalam angkatan kerja. PDRB mengalami kenaikan yang cukup baik, mencerminkan perbaikan aktivitas ekonomi pada sektor industri dan perdagangan. Sementara IPM yang meningkat menunjukkan bahwa kualitas

pendidikan dan kesehatan terus membaik. Perpaduan indikator tersebut mengukuhkan bahwa identitas cluster ini tetap sebagai cluster Maju dengan karakter pembangunan yang solid dan berkelanjutan.

- Cluster 2 (Produktif)

Menunjukkan wilayah dengan kapasitas ekonomi terbesar dan kualitas SDM tertinggi. Identitas Produktif terutama terlihat dari nilai PDRB dan IPM yang paling tinggi dibandingkan cluster lain. Kondisi ini mencerminkan wilayah yang mampu menggerakkan aktivitas ekonomi secara intensif dan memiliki kualitas tenaga kerja yang unggul. Tingginya kemampuan ekonomi dan iklim pembangunan manusia yang baik menjadikan wilayah dalam cluster ini sebagai pusat pertumbuhan ekonomi, meskipun indikator ketenagakerjaan seperti TPT terkadang fluktuatif akibat tingginya mobilitas penduduk.

Dalam cluster ini, nilai TPT sebesar 6,80%, TPAK sebesar 62,01%, PDRB sebesar 198.952,87 miliar, dan IPM sebesar 81,23% memperlihatkan pola yang konsisten dengan identitas produktif. PDRB yang sangat besar menandakan tingginya aktivitas ekonomi, terutama pada sektor industri, jasa, dan perdagangan skala besar. IPM yang tinggi menunjukkan kualitas SDM yang sudah matang dan menjadi pendorong utama produktivitas wilayah. Meskipun TPT meningkat dibandingkan 2022, kondisi ini dapat terjadi karena tingginya perpindahan tenaga kerja menuju pusat ekonomi sehingga persaingan kerja semakin besar. TPAK yang tidak terlalu tinggi menunjukkan bahwa tidak semua penduduk aktif masuk ke pasar kerja, tetapi hal ini tidak mengubah identitas produktif karena kekuatan utama terletak pada ekonomi dan kualitas manusia.

4.4.7 Pembahasan Dinamika Cluster Tahun 2019-2023

Pembahasan terhadap hasil clustering selama lima tahun menunjukkan bahwa struktur sosial ekonomi wilayah di Provinsi Sumatera Selatan memiliki pola dasar yang relatif stabil, namun tetap mengalami beberapa dinamika penting yang memengaruhi identitas cluster dari tahun ke tahun. Pada periode 2019–2022, algoritma K-Means secara konsisten menghasilkan empat cluster optimal ($k=4$), yaitu Menengah/Stabil, Produktif, Maju, dan Ekonomi Terbatas. Konsistensi ini mencerminkan bahwa variasi karakteristik antar wilayah masih cukup kuat, sehingga setiap identitas cluster memiliki ciri khusus yang jelas. Cluster Produktif secara konsisten diisi oleh wilayah dengan PDRB tinggi dan IPM tinggi, sedangkan cluster Maju mempertahankan identitasnya melalui TPAK tinggi dan TPT rendah yang menunjukkan struktur ketenagakerjaan yang sehat. Cluster Menengah/Stabil menjadi kelompok yang paling banyak anggotanya karena sebagian besar wilayah memiliki nilai indikator yang berada pada tingkat

menengah. Sementara itu, cluster Ekonomi Terbatas tetap teridentifikasi melalui PDRB rendah yang menunjukkan keterbatasan kapasitas ekonomi.


Meskipun identitas cluster relatif stabil, setiap tahun memperlihatkan dinamika internal yang dipengaruhi oleh kondisi ekonomi makro, terutama pandemi COVID-19. Tahun 2020 memperlihatkan perubahan signifikan, terutama pada cluster Produktif dan cluster Maju, akibat penurunan PDRB, tingginya tekanan pasar kerja, dan penyesuaian aktivitas ekonomi. Pada periode 2021–2022, pola secara bertahap kembali normal, ditandai oleh pemulihan nilai PDRB, perbaikan IPM, dan penguatan kembali TPAK di sejumlah wilayah. Namun dinamika ini tidak mengubah identitas inti tiap cluster, sehingga struktur empat cluster tetap bertahan hingga tahun 2022. Hal ini menunjukkan bahwa meskipun pandemi memberi dampak besar, pola ketimpangan kapasitas ekonomi dan ketenagakerjaan antar wilayah cenderung tetap.

Perubahan terbesar terjadi pada tahun 2023, ketika jumlah cluster optimal bergeser dari empat menjadi tiga ($k=3$). Pengurangan jumlah cluster ini bukan berarti penurunan kualitas analisis, tetapi mencerminkan penyederhanaan pola nilai indikator. Rentang nilai TPT, TPAK, dan IPM mulai menyempit sehingga beberapa identitas yang sebelumnya terpisah, khususnya Menengah/Stabil dan sebagian dari Maju, tidak lagi memiliki perbedaan yang cukup kuat untuk membentuk cluster terpisah. Akibatnya, K-Means mengelompokkan wilayah tersebut ke dalam struktur baru dengan tiga identitas: Ekonomi Terbatas, Maju, dan Produktif. Cluster Produktif tetap bertahan karena PDRB dan IPM wilayah di dalamnya masih jauh lebih besar dibanding cluster lain. Sementara itu, cluster Ekonomi Terbatas tetap dipertahankan karena PDRB yang rendah masih menjadi pembeda yang paling dominan pada tahun 2023.

Secara keseluruhan, pembahasan ini menunjukkan bahwa dinamika cluster selama 2019–2023 menggambarkan proses stabilitas dan penyederhanaan. Periode 2019–2022 memperlihatkan kondisi sosial ekonomi yang tersegmentasi dalam empat kelompok yang jelas, sedangkan tahun 2023 menunjukkan bahwa beberapa wilayah mulai mengalami konvergensi nilai indikator, terutama pada aspek ketenagakerjaan. Hal ini mengindikasikan bahwa tekanan pengangguran mulai merata antar wilayah, walaupun ketimpangan ekonomi (PDRB) masih kuat. Temuan ini penting sebagai dasar kebijakan daerah karena menunjukkan wilayah mana yang membutuhkan intervensi ekonomi, peningkatan ketenagakerjaan, atau penguatan kualitas SDM sesuai identitas cluster yang terbentuk.

4.5 Visualisasi

4.5.1 Visualisasi Barchart





Gambar 52. Visualisasi Barchart tahun 2019

Bar chart pada Gambar 52 menunjukkan jumlah kabupaten/kota pada setiap cluster hasil pengelompokan K-Means tahun 2019. Cluster 2 (kategori Maju) memiliki anggota terbanyak, yaitu 9 kabupaten/kota, yang menunjukkan bahwa sebagian besar wilayah di Provinsi Sumatera Selatan memiliki struktur ketenagakerjaan yang kuat ditandai oleh TPAK tinggi, TPT rendah, serta kapasitas pembangunan yang relatif kompetitif.

Cluster 0 (kategori Menengah/Stabil) beranggotakan 5 kabupaten/kota. Kelompok ini menggambarkan wilayah dengan kondisi sosial ekonomi moderat, di mana nilai TPT, TPAK, PDRB, dan IPM berada pada rentang menengah tanpa keistimewaan khusus maupun tekanan ekstrem. Cluster 3 (kategori Ekonomi Terbatas) terdiri dari 2 kabupaten/kota yang memiliki kapasitas ekonomi lebih kecil, terutama dilihat dari nilai PDRB yang rendah, meskipun indikator sosial lainnya cenderung berada pada level menengah. Sementara itu, Cluster 1 (kategori Produktif) hanya beranggotakan 1 kabupaten/kota. Hal ini menunjukkan adanya wilayah yang memiliki kapasitas ekonomi dan kualitas sumber daya manusia tertinggi pada tahun 2019.

4.5.2 Visualisasi Boxplot






Gambar 53. Visualisasi Boxplot tahun 2019

Boxplot pada Gambar 53 memperlihatkan perbedaan distribusi TPT, TPAK, PDRB, dan IPM pada setiap cluster hasil K-Means. Cluster 2 menunjukkan TPT terendah dan TPAK tertinggi, selaras dengan identitasnya sebagai cluster maju. Sebaliknya, Cluster 1 memiliki TPT tertinggi namun tetap tergolong produktif karena didukung oleh PDRB dan IPM yang tinggi. Pemisahan paling jelas terlihat pada PDRB, di mana Cluster 1 menempati posisi tertinggi, Cluster 0 dan Cluster 2 berada pada tingkat menengah, dan Cluster 3 konsisten menjadi yang terendah. Pada IPM, Cluster 1 kembali menunjukkan nilai tertinggi, diikuti Cluster 3 pada kategori menengah, sementara Cluster 0 dan Cluster 2 berada pada rentang sedang.

4.5.3 Visualisasi Peta tahun 2019




Gambar 54. Visualisasi Peta tahun 2019

Visualisasi peta tahun 2019 menampilkan persebaran Kabupaten/kota di Provinsi Sumatera Selatan berdasarkan hasil pengelompokan K-Means dengan empat cluster. Warna pada peta menunjukkan keanggotaan cluster setiap wilayah sehingga pola spasial dapat diamati dengan jelas.

- Cluster 2 menjadi kelompok terbesar dengan 9 Kabupaten/kota yang tersebar di berbagai wilayah daratan, menunjukkan bahwa karakteristik sosial ekonomi di kelompok ini cukup dominan.
- Cluster 0 terdiri dari 5 Kabupaten/kota yang tersebar di bagian tengah hingga selatan Provinsi.
- Cluster 3 mencakup 2 Kabupaten/kota yang lokasinya saling berdekatan.
- Cluster 1 hanya beranggotakan 1 wilayah dan muncul sebagai cluster tunggal dalam peta.

Pola spasial tahun 2019 menunjukkan bahwa wilayah dengan karakteristik serupa cenderung berdekatan, sementara wilayah dengan karakteristik yang sangat berbeda muncul sebagai cluster tunggal pada peta.

4.5.4 Visualisasi Peta tahun 2020




Gambar 55. Visualisasi Peta tahun 2020

Peta tahun 2020 menggambarkan pola persebaran empat cluster dengan struktur anggota yang berbeda dari tahun sebelumnya. Warna yang ditampilkan membantu menjelaskan bagaimana setiap wilayah terkelompok berdasarkan kemiripan indikator sosial ekonomi pada tahun tersebut.

- Cluster 1 merupakan kelompok terbesar dengan 10 Kabupaten/kota yang tersebar luas di wilayah tengah dan barat Provinsi, menunjukkan kemiripan karakteristik di area tersebut.
- Cluster 0 beranggotakan 4 wilayah yang tersebar di bagian timur dan sebagian tengah Provinsi Sumatera Selatan.
- Cluster 3 terdiri dari 2 kota yang berada di bagian selatan dan barat laut Provinsi.
- Cluster 2 hanya memiliki 1 anggota, yaitu Kota Palembang, dan tampak menonjol sebagai cluster tunggal.

Secara spasial, peta tahun 2020 memperlihatkan pola pengelompokan yang relatif konsisten, di mana wilayah dengan nilai indikator serupa cenderung membentuk kelompok yang berdekatan.

4.5.5 Visualisasi Peta tahun 2021



Gambar 56. Visualisasi Peta tahun 2021


Visualisasi peta tahun 2021 menunjukkan bagaimana wilayah Provinsi Sumatera Selatan kembali terbagi ke dalam empat cluster optimal berdasarkan data indikator sosial ekonomi tahun tersebut.

- Cluster 0 berisi sejumlah Kabupaten yang tersebar terutama di wilayah tengah.
- Cluster 1 terdiri dari beberapa Kabupaten/kota yang terletak di bagian barat dan selatan Provinsi.
- Cluster 2 mencakup beberapa wilayah yang berlokasi di sisi timur dan tengah.

- Cluster 3 kembali muncul sebagai kelompok kecil dengan anggota yang saling berdekatan lokasi geografisnya.

Peta tahun 2021 memperlihatkan bahwa meskipun komposisi anggotanya berubah, pola penyebaran spasial tetap menunjukkan kecenderungan pengelompokan wilayah yang memiliki karakteristik serupa.

4.5.6 Visualisasi Peta tahun 2022




Gambar 57. Visualisasi Peta tahun 2022

Peta tahun 2022 tetap menampilkan empat cluster, namun persebaran anggotanya menunjukkan variasi baru dibandingkan tahun-tahun sebelumnya. Warna peta memudahkan pemahaman mengenai kecenderungan spasial dari hasil pengelompokan.

- Cluster 0 terdiri dari beberapa wilayah yang tersebar pada bagian selatan dan barat Provinsi.
- Cluster 1 beranggotakan sejumlah Kabupaten/kota yang sebagian besar berlokasi di wilayah timur dan tengah.
- Cluster 2 mencakup wilayah dengan persebaran yang cukup berjauhan, memperlihatkan variasi karakteristik antar daerah.
- Cluster 3 berisi sejumlah wilayah yang berdekatan dan membentuk kelompok tersendiri dalam peta.

Visualisasi ini menunjukkan bahwa pola spasial cluster tahun 2022 masih mencerminkan keterkaitan geografis antar wilayah dengan karakteristik sosial ekonomi yang mirip.

4.5.7 Visualisasi Peta tahun 2023



Gambar 58. Visualisasi Peta tahun 2023

Pada tahun 2023, pola pengelompokan berubah karena jumlah cluster optimal bergeser menjadi tiga. Perubahan ini tampak jelas dalam visualisasi peta yang memperlihatkan penyederhanaan struktur kelompok wilayah.

- Cluster 0 terdiri dari beberapa wilayah yang memiliki persebaran spasial cukup terpusat.
- Cluster 1 mencakup wilayah yang tersebar di bagian barat dan tengah Provinsi.
- Cluster 2 berisi wilayah yang secara geografis lebih terfokus, termasuk wilayah perkotaan dengan karakteristik khusus.

Pengurangan jumlah cluster menjadi tiga menyebabkan wilayah yang sebelumnya terpisah ke dalam beberapa kategori digabungkan ke dalam kelompok baru yang lebih luas. Hal ini terlihat pada peta melalui penyusutan variasi warna, yang menunjukkan penyederhanaan struktur spasial pada tahun 2023.

Secara keseluruhan, visualisasi peta 2019–2023 memperlihatkan bahwa wilayah dengan karakteristik serupa cenderung membentuk kelompok yang berdekatan secara geografis. Pola ini menjadi dasar penting dalam memahami persebaran sosial ekonomi antar wilayah serta menunjukkan bahwa struktur pengelompokan tidak hanya terbentuk dari data numerik, tetapi juga memiliki konsistensi secara spasial.

4.5.8 Pembahasan Pola Spasial antar tahun 2019-2023

Analisis visualisasi peta selama periode 2019–2023 menunjukkan adanya pola spasial yang konsisten dalam pengelompokan wilayah, meskipun komposisi cluster berubah dari tahun ke tahun. Secara umum, wilayah dengan karakteristik sosial ekonomi yang serupa cenderung membentuk konsentrasi spasial tertentu, sementara wilayah dengan karakteristik ekstrem baik sangat tinggi maupun sangat rendah lebih sering muncul sebagai cluster tunggal atau cluster berukuran kecil.

1. Konsistensi Pola Spasial Wilayah Perkotaan

Kota Palembang secara konsisten muncul sebagai cluster tunggal pada tahun 2019–2022 dan tetap berada pada cluster khusus pada tahun 2023. Hal ini menegaskan bahwa perbedaan karakteristik ekonomi dan kualitas pembangunan manusia di Palembang sangat signifikan dibandingkan wilayah lain, sehingga selalu menjadi outlier positif secara spasial. Kota Prabumulih dan Kota Lubuklinggau juga menunjukkan kecenderungan untuk membentuk kelompok tersendiri atau bergabung dalam cluster kecil, yang menandakan karakter sosial ekonomi perkotaan yang berbeda dari wilayah kabupaten.

2. Konsentrasi Wilayah Menengah di Bagian Tengah dan Barat

Pada sebagian besar tahun, wilayah dengan karakteristik menengah atau stabil cenderung berkelompok di bagian tengah hingga barat Provinsi Sumatera Selatan. Meskipun anggota cluster mengalami perubahan, pola geografisnya relatif konsisten. Hal ini menunjukkan bahwa wilayah-wilayah tersebut memiliki profil sosial ekonomi yang berdekatan dan bergerak dalam rentang nilai indikator yang tidak terlalu ekstrem, sehingga secara spasial membentuk zona yang stabil.

3. Penyebaran Wilayah Berkinerja Rendah Cenderung Terkelompok

Wilayah dalam kategori kapasitas ekonomi terbatas sering kali muncul berdekatan, terutama pada wilayah kabupaten dengan PDRB rendah. Konsistensi pola ini menandakan bahwa keterbatasan kapasitas ekonomi cenderung terjadi di wilayah yang berbatasan satu sama lain, sehingga membentuk kluster spasial yang jelas.

4. Penyederhanaan Pola Spasial pada Tahun 2023

Perubahan jumlah cluster dari empat (2019–2022) menjadi tiga pada tahun 2023 menghasilkan pola spasial yang lebih sederhana. Penyederhanaan ini terlihat dari semakin sedikitnya warna cluster pada peta dan semakin luasnya area persebaran cluster tertentu. Hal ini menunjukkan adanya penyempitan variasi sosial ekonomi antar wilayah sehingga beberapa kelompok yang sebelumnya terpisah kini melebur dalam cluster yang lebih besar. Penyusutan jumlah cluster ini juga memperlihatkan bahwa wilayah kabupaten pada tahun

2023 memiliki kecenderungan karakteristik yang semakin mirip, terutama pada variabel ketenagakerjaan.

5. Pola Umum Konsistensi dan Dinamika Spasial

Secara keseluruhan, analisis tren spasial selama lima tahun memperlihatkan kombinasi antara konsistensi dan dinamika. Konsistensi terlihat dari pola berulang wilayah perkotaan dan wilayah ekonomi terbatas. Sementara dinamika tercermin dari perpindahan beberapa wilayah kabupaten antar cluster dari tahun ke tahun. Hal ini menunjukkan bahwa meskipun terdapat perubahan nilai indikator sosial ekonomi, pola spasial dasar tetap terjaga.

Tren pola spasial selama 2019–2023 memperlihatkan bahwa pengelompokan wilayah tidak hanya dipengaruhi oleh variasi indikator sosial ekonomi, tetapi juga berkaitan erat dengan kedekatan geografis. Wilayah dengan profil serupa cenderung terdistribusi pada area yang berdekatan, sedangkan wilayah dengan karakteristik berbeda tertarik membentuk cluster tersendiri. Temuan ini menguatkan bahwa visualisasi peta merupakan komponen penting dalam memahami hasil clustering, karena mampu menunjukkan bagaimana pola data numerik terhubung dengan kondisi spasial di Provinsi Sumatera Selatan.

V. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang dilakukan, maka dapat disimpulkan sebagai berikut:

1. Jumlah cluster optimal yang terbentuk dalam penelitian ini adalah $k=4$ untuk tahun 2019–2022 dan $k=3$ untuk tahun 2023, berdasarkan hasil dari metode elbow, *Davies-Bouldin Index* (DBI) dan *Silhouette Coefficient*.
2. Karakteristik cluster yang terbentuk menunjukkan pola yang relatif konsisten pada periode 2019–2022, di mana terbentuk empat cluster dengan identitas yang sama, yaitu Cluster Menengah/Stabil, Cluster Produktif, Cluster Maju, dan Cluster Ekonomi Terbatas. Namun, pada tahun 2023 terjadi perubahan struktur clustering menjadi tiga cluster, sehingga identitas cluster mengalami penyesuaian dan penggabungan karakteristik antarcluster. Perubahan ini mencerminkan meningkatnya kemiripan kondisi sosial ekonomi dan ketenagakerjaan antarwilayah, khususnya pada indikator TPT, TPAK, PDRB, dan IPM.
3. Selama periode pengamatan 2019–2023, terjadi dinamika komposisi anggota cluster. Wilayah kabupaten cenderung berada pada Cluster Menengah/Stabil dan Cluster Maju, sementara kota-kota seperti Prabumulih dan Lubuklinggau secara konsisten berada dalam kelompok yang sama. Kota Palembang secara konsisten membentuk cluster tersendiri yang menunjukkan karakteristik yang berbeda dibandingkan wilayah lainnya.

5.2 Saran

Adapun beberapa saran yang penulis berikan sebagai upaya pengembangan penelitian lebih lanjut adalah sebagai berikut:

1. Penelitian selanjutnya dapat menggunakan variabel tambahan, seperti tingkat kemiskinan, pendidikan, infrastruktur, dan struktur sektor ekonomi,
2. Disarankan menggunakan metode penentuan jumlah cluster lainnya, seperti gap statistic atau informasi kriteria lainnya, untuk memperoleh validasi yang lebih kuat terhadap jumlah cluster optimal.
3. Metode clustering lain seperti K-Medoids, Hierarchical Clustering, atau Fuzzy C-Means dapat diuji sebagai pembanding untuk melihat konsistensi pola pengelompokan dan meningkatkan akurasi interpretasi.

DAFTAR PUSTAKA

- Abda Salsabila, N., Andriani, S., & Andi Nohe, D. (2022). *Prosiding Seminar Nasional Matematika, Statistika, dan Aplikasinya Terbitan II*.
- Adha, R., Nurhaliza, N., & Soleha, U. (2021). Perbandingan Algoritma DBSCAN dan K-Means Clustering untuk Pengelompokan Kasus Covid-19 di Dunia. *Jurnal Sains, Teknologi Dan Industri*, 18(2), 206–211. <https://covid19.who.int>.
- Aditya, A., Jovian, I., & Sari, B. N. (2020). Implementasi K-Means Clustering Ujian Nasional Sekolah Menengah Pertama di Indonesia Tahun 2018/2019. *JURNAL MEDIA INFORMATIKA BUDIDARMA*, 4(1), 51. <https://doi.org/10.30865/mib.v4i1.1784>
- Adriyanto, A., Prasetyo, D., & Khodijah, R. (2020). Angkatan Kerja dan Faktor yang Mempengaruhi Pengangguran. *JURNAL ILMU EKONOMI & SOSIAL*, 11(2), 66–82. <https://doi.org/10.35724/jies.v11i2.2965>
- Agung Utomo, B., & Wisika Prajanti, S. D. (2022). Determinant Analysis of Open Unemployment Rate in West Java Province Article Info. *JEE*, 11(2), 328–334. <http://journal.unnes.ac.id/sju/index.php/jeec>
- Akbar Asyari, M., Ulfa, M., Omen, O., & Kurniawan, M. (2024). Analisis Pengaruh Tingkat Partisipasi Angkatan Kerja, Indeks Pembangunan Manusia dan Kemiskinan Terhadap Pertumbuhan Ekonomi Provinsi Papua Barat Tahun 2014-2022. *Jurnal Ekonomi, Akuntansi, Dan Perpajakan*, 1(3), 75–97. <https://doi.org/10.61132/jeap.v1i3.216>
- Akramunnisa, & Fajriani. (2020). K-Means Clustering Analysis pada PersebaranTingkat Pengangguran Kabupaten/Kota di Sulawesi Selatan. *Jurnal Varian*, 3(2), 103–112. <https://doi.org/10.30812/varian.v3i2.652>
- Aldino, A. A., Darwis, D., Prastowo, A. T., & Sujana, C. (2021). Implementation of K-Means Algorithm for Clustering Corn Planting Feasibility Area in South Lampung Regency. *Journal of Physics: Conference Series*, 1751(1). <https://doi.org/10.1088/1742-6596/1751/1/012038>
- Alifah, K., & Imaningsih, N. (2023). *PENGANGGURAN TEBUKA TERHADAP TINGKAT KEMISKINAN DI PROVINSI DAERAH ISTIMEWA YOGYAKARTA* (Vol. 12, Issue 1).
- Amrullah, W. A., Istiyani, N., Muslihatinningsih, F., Ekonomi, J. I., & Pembangunan, S. (2019). *Analisis Determinan Tingkat Pengangguran Terbuka di Pulau Jawa Tahun 2007-2016*.
- Arifatul Ulya, F., Nur Abdullah, A., Aisya Hanan, T., & Manfaati Nur, I. (2023). *Pengelompokkan Tingkat Pengangguran Terbuka di Jawa*

- Tengah Menggunakan Metode K-Means Clustering Info Artikel. 1(2), 71–80. <https://doi.org/10.26714/jodi>*
- Arista Putri, S., Alfianda Ghifari, S., Marhani Mahmuda, F., Al Firza Wahyudi, R., & Rosanti, N. (2024). *Pelatihan Visualisasi Data: Mengubah Data Menjadi Wawasan dalam Bentuk Dashboard Analitik.*
- Armayani, C., Fauzi, A., & Sembiring, H. (2021). IMPLEMENTASI DATA MINING PENGELOMPOKAN JUMLAH DATA PRODUKTIVITAS UBINAN TANAMAN PANGAN BERDASARKAN JENIS UBINAN DENGAN METODE CLUSTERING DIKAB LANGKAT (STUDI KASUS : BADAN PUSAT STATISTIK LANGKAT). *JIK*, 5(1).
- Aulia, R. E., Malia, S. S., Pujiati, A., & Nihayah, D. M. (2024). Faktor-Faktor yang Mempengaruhi Tingkat Pengangguran di Provinsi Jawa Barat Pada Tahun. *Jurnal Simki Economic*, 7(1), 300–309. <https://jipied.org/index.php/JSE>
- Aytaç, E. (2020). Unsupervised learning approach in defining the similarity of catchments: Hydrological response unit based k-means clustering, a demonstration on Western Black Sea Region of Turkey. *International Soil and Water Conservation Research*, 8(3), 321–331. <https://doi.org/10.1016/j.iswcr.2020.05.002>
- Ayu, D., Dewi, I. C., & Pramita, K. (2019). Analisis Perbandingan Metode Elbow dan Sillhouette pada Algoritma Clustering K-Medoids dalam Pengelompokan Produksi Kerajinan Bali. In *JURNAL MATRIX* (Vol. 9, Issue 3).
- Ayu Safitri, L. D., Putri Hermanto, E. M., & Indrasetianingsih, A. (2020). *Pemodelan Indeks Pembangunan Manusia Dan Indeks Pembangunan Gender Di Indonesia Dengan Pendekatan Regresi Probit Biner Bivariat. 16(2), 150–161. <https://doi.org/10.20956/jmsk.v%vi%i.7436>*
- Badan Pusat Statistik. (2023a). *Indeks Pembangunan Manusia (Metode 2014).*
- Badan Pusat Statistik. (2023b). *Tingkat Pengangguran Terbuka (TPT) dan Tingkat Partisipasi Angkatan Kerja (TPAK) Menurut Provinsi, 2023. [Www.Bps.Go.Id](http://www.bps.go.id).*
- BADAN PUSAT STATISTIK. (2025). Tingkat Pengangguran Terbuka (TPT) sebesar 4,76 persen. Rata-rata upah buruh sebesar 3,09 juta rupiah. <https://www.bps.go.id/Id/Pressrelease/2025/05/05/2432/Tingkat-Pengangguran-Terbuka--Tpt--Sebesar-4-76-Persen--Rata-Rata-Upah-Buruh-Sebesar-3-09-Juta-Rupiah-.Html>.
- Badan Pusat Statistik Sumatera Selatan. (2023). *Tingkat Pengangguran Terbuka (TPT) dan Tingkat Partisipasi Angkatan Kerja (TPAK) Menurut Kabupaten/Kota di Provinsi Sumatera Selatan, 2023. <https://sumsel.bps.go.id/>.*

- Badri, F., & Habibi, A. (2022). Implementasi Metode K-Means Clustering Analysis pada Pengelompokan Pengangguran di Indonesia sebagai Dampak dari Pandemi Covid-19. *ILKOMNIKA: Journal of Computer Science and Applied Informatics*, 4(2), 171–179. <https://doi.org/10.28926/ilkomnika.v4i2.471>
- Butar Butar, R. P. (2023). Analisis Hierarchical Dan Non-Hierarchical Clustering Untuk Pengelompokan Potensi Ekonomi Kelautan Indonesia 2021. *Jurnal Sistem Dan Teknologi Informasi (JustIN)*, 11(3), 543. <https://doi.org/10.26418/justin.v11i3.67283>
- Choirun Nafis Afisah, Rizkiana Prima R., & Akhmad Ridho A. (2019). Analisis Hierarchical Dan Non-Hierarchical Clustering Pada Data Indikator Kesejahteraan Rakyat Di Indonesia Tahun 2017. *Laporan Praktikum Analisis Multivariat - Modul Iv, July*.
- Dewi, S. (2020). *PENGANGGURAN TERBUKA : KASUS DI INDONESIA*.
- Diaz Danindra, M., Triwahyunigtyas, N., & Arrafi Juliannisa, I. (2022). Analisis Faktor-Faktor yang Mempengaruhi Pengangguran di Provinsi Banten 2015-2019. *Jurnal Indonesia Sosial Sains*, 3(5), 852–865. <https://doi.org/10.36418/jiss.v3i5.589>
- Ding, W., Zhang, Y., Sun, Y., & Qin, T. (2021). An Improved SFLA-Kmeans Algorithm Based on Approximate Backbone and Its Application in Retinal Fundus Image. *IEEE Access*, 9, 72259–72268. <https://doi.org/10.1109/ACCESS.2021.3079119>
- Dongga, J., Sarungallo, A. `., Koru, N., & Lante, G. (2023). Implementasi Data Mining Menggunakan Algoritma Apriori Dalam Menentukan Persediaan Barang (Studi Kasus: Toko Swapen Jaya Manokwari). *G-Tech: Jurnal Teknologi Terapan*, 7(1), 119–126. <https://doi.org/10.33379/gtech.v7i1.1938>
- Fahmi, M. N. (2023). Implementasi Mechine Learning menggunakan Python Library: Scikit-Learn (Supervised dan Unsupervised Learning). *Sains Data Jurnal Studi Matematika Dan Teknologi*, 1(2), 87–96. <https://doi.org/10.52620/sainsdata.v1i2.31>
- Fajriana. (2021). Analisis Algoritma K-Medoids pada Sistem Klasterisasi Produksi Perikanan Tangkap Kabupaten Aceh Utara. *Jurnal Edukasi Dan Penelitian Informatika (JEPIN)*, 7(2), 263. <https://doi.org/10.26418/jp.v7i2.47795>
- Fathurohman, A. (2021). *JURNAL INFORMATIKA DAN TEKNOLOGI KOMPUTER MACHINE LEARNING UNTUK PENDIDIKAN: MENGAPA DAN BAGAIMANA*. 1(3), 57–62.
- Gustientiedina, Adiya, M. H., & Desnelita, Y. (2019). Penerapan Algoritma K-Means Untuk Clustering Data Obat-Obatan. *Jurnal Nasional Teknologi Dan Sistem Informasi*, 5(1), 17–24. <https://doi.org/10.25077/teknosi.v5i1.2019.17-24>

- Gustrianda, R., & Mulyana, D. I. (2022). Penerapan Data Mining Dalam Pemilihan Produk Unggulan dengan Metode Algoritma K-Means Dan K-Medoids. *JURNAL MEDIA INFORMATIKA BUDIDARMA*, 6(1), 27. <https://doi.org/10.30865/mib.v6i1.3294>
- Hendri Doni, A., Alfiona, F., & Andespa, W. (2023). PENGANGGURAN DALAM PERSPEKTIF EKONOMI ISLAM DAN KOVENSIONAL. *Manajemen Dan Syariah JIEMAS*, 2(3), 2023–2024. <https://doi.org/10.55883/jiemas.v2i3>
- Imelda, R., Balafif, M., & Wahyuni, S. T. (2021). Pengaruh Pendidikan, Produk Domestik Regional Bruto (PDRB), dan Upah Minimum terhadap Indeks Pembangunan Manusia (IPM) Kabupaten Sidoarjo Tahun 1998-2017. *Bharanomics*, 1(2), 67–74. <https://doi.org/10.46821/bharanomics.v1i2.155>
- Johnson, R. A. (2007). *Applied Multivariate Statistical Analysis* (1st ed.).
- Jusia, P. A., & Irfan, P. M. (2019). *Penerapan Clustering Data Mining Untuk Rekomendasi Penentuan Jurusan Perguruan Tinggi Pada Siswa SMA Negeri 2 Kota Jambi Menggunakan Metode K-means*.
- Kahfi, M. D., Umbara, F. R., & Ashaury, H. (2022). *Prediksi Pengangguran Menggunakan Decision Tree Dengan Algoritma C5.0 Pada Data Penduduk Kecamatan Caringin Kabupaten Bogor* INFORMASI ARTIKEL ABSTRAK (Vol. 4, Issue 2). <https://e-journal.unper.ac.id/index.php/informatics>
- Khabaza, T. (2022). 9 *Laws of Data Mining*. <https://www.researchgate.net/publication/360159100>
- Kurnia, F., Fahmi, I., Wahyudi, E., & Mige, G. E. (2019). PENERAPAN ALGORITMA K-MEANS UNTUK PENGELOMPOKAN DIAGNOSA PENYAKIT MATA BERDASARKAN RENTANG USIA. *Jurnal SPEKTRO*, 2(1).
- Kusuma Arum, S., Astuti, R., & Muhammad Basysyar, F. (2024). PENERAPAN ALGORITMA K-MEANS PADA DATASET PENGANGGURAN TERBUKA BERDASARKAN PENDIDIKAN DI PROVINSI JAWA BARAT. In *Jurnal Mahasiswa Teknik Informatika* (Vol. 8, Issue 2).
- Larose, D. T., & Larose, C. T. (2015). *DATA MINING AND PREDICTIVE ANALYTICS*.
- M. Ikotun, A., E. Ezugwu, A., Abualigah, L., Abuhaija, B., & Heming, J. (2023). K-means clustering algorithms: A comprehensive review, variants analysis, and advances in the era of big data. *Information Sciences*, 622, 178–210.
- Madyatmadja, E. D., Ridho, M. N., Pratama, A. R., Fajri, M., & Novianto, L. (2022). PENERAPAN VISUALISASI DATA TERHADAP KLASIFIKASI

- TINDAK KRIMINAL DI INDONESIA. *Infotech: Journal of Technology Information*, 8(1), 61–68. <https://doi.org/10.37365/jti.v8i1.127>
- Mahroji, D. (2019). *PENGARUH INDEKS PEMBANGUNAN MANUSIA TERHADAP TINGKAT PENGANGGURAN DI PROVINSI BANTEN*. 9(1). <http://jurnal.untirta.ac.id/index.php/>
- Maliki, R., Falgenti, K., Priani, S., Fithri, F., Suherman, M., & Nugraha, D. S. (2022). *Perbandingan Tingkat Pengangguran Terbuka Provinsi di Indonesia Berbasis Metode K-Means Clustering*.
- Maulana, R., Zakia Rizki, C., Nazamuddin, B. S., & Afandi ZT, F. (2023). *PENGARUH TINGKAT PARTISIPASI ANGKATAN KERJA, TINGKAT PENGANGGURAN TERBUKA DAN TINGKAT PENDIDIKAN TERHADAP PERTUMBUHAN EKONOMI DI PROVINSI ACEH*.
- Mayoana Fitri, E., Randy Suryono, R., & Wantoro, A. (2023). *KLASTERISASI DATA PENJUALAN BERDASARKAN WILAYAH MENGGUNAKAN METODE K-MEANS PADA PT XYZ* (Vol. 11, Issue 2).
- Meliza, O., & Susanti, T. (2024). IMPLEMENTASI K-MEANS: SEBUAH STUDI LITERATUR. *Jurnal Informatika (JURI)*. <https://doi.org/10.12345/juri>
- Muharni, S., & Andriyanto, S. (2022). PENERAPAN METODE K-MEANS CLUSTERING PADA DATA TINGKAT PENGANGGURAN TERBUKA TAHUN 2016-2018 DAN 2019-2021. *Jurnal Informatika*.
- Munawir, & Saharuddin. (2023). *PENGARUH PARTISIPASI ANGKATAN KERJA (TPAK) DAN TINGKAT PENGANGGURAN TERBUKA (TPT) TERHADAP PDRB DI PROVINSI ACEH*.
- Nurjanah, N., Suarna, N., & Prihartono, W. (2024). IMPLEMENTASI K-MEANS CLUSTERING UNTUK MENGELOMPOKAN TINGKAT PENGANGGURAN. In *Jurnal Mahasiswa Teknik Informatika* (Vol. 8, Issue 2).
- Nurkholik, D. (2022). *ANALISIS K-MEDOIDS CLUSTERING METODE ELBOW PADA KASUS COVID-19 DI PROVINSI DKI JAKARTA*.
- Paembonan, S., & Abduh, H. (2021). *Penerapan Metode Silhouette Coeficient Untuk Evaluasi Clustering Obat Clustering; K-means; Silhouette coeficient* (Vol. 6, Issue 2). <https://ojs.unanda.ac.id/index.php/jiit/index>
- Prasetyo, E. (2012). *Data mining: konsep dan aplikasi menggunakan MATLAB*. CV Andi Offset .
- Priastiwi, D., & Herniawati, R. H. (2019). “Analisis Pengaruh Jumlah Penduduk, Pendidikan, Upah Minimum, Dan PDRB Terhadap Tingkat Pengangguran Terbuka Di Provinsi Sulawesi Selatan .” *Diponegoro Journal of Economics*, 1(1): 159–69.

- Priskilla, V. G., Oslan, Y., & Ernawati, L. (2021). Implementasi Dashboard Untuk Visualisasi Data Penerimaan Mahasiswa Baru Studi Kasus : Universitas Kristen Duta Wacana. *Jurnal Terapan Teknologi Informasi*, 5(2), 11–23. <https://doi.org/10.21460/jutei.2021.52.234>
- Puji Astuti, L., Wahyudi, M., & Solikhun. (2022). *Komparasi K - Means Clustering dan K - Medoids dalam Mengelompokkan Produksi Susu Segar di Indonesia*.
- Pulungan, N., Suhada, S., & Suhendro, D. (2019). PENERAPAN ALGORITMA K-MEDOIDS UNTUK MENGELOMPOKKAN PENDUDUK 15 TAHUN KEATAS MENURUT LAPANGAN PEKERJAAN UTAMA. *KOMIK (Konferensi Nasional Teknologi Informasi Dan Komputer)*, 3(1). <https://doi.org/10.30865/komik.v3i1.1609>
- Putri, M. M., Dewi, C., Permata Siam, E., Asri Wijayanti, G., Aulia, N., & Nooraeni, R. (2021). *Comparison of DBSCAN and K-Means Clustering for Grouping the Village Status in Central Java 2020* *Komparasi DBSCAN dan K-Means Clustering pada Pengelompokan Status Desa di Jawa Tengah Tahun 2020*. 17(3), 394–404. <https://doi.org/10.20956/j.v17i3.11704>
- Putrie, A. A., & Sanjaya, R. (2021). *Pengelompokan Kabupaten/Kota Berdasarkan Indikator Tingkat Pengangguran Menggunakan Algoritma K-Means Clustering (Studi Kasus: Provinsi Jawa Barat)*. 2(2). <https://jabar.bps.go.id>
- Rahmadayanti, F., Anggraini, I., & Susanti, T. (2023). Pengklasterisian Data Penyakit Hipertensi dengan Menggunakan Metode K-Means. *Journal of Information System Research (JOSH)*, 4(2), 737–741. <https://doi.org/10.47065/josh.v4i2.2905>
- Rahmawati, & Faisal, M. (2019). Analisis Cluster untuk Pengelompokan Desa Berdasarkan Indikator Penyakit Diare. *SAINTIFIK*, 5(1), 75–80.
- Rais, M., Goejantoro, R., & Prangga, S. (2021). Optimalisasi K-Means Cluster dengan Principal Component Analysis Optimization of K-Means Cluster with Principal Component Analysis on the Grouping of Districts/Cities on the Island of Kalimantan Based on Unemployment Rate Indicator. In *Jurnal EKSPONENSIAL* (Vol. 12, Issue 2).
- Ramadhan, H., Rizal Abdan Kamaludin, M., Alfian Nasrullah, M., & Rolliawati, D. (2023). Comparison of Hierarchical, K-Means and DBSCAN Clustering Methods for Credit Card Customer Segmentation Analysis Based on Expenditure Level. In *Journal of Applied Informatics and Computing (JAIC)* (Vol. 7, Issue 2). <http://jurnal.polibatam.ac.id/index.php/JAIC>
- Sanjaya, R., & Fitriyani. (2019). *Prediksi Bedah Toraks Menggunakan Seleksi Fitur Forward Selection dan K-Nearest Neighbor*.

- Saputri, W., & Muttakin, F. (2022). Cluster Analysis Menggunakan Algoritma Fuzzy K-Means Untuk Tingkat. *Jurnal Teknologi Dan Manajemen Industri Terapan (JTMIT)*, 1, 78–84.
- Selvi, C., Sembiring, D., Hanum, L., & Parsaoran Tamba, S. (2022). PENERAPAN DATA MINING MENGGUNAKAN ALGORITMA K-MEANS UNTUK MENENTUKAN JUDUL SKRIPSI DAN JURNAL PENELITIAN (STUDI KASUS FTIK UNPRI). *Jurnal Sistem Informasi Dan Ilmu Komputer Prima*, 5(2).
- Sembiring, M. A., Agus, T. A., Fitri, M., & Sibuea, L. (2021). PENERAPAN METODE ALGORITMA K-MEANS CLUSTERING UNTUK PEMETAAN PENYEBARAN PENYAKIT DEMAM BERDARAH DENGUE (DBD). In *Journal of Science and Social Research* (Issue 3). <http://jurnal.goretanpena.com/index.php/JSSR>
- Sholeh, M., & Aeni, K. (2023). PERBANDINGAN EVALUASI METODE DAVIES BOULDIN, ELBOW DAN SILHOUETTE PADA MODEL CLUSTERING DENGAN MENGGUNAKAN ALGORITMA K MEANS. <https://archive.ics.uci.edu/ml/datasets/Trave>
- Sianipar, K. D. R., Siahaan, S. W., Siregar, M., R.H Zer, P. P. P. A. N. W. F. I., & Hartama, D. (2020). PENERAPAN ALGORITMA K-MEANS DALAM MENENTUKAN TINGKAT KEPUASAN PEMBELAJARAN ONLINE PADA MASA PANDEMI COVID-19. *Jurnal Teknologi Informasi*, 4(1).
- Sindi, S., Ratnasari, W., Ningse, O., Sihombing, I. A., Fikrul, P. P. P. A. N. W., Zer, I. R. H., & Hartama, D. (2020). ANALISIS ALGORITMA K-MEDOIDES CLUSTERING DALAM PENGELOMPOKAN PENYEBARAN COVID-19 DI INDONESIA. *Jurnal Teknologi Informasi*, 4(1).
- Sopyan, Y., Lesmana, A. D., & Juliane, C. (2022). Analisis Algoritma K-Means dan Davies Bouldin Index dalam Mencari Cluster Terbaik Kasus Perceraian di Kabupaten Kuningan. *Building of Informatics, Technology and Science (BITS)*, 4(3). <https://doi.org/10.47065/bits.v4i3.2697>
- Sutris, D., Gunawan, I., Sumarno, Poningsih, & Purnama Sari, I. (2023). Penerapan Algoritma K-Medoids Untuk Pengelompokan Pengangguran Umur 25 tahun Keatas Di Sumatera Utara (Vol. 3). <https://ejournal.catuspata.com/index.php/jkdn/index>
- Syahputra, H. (2022). Clustering Tingkat Penjualan Menu (Food and Beverage) Menggunakan Algoritma K-Means. *Jurnal KomtekInfo*, 29–33. <https://doi.org/10.35134/komtekinfo.v9i1.274>
- Tanjung, F. A., Windarto, A. P., & Fauzan, M. (2021). Penerapan Metode K-Means Pada Pengelompokan Pengangguran Di Indonesia. 6, 61–74. <https://tunasbangsa.ac.id/ejurnal/index.php/jurasik>

- Tempola, F., & Assagaf, A. F. (2018). *Clustering of Potency of Shrimp in Indonesia with K-Means Algorithm and Validation of Davies-Bouldin Index*.
- Ulfah Siregar, M. (2022). Comparative Study of K-Means Clustering Algorithm and K-Medoids Clustering in Student Data Clustering. In *Jurnal Informatika Sunan Kalijaga* (Vol. 7, Issue 2). MEI.
- Ulvi, H. A., & Ikhsan, M. (2024). Comparison of K-Means and K-Medoids Clustering Algorithms for Export and Import Grouping of Goods in Indonesia. *Sinkron*, 8(3), 1671–1685. <https://doi.org/10.33395/sinkron.v8i3.13815>
- Utami, N. W., & Paramitha, A. A. I. I. (2021). *PENERAPAN DATA MINING UNTUK MENGETAHUI POLA PEMILIHAN PROGRAM STUDI DI STMIK PRIMAKARA MENGGUNAKAN ALGORITMA K-MEANS CLUSTERING*.
- Wahyudi, M., Masitha, Saragih, R., & Solikhun. (2020). *Data Mining: Penerapan Algoritma K-Means Clustering dan K-Medoids Clustering* (1st ed.).
- Wardah Bonitta, N., & Primandari, A. H. (2024). Analisis Clustering Tingkat Pengangguran Terbuka di Provinsi DIY Tahun 2010-2022 dengan Dynamic Time Warping. *Emerging Statistics and Data Science Journal*, 2(1).
- Wibowo, A., & Sasongko, R. (2022). PENERAPAN DATA MINING PADA SUKU BUNGA INVESTASI DEPOSITO DI INDONESIA MENGGUNAKAN METODE K-MEANS CLUSTERING UNTUK PENGELOMPOKAN PROFITABILITAS (Application of Data Mining on Deposit Investment Rate in Indonesia Using K-Means Clustering Method for Profitability Clustering). *ASCARYA*, 2(1). <https://doi.org/10.53754/iscs.v2i1.369>
- Wikipedia. (2024). *Pengangguran*. <https://Id.Wikipedia.Org/Wiki/Pengangguran>.
- Yang, M. S., & Sinaga, K. P. (2019). A feature-reduction multi-view k-means clustering algorithm. *IEEE Access*, 7, 114472–114486. <https://doi.org/10.1109/ACCESS.2019.2934179>
- Zahra, S. N., Eko, P., Utomo, P., Pd, S., & Cs, M. 2. (2023). Visualisasi Data Penjualan Barang Retail di Seluruh Dunia Menggunakan Tableau. In *Jurnal Nasional Ilmu Komputer* (Vol. 4, Issue 3).

LAMPIRAN

Lampiran 1. Dataset Pengangguran tahun 2019-2023

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM												
1	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM												
2	Ogan Komering Ulu	2019	4,58	68,53	14647,67	69,45												
3	Ogan Komering Ilir	2019	2,98	70,96	28752,47	66,96												
4	Muara Enim	2019	4,84	70,21	57333,51	68,88												
5	Lahat	2019	3,68	71,14	17130,2	67,62												
6	Musi Rawas	2019	2,93	71,39	19062,78	66,92												
7	Musi Banyuasin	2019	4,15	66,16	65811	67,83												
8	Banyu Asin	2019	3,94	63,36	28655,74	66,9												
9	Ogan Komering Ulu Selatan	2019	2,99	76,82	8785,71	65,43												
10	Ogan Komering Ulu Timur	2019	3,46	66,84	14935,85	69,34												
11	Ogan Ilir	2019	3,29	72,61	11159,4	67,22												
12	Empat Lawang	2019	2,66	71,72	4991,08	65,1												
13	Penukal Abab Lematang Ilir	2019	4,14	73,49	7083,68	64,33												
14	Musi Rawas Utara	2019	3,81	70,39	7103,69	64,32												
15	Kota Palembang	2019	8,01	60,97	154220,3	78,44												
16	Kota Prabumulih	2019	6,12	69,3	7791,06	74,4												
17	Kota Pagar Alam	2019	2,48	69,26	2791,62	68,44												
18	Kota Lubuklinggau	2019	4,71	70,65	6643,68	74,81												

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM												
1	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM												
2	Ogan Komering Ulu	2020	6,01	70,5	14815,09	71,5												
3	Ogan Komering Ilir	2020	3,29	65,25	29291,97	68,96												
4	Muara Enim	2020	4,9	68,45	57493,55	70,84												
5	Lahat	2020	4,18	71,79	17230,57	70,48												
6	Musi Rawas	2020	3,29	71,8	19237,35	69,05												
7	Musi Banyuasin	2020	4,79	70,61	65943,88	69,83												
8	Banyu Asin	2020	4,73	64,1	29100,61	68,76												
9	Ogan Komering Ulu Selatan	2020	3,28	71,47	8971,73	67,81												
10	Ogan Komering Ulu Timur	2020	3,81	71,7	15282,54	71,37												
11	Ogan Ilir	2020	4,91	70,02	11328,48	70,29												
12	Empat Lawang	2020	3,61	75,89	5084,15	67,64												
13	Penukal Abab Lematang Ilir	2020	3,74	77,7	7129,71	66,84												
14	Musi Rawas Utara	2020	6,88	71,87	7194,15	67,48												
15	Kota Palembang	2020	9,86	65,41	155203,9	80,08												
16	Kota Prabumulih	2020	6,64	69,4	7867,32	76,19												
17	Kota Pagar Alam	2020	2,5	66,85	2830,35	71,1												
18	Kota Lubuklinggau	2020	7,41	70,25	6717,98	76,99												

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM												
1	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM												
2	Ogan Komering Ulu	2021	4,57	69,96	15730,26	71,79												
3	Ogan Komering Ilir	2021	3,01	69,68	31236,04	69,33												
4	Muara Enim	2021	5,03	69,57	69569,67	70,95												
5	Lahat	2021	3,6	69,54	19635,54	70,62												
6	Musi Rawas	2021	2,78	70,53	20412,49	69,26												
7	Musi Banyuasin	2021	3,99	69,18	72643,72	70,25												
8	Banyu Asin	2021	3,84	65,54	30992,96	69,15												
9	Ogan Komering Ulu Selatan	2021	3,23	76,17	9530,24	67,85												
10	Ogan Komering Ulu Timur	2021	3,18	71,31	16243,46	71,68												
11	Ogan Ilir	2021	3,07	68,48	12048,82	70,4												
12	Empat Lawang	2021	2,41	72,3	5391,04	67,77												
13	Penukal Abab Lematang Ilir	2021	3,61	73,13	7527,14	67,03												
14	Musi Rawas Utara	2021	6,72	69,69	7744	67,94												
15	Kota Palembang	2021	10,11	63,93	162032,8	80,46												
16	Kota Prabumulih	2021	5,86	69,41	8345,93	76,3												
17	Kota Pagar Alam	2021	1,64	74,2	3001,94	71,47												
18	Kota Lubuklinggau	2021	6,27	73,6	7030,47	77,09												

	A	B	C	D	E	F
1	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM
2	Ogan Komering Ulu	2022	4,39	69,9	17613,75	72,41
3	Ogan Komering Ilir	2022	3,75	68,79	34239,34	70,17
4	Muara Enim	2022	4,12	72,53	113577,5	71,52
5	Lahat	2022	4,02	70,73	27834,48	71,45
6	Musi Rawas	2022	1,92	69,06	22342,12	70,04
7	Musi Banyuasin	2022	4,4	71,12	82431,54	70,73
8	Banyu Asin	2022	3,39	64,32	24442,77	69,95
9	Ogan Komering Ulu Selatan	2022	1,83	72,99	10328,5	68,33
10	Ogan Komering Ulu Timur	2022	4,79	67,93	17832,84	72,33
11	Ogan Ilir	2022	2,15	81,1	13250,92	71,2
12	Empat Lawang	2022	3,59	71,17	5837,97	68,39
13	Penukal Abab Lematang Ilir	2022	4,31	79,82	8194,74	67,89
14	Musi Rawas Utara	2022	5,29	73,06	8548,51	68,76
15	Kota Palembang	2022	8,2	64,48	179106,8	81,19
16	Kota Prabumulih	2022	5,25	71,72	9208,5	77,14
17	Kota Pagar Alam	2022	3,62	73,1	3255,93	72,4
18	Kota Lubuklinggau	2022	5,94	67,93	7687,85	77,71

	A	B	C	D	E	F
1	Kabupaten/Kota	Tahun	TPT	TPAK	PORB	IPM
2	Ogan Komering Ulu	2023	4,13	72,67	19019,37	73,17
3	Ogan Komering Ilir	2023	3,23	69,34	37395,24	70,8
4	Muara Enim	2023	3,92	72,99	118517,5	72,33
5	Lahat	2023	3,41	74,79	29288,89	72,15
6	Musi Rawas	2023	1,95	68,36	23526,55	70,52
7	Musi Banyuasin	2023	2,58	72,63	85771,07	71,3
8	Banyu Asin	2023	3,35	62,68	37439,52	70,67
9	Ogan Komering Ulu Selatan	2023	1,81	75,56	11090,39	69,05
10	Ogan Komering Ulu Timur	2023	3,96	76,53	19464,92	73,05
11	Ogan Ilir	2023	2,1	73,38	14250,81	72,01
12	Empat Lawang	2023	3,09	72,41	6302,9	69,07
13	Penukal Abab Lematang Ilir	2023	3,99	79,39	8719,08	68,78
14	Musi Rawas Utara	2023	5,11	70,12	9067,07	69,63
15	Kota Palembang	2023	7,49	67,51	194569,6	81,72
16	Kota Prabumulih	2023	5,05	68,6	9834,13	78,07
17	Kota Pagar Alam	2023	2,71	73,9	3490,53	73,25
18	Kota Lubuklinggau	2023	5,64	70,88	8233,71	78,36

Lampiran 2. Package dan source Anaconda Navigator

```
# =====
# TAHAP 0: IMPORT LIBRARY
# =====

import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, davies_bouldin_score
import matplotlib.pyplot as plt
import seaborn as sns
```

```

import folium

import geopandas as gpd

import json

# --- Setting Tampilan Pandas ---
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('display.width', None)
pd.set_option('display.colheader_justify', 'center')
pd.set_option('display.precision', 6)

# =====

# TAHAP 1: LOAD DATA

# =====

df = pd.read_excel('data_pengangguran_2019.xlsx')
print("\n=== Data Awal ===")
print(df)

# =====

# TAHAP 2: DATA CLEANING

# =====

print("\n=== Missing Values per Kolom ===")
print(df.isnull().sum())

# =====

# TAHAP 3: SELEKSI VARIABEL

# =====

features = ["TPT", "TPAK", "PDRB", "IPM"]
data_selected = df[features]

print("\n=== Data Setelah Seleksi Variabel ===")
print(data_selected)

# =====

# TAHAP 4: NORMALISASI (Z-SCORE)

# =====

scaler = StandardScaler()
data_normalized = scaler.fit_transform(data_selected)

```

```

df_normalized = pd.DataFrame(data_normalized, columns=features)
df_normalized["Kabupaten/Kota"] = df["Kabupaten/Kota"].values

print("\n=== Data Setelah Normalisasi Z-Score ===")
print(df_normalized)

# =====
# TAHAP 5: MENENTUKAN JUMLAH CLUSTER OPTIMAL (ELBOW METHOD)
# =====

inertia = []
K_range = range(1, 10)

for k in K_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(df_normalized[features])
    inertia.append(kmeans.inertia_)

plt.figure(figsize=(8, 5))
plt.plot(K_range, inertia, marker='o')
plt.title('Metode Elbow untuk Menentukan Jumlah Cluster Optimal')
plt.xlabel('Jumlah Cluster (K)')
plt.ylabel('Inertia')
plt.grid(True)
plt.show()

# =====
# TAHAP 6: EVALUASI MODEL (DBI & SILHOUETTE)
# =====

evaluation_results = []

for k in range(2, 11):
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = kmeans.fit_predict(df_normalized[features])

    dbi = davies_bouldin_score(df_normalized[features], labels)

```

```

silhouette = silhouette_score(df_normalized[features], labels)

evaluation_results.append({
    "K": k,
    "Davies-Bouldin Index": dbi,
    "Silhouette Score": silhouette,
})

eval_df = pd.DataFrame(evaluation_results)

print("\n=== Evaluasi Nilai K ===")
print(eval_df)

# =====
# TAHAP 7: K-MEANS FINAL (K=4)
# =====

kmeans_final = KMeans(n_clusters=4, random_state=42, n_init=10)
labels_final = kmeans_final.fit_predict(df_normalized[features])

df_clustered = df_normalized.copy()
df_clustered["Cluster"] = labels_final

df_clustered = df_clustered[["TPT", "TPAK", "PDRB", "IPM", "Cluster",
                             "Kabupaten/Kota"]]

print("\n=== Hasil Clustering Tahun 2019 ===")
print(df_clustered.to_string(index=False))

# =====
# TAHAP 7.1: RINGKASAN RATA-RATA PER CLUSTER (NORMALISASI)
# =====

cluster_summary_original = df_clustered.groupby("Cluster")[features].mean()

print("\n=== Rata-rata Tiap Fitur per Cluster (Normalisasi) ===")
pd.set_option('display.precision', 6)
print(cluster_summary_original)
pd.set_option('display.precision', 6)

```

```

# =====
# TAHAP 7.2: RINGKASAN RATA-RATA PER CLUSTER (Z-SCORE)
# =====

df_normalized_with_cluster = df_normalized.copy()
df_normalized_with_cluster["Cluster"] = df_clustered["Cluster"].values

cluster_summary_z =
df_normalized_with_cluster.groupby("Cluster")[features].mean()

# =====
# TAHAP 7.3: DENORMALISASI (KEMBALI KE SKALA ASLI)
# =====

cluster_summary_denorm = pd.DataFrame(
    scaler.inverse_transform(cluster_summary_z.values),
    columns=features,
    index=cluster_summary_z.index
)

print("\n=== Rata-rata Tiap Fitur per Cluster (Denormalisasi) ===")
pd.set_option('display.precision', 2)
print(cluster_summary_denorm)
pd.set_option('display.precision', 6)

# =====
# TAHAP 7.4: DAFTAR DAERAH PER CLUSTER
# =====

for i in sorted(df_clustered["Cluster"].unique()):
    print(f'\nCluster {i}:')
    daerah_cluster = df_clustered[df_clustered["Cluster"] ==
i]["Kabupaten/Kota"].tolist()
    for daerah in daerah_cluster:
        print(f'- {daerah}')

# =====
# TAHAP 8: VISUALISASI BAR CHART & BOXPLOT
# =====

```



```

# Bar Chart – jumlah daerah per cluster
plt.figure(figsize=(6, 4))
sns.countplot(data=df_clustered, x="Cluster", palette="tab10")
plt.title("Jumlah Kabupaten/Kota per Cluster")
plt.xlabel("Cluster")
plt.ylabel("Jumlah")
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()

# Boxplot tiap fitur berdasarkan cluster
for feature in features:
    plt.figure(figsize=(6, 4))
    sns.boxplot(x='Cluster', y=feature, data=df_clustered)
    plt.title(f'Distribusi {feature} Berdasarkan Cluster')
    plt.show()

# =====

# TAHAP 9: VISUALISASI PETA CLUSTER FOLIUM

# =====

# --- 9.1 Baca file GeoJSON ---
json_path = "38 Provinsi Indonesia - Kabupaten (1).json"

with open(json_path, 'r', encoding='utf-8') as f:
    geo_json_data = json.load(f)

geo_data = gpd.GeoDataFrame.from_features(geo_json_data["features"])
geo_data.set_crs(epsg=4326, inplace=True)

# --- 9.2 Bersihkan nama daerah ---
geo_data["WADMKK"] = geo_data["WADMKK"].str.strip()

# --- 9.3 Merge dengan hasil clustering ---
geo_merged = geo_data.merge(df_clustered, left_on="WADMKK",
                             right_on="Kabupaten/Kota", how="left")

```

```

# --- 9.4 Warna cluster ---
cluster_colors = {
    0: '#2196F3',
    1: '#FF9800',
    2: '#4CAF50',
    3: '#F44336',
}

# --- 9.5 Deskripsi cluster ---
deskripsi_cluster = {
    0: 'TPT 4.19%, TPAK 67.02%, PDRB 36,276.75 miliar, IPM (sedang) 68.48% ',
    1: 'TPT 8.01%, TPAK 60.97%, PDRB 154,220.32 miliar, IPM (tinggi) 78.44%',
    2: 'TPT 3.22%, TPAK 71.98%, PDRB 11,873.40 miliar, IPM (sedang) 66.26%',
    3: 'TPT 5.42%, TPAK 69.97%, PDRB 7,217.37 miliar, IPM (tinggi) 74.61%',
}

geo_merged["Deskripsi"] = geo_merged["Cluster"].map(deskripsi_cluster)

# --- 9.5b Label nama cluster ---
cluster_labels = {
    0: '0 (Menengah/Stabil)',
    1: '1 (Produktif)',
    2: '2 (Maju)',
    3: '3 (Ekonomi Terbatas)',
}

geo_merged["Cluster_Label"] = geo_merged["Cluster"].map(cluster_labels)

# --- 9.5c Tooltip HTML agar titik dua sejajar ---
geo_merged["Tooltip_HTML"] = (
    "<table>"
    "<tr><td><b>Kabupaten/Kota</b></td><td>:</td><td>" +
    geo_merged["WADMKK"] + "</td></tr>"
    "<tr><td><b>Cluster</b></td><td>:</td><td>" + geo_merged["Cluster_Label"]
    + "</td></tr>"
    "<tr><td><b>Deskripsi Cluster</b></td><td>:</td><td>" +
    geo_merged["Deskripsi"] + "</td></tr>"

```

```

"</table>"
)
# --- 9.6 Peta dasar ---
peta_cluster = folium.Map(location=[-3.2, 104.5], zoom_start=7)

# --- 9.7 Layer wilayah ---
folium.GeoJson(
    geo_merged,
    style_function=lambda feature: {
        'fillColor': cluster_colors.get(feature['properties'].get('Cluster'), 'gray'),
        'color': 'black',
        'weight': 0.3,
        'fillOpacity': 0.6,
    },
    tooltip=folium.GeoJsonTooltip(
        fields=['Tooltip_HTML'],
        aliases=[],
        localize=True,
        sticky=True,
        labels=True,
        style=(
            "background-color: white; "
            "border: 3px solid gray; "
            "border-radius: 15px; "
            "padding: 15px; "
            "font-size: 25px; "
            "font-weight: 500;"
        )
    )
).add_to(peta_cluster)

# --- 9.8 Keterangan warna ---
legend_html = ""
<div style="

```

```

position: fixed;
bottom: 50px; left: 50px; width: 300px; height: 200px;
background-color: white;
border: 6px solid grey;
z-index: 9999;
font-size: 20px;
padding: 18px;
">
<b>Keterangan Cluster</b><br>
<i style="background:#2196F3; width:15px; height:15px; float:left; margin-
right:5px;"></i> Cluster 0<br>
<i style="background:#FF9800; width:15px; height:15px; float:left; margin-
right:5px;"></i> Cluster 1<br>
<i style="background:#4CAF50; width:15px; height:15px; float:left; margin-
right:5px;"></i> Cluster 2<br>
<i style="background:#F44336; width:15px; height:15px; float:left; margin-
right:5px;"></i> Cluster 3<br>
</div>
'''
peta_cluster.get_root().html.add_child(folium.Element(legend_html))

# --- 9.9 Simpan Peta ---
peta_cluster.save("peta_cluster_sumsel_2019.html")
print("Peta wilayah berhasil disimpan sebagai 'peta_cluster_sumsel_2019.html'")

```